

Data Profiling

Analítica de Datos, Universidad de San Andrés

Si encuentran algún error en el documento o hay alguna duda, mandenme un mail a rodriguezr@udesa.edu.ar y lo revisamos.

1. Introducción al Data Profiling

El Data Profiling es una técnica fundamental en el análisis de datos que nos permite entender la estructura, calidad y características de nuestros datasets antes de comenzar cualquier análisis o modelado. Es el primer paso en cualquier proyecto de ciencia de datos y nos ayuda a identificar problemas potenciales en los datos.

2. Tipos de Variables

Una variable es cualquier característica o atributo que puede ser medido o observado. Una variable puede ser edad, género, ingreso, país de nacimiento, color de ojos, tipo de vehículo, etc.

2.1. Clasificación de Variables

- **Variables Numéricas:**

- **Discretas:** Toman valores enteros específicos como tener cuatro hijos o un stock de 420 productos.
- **Continuas:** Pueden tomar cualquier valor en un rango como la altura, peso, temperatura (osea, pueden tener una coma)

- **Variables Categóricas:**

- **Nominales:** Sin orden inherente como puede ser país de nacimiento o color de ojos.
- **Ordinales:** Con orden natural como bajo, medio, alto o primera o segunda división.

- **Variables de Fecha y Hora:** Representan momentos específicos en el tiempo.
- **Variables Compuestas:** Combinan múltiples tipos de información.

3. Medidas Estadísticas

3.1. Medidas de Tendencia Central

Estas medidas nos indican dónde se concentran los valores de una variable:

- **Media:** Promedio de todos los valores.
- **Mediana:** Valor que divide la distribución en dos partes iguales.
- **Moda:** Valor que aparece con mayor frecuencia. Solo para variables categóricas.

3.2. Medidas de Dispersión

Estas medidas nos indican qué tan dispersos están los valores:


- **Varianza:** Promedio de las desviaciones al cuadrado respecto a la media.
- **Desviación Estándar:** Raíz cuadrada de la varianza.
- **Rango Intercuartil (IQR):** Diferencia entre el tercer y primer cuartil.
- **Cuartiles:** Valores que dividen los datos en cuatro partes iguales (de cantidad de datos).

4. Forma de la Distribución

- **Skewness (Asimetría):** Mide la simetría de la distribución
- **Curtosis:** Mide qué tan puntiaguda o plana es la distribución

4.1. Skewness (Asimetría)

La asimetría nos indica si la distribución está sesgada hacia la izquierda o derecha:



4.1.1. Interpretación del Skewness

Cuando el skewness es igual a cero, tenemos una distribución simétrica como la altura o peso en una población general. Un skewness positivo indica que la distribución está sesgada hacia la derecha, típico en variables como ingresos o precios de viviendas donde hay pocos valores muy altos. Un skewness negativo indica sesgo hacia la izquierda, como en la edad de jubilación o calificaciones altas donde hay pocos valores muy bajos.

4.1.2. Implicaciones Prácticas

En distribuciones sesgadas, la media se ve fuertemente afectada por valores extremos, por lo que la mediana suele ser una mejor medida de tendencia central. Para normalizar datos sesgados, podemos usar transformaciones como logaritmo, raíz cuadrada o la transformación de Box-Cox. Es importante notar que algunos algoritmos como la regresión lineal asumen normalidad, por lo que datos muy sesgados pueden afectar su rendimiento. Además, los datos sesgados suelen tener más outliers en una dirección específica.

4.1.3. Ejemplos Reales


Los ingresos y precios de casas suelen tener skewness positivo, ya que hay pocas personas con ingresos muy altos o casas muy costosas. Las edades de muerte por enfermedades cardiovasculares tienden a tener skewness negativo, con pocos valores muy bajos. Variables como altura, peso o temperatura en climas templados suelen ser aproximadamente simétricas.

4.1.4. Reglas de Interpretación

Como regla general, un skewness entre -0.5 y 0.5 indica una distribución aproximadamente simétrica. Valores entre -1 y -0.5 o entre 0.5 y 1 indican una distribución moderadamente sesgada. Finalmente, valores menores a -1 o mayores a 1 indican una distribución altamente sesgada que requiere atención especial.

4.2. Curtosis

La curtosis nos indica qué tan puntiaguda o plana es la distribución comparada con una normal:



4.2.1. Interpretación de la Curtosis

Una curtosis de cero indica una distribución mesocúrtica, que corresponde a la distribución normal estándar. Una curtosis positiva indica una distribución leptocúrtica, que es más puntiaguda en el centro y tiene colas más pesadas. Una curtosis negativa indica una distribución platicúrtica, que es más plana en el centro y tiene colas más ligeras.

4.2.2. Implicaciones Prácticas

Las distribuciones leptocúrticas tienen mayor concentración de datos cerca de la media, pero también más outliers extremos, lo que indica mayor riesgo de eventos extremos. Las distribuciones platicúrticas tienen datos más dispersos y menos concentración en el centro. Es importante notar que algunos algoritmos asumen normalidad y pueden fallar cuando la curtosis es muy extrema.

4.2.3. Ejemplos Reales

Los retornos financieros y precios de commodities suelen ser leptocúrticos, mientras que las temperaturas diarias y velocidades de viento tienden a ser platicúrticas. Variables como altura, peso o errores de medición bien controlados suelen ser mesocúrticas.

4.2.4. Reglas de Interpretación

Como regla general, una curtosis entre -0.5 y 0.5 indica una distribución aproximadamente normal. Valores entre -1 y -0.5 o entre 0.5 y 1 indican una distribución moderadamente diferente a la normal. Finalmente, valores menores a -1 o mayores a 1 indican una distribución muy diferente a la normal que requiere atención especial.

5. Aspectos Críticos a Considerar

5.1. Datos Faltantes

Los datos faltantes son valores ausentes en el dataset. Es fundamental entender los diferentes tipos para aplicar el tratamiento adecuado. Nunca podemos

tener la seguridad de por qué es que faltan los datos pero podemos tener hipótesis y testearlas.

5.1.1. MCAR (Missing Completely At Random)

Los datos faltantes no están relacionados con ninguna variable observable. El patrón de faltantes es completamente aleatorio.

Id	Edad	Rubro	Salario
1	29	Abogado/a	1.500.000
2	53	Null	430.000
3	21	Analista de datos	Null
4	34	Analista de marketing	1.000.000
5	Null	A. financiero/a	600.000
5	31	Asesor/a del congreso	700.000
6	48	Recepcionista	Null

En este ejemplo, los datos faltantes aparecen de forma aleatoria sin relación con ninguna variable observable. Los participantes se olvidaron de responder preguntas al azar.

5.1.2. MAR (Missing At Random)

Los datos faltantes están relacionados con variables observables, pero no con el valor faltante mismo.

Id	Edad	Rubro	Salario
1	29	Abogado	1.500.000
2	37	Profesora	430.000
3	53	Analista de datos	Null
4	34	Analista de marketing	1.000.000
5	23	A. financiera	600.000
5	31	Asesora del congreso	700.000
6	48	Recepcionista	Null

Hay un patrón, la falta depende de los datos observados (la edad). Los entrevistados mayores de 40 años no se sienten cómodos de divulgar su salario.

5.1.3. MNAR (Missing Not At Random)

Los datos faltantes están relacionados con el valor faltante mismo.

Id	Edad	Rubro	Salario
1	45	Abogado	Null
2	52	Profesora	430.000
3	21	Analista de datos	Null
4	34	Analista de marketing	Null
5	23	A. financiera	600.000
5	31	Asesora del congreso	700.000
6	48	Recepcionista	770.000

La falta depende del dato que no tengo. Las personas con salarios más altos tienden a evitar contestar la pregunta.

5.2. Cardinalidad y Etiquetas Raras

- **Cardinalidad:** Número de valores únicos en una variable categórica
- **Etiquetas Raras:** Categorías con muy pocas observaciones

5.3. Valores Extremos

Los outliers pueden afectar significativamente el análisis y deben ser identificados y tratados apropiadamente.

5.4. Magnitudes y Escalas

Diferentes variables pueden tener escalas muy distintas, lo que puede afectar el rendimiento de ciertos algoritmos.

6. Supuestos de Linealidad

Para análisis que asumen relaciones lineales, debemos verificar:

- **Relación Lineal:** La relación entre variables debe ser aproximadamente lineal
- **Normalidad:** Los residuos deben seguir una distribución normal
- **Ausencia de Colinealidad:** Las variables independientes no deben estar altamente correlacionadas
- **Homocedasticidad:** La varianza de los residuos debe ser constante