

Data Profiling

Analítica de Datos



¿Qué es Data Profiling?

Técnica fundamental en el análisis de datos

¿Qué es Data Profiling?

Técnica fundamental en el análisis de datos

Q Entender la estructura de los datos

¿Qué es Data Profiling?

Técnica fundamental en el análisis de datos

- Q Entender la estructura de los datos
- ✓ Evaluar la calidad del dataset

¿Qué es Data Profiling?

Técnica fundamental en el análisis de datos

- 🔍 Entender la estructura de los datos
- ✓ Evaluar la calidad del dataset
- ⚠ Identificar problemas potenciales

¿Qué es Data Profiling?

Técnica fundamental en el análisis de datos

- 🔍 Entender la estructura de los datos
- ✓ Evaluar la calidad del dataset
- ⚠ Identificar problemas potenciales
- ▶ Primer paso en cualquier proyecto de analítica o ciencia de datos

Tipos de Variables

Variables Numéricas:

- **Discretas:** Valores enteros específicos
- **Continuas:** Cualquier valor en un rango

Tipos de Variables

Variables Numéricas:

- **Discretas:** Valores enteros específicos
- **Continuas:** Cualquier valor en un rango

Variables Categóricas:

- **Nominales:** Sin orden inherente
- **Ordinales:** Con orden natural

Tipos de Variables

Variables Numéricas:

- **Discretas:** Valores enteros específicos
- **Continuas:** Cualquier valor en un rango

Variables Categóricas:

- **Nominales:** Sin orden inherente
- **Ordinales:** Con orden natural

Otros Tipos:

- **Fecha y Hora:** Momentos específicos
- **Compuestas:** Múltiples tipos de información
 - Ej: Direccion completa (calle, numero, ciudad, pais)

¿Dónde se concentran los valores?



Media

Promedio de todos los
valores



Mediana

Valor central de la
distribución



Moda

Valor más frecuente

¿Qué tan dispersos están los valores?

- **Varianza:** Promedio de desviaciones al cuadrado

¿Qué tan dispersos están los valores?

- **Varianza:** Promedio de desviaciones al cuadrado
- **Desviación Estándar:** Raíz cuadrada de la varianza

¿Qué tan dispersos están los valores?

- **Varianza:** Promedio de desviaciones al cuadrado
- **Desviación Estándar:** Raíz cuadrada de la varianza
- **Rango Intercuartil (IQR):** $Q3 - Q1$

¿Qué tan dispersos están los valores?

- **Varianza:** Promedio de desviaciones al cuadrado
- **Desviación Estándar:** Raíz cuadrada de la varianza
- **Rango Intercuartil (IQR):** $Q3 - Q1$
- **Cuartiles:** División en cuatro partes iguales

Características de la Distribución


Skewness (Asimetría):

- Mide la simetría de la distribución
- Indica si está sesgada hacia la izquierda o derecha
- Afecta la elección entre media y mediana

Curtosis:

- Mide qué tan puntiaguda o plana es
- Compara con la distribución normal
- Indica presencia de outliers extremos

Skewness - Tipos de Distribución



¿Qué significa cada tipo de asimetría?

 **Skewness = 0:** Distribución simétrica (altura, peso en población general)

¿Qué significa cada tipo de asimetría?

-  **Skewness = 0:** Distribución simétrica (altura, peso en población general)
- ➔ **Skewness > 0:** Cola larga a la derecha (ingresos, precios de viviendas)

¿Qué significa cada tipo de asimetría?

-  **Skewness = 0:** Distribución simétrica (altura, peso en población general)
- ➔ **Skewness > 0:** Cola larga a la derecha (ingresos, precios de viviendas)
- ⬅ **Skewness < 0:** Cola larga a la izquierda (edad de jubilación, calificaciones altas)

¿Qué hacer con distribuciones sesgadas?

- ◆ **Usar mediana en lugar de media** - Menos afectada por valores extremos

¿Qué hacer con distribuciones sesgadas?

- ◆ **Usar mediana en lugar de media** - Menos afectada por valores extremos
- ⚙ **Aplicar transformaciones** - Logaritmo, raíz cuadrada, Box-Cox

¿Qué hacer con distribuciones sesgadas?

- ◆ **Usar mediana en lugar de media** - Menos afectada por valores extremos
- ⚙️ **Aplicar transformaciones** - Logaritmo, raíz cuadrada, Box-Cox
- ⚠️ **Revisar algoritmos** - Algunos asumen normalidad

¿Qué hacer con distribuciones sesgadas?

- ◆ **Usar mediana en lugar de media** - Menos afectada por valores extremos
- ⚙️ **Aplicar transformaciones** - Logaritmo, raíz cuadrada, Box-Cox
- ⚠️ **Revisar algoritmos** - Algunos asumen normalidad
- 🔍 **Identificar outliers** - Más comunes en una dirección específica

¿Cuándo considerar una distribución sesgada?

- **-0.5 a 0.5:** Aproximadamente simétrica. Podemos usar la media o la mediana porque son parecidas.


¿Cuándo considerar una distribución sesgada?

- **-0.5 a 0.5:** Aproximadamente simétrica. Podemos usar la media o la mediana porque son parecidas.
- **-1 a -0.5 o 0.5 a 1:** Moderadamente sesgada hacia la izquierda/derecha. Acá ya podemos considerar la mediana.

¿Cuándo considerar una distribución sesgada?

- **-0.5 a 0.5:** Aproximadamente simétrica. Podemos usar la media o la mediana porque son parecidas.
- **-1 a -0.5 o 0.5 a 1:** Moderadamente sesgada hacia la izquierda/derecha. Acá ya podemos considerar la mediana.
- **< -1 o > 1:** Altamente sesgada. Debemos usar la mediana.

Curtosis - Forma de la Distribución



¿Qué significa cada tipo de curtosis?

 **Curtosis = 0:** Distribución normal estándar (altura, peso bien controlados)

¿Qué significa cada tipo de curtosis?

- 🔔 **Curtosis = 0:** Distribución normal estándar (altura, peso bien controlados)
- ⚠️ **Curtosis > 0:** Más puntiaguda, colas pesadas (retornos financieros, precios de commodities)

¿Qué significa cada tipo de curtosis?

-  **Curtosis = 0:** Distribución normal estándar (altura, peso bien controlados)
-  **Curtosis > 0:** Más puntiaguda, colas pesadas (retornos financieros, precios de commodities)
-  **Curtosis < 0:** Más plana, colas ligeras (temperaturas diarias, velocidades de viento)

¿Qué hacer con diferentes tipos de curtosis?

⚠ Leptocúrtica: Mayor riesgo de eventos extremos, más outliers

¿Qué hacer con diferentes tipos de curtosis?

- ⚠ **Leptocúrtica:** Mayor riesgo de eventos extremos, más outliers
- ↔ **Platicúrtica:** Datos más dispersos, menos concentración central

¿Qué hacer con diferentes tipos de curtosis?

- ⚠ **Leptocúrtica:** Mayor riesgo de eventos extremos, más outliers
- ↔ **Platicúrtica:** Datos más dispersos, menos concentración central
- ⚙ **Revisar algoritmos** - Algunos fallan con curtosis extrema

¿Qué hacer con diferentes tipos de curtosis?

- ⚠ **Leptocúrtica:** Mayor riesgo de eventos extremos, más outliers
- ↔ **Platicúrtica:** Datos más dispersos, menos concentración central
- ⚙ **Revisar algoritmos** - Algunos fallan con curtosis extrema
- 🛡 **Evaluar robustez** - Métodos robustos vs sensibles a outliers

¿Cuándo considerar una distribución diferente a la normal?

- **-0.5 a 0.5:** Aproximadamente normal. Podemos usar los métodos estándar.

¿Cuándo considerar una distribución diferente a la normal?

- **-0.5 a 0.5:** Aproximadamente normal. Podemos usar los métodos estándar.
- **-1 a -0.5 o 0.5 a 1:** Moderadamente diferente a la normal. Podríamos revisar la robustez de los métodos.

¿Cuándo considerar una distribución diferente a la normal?

- **-0.5 a 0.5:** Aproximadamente normal. Podemos usar los métodos estándar.
- **-1 a -0.5 o 0.5 a 1:** Moderadamente diferente a la normal. Podríamos revisar la robustez de los métodos.
- **< -1 o > 1:** Muy diferente a la normal. Usar métodos robustos que funcionen bien para estos casos.

Clasificación de Datos Faltantes

✂ MCAR (Missing Completely At Random): Faltantes aleatorios

Clasificación de Datos Faltantes

- ✂ **MCAR (Missing Completely At Random):** Faltantes aleatorios
- 🔗 **MAR (Missing At Random):** Faltantes relacionados con variables observables

Clasificación de Datos Faltantes

- ✂ **MCAR (Missing Completely At Random):** Faltantes aleatorios
- 🔗 **MAR (Missing At Random):** Faltantes relacionados con variables observables
- ! **MNAR (Missing Not At Random):** Faltantes relacionados con el valor faltante

MCAR - Missing Completely At Random

Datos faltantes completamente aleatorios

Id	Edad	Rubro	Salario
1	29	Abogado/a	1.500.000
2	53	Null	430.000
3	21	Analista de datos	Null
4	34	Analista de marketing	1.000.000
5	Null	A. financiero/a	600.000

MCAR - Missing Completely At Random

Datos faltantes completamente aleatorios

Id	Edad	Rubro	Salario
1	29	Abogado/a	1.500.000
2	53	Null	430.000
3	21	Analista de datos	Null
4	34	Analista de marketing	1.000.000
5	Null	A. financiero/a	600.000

Acá tal vez los participantes se olvidaron de responder preguntas

MAR - Missing At Random

Datos faltantes relacionados con variables observables

Id	Edad	Rubro	Salario
1	29	Abogado	1.500.000
2	37	Profesora	430.000
3	53	Analista de datos	Null
4	34	Analista de marketing	1.000.000
5	23	A. financiera	600.000
6	48	Recepcionista	Null

MAR - Missing At Random

Datos faltantes relacionados con variables observables

Id	Edad	Rubro	Salario
1	29	Abogado	1.500.000
2	37	Profesora	430.000
3	53	Analista de datos	Null
4	34	Analista de marketing	1.000.000
5	23	A. financiera	600.000
6	48	Recepcionista	Null

Acá tal vez los entrevistados mayores de 40 años no quieren decir su salario

MNAR - Missing Not At Random

Datos faltantes relacionados con el valor faltante

Id	Edad	Rubro	Salario
1	45	Abogado	Null
2	52	Profesora	430.000
3	21	Analista de datos	Null
4	34	Analista de marketing	Null
5	23	A. financiera	600.000
6	48	Recepcionista	770.000

MNAR - Missing Not At Random

Datos faltantes relacionados con el valor faltante

Id	Edad	Rubro	Salario
1	45	Abogado	Null
2	52	Profesora	430.000
3	21	Analista de datos	Null
4	34	Analista de marketing	Null
5	23	A. financiera	600.000
6	48	Recepcionista	770.000

Acá tal vez las personas con salarios más altos evitan contestar

Elementos importantes a considerar

Cardinalidad:

- Número de valores únicos en variables categóricas
- Puede indicar problemas de calidad

Etiquetas Raras:

- Categorías con muy pocas observaciones
- Pueden causar problemas en el modelado

Valores Extremos:

- Outliers que afectan el análisis
- Deben ser identificados y tratados

Magnitudes y Escalas:

- Variables con escalas muy distintas
- Pueden afectar el rendimiento de algoritmos

Para análisis que asumen relaciones lineales

 **Relación Lineal:** La relación entre variables debe ser aproximadamente lineal

Para análisis que asumen relaciones lineales

-  **Relación Lineal:** La relación entre variables debe ser aproximadamente lineal
-  **Normalidad:** Los residuos deben seguir una distribución normal

Para análisis que asumen relaciones lineales

-  **Relación Lineal:** La relación entre variables debe ser aproximadamente lineal
-  **Normalidad:** Los residuos deben seguir una distribución normal
-  **Ausencia de Colinealidad:** Variables independientes no altamente correlacionadas

Para análisis que asumen relaciones lineales

-  **Relación Lineal:** La relación entre variables debe ser aproximadamente lineal
-  **Normalidad:** Los residuos deben seguir una distribución normal
-  **Ausencia de Colinealidad:** Variables independientes no altamente correlacionadas
-  **Homocedasticidad:** Varianza constante de los residuos

¿Dudas?
¿Consultas?



Universidad de
SanAndrés