ANALÍTICA DE DATOS · APUNTE

Data Profiling

Tipos de variables · medidas de resumen · calidad de datos · 2do cuatrimestre 2026

1. Qué es y para qué sirve

Hacer profiling de un dataset es **mirar los datos antes de usarlos**: entender qué es cada columna y de qué tipo es, evaluar la calidad (qué falta, qué está repetido, qué no cierra) e identificar los problemas que van a distorsionar cualquier análisis posterior. Es el primer paso de cualquier proyecto de analítica.

La razón es simple: los métodos que vienen después (promedios, gráficos, modelos) operan sobre los números tal como están. Una regresión que predice el gasto de un cliente no sabe qué es un cliente ni un peso: ajusta números. Si un gasto está cargado en dólares entre miles de pesos, el modelo lo toma como un cliente mil veces más chico. Si un faltante quedó registrado como 0, el modelo aprende que ese cliente "gasta cero". Si un cliente figura dos veces, pesa el doble que los demás. Ninguno de estos problemas los detecta el algoritmo: hay que encontrarlos antes, mirando los datos.

2. Tipos de variables

Las familias principales:

Familia	Subtipos	Ejemplos
Numéricas	discretas · continuas	cantidad de compras · monto gastado
Categóricas	nominales · ordinales	barrio · nivel de satisfacción
Fecha y hora	-	fecha de alta, hora de la compra
Compuestas	-	dirección (calle + número + ciudad)
Identificadores	-	DNI, teléfono, número de cliente

Numéricas: discretas y continuas

Las **discretas** toman valores enteros, contables: cantidad de compras (0, 1, 2, 3…), personas en un local, unidades vendidas. Entre dos valores consecutivos no hay nada. Las **continuas** pueden tomar cualquier valor dentro de un rango: un monto de $87.350,50, un peso de 1,248 kg, un tiempo de 4,7 minutos. Con ambas se puede sumar, promediar y medir distancias: esa es la definición operativa de "numérica".

Categóricas: nominales y ordinales

Las **nominales** son etiquetas sin orden: barrio, medio de pago, rubro. Ninguna categoría es "más" que otra. Las **ordinales** admiten un orden natural (satisfacción baja < media < alta, talles S < M < L), pero la distancia entre categorías no está definida: no se sabe si "alta" menos "media" es lo mismo que "media" menos "baja". Por eso con las ordinales se puede ordenar pero no restar ni promediar.

Las disfrazadas: números que no son numéricos

Que algo se escriba con dígitos no lo hace numérico:

Columna	Parece	Es
Código postal: 1425	numérica	categórica nominal (etiqueta de zona)
DNI / teléfono	numérica	identificador
Plan: 1, 2, 3	numérica	categórica (el "3" no es tres veces el "1")
Satisfacción: 1 a 5	numérica	ordinal (las estrellas se ordenan, no se restan)

El test es siempre el mismo: **¿tiene sentido el promedio? ¿tiene sentido "el doble"?** Si no, es una etiqueta escrita con dígitos. "El código postal promedio es 1.417,3" se puede calcular, y no significa nada.

Qué operación admite cada tipo

	Contar / moda	Ordenar / mediana / percentiles	Sumar / promediar / desvío
Nominal	sí	no	no
Ordinal	sí	sí	no
Numérica	sí	sí	sí

Cada fila hereda las operaciones de la anterior y agrega una. Clasificar bien la variable es lo que decide qué medidas de resumen son válidas para ella.

3. Medidas de tendencia central

Responden a la pregunta: ¿dónde se concentran los valores?

- **Media:** la suma dividida la cantidad. Usa toda la información, y por eso todo la afecta.
- **Mediana:** el valor del medio con los datos ordenados; la mitad queda abajo y la mitad arriba. Con una cantidad par de datos, el promedio de los dos del medio.
- **Moda:** el valor más frecuente. Es la única de las tres definida para variables categóricas.

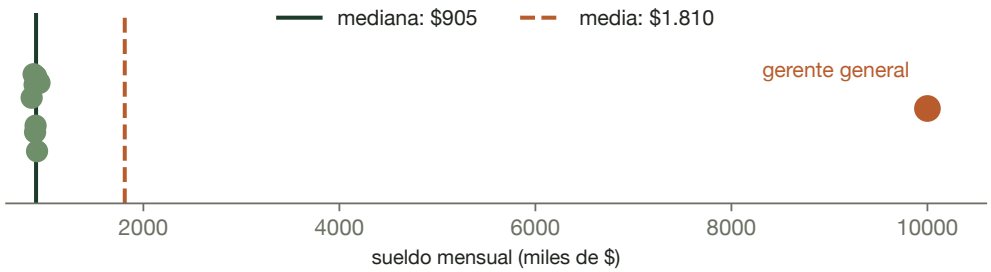
EJEMPLO

Con los datos 58, 64, 71, 78, 83, 88, 92: media = 534 / 7 = 76,3 y mediana = 78 (el cuarto valor de los siete ordenados). Dan parecido: es lo que ocurre cuando la distribución es aproximadamente simétrica y no hay valores extremos.

La media es sensible a los extremos

EJEMPLO

Nueve empleados ganan alrededor de $900 mil por mes. Media y mediana: ambas cerca de $900 mil. Entra a la nómina el gerente general, que gana $10 millones. Ahora la media es (9 × 900 + 10.000) / 10 ≈ **$1,81 millones** (se duplicó), mientras la mediana pasa a ≈ $905 mil: casi no se movió. "El sueldo promedio es $1,8 millones" es una afirmación técnicamente cierta que no describe a ninguna de las diez personas.



Cuándo usar cada una:

Situación	Qué conviene	Por qué
Distribución simétrica, sin extremos	media (o cualquiera)	usa toda la información y coincide con la mediana
Valores extremos u outliers	mediana	robusta: un valor no la arrastra
Distribución sesgada (ingresos, precios)	mediana	describe mejor al caso típico
Variable ordinal	mediana	la media no está definida para ordinales

Regla práctica: **calcular las dos**. Si dan parecido, cualquiera sirve. Si dan distinto, esa diferencia ya es información: hay extremos o asimetría que conviene entender antes de seguir.

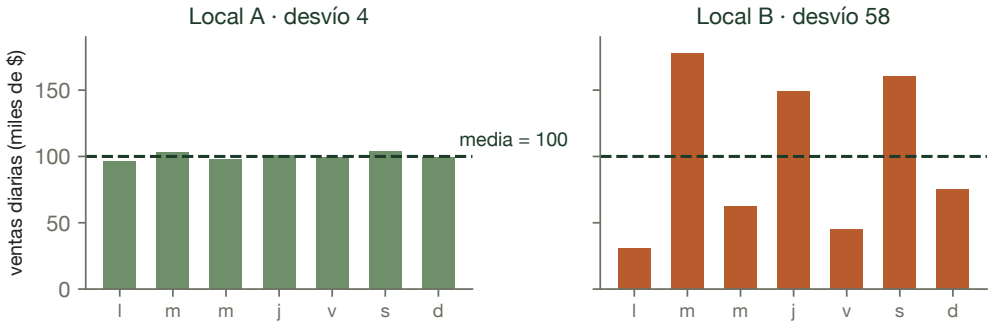
4. Medidas de dispersión

Responden a la otra mitad de la pregunta: ¿qué tan lejos del centro viven los datos?

- **Rango:** máximo menos mínimo. Simple pero frágil: lo definen justo los dos valores más raros del dataset.

- **Varianza:** el promedio de las desviaciones al cuadrado respecto de la media.
- **Desvío estándar:** la raíz cuadrada de la varianza. Vuelve a las unidades originales de la variable, por eso es la medida que se reporta: "los clientes gastan $400 mil ± $150 mil" se interpreta directo.
- **Cuartiles:** los valores que parten los datos ordenados en cuatro partes iguales: Q1 (25%), Q2 (la mediana), Q3 (75%).
- **Rango intercuartil (IQR):** Q3 − Q1, el ancho del 50% central. Como la mediana, es robusto a extremos.

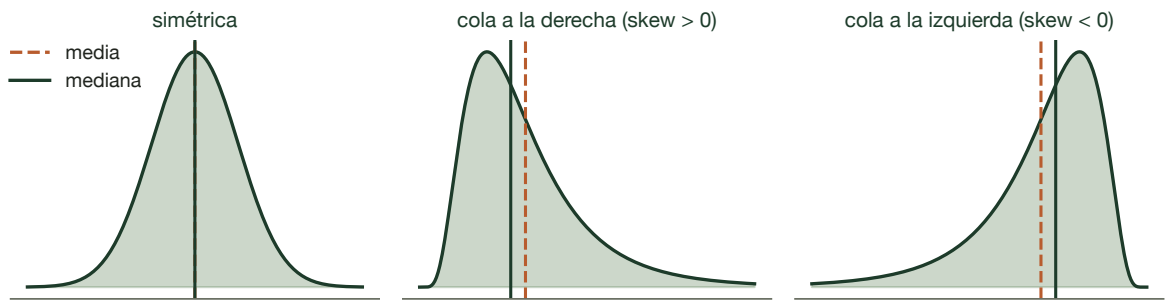
> **EJEMPLO**
>
> Dos locales venden en promedio $100 mil por día. Local A: 96, 103, 98, 101, 99, 104, 99 (desvío ≈ 4). Local B: 31, 178, 62, 149, 45, 160, 75 (desvío ≈ 58). El mismo promedio describe un negocio estable y una montaña rusa. Por eso un promedio se reporta junto con su dispersión: solo, no distingue entre estos dos locales.



5. La forma de la distribución

Asimetría (skewness)

Mide hacia dónde se estira la cola de la distribución. En una distribución **simétrica** (altura o peso de una población), media y mediana coinciden. Con **cola a la derecha** (skew > 0), pocos valores muy altos arrastran la media por encima de la mediana: es el caso de ingresos, precios de propiedades y gasto por cliente. Con **cola a la izquierda** (skew < 0), pasa lo inverso: edad de jubilación, notas de un examen fácil.



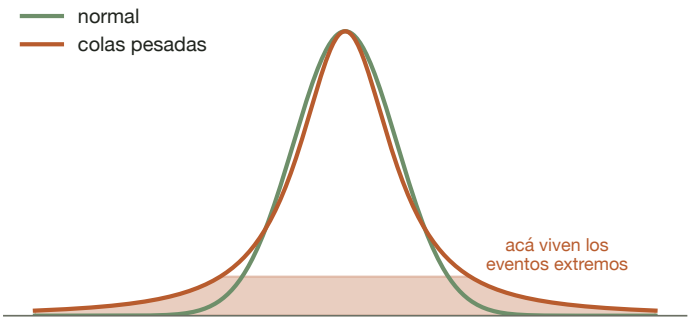
Casi todas las variables de plata tienen cola a la derecha; por eso la mediana aparece tanto en análisis de negocios. Referencias prácticas para el coeficiente:

Skewness	Lectura	Qué usar
−0,5 a 0,5	aproximadamente simétrica	media o mediana, van a dar parecido
±0,5 a ±1	moderadamente sesgada	considerar la mediana
más allá de ±1	altamente sesgada	mediana, y mirar los extremos de cerca

Para distribuciones muy sesgadas existen además **transformaciones** (logaritmo, raíz cuadrada) que las vuelven más simétricas; aparecen cuando se modela.

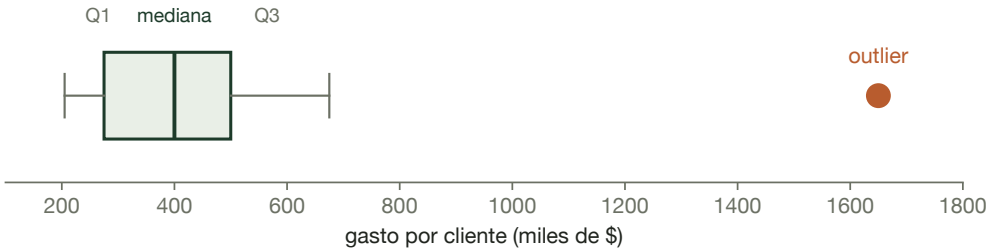
Curtosis

Mide el peso de las colas comparado con una distribución normal. Curtosis alta (leptocúrtica) significa colas pesadas: más eventos extremos de los esperables, típico de retornos financieros. Curtosis baja (platicúrtica) significa una distribución más chata, con valores repartidos de manera más pareja. En profiling, una curtosis alta es una advertencia temprana de que va a haber outliers.



6. Outliers

Un outlier es un valor anormalmente alejado del resto. La regla más usada para marcarlos: es outlier todo valor fuera del intervalo **[Q1 − 1,5 · IQR ; Q3 + 1,5 · IQR]**.



Marcarlo es lo fácil; la pregunta importante es **por qué está ahí**. Hay dos casos con tratamientos opuestos:

- **Es un error:** un tipeo, una unidad equivocada, un sensor roto. Se corrige si se puede reconstruir el valor real, o se descarta.
- **Es real:** el cliente mayorista entre minoristas, el día de Hot Sale. Existe de verdad; la decisión es si pertenece a la pregunta que se está respondiendo. Un análisis del "cliente típico minorista" puede excluirlo; un análisis de facturación total, no.

En ambos casos la decisión se documenta: "analizamos clientes minoristas; excluimos al mayorista X". **Nunca se borra sin dejarlo escrito.**

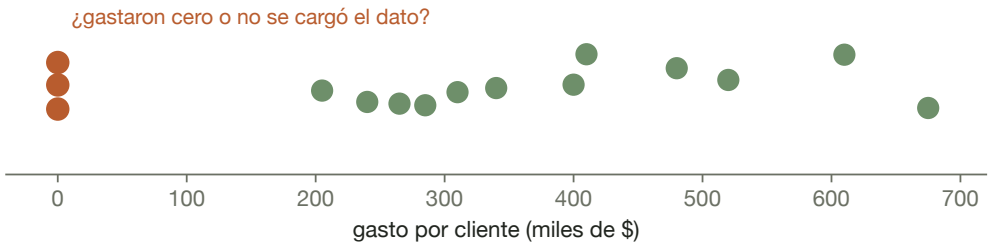
7. Calidad de datos

Faltantes: los que se ven y los que no

Los faltantes **honestos** (celda vacía, NULL, NaN) se ven, se cuentan y se decide qué hacer con ellos. Los **disfrazados** son peores porque entran en las cuentas como si fueran datos reales:

- Un **0** donde no se cargó el dato (y un cero sí entra en el promedio) y lo tira hacia abajo.
- Texto tipo "**s/d**", "N/A", "-".
- Códigos internos de "no sé": **999, 9999, −1**.
- Fechas imposibles: 01/01/1900.

Un cliente con 7 compras y gasto $0 no gastó cero: nadie cargó cuánto gastó. Distinguir esas dos situaciones cambia todas las cuentas que siguen.



Duplicados

Los duplicados **exactos** (la misma fila dos veces) se encuentran fácil. Los **disfrazados** ("María Fernández" y "M. Fernandez" con el mismo teléfono y la misma dirección) solo aparecen cruzando columnas. El efecto es el mismo: esa persona pesa doble en cada promedio, cada conteo y cada modelo.

Inconsistencias

- **Categorías inconsistentes:** "Palermo", "palermo" y "PALERMO " son tres categorías para cualquier programa y una sola en la realidad. Fragmentan los grupos al agrupar.
- **Unidades mezcladas:** un monto en dólares en una columna de pesos, kilos entre gramos. El número es válido; la unidad lo vuelve absurdo.

- **Valores fuera de escala o imposibles:** satisfacción 7 en una escala de 1 a 5, fecha de alta en el futuro, edad 208. Suelen ser errores de carga y se tratan como faltantes salvo que se puedan verificar en el origen.

Qué rompe cada problema

Problema	Qué rompe si no se trata
Outlier sin revisar	arrastra la media, el desvío y cualquier modelo con pérdida cuadrática
Faltante disfrazado de 0	subestima promedios; un modelo aprende clientes "que gastan cero"
Duplicado	sobrecuenta: esa entidad vale doble en cada métrica
Categórica tratada como número	inventa relaciones de magnitud que no existen
Unidades mezcladas	un valor absurdo contamina todas las cuentas donde entra
Categorías inconsistentes	fragmenta los grupos: la misma categoría aparece repartida en varias

8. El checklist

Qué mirar cuando llega un dataset nuevo, en orden:

1. **Tipos:** qué es cada columna, qué operaciones admite, si hay números que en realidad son etiquetas.
2. **Rangos:** mínimo y máximo de cada columna; valores imposibles, fuera de escala, fechas raras.
3. **Faltantes:** cuántos hay, y cuántos están disfrazados de 0, de "s/d" o de 999.
4. **Duplicados:** filas o entidades repetidas, exactas o con variantes.
5. **Extremos:** quiénes son los outliers, si son errores o casos reales, y si entran en la pregunta.
6. **Resúmenes:** media y mediana de cada numérica; si difieren mucho, hay asimetría o extremos que explicar.