ANALÍTICA DE DATOS

Data Profiling

Tipos de variables · medidas de resumen · calidad de datos

Clase práctica 3 · 2do cuatrimestre 2026

Universidad de SanAndrés

¿Qué es hacer profiling de un dataset?

Es **mirar los datos antes de usarlos**. Antes de calcular, graficar o modelar:

- **Entender la estructura:** qué es cada columna, de qué tipo es, qué valores puede tomar.
- **Evaluar la calidad:** qué falta, qué está repetido, qué no cierra.
- **Identificar problemas** que van a distorsionar cualquier análisis posterior.

Es el **primer paso de cualquier proyecto** de analítica.

Por qué importa: el modelo come lo que le des

En la teórica entrenaron una regresión que predice el gasto de un cliente. Ese modelo **no sabe** qué es un cliente, un peso ni un error de tipeo: ajusta números.

- Si un gasto está cargado en dólares entre miles de pesos, el modelo lo toma como un cliente 1.000 veces más chico.
- Si un faltante quedó como 0, el modelo aprende que ese cliente "gasta cero".
- Si un cliente figura dos veces, pesa el doble que los demás.

Ninguno de estos problemas los detecta el algoritmo: hay que encontrarlos antes, mirando los datos.

Tipos de variables: el mapa

Familia	Subtipos	Ejemplos
Numéricas	discretas · continuas	cantidad de compras · monto gastado
Categóricas	nominales · ordinales	barrio · nivel de satisfacción
Fecha y hora	-	fecha de alta, hora de la compra
Compuestas	-	dirección (calle + número + ciudad)
Identificadores	-	DNI, teléfono, número de cliente

La pregunta que define todo lo que viene: **¿qué operaciones tiene sentido hacer con cada una?**

Numéricas: discretas y continuas

Discretas

Valores enteros, contables. Entre dos valores consecutivos no hay nada.

- Cantidad de compras: 0, 1, 2, 3…
- Personas en una sucursal
- Unidades vendidas

Continuas

Cualquier valor dentro de un rango. Siempre hay un valor intermedio posible.

- Monto gastado: $87.350,50
- Peso de un envío: 1,248 kg
- Tiempo en el sitio: 4,7 minutos

Con ambas se puede **sumar, promediar y medir distancias**. Esa es la definición operativa de "numérica".

Categóricas: nominales y ordinales

Nominales: sin orden

Etiquetas. Ninguna categoría es "más" que otra.

- Barrio: Palermo, Flores, Belgrano
- Medio de pago: efectivo, tarjeta, QR
- Rubro del comercio

Ordinales: con orden natural

Las categorías se pueden ordenar, pero la distancia entre ellas no está definida.

- Satisfacción: baja < media < alta
- Talle: S < M < L < XL
- Nivel educativo

¿"Alta" menos "media" es igual a "media" menos "baja"? **Nadie lo sabe.** Por eso ordenar sí, restar no.

Las disfrazadas: números que no son numéricos

Que algo se escriba con dígitos **no lo hace numérico**:

Columna	Parece	Es
Código postal: 1425	numérica	categórica nominal (etiqueta de zona)
DNI / teléfono	numérica	identificador
Plan: 1, 2, 3	numérica	categórica (el "3" no es tres veces el "1")
Satisfacción: 1 a 5	numérica	ordinal (las estrellas se ordenan, no se restan)

El test es siempre el mismo: **¿tiene sentido el promedio? ¿tiene sentido "el doble"?** Si no, no es un número: es una etiqueta escrita con dígitos.

Qué operación admite cada tipo

	Contar / moda	Ordenar / mediana / percentiles	Sumar / promediar / desvío
Nominal	sí	no	no
Ordinal	sí	sí	no
Numérica	sí	sí	sí

Cada fila hereda lo de la anterior y agrega algo. Y funciona de chequeo en ambas direcciones:

- "El barrio promedio de nuestros clientes": no existe.
- "El código postal promedio es 1.417,3": se puede calcular, y no significa nada.

¿Dónde se concentran los valores?

Media

La suma dividida la cantidad. Usa toda la información, y por eso todo la afecta.

Mediana

El valor del medio con los datos ordenados. La mitad está abajo, la mitad arriba.

Moda

El valor más frecuente. La única de las tres que existe para categóricas.

Con los datos: 58, 64, 71, 78, **83**, 88, 92 → media = 76,3 · mediana = 78

Parecidas. Eso pasa cuando la distribución es más o menos simétrica. Veamos cuando no.

La media es sensible a los extremos

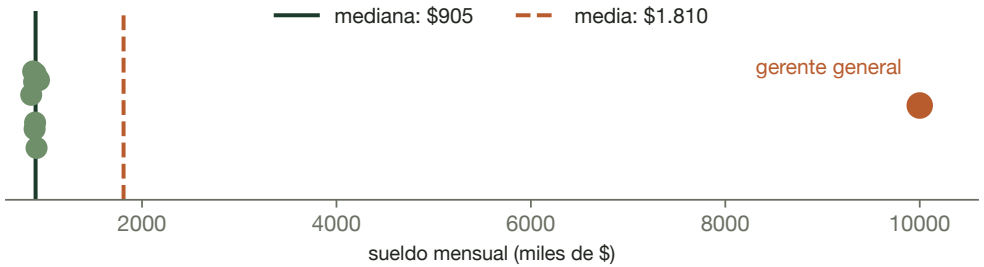
Nueve empleados ganan alrededor de $900 mil. Entra el gerente general, que gana $10 millones:

Antes (9 personas)

media ≈ **$900 mil**
mediana ≈ **$900 mil**

Después (10 personas)

media ≈ **$1,81 millones** (se duplicó)
mediana ≈ **$905 mil** (casi no se movió)



¿Media o mediana?

Situación	Qué conviene	Por qué
Distribución simétrica, sin extremos	media (o cualquiera: van a ser parecidas)	usa toda la información
Valores extremos u outliers	**mediana**	robusta: un valor no la arrastra
Distribución sesgada (ingresos, precios)	**mediana**	describe mejor al caso típico
Variable ordinal	**mediana** (la media no está definida)	solo se puede ordenar

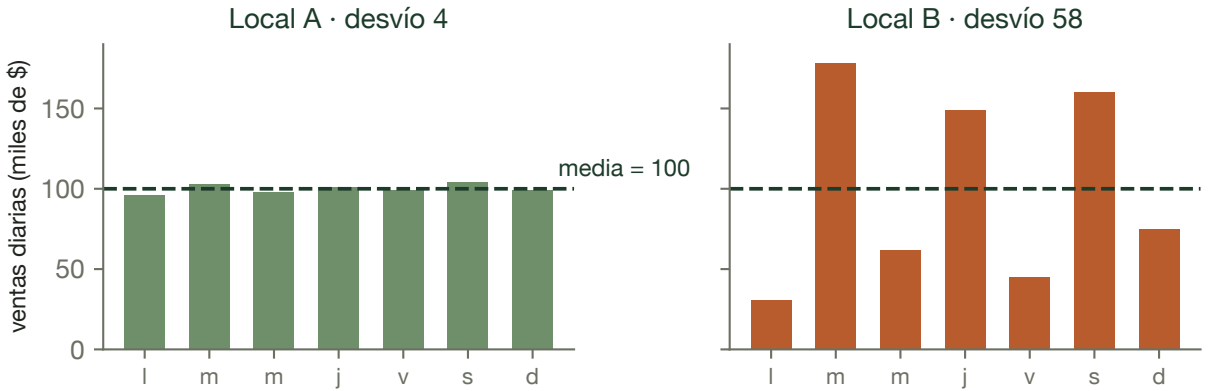
Regla práctica: **calculá las dos.** Si dan parecido, da igual cuál uses. Si dan distinto, la diferencia entre ellas ya es un hallazgo: hay extremos o asimetría que explicar.

¿Qué tan dispersos están los valores?

- **Rango:** máximo menos mínimo. Simple y frágil: lo definen justo los dos valores más raros.
- **Varianza:** promedio de las desviaciones al cuadrado respecto de la media.
- **Desvío estándar:** la raíz de la varianza: vuelve a las unidades originales. "Los clientes gastan $88 mil ± $20 mil" se entiende; "± 400 millones de pesos cuadrados", no.
- **Cuartiles:** los valores que parten los datos ordenados en cuatro partes iguales (Q1, Q2 = mediana, Q3).
- **Rango intercuartil (IQR):** Q3 − Q1. Dónde vive el 50% central. Robusto, como la mediana.

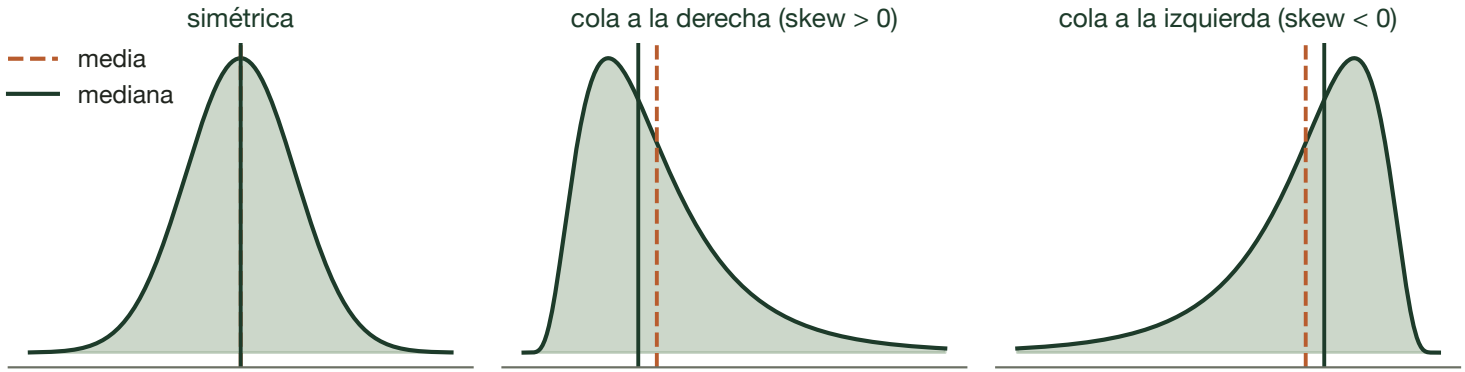
Misma media, negocios distintos

Ventas diarias de dos locales, en miles de $. Los dos promedian **100**. El local A es estable y permite planificar; el B es una montaña rusa donde el "promedio 100" no describe ningún día real:



Por eso un promedio se reporta junto con su dispersión: solo, no distingue entre estos dos locales.

La forma: asimetría (skewness)



Ejemplos: altura y peso (simétrica) · ingresos, precios, gasto por cliente (cola a la derecha) · edad de jubilación, notas de un examen fácil (cola a la izquierda).

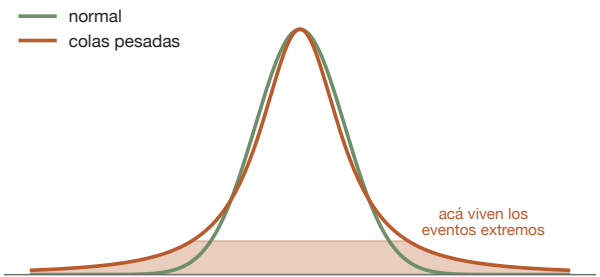
Casi todas las variables de plata tienen cola a la derecha: la media queda por encima de la mediana. Por eso la mediana aparece tanto en análisis de negocios.

Asimetría: regla práctica

Skewness	Lectura	Qué usar
$-0{,}5$ a $0{,}5$	aproximadamente simétrica	media o mediana, van a ser parecidas
$\pm 0{,}5$ a ± 1	moderadamente sesgada	considerar la mediana
más allá de ± 1	altamente sesgada	**mediana**, y mirar los extremos de cerca

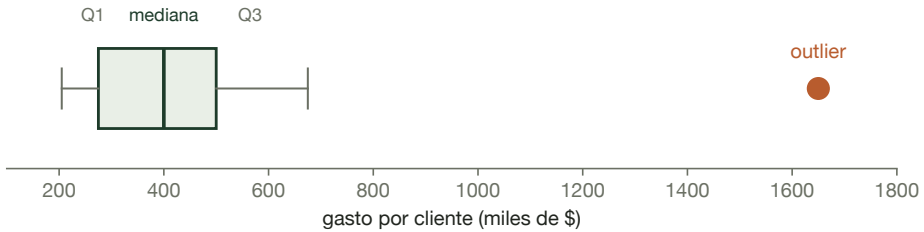
Para distribuciones muy sesgadas existen **transformaciones** (logaritmo, raíz) que las vuelven más simétricas.

Y una hermana de la asimetría: la **curtosis**, qué tan pesadas son las colas. Colas pesadas = más eventos extremos de los que esperarías.



Outliers: los valores que no encajan

Un outlier es un valor **anormalmente lejos del resto**. La regla más usada para marcarlos: fuera de [Q1 − 1,5·IQR ; Q3 + 1,5·IQR].



Es un error

Un tipeo, una unidad equivocada. Se corrige o se descarta, documentando.

Es real

El mayorista entre minoristas. Se decide si entra en la pregunta, **y se deja escrito**.

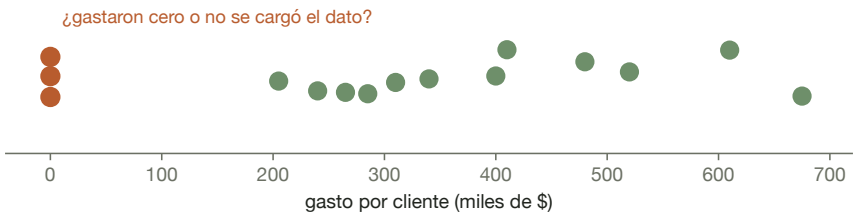
Faltantes: los que se ven y los que no

Faltantes honestos

Celda vacía, NULL, NaN. Se ven, se cuentan, se decide qué hacer con ellos.

Faltantes disfrazados

- **0** donde no se cargó el dato (y un cero sí entra en el promedio)
- "**s/d**", "N/A", "-" como texto
- **999, 9999, −1**: códigos internos de "no sé"
- Fechas imposibles: 01/01/1900



Duplicados e inconsistencias

- **Duplicados exactos:** la misma fila dos veces. Fáciles de encontrar.
- **Duplicados disfrazados:** "María Fernández" y "M. Fernandez", mismo teléfono, misma dirección. La misma persona pesa doble en cada cuenta, y solo se descubre cruzando columnas.
- **Categorías inconsistentes:** "Palermo", "palermo", "PALERMO ": tres barrios para cualquier programa, uno solo en la realidad.
- **Unidades mezcladas:** un monto en dólares en una columna de pesos, kilos entre gramos. El número es válido; la unidad lo hace absurdo.
- **Valores fuera de escala o imposibles:** satisfacción 7 en una escala de 1 a 5, fecha de alta en el futuro, edad 208.

Cada problema rompe algo distinto

Problema	Qué rompe si no lo tratás
Outlier sin revisar	arrastra la media, el desvío y cualquier modelo con pérdida cuadrática
Faltante disfrazado de 0	subestima promedios; el modelo aprende clientes "que gastan cero"
Duplicado	sobrecuenta: ese cliente vale doble en cada métrica
Categórica tratada como número	inventa relaciones: "CP 1428 > CP 1405" no significa nada
Unidades mezcladas	un valor absurdo contamina todas las cuentas donde entra
Categorías inconsistentes	fragmenta los grupos: Palermo aparece tres veces con un tercio del peso

El checklist: qué mirar cuando te dan un dataset

- **1 · Tipos:** ¿qué es cada columna? ¿Qué operaciones admite? ¿Hay números que son etiquetas?
- **2 · Rangos:** mínimo y máximo de cada columna. ¿Hay valores imposibles, fuera de escala, fechas raras?
- **3 · Faltantes:** ¿cuántos hay? ¿Y cuántos están disfrazados de 0, de "s/d", de 999?
- **4 · Duplicados:** ¿hay filas o entidades repetidas, exactas o con variantes?
- **5 · Extremos:** ¿quiénes son los outliers? ¿Errores o casos reales? ¿Entran en la pregunta?
- **6 · Resúmenes:** media y mediana de lo numérico. Si difieren mucho, ahí hay algo que explicar.

ANALÍTICA DE DATOS

Hasta acá llegamos

Data Profiling · clase práctica 3

Universidad de SanAndrés