CANICHE – SOLUCIONARIO

1 · TIPOS DE VARIABLES

Columna	Tipo	Comentario
Cliente	texto / identificador	nombre propio, no admite ninguna operación
Barrio	categórica nominal	etiquetas sin orden
Fecha de alta	fecha	se puede ordenar y restar (antigüedad), no promediar a ciegas
Plan (1/2/3)	categórica ordinal	se escribe con dígitos pero es categoría: Premium no es "3 Básicos"
Código postal	categórica nominal	etiqueta de zona con forma de número
Teléfono	identificador	número que no es numérico
Compras	numérica discreta	conteo entero
Gasto 12 meses	numérica continua	monto en miles de $
Satisfacción (1-5)	categórica ordinal	se ordena, la distancia entre niveles no está definida

2 · ¿QUÉ ADMITE PROMEDIO?

Solo **Compras** y **Gasto**. El "código postal promedio" o el "plan promedio 1,9" se pueden calcular y no significan nada: son etiquetas. La satisfacción promedio (estilo "4,2 estrellas") es de uso extendido pero técnicamente discutible — se está promediando una ordinal; la mediana es más defendible. Vale como discusión, no como error.

3 y 4 · MEDIA Y MEDIANA DEL GASTO

Valores utilizables (12): 205, 240, 265, 285, 310, 400, 410, 480, 520, 610, 675, 24.400. Quedan afuera: el 0 de Lynch (faltante disfrazado, ver problemas), el "s/d" de Ocampo, el duplicado de M. Fernandez (fila 15) y los USD 320 de Casas (otra unidad).

Con la ballena: media = 28.800 / 12 = **2.400** · mediana = (400+410)/2 = **405**. La media dice que el cliente típico gasta $2,4 millones al año: 11 de los 12 clientes están muy por debajo.
Sin la ballena (Nublar SRL): media = 4.400 / 11 = **400** · mediana = **400**. La media cayó 6 veces y ahora coincide con la mediana; la mediana apenas se movió (405 → 400).

La mediana describe mejor al cliente típico: es robusta al extremo. Si un grupo tomó otras decisiones razonables de exclusión, los números cambian poco — salvo que hayan dejado el 0 o la ballena adentro, que es la discusión a dar en la corrección.

CANICHE – SOLUCIONARIO (CONT.)

5 · LOS PROBLEMAS DE LA TABLA (SON 9)

Fila	Problema	Tipo	Qué hacer
5	Gasto 24.400 (Distribuidora Nublar SRL)	outlier real: es un mayorista entre minoristas	no es un error — decidir si entra en la pregunta y documentarlo
7	Gasto 0 con 7 compras	faltante disfrazado de cero	tratar como faltante; jamás promediarlo
11	Gasto "s/d"	faltante como texto	tratar como faltante
13 y 15	María Fernández / M. Fernandez — mismo teléfono, CP, fecha y compras	duplicado disfrazado	quedarse con una fila
10	Satisfacción 7	fuera de la escala 1-5	inválido: faltante o verificación en el origen
16	Fecha de alta 03/11/2026	fecha futura (hoy es agosto 2026)	inválida: error de carga
8	"palermo" en minúscula	inconsistencia de categoría	normalizar a "Palermo"
16	Gasto "USD 320"	unidad mezclada en columna de miles de $	convertir o excluir; nunca operar mezclado
11	Código postal 9999	faltante disfrazado / código inválido	tratar como faltante

6 · ¿QUÉ LE HACE CADA UNO A LA REGRESIÓN DE GASTO?

- **La ballena (fila 5):** con pérdida cuadrática, un solo punto 60 veces más grande que la mediana domina el ajuste — la recta se corre hacia el mayorista y empeora la predicción de los otros 15. Es el "cliente ballena" de la teórica.
- **El 0 de Lynch (fila 7):** el modelo aprende que existe un cliente con 7 compras y gasto cero — un patrón falso que achata la relación compras-gasto y sesga la predicción de clientes nuevos hacia abajo.
- **El duplicado (13/15):** María pesa doble en el entrenamiento: el modelo ajusta dos veces el mismo punto, como si esa clienta fuera el doble de representativa de lo que es.
- **El plan o el CP como número:** el modelo inventa relaciones de magnitud ("Premium = 3 Básicos", "CP 1428 > CP 1405") que no existen — es el "¿número o categoría?" de la teórica: las categóricas se codifican, no se usan crudas.
- **Los USD 320 (fila 16):** el modelo lo lee como 320 (miles de pesos), cuando al tipo de cambio (~$1.500) son ~$480 mil: la predicción para ese cliente arranca con un error del 33% inyectado en la carga. Un valor con otra unidad es un outlier artificial inyectado por el proceso de carga, no por la realidad.