

CART

(Classification And Regression Trees)

Analítica de Datos, Universidad de San Andrés

Si encuentran algún error en el documento o hay alguna duda, mandenme un mail a rodriguezr@udesa.edu.ar y lo revisamos.

1. Introducción a CART

El algoritmo CART (Classification And Regression Trees) es una técnica de aprendizaje automático utilizada para la clasificación y la regresión. Su principal objetivo es dividir un conjunto de datos en grupos homogéneos.

El índice de Gini es una medida de impureza o pureza de un nodo en un árbol de decisión. Se utiliza para evaluar la calidad de una división en el árbol. La fórmula del índice de Gini es:

$$\text{Gini} = 1 - \sum_{k=1}^K p_k^2,$$

donde p_k es la proporción de la clase k en el nodo. Un Gini de 0 indica un nodo puro (todas las instancias pertenecen a una sola clase), mientras que un Gini de 0.5 indica máxima impureza (las instancias están distribuidas uniformemente entre las clases).

En el caso de las variables categóricas el índice Gini se calcula más fácilmente ya que es necesario nada más ver cuantos valores pertenecen a cada clase cuando hacemos una versus las demás. Para las variables continuas, el algoritmo CART busca los puntos de corte que minimizan el índice de Gini. En computadora, el algoritmo de CART se fija para cada punto de corte el Gini, lo cual se hace impráctico a mano si tenemos muchos datos.

A chequear cada punto y determinar si es útil o no sin tener en cuenta todo lo que viene después se le llama búsqueda **greedy** (voraz). Es como si en cada paso tomáramos la mejor decisión localmente, sin pensar en el futuro. Esto puede llevar a soluciones subóptimas, pero en muchos casos es suficiente.

2. Ejercicio 1

2.1. Datos

Tenemos la siguiente tabla donde queremos predecir si una persona es aprobada o no para un crédito. La variable objetivo es “Aprobado” y las variables predictoras son “Edad”, “Ingreso”, “Historial” y “Deuda Actual”.

Edad	Ingreso	Historial	Deuda Actual	Aprobado
25	3.5	Bueno	10	Sí
40	5.0	Malo	20	No
30	4.2	Bueno	30	Sí
22	2.8	Malo	40	No
35	6.1	Bueno	15	Sí

2.2. Partición por Variable Objetivo

Para calcular el índice de Gini para la variable “Aprobado”, consideramos las instancias en la tabla:

- **Aprobado = Sí:** 3 instancias.
- **Aprobado = No:** 2 instancias.

Calculamos entonces el índice de Gini, viendo que tenemos 5 instancias en total:

$$\text{Gini}_{\text{Aprobado}} = 1 - \left[\left(\frac{3}{5} \right)^2 + \left(\frac{2}{5} \right)^2 \right] = 0,48$$

Esto nos sirve para tener un benchmark de la calidad de la partición. A partir de este valor, intentaremos mejorarlo.

2.3. Partición por Edad

Cuando tenemos una variable continua, debemos ordenar los valores y calcular el gini en cada corte. En este caso, tenemos la siguiente tabla, ordenada de menor a mayor por Edad:

Edad	Aprobado
22	No
25	Sí
30	Sí
35	Sí
40	No

Para calcular el índice de Gini vamos entonces a considerar la mitad entre los puntos de corte, por ejemplo entre 22 y 25 tomamos 23.5, o entre 35 y 40 tomamos 37.5.

- **Edad ≤ 23.5 :** 1 instancia (0 aprobados, 1 no aprobado).
- **Edad > 23.5 :** 4 instancias (3 aprobados, 1 no aprobado).

$$\begin{aligned} \text{Gini}_{\leq 23,5} &= 1 - \left[\left(\frac{0}{1} \right)^2 + \left(\frac{1}{1} \right)^2 \right] = 0 \\ \text{Gini}_{> 23,5} &= 1 - \left[\left(\frac{3}{4} \right)^2 + \left(\frac{1}{4} \right)^2 \right] = 0,375 \\ \Rightarrow \text{Gini}_{\text{Edad}, 23,5} &= \frac{1}{5} \times 0 + \frac{4}{5} \times 0,375 = 0,3 \end{aligned}$$

- **Edad ≤ 27.5 :** 2 instancias (1 aprobado, 1 no aprobado).
- **Edad > 27.5 :** 3 instancias (2 aprobados, 1 no aprobado).

$$\begin{aligned} \text{Gini}_{\leq 27,5} &= 1 - \left[\left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right] = 0,5 \\ \text{Gini}_{> 27,5} &= 1 - \left[\left(\frac{2}{3} \right)^2 + \left(\frac{1}{3} \right)^2 \right] = 0,444 \\ \Rightarrow \text{Gini}_{\text{Edad}, 27,5} &= \frac{2}{5} \times 0,5 + \frac{3}{5} \times 0,444 = 0,467 \end{aligned}$$

- **Edad ≤ 32.5 :** 3 instancias (2 aprobados, 1 no aprobado).
- **Edad > 32.5 :** 2 instancias (1 aprobado, 1 no aprobado).

$$\text{Gini}_{\leq 32,5} = 1 - \left[\left(\frac{2}{3} \right)^2 + \left(\frac{1}{3} \right)^2 \right] = 0,444$$

$$\text{Gini}_{> 32,5} = 1 - \left[\left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right] = 0,5$$

$$\Rightarrow \text{Gini}_{\text{Edad}, 32,5} = \frac{3}{5} \times 0,444 + \frac{2}{5} \times 0,5 = 0,467$$

- **Edad ≤ 37.5 :** 4 instancias (3 aprobados, 1 no aprobado).
- **Edad > 37.5 :** 1 instancia (0 aprobados, 1 no aprobado).

$$\text{Gini}_{\leq 37,5} = 1 - \left[\left(\frac{3}{4} \right)^2 + \left(\frac{1}{4} \right)^2 \right] = 0,375$$

$$\text{Gini}_{> 37,5} = 1 - \left[\left(\frac{0}{1} \right)^2 + \left(\frac{1}{1} \right)^2 \right] = 0$$

$$\Rightarrow \text{Gini}_{\text{Edad}, 37,5} = \frac{4}{5} \times 0,375 + \frac{1}{5} \times 0 = 0,3$$

2.4. Partición por Historial

Para calcular el índice de Gini para la variable "Historial", consideramos las instancias en la tabla. Tenemos que tener en cuenta si fue aprobado o no.

- **Historial = Bueno:** 3 instancias (3 aprobados, 0 no aprobados).
- **Historial = Malo:** 2 instancias (0 aprobados, 2 no aprobados).

$$\text{Gini}_{\text{Bueno}} = 1 - \left[\left(\frac{3}{3} \right)^2 + \left(\frac{0}{3} \right)^2 \right] = 0$$


$$\text{Gini}_{\text{Malo}} = 1 - \left[\left(\frac{0}{2} \right)^2 + \left(\frac{2}{2} \right)^2 \right] = 0$$

$$\Rightarrow \text{Gini}_{\text{Historial}} = \frac{3}{5} \times 0 + \frac{2}{5} \times 0 = 0$$

Dado que tenemos un Gini de 0 en este nodo, no es necesario continuar porque encontramos una forma de dividir perfectamente los datos. Un **Gini = 0** indica un nodo puro (división perfecta), mientras que **Gini = 0.5** indica máxima impureza (no se gana información). Si tenemos alguna categoría con un Gini = 0 entonces podemos generar un árbol de un solo nodo.

2.5. Árbol resultante

Para armar el árbol de decisión en este caso es fácil ya que tenemos una clase cuyo Gini es 0. Por lo tanto, podemos hacer un árbol de un solo nodo y no es necesario seguir dividiendo cada rama. Esto en la práctica jamás sucede, pero es un buen ejemplo para entender cómo funciona el algoritmo.



CART siempre nos garantiza que el árbol que encontremos sea el que menos nodos tenga, siempre y cuando hayamos buscado todos los Gini de cada punto de corte, y no como hicimos nosotros a mano.

3. Ejercicio 2

3.1. Datos

Tenemos la siguiente tabla:

Departamento	Antigüedad	Cumplimiento de Objetivos	Recibe Bono
Ventas	2	80	No
Soporte	5	60	No
Logística	3	75	Sí
Ventas	1	50	No
Soporte	4	85	Sí
Logística	6	70	No

3.2. Partición por Variable Objetivo

$$\text{Gini}_{\text{Recibe Bono}} = 1 - \left[\left(\frac{2}{6} \right)^2 + \left(\frac{4}{6} \right)^2 \right] = 0,444$$

3.3. Partición por Departamento

Acá lo importante es dividir el dataset entre la categoría versus las demás.

3.3.1. Ventas vs Soporte y Logística

- **Ventas:** 2 observaciones (0 Sí, 2 No).
- **Soporte y Logística:** 4 observaciones (2 Sí, 2 No).

$$\text{Gini}_{\text{Ventas}} = 1 - \left[\left(\frac{0}{2} \right)^2 + \left(\frac{2}{2} \right)^2 \right] = 0$$

$$\text{Gini}_{\text{Soporte y Logística}} = 1 - \left[\left(\frac{2}{4} \right)^2 + \left(\frac{2}{4} \right)^2 \right] = 0,5$$

$$\Rightarrow \text{Gini}_{\text{Departamento, Ventas}} = \frac{2}{6} \times 0 + \frac{4}{6} \times 0,5 = 0,333$$

3.3.2. Soporte vs Ventas y Logística

- **Soporte:** 2 observaciones (1 Sí, 1 No).
- **Ventas y Logística:** 4 observaciones (1 Sí, 3 No).

$$\text{Gini}_{\text{Soporte}} = 1 - \left[\left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right] = 0,5$$

$$\text{Gini}_{\text{Ventas y Logística}} = 1 - \left[\left(\frac{1}{4} \right)^2 + \left(\frac{3}{4} \right)^2 \right] = 0,375$$

$$\Rightarrow \text{Gini}_{\text{Departamento, Soporte}} = \frac{2}{6} \times 0,5 + \frac{4}{6} \times 0,375 = 0,4167$$

3.3.3. Logística vs Ventas y Soporte

- **Logística:** 2 observaciones (1 Sí, 1 No).
- **Ventas y Soporte:** 4 observaciones (1 Sí, 3 No).

$$\text{Gini}_{\text{Logística}} = 1 - \left[\left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right] = 0,5$$

$$\text{Gini}_{\text{Ventas y Soporte}} = 1 - \left[\left(\frac{1}{4} \right)^2 + \left(\frac{3}{4} \right)^2 \right] = 0,375$$

$$\Rightarrow \text{Gini}_{\text{Departamento, Logística}} = \frac{2}{6} \times 0,5 + \frac{4}{6} \times 0,375 = 0,4167$$

3.4. Particion por Cumplimiento de Objetivos

Vamos a calcular todos los puntos de corte posibles para la variable “Cumplimiento de Objetivos”. Ordenamos los valores y armamos la tabla:

Cumplimiento de Objetivos	Recibe Bono
50	No
60	No
70	No
75	Si
80	No
85	Si

Los puntos de corte posibles son entre cada par de valores consecutivos: 50 y 60, 60 y 70, 70 y 75, 75 y 80, 80 y 85. Los puntos de corte serian: 55, 65, 72.5, 77.5 y 82.5.

- **Cumplimiento de Objetivos ≤ 55 :** 1 instancia (0 Si, 1 No).
- **Cumplimiento de Objetivos > 55 :** 5 instancias (2 Si, 3 No).

$$\text{Gini}_{\leq 55} = 1 - \left[\left(\frac{0}{1} \right)^2 + \left(\frac{1}{1} \right)^2 \right] = 0$$

$$\text{Gini}_{> 55} = 1 - \left[\left(\frac{2}{5} \right)^2 + \left(\frac{3}{5} \right)^2 \right] = 0,48$$

$$\Rightarrow \text{Gini}_{55} = \frac{1}{6} \times 0 + \frac{5}{6} \times 0,48 = 0,4$$

- **Cumplimiento de Objetivos ≤ 65 :** 2 instancias (0 Si, 2 No).

- **Cumplimiento de Objetivos > 65:** 4 instancias (2 Si, 2 No).

$$\begin{aligned} \text{Gini}_{\leq 65} &= 1 - \left[\left(\frac{0}{2} \right)^2 + \left(\frac{2}{2} \right)^2 \right] = 0 \\ \text{Gini}_{> 65} &= 1 - \left[\left(\frac{2}{4} \right)^2 + \left(\frac{2}{4} \right)^2 \right] = 0,5 \\ \Rightarrow \text{Gini}_{65} &= \frac{2}{6} \times 0 + \frac{4}{6} \times 0,5 = 0,333 \end{aligned}$$

- **Cumplimiento de Objetivos ≤ 72.5:** 3 instancias (0 Si, 3 No).
- **Cumplimiento de Objetivos > 72.5:** 3 instancias (2 Si, 1 No).

$$\begin{aligned} \text{Gini}_{\leq 72,5} &= 1 - \left[\left(\frac{0}{3} \right)^2 + \left(\frac{3}{3} \right)^2 \right] = 0 \\ \text{Gini}_{> 72,5} &= 1 - \left[\left(\frac{2}{3} \right)^2 + \left(\frac{1}{3} \right)^2 \right] = 0,444 \\ \Rightarrow \text{Gini}_{72,5} &= \frac{3}{6} \times 0 + \frac{3}{6} \times 0,444 = 0,222 \end{aligned}$$

- **Cumplimiento de Objetivos ≤ 77.5:** 4 instancias (1 Si, 3 No).
- **Cumplimiento de Objetivos > 77.5:** 2 instancias (1 Si, 1 No).

$$\begin{aligned} \text{Gini}_{\leq 77,5} &= 1 - \left[\left(\frac{1}{4} \right)^2 + \left(\frac{3}{4} \right)^2 \right] = 0,375 \\ \text{Gini}_{> 77,5} &= 1 - \left[\left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right] = 0,5 \\ \Rightarrow \text{Gini}_{77,5} &= \frac{4}{6} \times 0,375 + \frac{2}{6} \times 0,5 = 0,417 \end{aligned}$$

- **Cumplimiento de Objetivos ≤ 82.5:** 5 instancias (1 Si, 4 No).
- **Cumplimiento de Objetivos > 82.5:** 1 instancia (1 Si, 0 No).

$$\begin{aligned} \text{Gini}_{\leq 82,5} &= 1 - \left[\left(\frac{1}{5} \right)^2 + \left(\frac{4}{5} \right)^2 \right] = 0,32 \\ \text{Gini}_{> 82,5} &= 1 - \left[\left(\frac{1}{1} \right)^2 + \left(\frac{0}{1} \right)^2 \right] = 0 \\ \Rightarrow \text{Gini}_{82,5} &= \frac{5}{6} \times 0,32 + \frac{1}{6} \times 0 = 0,267 \end{aligned}$$

3.5. Particion por Antigüedad

Ordenamos los valores de “Antigüedad” y encontramos todos los puntos de corte posibles, que son los promedios entre cada par de valores consecutivos. En este caso, los puntos de corte son: 1.5, 2.5, 3.5, 4.5 y 5.5.

Antigüedad	Recibe Bono
1	No
2	No
3	Si
4	Si
5	No
6	No

- **Antigüedad ≤ 1.5 :** 1 instancia (0 Si, 1 No)

- **Antigüedad > 1.5 :** 5 instancias (2 Si, 3 No)

$$\text{Gini}_{\leq 1,5} = 1 - \left[\left(\frac{0}{1} \right)^2 + \left(\frac{1}{1} \right)^2 \right] = 0$$

$$\text{Gini}_{> 1,5} = 1 - \left[\left(\frac{2}{5} \right)^2 + \left(\frac{3}{5} \right)^2 \right] = 0,48$$

$$\Rightarrow \text{Gini}_{\text{Antigüedad}, 1,5} = \frac{1}{6} \times 0 + \frac{5}{6} \times 0,48 = 0,4$$

- **Antigüedad ≤ 2.5 :** 2 instancias (0 Si, 2 No)

- **Antigüedad > 2.5 :** 4 instancias (2 Si, 2 No)

$$\text{Gini}_{\leq 2,5} = 1 - \left[\left(\frac{0}{2} \right)^2 + \left(\frac{2}{2} \right)^2 \right] = 0$$

$$\text{Gini}_{> 2,5} = 1 - \left[\left(\frac{2}{4} \right)^2 + \left(\frac{2}{4} \right)^2 \right] = 0,5$$

$$\Rightarrow \text{Gini}_{\text{Antigüedad}, 2,5} = \frac{2}{6} \times 0 + \frac{4}{6} \times 0,5 = 0,333$$

- **Antigüedad ≤ 3.5 :** 3 instancias (2 Si, 1 No)

- **Antigüedad > 3.5:** 3 instancias (0 Si, 3 No)

$$\text{Gini}_{\leq 3,5} = 1 - \left[\left(\frac{2}{3} \right)^2 + \left(\frac{1}{3} \right)^2 \right] = 0,444$$

$$\text{Gini}_{> 3,5} = 1 - \left[\left(\frac{0}{3} \right)^2 + \left(\frac{3}{3} \right)^2 \right] = 0$$

$$\Rightarrow \text{Gini}_{\text{Antigüedad}, 3.5} = \frac{3}{6} \times 0,444 + \frac{3}{6} \times 0 = 0,222$$

- **Antigüedad ≤ 4.5:** 4 instancias (2 Si, 2 No)

- **Antigüedad > 4.5:** 2 instancias (0 Si, 2 No)

$$\text{Gini}_{\leq 4,5} = 1 - \left[\left(\frac{2}{4} \right)^2 + \left(\frac{2}{4} \right)^2 \right] = 0,5$$

$$\text{Gini}_{> 4,5} = 1 - \left[\left(\frac{0}{2} \right)^2 + \left(\frac{2}{2} \right)^2 \right] = 0$$

$$\Rightarrow \text{Gini}_{\text{Antigüedad}, 4.5} = \frac{4}{6} \times 0,5 + \frac{2}{6} \times 0 = 0,333$$

- **Antigüedad ≤ 5.5:** 5 instancias (2 Si, 3 No)

- **Antigüedad > 5.5:** 1 instancia (0 Si, 1 No)

$$\text{Gini}_{\leq 5,5} = 1 - \left[\left(\frac{2}{5} \right)^2 + \left(\frac{3}{5} \right)^2 \right] = 0,48$$

$$\text{Gini}_{> 5,5} = 1 - \left[\left(\frac{0}{1} \right)^2 + \left(\frac{1}{1} \right)^2 \right] = 0$$

$$\Rightarrow \text{Gini}_{\text{Antigüedad}, 5.5} = \frac{5}{6} \times 0,48 + \frac{1}{6} \times 0 = 0,4$$

3.6. Armandando el árbol

Para armar el árbol de decisión, comenzamos con la variable que tiene el menor índice de Gini. La siguiente tabla muestra los índices de Gini calculados para cada partición:

Variable	Partición	Gini
Cumplimiento de Objetivos	72.5	0.222
Antigüedad	3.5	0.222
Departamento	Ventas	0.333
Antigüedad	2.5	0.333
Antigüedad	4.5	0.333
Cumplimiento de Objetivos	65	0.333
Antigüedad	1.5	0.4
Antigüedad	5.5	0.4
Cumplimiento de Objetivos	55	0.4
Cumplimiento de Objetivos	82.5	0.4
Departamento	Soporte	0.4167
Departamento	Logística	0.4167
Cumplimiento de Objetivos	77.5	0.417

En este caso, la variable Cumplimiento de Objetivos (72.5) es la que mejor divide los datos. Está empatada con Antigüedad (3.5) decidir cual va es arbitrario. Para los siguientes nodos iremos agregando variables a medida que necesitemos hasta que no quede ningún dato sin clasificar, pero el tema es que ahora debemos calcular los Ginis de vuelta para los datos que nos quedan, porque si usamos los Ginis de antes estamos usando información que ya no es cierta. Veamos como tenemos la tabla ahora, sacando los datos que siguen sin tener una clasificación (osea, aquellos que la respuesta a la pregunta “Cumplimiento de Objetivos ≤ 72.5 ?” es “No”):

Departamento	Antigüedad	Cumplimiento de Objetivos	Recibe Bono
Ventas	2	80	No
Logística	3	75	Sí
Soporte	4	85	Sí

3.6.1. Gini por Departamento

3.6.2. Ventas vs Soporte y Logística

- **Ventas:** 1 observación (0 Sí, 1 No).
- **Soporte y Logística:** 2 observaciones (2 Sí, 0 No).

$$\text{Gini}_{\text{Ventas}} = 1 - \left[\left(\frac{0}{1} \right)^2 + \left(\frac{1}{1} \right)^2 \right] = 0$$

$$\text{Gini}_{\text{Soporte y Logística}} = 1 - \left[\left(\frac{2}{2} \right)^2 + \left(\frac{0}{2} \right)^2 \right] = 0$$

$$\Rightarrow \text{Gini}_{\text{Departamento, Ventas}} = \frac{1}{3} \times 0 + \frac{2}{3} \times 0 = 0$$

3.6.3. Soporte vs Ventas y Logística

- **Soporte:** 1 observación (1 Sí, 0 No).
- **Ventas y Logística:** 2 observaciones (1 Sí, 1 No).

$$\text{Gini}_{\text{Soporte}} = 1 - \left[\left(\frac{1}{1} \right)^2 + \left(\frac{0}{1} \right)^2 \right] = 0$$

$$\text{Gini}_{\text{Ventas y Logística}} = 1 - \left[\left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right] = 0,5$$

$$\Rightarrow \text{Gini}_{\text{Departamento, Soporte}} = \frac{1}{3} \times 0 + \frac{2}{3} \times 0,5 = 0,333$$

3.6.4. Logística vs Ventas y Soporte

- **Logística:** 1 observación (1 Sí, 0 No).
- **Ventas y Soporte:** 2 observaciones (1 Sí, 1 No).

$$\text{Gini}_{\text{Logística}} = 1 - \left[\left(\frac{1}{1} \right)^2 + \left(\frac{0}{1} \right)^2 \right] = 0$$

$$\text{Gini}_{\text{Ventas y Soporte}} = 1 - \left[\left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right] = 0,5$$

$$\Rightarrow \text{Gini}_{\text{Departamento, Logística}} = \frac{1}{3} \times 0 + \frac{2}{3} \times 0,5 = 0,333$$

3.6.5. Gini por Antigüedad

- **Antigüedad ≤ 2.5 :** 1 instancia (0 Si, 1 No)
- **Antigüedad > 2.5 :** 2 instancias (2 Si, 0 No)

$$\text{Gini}_{\leq 2,5} = 1 - \left[\left(\frac{0}{1} \right)^2 + \left(\frac{1}{1} \right)^2 \right] = 0$$

$$\text{Gini}_{> 2,5} = 1 - \left[\left(\frac{2}{2} \right)^2 + \left(\frac{0}{2} \right)^2 \right] = 0$$

$$\Rightarrow \text{Gini}_{\text{Antigüedad}, 2.5} = \frac{1}{3} \times 0 + \frac{2}{3} \times 0 = 0$$

- **Antigüedad ≤ 3.5 :** 2 instancias (1 Si, 1 No)
- **Antigüedad > 3.5 :** 1 instancia (1 Si, 0 No)

$$\text{Gini}_{\leq 3,5} = 1 - \left[\left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right] = 0,5$$

$$\text{Gini}_{> 3,5} = 1 - \left[\left(\frac{1}{1} \right)^2 + \left(\frac{0}{1} \right)^2 \right] = 0$$

$$\Rightarrow \text{Gini}_{\text{Antigüedad}, 3.5} = \frac{2}{3} \times 0,5 + \frac{1}{3} \times 0 = 0,333$$

3.6.6. Gini por Cumplimiento de Objetivos

- **Cumplimiento de Objetivos ≤ 77.5 :** 1 instancia (1 Si, 0 No)
- **Cumplimiento de Objetivos > 77.5 :** 2 instancias (1 Si, 1 No)

$$\text{Gini}_{\leq 77,5} = 1 - \left[\left(\frac{1}{1} \right)^2 + \left(\frac{0}{1} \right)^2 \right] = 0$$

$$\text{Gini}_{> 77,5} = 1 - \left[\left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right] = 0,5$$

$$\Rightarrow \text{Gini}_{\text{Cumplimiento de Objetivos}, 77.5} = \frac{1}{3} \times 0 + \frac{2}{3} \times 0,5 = 0,333$$

- **Cumplimiento de Objetivos ≤ 82.5 :** 1 instancias (1 Si, 1 No)

- **Cumplimiento de Objetivos > 82.5:** 2 instancias (1 Si, 0 No)

$$\text{Gini}_{\leq 82,5} = 1 - \left[\left(\frac{1}{1} \right)^2 + \left(\frac{1}{1} \right)^2 \right] = 0,5$$

$$\text{Gini}_{> 82,5} = 1 - \left[\left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right] = 0$$


$$\Rightarrow \text{Gini}_{\text{Cumplimiento de Objetivos}, 82,5} = \frac{1}{3} \times 0,5 + \frac{2}{3} \times 0 = 0,167$$

3.7. Tabla ordenada de Ginis nuevos

Ordenamos entonces los Ginis que nos dieron las cuentas de recién. Dado que hay un Gini que es 0 podemos dar por finalizado el árbol. Qué variable de las dos que son cero elegimos da lo mismo.

Variable	Partición	Gini
Antigüedad	2.5	0
Departamento	Ventas	0
Cumplimiento de Objetivos	82.5	0.167
Departamento	Soporte	0.333
Departamento	Logística	0.333
Antigüedad	3.5	0.333
Cumplimiento de Objetivos	77.5	0.333

3.8. Árbol Resultante



4. En resumen

El algoritmo CART tiene varias características importantes que lo distinguen de otros algoritmos de machine learning:

- **Algoritmo greedy:** Toma la mejor decisión local en cada paso
- **División binaria:** Cada nodo se divide en exactamente dos ramas
- **Índice de Gini:** Minimiza la impureza en cada división
- **Árbol óptimo:** CART garantiza el árbol con menos nodos

4.1. Ventajas de CART

Los árboles de decisión CART ofrecen varias ventajas importantes:

- Fácil de interpretar y visualizar
- Maneja variables categóricas y numéricas
- No requiere normalización de datos
- Maneja valores faltantes automáticamente
- No es sensible a valores atípicos

4.2. Desventajas de CART

Sin embargo, CART también presenta algunas limitaciones importantes:

- Propenso al sobreajuste (overfitting)
- Inestable con pequeños cambios en los datos
- Sesgado hacia variables con muchos niveles
- No funciona bien con relaciones no lineales complejas
- Algoritmo greedy puede no encontrar la solución óptima global

4.3. Consideraciones Prácticas

Al usar CART en la práctica, es importante considerar:

- **Pruning:** Técnica para reducir el sobreajuste eliminando ramas poco importantes
- **Validación cruzada:** Para evaluar el rendimiento real del modelo
- **Ensemble methods:** Combinar múltiples árboles (Random Forest, Gradient Boosting) para mejorar el rendimiento
- **Balance de clases:** Considerar técnicas de balanceo cuando las clases están desbalanceadas
- **Selección de hiperparámetros:** Ajustar parámetros como profundidad máxima y número mínimo de muestras por hoja