ANALÍTICA DE DATOS

MSE y KNN

Cómo se mide el error de un modelo · cómo predicen los vecinos

Clase práctica 4 · 2do cuatrimestre 2026

Universidad de SanAndrés

Dónde estás parado hoy

En la teórica ya vieron: predicción y clasificación, regresión lineal y logística, KNN, la separación entre entrenamiento y test, y el dilema sesgo-varianza.

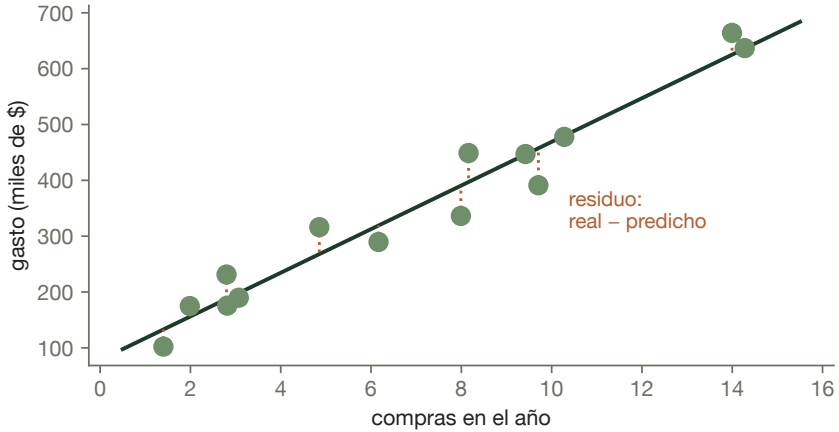
Hoy repasamos en detalle dos de esos temas:

- **El MSE:** la función de error que el entrenamiento minimiza.
- **KNN:** un método simple que permite fijar los conceptos de clasificación y predicción.

El residuo

El modelo predice el gasto de un cliente a partir de sus compras. Para cada cliente hay un valor **real** y un valor **predicho** (el punto sobre la recta).

Residuo = real − predicho. Es la distancia vertical de cada punto a la recta: cuánto le erró el modelo a ese cliente.



Por qué no se promedian los residuos con signo

Un modelo le erra $+10$ a un cliente y -10 a otro. El promedio de los residuos da **cero**, aunque el modelo erró en los dos casos: los signos se cancelan y esconden el error.

Las dos salidas clásicas:

MAE

Promedio de los errores **en valor absoluto**. Se lee directo: "le erramos $17 mil en promedio".

MSE

Promedio de los errores **al cuadrado**. El cuadrado elimina el signo y castiga más que proporcionalmente a los errores grandes.

El MSE con cuatro clientes

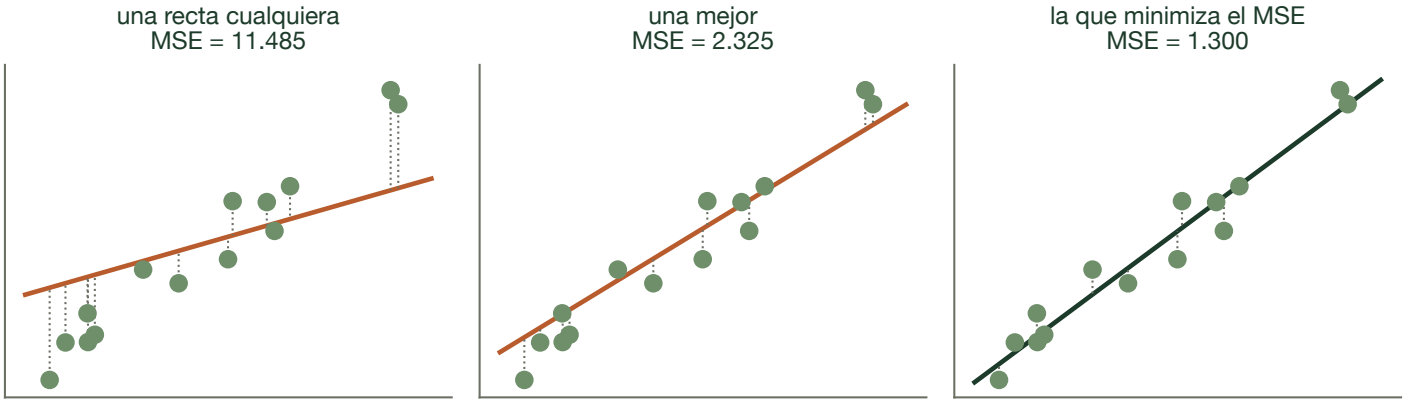
Cliente	Gasto real	Predicho	Error	|Error|	Error²
1	120	100	+20	20	400
2	200	210	−10	10	100
3	150	130	+20	20	400
4	90	110	−20	20	400

Promedio de errores con signo: 10 / 4 = 2,5 (engañoso). **MAE** = 70 / 4 = **17,5**. **MSE** = 1.300 / 4 = **325**.

El MSE no está en miles de pesos: está en "miles de pesos al cuadrado". Para volver a unidades reales se toma la raíz: **RMSE = √325 ≈ 18**.

Entrenar = buscar la recta con menor MSE

Cada recta posible tiene su MSE. Entrenar el modelo es recorrer candidatas hasta encontrar la que lo minimiza:

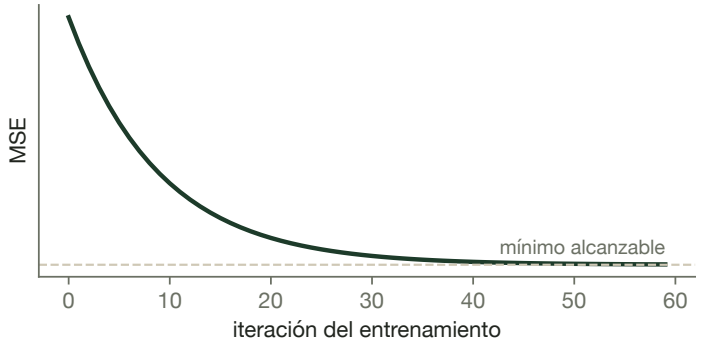


Las líneas punteadas son los residuos: la recta óptima los minimiza **en conjunto**.

El MSE durante el entrenamiento

El descenso por gradiente que vieron en la teórica es exactamente esto: en cada iteración mueve un poco la recta en la dirección que **más baja el MSE**.

La curva aplana cuando llega al mínimo: mover la recta en cualquier dirección ya no mejora nada.



El cuadrado castiga al error grande

Modelo	Errores	MAE	MSE
A: dos errores medianos	5 y 5	5	25
B: un acierto y un error grande	0 y 10	5	**50**

Mismo error total, mismo MAE. Pero para el MSE el modelo B es el doble de malo: un error de 10 pesa como cuatro errores de 5.

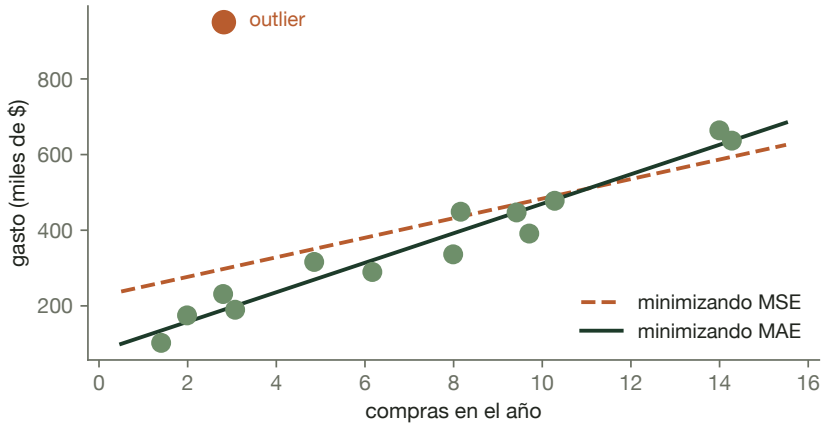
Elegir MSE implica **priorizar muchos errores chicos por sobre un error grande**. Según el problema, ese criterio puede ser el adecuado o no.

El efecto de un outlier sobre el MSE

Un solo cliente atípico, elevado al cuadrado, domina la suma. La recta que minimiza MSE se corre hacia él y empeora para todos los demás.

La recta que minimiza MAE se desplaza mucho menos.

Por esto el profiling de la clase pasada viene **antes** de modelar: los valores atípicos se detectan y se tratan antes de entrenar.



KNN: la idea del método

Para predecir algo de un caso nuevo, KNN busca **los k casos conocidos más parecidos y usa la respuesta de ellos**.

- No hay ecuación, no hay entrenamiento, no hay recta: el "modelo" es el dataset guardado.
- "Parecido" = cercano. La distancia se mide con las variables disponibles (compras, gasto, antigüedad...).
- **k** es cuántos vecinos se consultan. Es la única decisión importante del método.

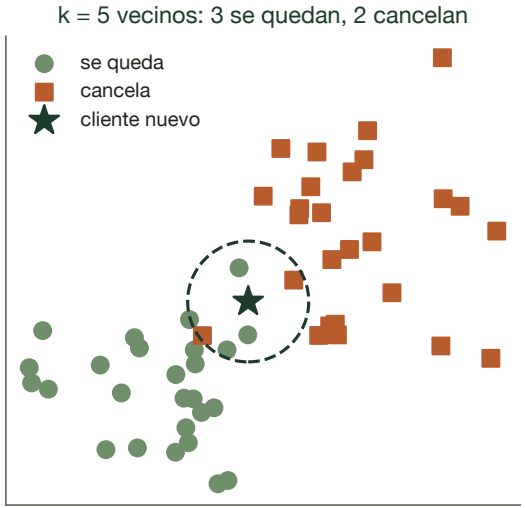
Sirve para las dos tareas que vieron: **clasificar** (los vecinos votan) y **predecir** (los vecinos se promedian).

KNN para clasificar: los vecinos votan

¿Este cliente nuevo va a cancelar la suscripción? Se buscan los 5 clientes históricos más parecidos y se mira qué hicieron.

De los 5 vecinos, 3 se quedaron y 2 cancelaron: el modelo predice **se queda**, por 3 votos contra 2.

La proporción de vecinos que cancelan (2 de 5) sirve además como probabilidad estimada de cancelación: 40%.

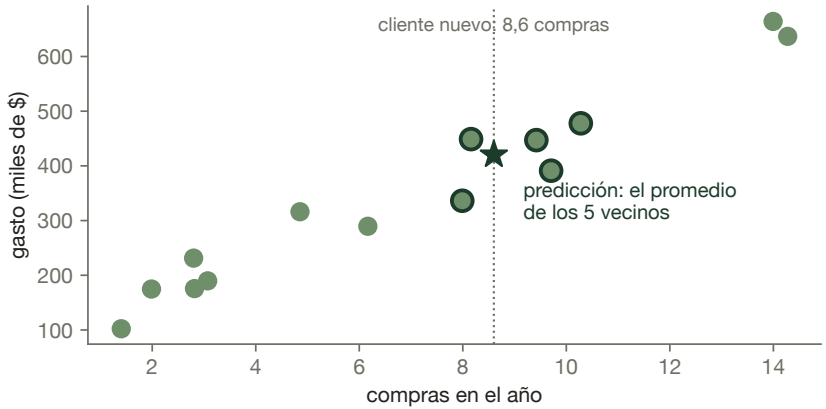


KNN para predecir: los vecinos se promedian

¿Cuánto va a gastar un cliente que hace 8,6 compras al año? Se buscan los 5 clientes con cantidad de compras más parecida y se promedia su gasto.

La predicción es **el promedio de los k vecinos**. No hay recta ni parámetros: sale directamente de los datos.

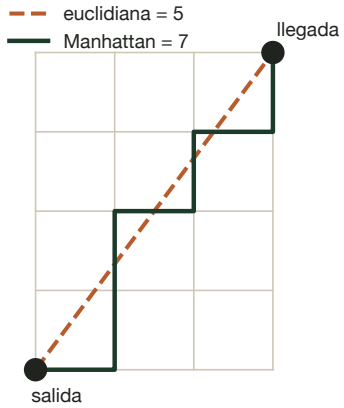
A esta predicción también se le puede calcular el MSE en test y compararla contra la regresión lineal, como hicieron con el notebook de churn.



Cómo se mide "parecido": métricas de distancia

Euclidiana: la línea recta entre dos puntos. Raíz de la suma de las diferencias al cuadrado en cada variable. Es la que usamos hasta acá.

Manhattan: la suma de las diferencias absolutas. Es la distancia de moverse por una ciudad en cuadrícula: tres cuadras en una dirección y cuatro en la otra son 7 cuadras caminadas, aunque en línea recta haya 5.



Minkowski: la generalización

Las dos anteriores son casos particulares de la distancia de Minkowski, que depende de un parámetro p:

p	Distancia	Qué hace
1	Manhattan	suma las diferencias absolutas
2	Euclidiana	la línea recta
$\to \infty$	Chebyshev	solo cuenta la diferencia máxima entre todas las variables

Dos clientes que difieren en 4, 1, 2 y 2 en sus cuatro variables: Manhattan $= 9 \cdot$ Euclidiana $= \sqrt{(16+1+4+4)} = 5 \cdot$ Chebyshev $= 4$.

A mayor p, más pesan las diferencias grandes, igual que el cuadrado en el MSE.

Hamming: distancia para categóricas

Con variables categóricas no hay resta posible. La distancia de Hamming cuenta **en cuántos atributos difieren** dos casos: cada atributo distinto suma 1.

	Plan	Barrio	Medio de pago	Envío
Cliente A	Plus	Palermo	QR	domicilio
Cliente B	Plus	Caballito	tarjeta	sucursal
¿Difieren?	0	1	1	1

Distancia de Hamming = 0 + 1 + 1 + 1 = **3**.

Guía rápida: solo numéricas → euclidiana, estandarizando antes · escalas muy dispares u outliers → Manhattan · solo categóricas → Hamming · mixtas → codificar las categóricas y combinar.

KNN depende de la distancia, y la distancia depende de la escala

Vecinos según ingreso mensual (en $) y edad (en años), sin tocar nada:

Cliente	Ingreso	Edad	Distancia al cliente nuevo (ingreso $900.000, 30 años)
A	905.000	65 años	$\sqrt{(5.000^2 + 35^2)} \approx$ **5.000** → "el más parecido"
B	950.000	31 años	$\sqrt{(50.000^2 + 1^2)} \approx$ **50.000**

La edad quedó aplastada: 35 años de diferencia pesan menos que $5.000 de ingreso. La distancia la definió una sola variable, la de mayor magnitud.

Por eso antes de KNN **se estandariza** (la transformación que vieron en la teórica): todas las variables pasan a la misma escala y ninguna domina la distancia por su magnitud.

Pesos por distancia

En la versión básica de KNN los k vecinos valen lo mismo. En la versión ponderada, cada vecino pesa **1/distancia**: los más cercanos influyen más en el voto o en el promedio.

Tres vecinos con gastos 400, 410 y 700, a distancias 1, 2 y 10 del cliente nuevo:

Promedio	Cuenta	Resultado
Simple	(400 + 410 + 700) / 3	503
Ponderado por 1/d	(400·1 + 410·0,5 + 700·0,1) / (1 + 0,5 + 0,1)	**422**

El vecino lejano deja de arrastrar la predicción. Conviene cuando los k vecinos quedan a distancias muy distintas entre sí.

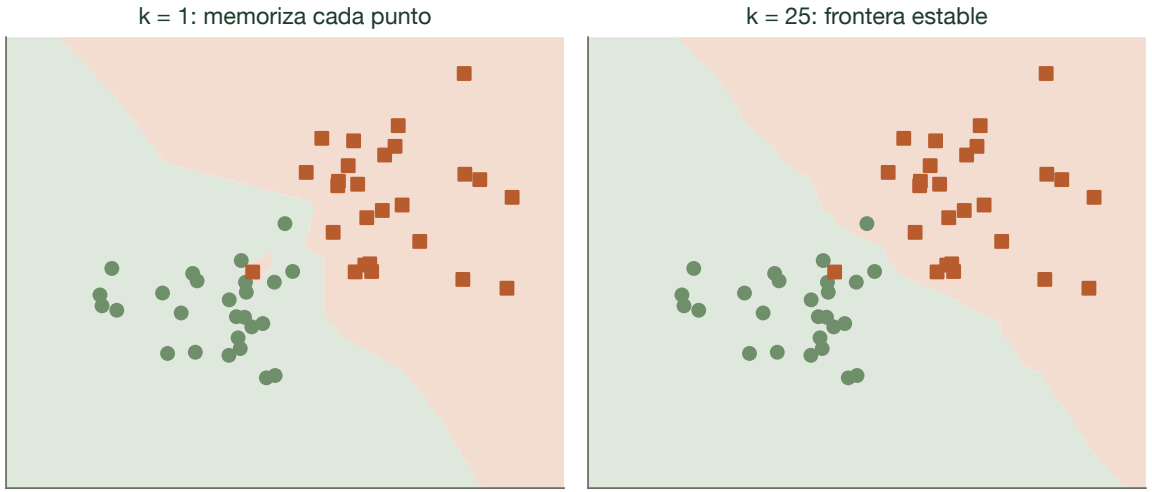
Cómo se mide el error de un KNN

KNN no minimiza ninguna función durante un entrenamiento: guarda los datos y predice. Pero se evalúa igual que cualquier otro modelo: **prediciendo sobre test y midiendo cuánto le erra**.

- **KNN de regresión:** con las métricas de la primera parte de la clase: MSE, MAE o RMSE sobre los casos de test. Son los mismos números que permiten compararlo contra la regresión lineal.
- **KNN de clasificación:** con la proporción de aciertos en test, la accuracy que vieron en la teórica. En las próximas clases van a ver que la accuracy sola no siempre alcanza, y qué otras métricas la complementan.

La regla es general: **el modelo se evalúa en datos que no vio, con la métrica que corresponde a su tarea.**

El efecto de k



Con k = 1 la frontera persigue cada punto, incluidos los raros: **overfitting**, el extremo "varianza" del dilema que vieron. Con k demasiado grande el modelo se vuelve rígido: el extremo "sesgo".

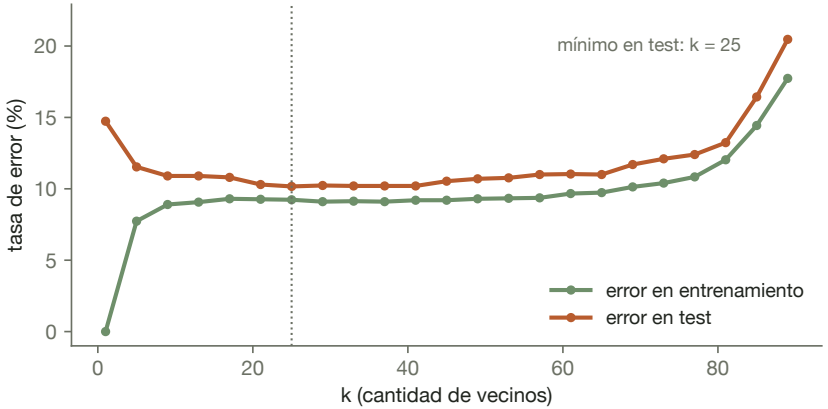
¿Y entonces qué k uso?

- **Se prueba.** Se entrena con varios k y se compara el error en datos que el modelo no vio (test o validación). El k ganador es el que mejor predice ahí, no en entrenamiento.
- En entrenamiento, $k = 1$ es imbatible por definición: cada punto es su propio vecino y el error da cero. Por eso evaluar en entrenamiento no sirve: **el modelo que memoriza obtiene siempre el mejor resultado ahí**.
- Para clasificar conviene k impar: no hay empates en la votación.
- Valores típicos: entre 3 y 20 para datasets chicos; depende de los datos y se determina probando.

El error según k, en entrenamiento y en test

Con los datos de los gráficos anteriores, divididos en entrenamiento y test: el error de entrenamiento arranca en cero con k = 1 y crece con k. El de test baja primero y sube después: **el mínimo está en un k intermedio**.

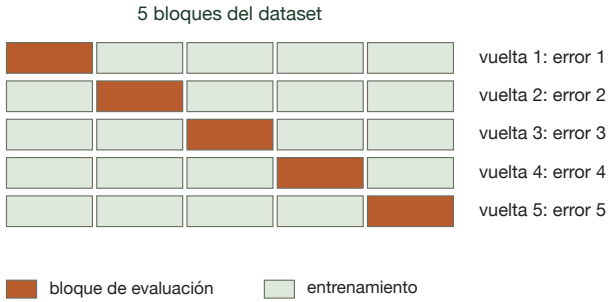
Es el dilema sesgo-varianza medido: k chico, varianza; k grande, sesgo. El k que se elige es el del mínimo en test.



Validación cruzada

Un solo split puede engañar: si el test que tocó es fácil, el error se subestima; si es difícil, se sobreestima.

K-fold: se parte el dataset en 5 bloques y se entrena 5 veces, dejando un bloque distinto para evaluar en cada vuelta. El error estimado es **el promedio de los 5**.

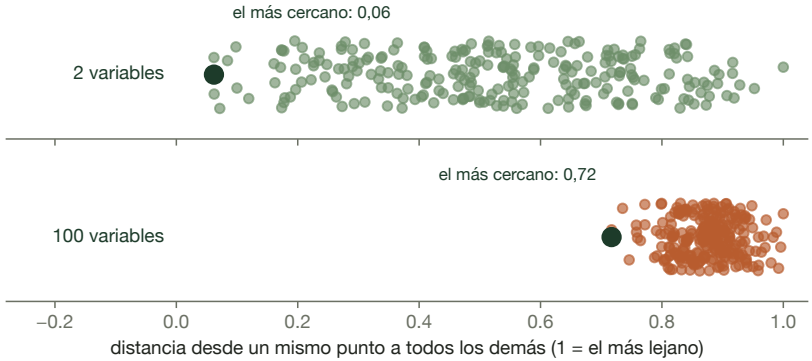


Curse of dimensionality

Un punto de referencia, y la distancia desde él a otros 250 puntos al azar. Cada punto del gráfico es una de esas distancias.

Con 2 variables, el más cercano está al 6% de la distancia del más lejano: hay vecinos de verdad. Con 100 variables, el más cercano ya está al 72%: **todos los puntos quedan casi igual de lejos**, y elegir "los k más cercanos" pierde sentido.

Las salidas: seleccionar variables o reducir dimensiones (PCA).



KNN en perspectiva

Lo bueno

Simple de entender y explicar. No asume ninguna forma (sirve donde la recta no llega). Un solo hiperparámetro. Clasifica y predice con la misma idea.

Los límites

Predecir es caro: calcula distancias contra todo el dataset cada vez. Exige estandarizar. Y con muchas variables la noción de "vecino cercano" se degrada: todos quedan lejos de todos.

KNN se usa con frecuencia como línea de base: un modelo más complejo debería superarlo en la misma métrica sobre test para justificar su complejidad.

ANALÍTICA DE DATOS

Hasta acá llegamos

MSE y KNN · clase práctica 4

Universidad de SanAndrés