ANALÍTICA DE DATOS

CART

Classification and Regression Trees · árboles de decisión e índice de Gini

Clase práctica 5 · 2do cuatrimestre 2026

Universidad de SanAndrés

Qué es CART

CART (Classification and Regression Trees) es un método de aprendizaje automático para clasificación y regresión. Divide el conjunto de datos en grupos cada vez más homogéneos respecto de la variable objetivo, mediante preguntas binarias sobre las variables predictoras.

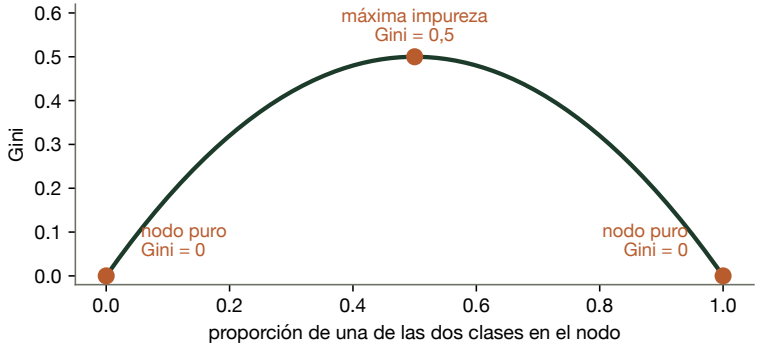
El resultado es un árbol de decisión: en cada nodo interno, una condición sobre una variable; en cada hoja, una predicción. La pregunta central es **por cuál variable y en qué punto conviene partir**, y para responderla se usa el índice de Gini.

Índice de Gini

Mide la impureza de un nodo: la probabilidad de clasificar mal si se asignara la clase al azar según las proporciones del nodo.

$$\text{Gini} = 1 - \Sigma_k \, p_k^2$$

Gini = 0: nodo puro. **Gini = 0,5:** máxima impureza en dos clases.



Algoritmo greedy

Para una variable **categórica**, se evalúa cada categoría contra el resto. Para una **continua**, se ordenan los valores y se prueban como cortes los promedios entre valores consecutivos.

Para cada corte se calcula el **Gini ponderado** de los dos nodos, pesando por su cantidad de instancias, y se elige el de menor Gini.

El algoritmo es **greedy**: toma la mejor partición local en cada paso, sin anticipar el efecto sobre las siguientes. Puede dar soluciones subóptimas, pero es tratable computacionalmente.

Ejercicio 1 · datos

Edad	Ingreso	Historial	Deuda	Aprobado
25	3,5	Bueno	10	Sí
40	5,0	Malo	20	No
30	4,2	Bueno	30	Sí
22	2,8	Malo	40	No
35	6,1	Bueno	15	Sí

Variable objetivo: **Aprobado**. Predictoras: Edad, Ingreso, Historial, Deuda.

Ejercicio 1 · partición por la variable objetivo

Calculamos el Gini del nodo raíz para tener un punto de partida. Sobre 5 instancias: 3 aprobados (Sí), 2 no aprobados (No).

$$\text{Gini}_{\text{Aprobado}} = 1 - \left[\frac{3}{5}^2 + \frac{2}{5}^2\right] = \mathbf{0{,}48}$$

A partir de este valor, buscamos la partición que más lo reduzca.

Ejercicio 1 · partición por Edad · ordenamiento

Edad	Aprobado
22	No
25	Sí
30	Sí
35	Sí
40	No

Para una variable continua, calculamos el Gini en cada punto de corte intermedio.

Ejercicio 1 · Edad · corte 23,5

- **Edad ≤ 23,5**: 1 instancia (0 sí, 1 no)
- **Edad > 23,5**: 4 instancias (3 sí, 1 no)

$$\text{Gini}_{\leq 23{,}5} = 1 - \left[\left(\frac{0}{1}\right)^2 + \left(\frac{1}{1}\right)^2\right] = \mathbf{0}$$

$$\text{Gini}_{> 23{,}5} = 1 - \left[\left(\frac{3}{4}\right)^2 + \left(\frac{1}{4}\right)^2\right] = \mathbf{0{,}375}$$

$$\text{Gini}_{\text{Edad, } 23{,}5} = \frac{1}{5}\cdot 0 + \frac{4}{5}\cdot 0{,}375 = \mathbf{0{,}3}$$

Ejercicio 1 · Edad · corte 27,5

- **Edad ≤ 27,5**: 2 instancias (1 sí, 1 no)
- **Edad > 27,5**: 3 instancias (2 sí, 1 no)

$$\text{Gini}_{\leq 27,5} = 1 - \left[\left(\frac{1}{2}\right)^2 + \left(\frac{1}{2}\right)^2\right] = \mathbf{0,5}$$

$$\text{Gini}_{>27,5} = 1 - \left[\left(\frac{2}{3}\right)^2 + \left(\frac{1}{3}\right)^2\right] = \mathbf{0,444}$$

$$\text{Gini}_{\text{Edad, } 27,5} = \frac{2}{5}\cdot 0,5 + \frac{3}{5}\cdot 0,444 = \mathbf{0,467}$$

Ejercicio 1 · Edad · corte 32,5

- **Edad ≤ 32,5**: 3 instancias (2 sí, 1 no)
- **Edad > 32,5**: 2 instancias (1 sí, 1 no)

$$\text{Gini}_{\leq 32,5} = 1 - \left[\frac{2}{3}^2 + \frac{1}{3}^2\right] = \mathbf{0,444}$$

$$\text{Gini}_{>32,5} = 1 - \left[\frac{1}{2}^2 + \frac{1}{2}^2\right] = \mathbf{0,5}$$

$$\text{Gini}_{\text{Edad, } 32,5} = \frac{3}{5}\cdot 0,444 + \frac{2}{5}\cdot 0,5 = \mathbf{0,467}$$

Ejercicio 1 · Edad · corte 37,5

- **Edad ≤ 37,5**: 4 instancias (3 sí, 1 no)
- **Edad > 37,5**: 1 instancia (0 sí, 1 no)

$$\text{Gini}_{\leq 37,5} = 1 - \left[\left(\frac{3}{4}\right)^2 + \left(\frac{1}{4}\right)^2\right] = \mathbf{0,375}$$

$$\text{Gini}_{>37,5} = 1 - \left[\left(\frac{0}{1}\right)^2 + \left(\frac{1}{1}\right)^2\right] = \mathbf{0}$$

$$\text{Gini}_{\text{Edad, } 37,5} = \frac{4}{5}\cdot 0,375 + \frac{1}{5}\cdot 0 = \mathbf{0,3}$$

Ejercicio 1 · Edad · resumen

Los cuatro cortes de Edad:

Corte	Gini ponderado
23,5	**0,300**
27,5	0,467
32,5	0,467
37,5	**0,300**

El mejor corte por Edad da 0,300, mejorando el 0,48 del nodo raíz.

Ejercicio 1 · partición por Historial

Historial es categórica con dos valores. Calculamos el Gini de cada nodo:

- **Historial = Bueno**: 3 instancias (3 sí, 0 no)
- **Historial = Malo**: 2 instancias (0 sí, 2 no)

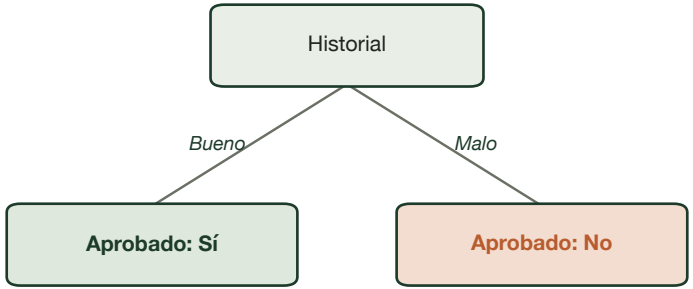
$$\text{Gini}_{\text{Bueno}} = 1 - \left[\frac{3}{3}^2 + \frac{0}{3}^2\right] = \mathbf{0}$$

$$\text{Gini}_{\text{Malo}} = 1 - \left[\frac{0}{2}^2 + \frac{2}{2}^2\right] = \mathbf{0}$$

$$\text{Gini}_{\text{Historial}} = \frac{3}{5}\cdot 0 + \frac{2}{5}\cdot 0 = \mathbf{0}$$

Gini = 0: Historial separa perfectamente los datos. Ambos nodos son puros y el árbol se cierra en un paso.

Ejercicio 1 · árbol resultante



Con Historial alcanza: un solo nodo produce dos hojas puras.

Una división perfecta en un paso casi nunca ocurre en datos reales; aquí fija el procedimiento. CART garantiza el árbol de menor cantidad de nodos si se evaluaron todos los cortes.

Ejercicio 2 · datos

Depto.	Antig.	Cumpl.	Bono
Ventas	2	80	No
Soporte	5	60	No
Logística	3	75	Sí
Ventas	1	50	No
Soporte	4	85	Sí
Logística	6	70	No

Variable objetivo: **Recibe Bono**. Predictoras: Departamento (categórica), Antigüedad y Cumplimiento de Objetivos (continuas).

Ejercicio 2 · partición por la variable objetivo

Nodo raíz: sobre 6 instancias, 2 reciben bono (Sí) y 4 no (No).

$$\text{Gini}_{\text{Bono}} = 1 - \left[\frac{2}{6}^2 + \frac{4}{6}^2\right] = \mathbf{0{,}444}$$

Ejercicio 2 · Departamento · Ventas vs resto

- **Ventas**: 2 observaciones (0 sí, 2 no)
- **Resto**: 4 observaciones (2 sí, 2 no)

$$\text{Gini}_{\text{Ventas}} = 1 - \left[\frac{0}{2}^2 + \frac{2}{2}^2\right] = \mathbf{0}$$

$$\text{Gini}_{\text{resto}} = 1 - \left[\frac{2}{4}^2 + \frac{2}{4}^2\right] = \mathbf{0{,}5}$$

$$\text{Gini}_{\text{Departamento, Ventas}} = \frac{2}{6}\cdot 0 + \frac{4}{6}\cdot 0{,}5 = \mathbf{0{,}333}$$

Ejercicio 2 · Departamento · Soporte vs resto

- **Soporte**: 2 observaciones (1 sí, 1 no)
- **Resto**: 4 observaciones (1 sí, 3 no)

$$\text{Gini}_{\text{Soporte}} = 1 - \left[\left(\frac{1}{2}\right)^2 + \left(\frac{1}{2}\right)^2\right] = \mathbf{0{,}5}$$

$$\text{Gini}_{\text{resto}} = 1 - \left[\left(\frac{1}{4}\right)^2 + \left(\frac{3}{4}\right)^2\right] = \mathbf{0{,}375}$$

$$\text{Gini}_{\text{Departamento, Soporte}} = \frac{2}{6}\cdot 0{,}5 + \frac{4}{6}\cdot 0{,}375 = \mathbf{0{,}417}$$

Ejercicio 2 · Departamento · Logística vs resto

- **Logística**: 2 observaciones (1 sí, 1 no)
- **Resto**: 4 observaciones (1 sí, 3 no)

$$\text{Gini}_{\text{Logística}} = 1 - \left[\left(\frac{1}{2}\right)^2 + \left(\frac{1}{2}\right)^2\right] = \mathbf{0{,}5}$$

$$\text{Gini}_{\text{resto}} = 1 - \left[\left(\frac{1}{4}\right)^2 + \left(\frac{3}{4}\right)^2\right] = \mathbf{0{,}375}$$

$$\text{Gini}_{\text{Departamento, Logística}} = \frac{2}{6}\cdot 0{,}5 + \frac{4}{6}\cdot 0{,}375 = \mathbf{0{,}417}$$

Ejercicio 2 · Cumplimiento · ordenamiento

Cumplimiento	Bono
50	No
60	No
70	No
75	Sí
80	No
85	Sí

Cortes a probar: 55, 65, 72,5, 77,5 y 82,5.

Ejercicio 2 · Cumplimiento · corte 55

- **Cumplimiento ≤ 55**: 1 instancia (0 sí, 1 no)
- **Cumplimiento > 55**: 5 instancias (2 sí, 3 no)

$$\text{Gini}_{\leq 55} = 1 - \left[\left(\frac{0}{1}\right)^2 + \left(\frac{1}{1}\right)^2\right] = \mathbf{0}$$

$$\text{Gini}_{>55} = 1 - \left[\left(\frac{2}{5}\right)^2 + \left(\frac{3}{5}\right)^2\right] = \mathbf{0{,}48}$$

$$\text{Gini}_{\text{Cumplimiento, 55}} = \frac{1}{6}\cdot 0 + \frac{5}{6}\cdot 0{,}48 = \mathbf{0{,}4}$$

Ejercicio 2 · Cumplimiento · corte 65

- **Cumplimiento ≤ 65**: 2 instancias (0 sí, 2 no)
- **Cumplimiento > 65**: 4 instancias (2 sí, 2 no)

$$\text{Gini}_{\leq 65} = 1 - \left[\left(\frac{0}{2}\right)^2 + \left(\frac{2}{2}\right)^2\right] = \mathbf{0}$$

$$\text{Gini}_{>65} = 1 - \left[\left(\frac{2}{4}\right)^2 + \left(\frac{2}{4}\right)^2\right] = \mathbf{0{,}5}$$

$$\text{Gini}_{\text{Cumplimiento, 65}} = \frac{2}{6}\cdot 0 + \frac{4}{6}\cdot 0{,}5 = \mathbf{0{,}333}$$

Ejercicio 2 · Cumplimiento · corte 72,5

- **Cumplimiento ≤ 72,5**: 3 instancias (0 sí, 3 no)
- **Cumplimiento > 72,5**: 3 instancias (2 sí, 1 no)

$$\text{Gini}_{\leq 72,5} = 1 - \left[\frac{0}{3}^2 + \frac{3}{3}^2\right] = \mathbf{0}$$

$$\text{Gini}_{>72,5} = 1 - \left[\frac{2}{3}^2 + \frac{1}{3}^2\right] = \mathbf{0,444}$$

$$\text{Gini}_{\text{Cumplimiento, } 72,5} = \frac{3}{6}\cdot 0 + \frac{3}{6}\cdot 0,444 = \mathbf{0,222}$$

Ejercicio 2 · Cumplimiento · corte 77,5

- **Cumplimiento ≤ 77,5**: 4 instancias (1 sí, 3 no)
- **Cumplimiento > 77,5**: 2 instancias (1 sí, 1 no)

$$\text{Gini}_{\leq 77{,}5} = 1 - \left[\left(\frac{1}{4}\right)^2 + \left(\frac{3}{4}\right)^2\right] = \mathbf{0{,}375}$$

$$\text{Gini}_{> 77{,}5} = 1 - \left[\left(\frac{1}{2}\right)^2 + \left(\frac{1}{2}\right)^2\right] = \mathbf{0{,}5}$$

$$\text{Gini}_{\text{Cumplimiento, } 77{,}5} = \frac{4}{6}\cdot 0{,}375 + \frac{2}{6}\cdot 0{,}5 = \mathbf{0{,}417}$$

Ejercicio 2 · Cumplimiento · corte 82,5

- **Cumplimiento ≤ 82,5**: 5 instancias (1 sí, 4 no)
- **Cumplimiento > 82,5**: 1 instancia (1 sí, 0 no)

$$\text{Gini}_{\leq 82{,}5} = 1 - \left[\left(\frac{1}{5}\right)^2 + \left(\frac{4}{5}\right)^2\right] = \mathbf{0{,}32}$$

$$\text{Gini}_{> 82{,}5} = 1 - \left[\left(\frac{1}{1}\right)^2 + \left(\frac{0}{1}\right)^2\right] = \mathbf{0}$$

$$\text{Gini}_{\text{Cumplimiento, } 82{,}5} = \frac{5}{6}\cdot 0{,}32 + \frac{1}{6}\cdot 0 = \mathbf{0{,}267}$$

Ejercicio 2 · Antigüedad · ordenamiento

Antigüedad	Bono
1	No
2	No
3	Sí
4	Sí
5	No
6	No

Cortes a probar: 1,5, 2,5, 3,5, 4,5 y 5,5.

Ejercicio 2 · Antigüedad · corte 1,5

- **Antigüedad ≤ 1,5**: 1 instancia (0 sí, 1 no)
- **Antigüedad > 1,5**: 5 instancias (2 sí, 3 no)

$$\text{Gini}_{\leq 1,5} = 1 - \left[\left(\frac{0}{1}\right)^2 + \left(\frac{1}{1}\right)^2\right] = \mathbf{0}$$

$$\text{Gini}_{>1,5} = 1 - \left[\left(\frac{2}{5}\right)^2 + \left(\frac{3}{5}\right)^2\right] = \mathbf{0,48}$$

$$\text{Gini}_{\text{Antigüedad, 1,5}} = \frac{1}{6}\cdot 0 + \frac{5}{6}\cdot 0,48 = \mathbf{0,4}$$

Ejercicio 2 · Antigüedad · corte 2,5

- **Antigüedad ≤ 2,5**: 2 instancias (0 sí, 2 no)
- **Antigüedad > 2,5**: 4 instancias (2 sí, 2 no)

$$\text{Gini}_{\leq 2,5} = 1 - \left[\left(\frac{0}{2}\right)^2 + \left(\frac{2}{2}\right)^2\right] = \mathbf{0}$$

$$\text{Gini}_{>2,5} = 1 - \left[\left(\frac{2}{4}\right)^2 + \left(\frac{2}{4}\right)^2\right] = \mathbf{0,5}$$

$$\text{Gini}_{\text{Antigüedad, 2,5}} = \frac{2}{6}\cdot 0 + \frac{4}{6}\cdot 0,5 = \mathbf{0,333}$$

Ejercicio 2 · Antigüedad · corte 3,5

- **Antigüedad ≤ 3,5**: 3 instancias (2 sí, 1 no)
- **Antigüedad > 3,5**: 3 instancias (0 sí, 3 no)

$$\text{Gini}_{\leq 3,5} = 1 - \left[\left(\frac{2}{3}\right)^2 + \left(\frac{1}{3}\right)^2\right] = \mathbf{0,444}$$

$$\text{Gini}_{>3,5} = 1 - \left[\left(\frac{0}{3}\right)^2 + \left(\frac{3}{3}\right)^2\right] = \mathbf{0}$$

$$\text{Gini}_{\text{Antigüedad, 3,5}} = \frac{3}{6}\cdot 0,444 + \frac{3}{6}\cdot 0 = \mathbf{0,222}$$

Ejercicio 2 · Antigüedad · corte 4,5

- **Antigüedad ≤ 4,5**: 4 instancias (2 sí, 2 no)
- **Antigüedad > 4,5**: 2 instancias (0 sí, 2 no)

$$\text{Gini}_{\leq 4,5} = 1 - \left[\left(\frac{2}{4}\right)^2 + \left(\frac{2}{4}\right)^2\right] = \mathbf{0,5}$$

$$\text{Gini}_{>4,5} = 1 - \left[\left(\frac{0}{2}\right)^2 + \left(\frac{2}{2}\right)^2\right] = \mathbf{0}$$

$$\text{Gini}_{\text{Antigüedad, 4,5}} = \frac{4}{6}\cdot 0,5 + \frac{2}{6}\cdot 0 = \mathbf{0,333}$$

Ejercicio 2 · Antigüedad · corte 5,5

- **Antigüedad ≤ 5,5**: 5 instancias (2 sí, 3 no)
- **Antigüedad > 5,5**: 1 instancia (0 sí, 1 no)

$$\text{Gini}_{\leq 5,5} = 1 - \left[\frac{2}{5}^2 + \frac{3}{5}^2\right] = \mathbf{0,48}$$

$$\text{Gini}_{>5,5} = 1 - \left[\frac{0}{1}^2 + \frac{1}{1}^2\right] = \mathbf{0}$$

$$\text{Gini}_{\text{Antigüedad, 5,5}} = \frac{5}{6}\cdot 0,48 + \frac{1}{6}\cdot 0 = \mathbf{0,4}$$

Ejercicio 2 · tabla de Ginis

Ordenamos todos los Gini calculados:

Variable	Partición	Gini
Cumplimiento de Objetivos	72,5	**0,222**
Antigüedad	3,5	**0,222**
Departamento	Ventas vs resto	0,333
Antigüedad	2,5	0,333
Antigüedad	4,5	0,333
Cumplimiento de Objetivos	65	0,333
… el resto, con Gini entre 0,4 y 0,417		

Gana **Cumplimiento ≤ 72,5** (empatada con Antigüedad 3,5; el desempate es arbitrario).

Ejercicio 2 · segunda iteración · datos restantes

El nodo Cumplimiento ≤ 72,5 quedó puro (3 No). Seguimos con las 3 instancias de Cumplimiento > 72,5. **Recalculamos los Gini solo con estos datos**: usar los anteriores sería usar información que ya no aplica.

Depto.	Antig.	Cumpl.	Bono
Ventas	2	80	No
Logística	3	75	Sí
Soporte	4	85	Sí

Ejercicio 2 · 2da iteración · Departamento · Ventas vs resto

- **Ventas**: 1 observacion (0 sí, 1 no)
- **Resto**: 2 observaciones (2 sí, 0 no)

$$\text{Gini}_{\text{Ventas}} = 1 - \left[\frac{0}{1}^2 + \frac{1}{1}^2\right] = \mathbf{0}$$

$$\text{Gini}_{\text{resto}} = 1 - \left[\frac{2}{2}^2 + \frac{0}{2}^2\right] = \mathbf{0}$$

$$\text{Gini}_{\text{Departamento, Ventas}} = \frac{1}{3}\cdot 0 + \frac{2}{3}\cdot 0 = \mathbf{0}$$

Ejercicio 2 · 2da iteración · Departamento · Soporte vs resto

- **Soporte**: 1 observacion (1 sí, 0 no)
- **Resto**: 2 observaciones (1 sí, 1 no)

$$\text{Gini}_{\text{Soporte}} = 1 - \left[\frac{1}{1}^2 + \frac{0}{1}^2\right] = \mathbf{0}$$

$$\text{Gini}_{\text{resto}} = 1 - \left[\frac{1}{2}^2 + \frac{1}{2}^2\right] = \mathbf{0{,}5}$$

$$\text{Gini}_{\text{Departamento, Soporte}} = \frac{1}{3}\cdot 0 + \frac{2}{3}\cdot 0{,}5 = \mathbf{0{,}333}$$

Ejercicio 2 · 2da iteración · Departamento · Logística vs resto

- **Logística**: 1 observacion (1 sí, 0 no)
- **Resto**: 2 observaciones (1 sí, 1 no)

$$\text{Gini}_{\text{Logística}} = 1 - \left[\frac{1}{1}^2 + \frac{0}{1}^2\right] = \mathbf{0}$$

$$\text{Gini}_{\text{resto}} = 1 - \left[\frac{1}{2}^2 + \frac{1}{2}^2\right] = \mathbf{0{,}5}$$

$$\text{Gini}_{\text{Departamento, Logística}} = \frac{1}{3}\cdot 0 + \frac{2}{3}\cdot 0{,}5 = \mathbf{0{,}333}$$

Ejercicio 2 · 2da iteración · Antigüedad · corte 2,5

- **Antigüedad ≤ 2,5**: 1 instancia (0 sí, 1 no)
- **Antigüedad > 2,5**: 2 instancias (2 sí, 0 no)

$$\text{Gini}_{\leq 2,5} = 1 - \left[\left(\frac{0}{1}\right)^2 + \left(\frac{1}{1}\right)^2\right] = \mathbf{0}$$

$$\text{Gini}_{>2,5} = 1 - \left[\left(\frac{2}{2}\right)^2 + \left(\frac{0}{2}\right)^2\right] = \mathbf{0}$$

$$\text{Gini}_{\text{Antigüedad, 2,5}} = \frac{1}{3}\cdot 0 + \frac{2}{3}\cdot 0 = \mathbf{0}$$

Ejercicio 2 · 2da iteración · Antigüedad · corte 3,5

- **Antigüedad ≤ 3,5**: 2 instancias (1 sí, 1 no)
- **Antigüedad > 3,5**: 1 instancia (1 sí, 0 no)

$$\text{Gini}_{\leq 3,5} = 1 - \left[\left(\frac{1}{2}\right)^2 + \left(\frac{1}{2}\right)^2\right] = \mathbf{0,5}$$

$$\text{Gini}_{>3,5} = 1 - \left[\left(\frac{1}{1}\right)^2 + \left(\frac{0}{1}\right)^2\right] = \mathbf{0}$$

$$\text{Gini}_{\text{Antigüedad, 3,5}} = \frac{2}{3}\cdot 0,5 + \frac{1}{3}\cdot 0 = \mathbf{0,333}$$

Ejercicio 2 · 2da iteración · Cumplimiento · corte 77,5

- **Cumplimiento ≤ 77,5**: 1 instancia (1 sí, 0 no)
- **Cumplimiento > 77,5**: 2 instancias (1 sí, 1 no)

$$\text{Gini}_{\leq 77{,}5} = 1 - \left[\left(\frac{1}{1}\right)^2 + \left(\frac{0}{1}\right)^2\right] = \mathbf{0}$$

$$\text{Gini}_{>77{,}5} = 1 - \left[\left(\frac{1}{2}\right)^2 + \left(\frac{1}{2}\right)^2\right] = \mathbf{0{,}5}$$

$$\text{Gini}_{\text{Cumplimiento, } 77{,}5} = \frac{1}{3}\cdot 0 + \frac{2}{3}\cdot 0{,}5 = \mathbf{0{,}333}$$

Ejercicio 2 · 2da iteración · Cumplimiento · corte 82,5

- **Cumplimiento ≤ 82,5**: 2 instancias (1 sí, 1 no)
- **Cumplimiento > 82,5**: 1 instancia (1 sí, 0 no)

$$\text{Gini}_{\leq 82{,}5} = 1 - \left[\left(\frac{1}{2}\right)^2 + \left(\frac{1}{2}\right)^2\right] = \mathbf{0{,}5}$$

$$\text{Gini}_{> 82{,}5} = 1 - \left[\left(\frac{1}{1}\right)^2 + \left(\frac{0}{1}\right)^2\right] = \mathbf{0}$$

$$\text{Gini}_{\text{Cumplimiento, } 82{,}5} = \frac{2}{3}\cdot 0{,}5 + \frac{1}{3}\cdot 0 = \mathbf{0{,}333}$$

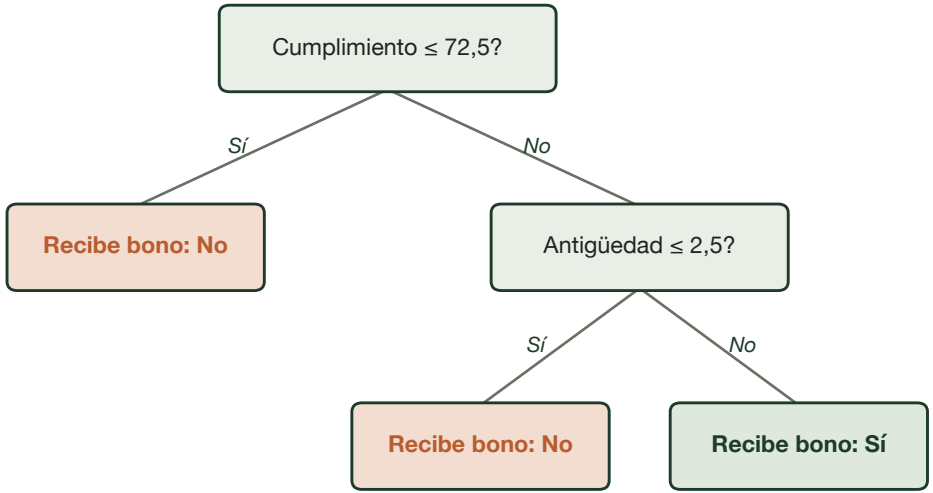
Ejercicio 2 · 2da iteración · Ginis

Ordenamos los Gini nuevos. Como hay uno en 0, el árbol se cierra:

Variable	Partición	Gini
Antigüedad	2,5	**0**
Departamento	Ventas vs resto	**0**
Cumplimiento de Objetivos	82,5	0,167
Departamento / Antigüedad / Cumplimiento	resto	0,333

Dos particiones con Gini 0 (Antigüedad $\leq$ 2,5 y Ventas vs resto): cualquiera cierra el árbol. Elegimos Antigüedad $\leq$ 2,5.

Ejercicio 2 · árbol resultante



Dos niveles de decisión clasifican correctamente las seis instancias.

Ejercicio 3 · el mismo árbol, ahora para regresión

Hasta acá la variable objetivo era una categoría (Aprobado, Bono) y medíamos la impureza con Gini. Cuando la variable objetivo es **un número**, el árbol funciona igual pero cambian dos cosas:

- El criterio de partición pasa a ser el **MSE**: se busca el corte que deja cada grupo con valores más parecidos entre sí (menor varianza interna).
- La hoja ya no predice una clase por mayoría, sino **el promedio** de los valores que caen en ella.

El MSE es el mismo de la clase anterior: el promedio de los errores al cuadrado dentro de cada grupo respecto de su media.

Ejercicio 3 · datos

m²	Antigüedad	Refaccionada	Precio
60	8	Sí	260
80	22	No	160
90	12	Sí	300
100	15	No	180
120	5	Sí	320
140	20	No	220
170	4	No	240

Predecimos el **precio** (miles de USD) a partir de tres variables: m^2 y antigüedad (continuas) y si está refaccionada (categórica).

Promedio de los 7 precios: 240. El MSE del nodo raíz es el promedio de los desvíos al cuadrado respecto de ese promedio:

$$\text{MSE}_{\text{raíz}} = [(260-240)^2 + (160-240)^2 + (300-240)^2 + (180-240)^2 + (320-240)^2 + (220-240)^2 + (240-240)^2] / 7 = \mathbf{2.971{,}4}$$

Ejercicio 3 · m² · ordenamiento

m²	Precio
60	260
80	160
90	300
100	180
120	320
140	220
170	240

Ordenada por m². El precio sube y baja: la relación con los m² no es limpia. Cortes a probar: 70, 85, 95, 110, 130 y 155.

Ejercicio 3 · m² · corte 70

- **m² ≤ 70**: precios {260} → promedio 260
- **m² > 70**: precios {160, 300, 180, 320, 220, 240} → promedio 236,667

$$\text{MSE}_{\leq 70} = 0$$

$$\text{MSE}_{>70} = [(160-236{,}667)^2 + (300-236{,}667)^2 + (180-236{,}667)^2 + (320-236{,}667)^2 + (220-236{,}667)^2 + (240-236{,}667)^2] / 6 = 3.388{,}9$$

$$\text{MSE}_{m^2,\ 70} = \frac{1}{7}\cdot 0 + \frac{6}{7}\cdot 3.388{,}9 = \mathbf{2.904{,}8}$$

Ejercicio 3 · m² · corte 85

- **m² ≤ 85**: precios {260, 160} → promedio 210
- **m² > 85**: precios {300, 180, 320, 220, 240} → promedio 252

$$\text{MSE}_{\leq 85} = [(260-210)^2 + (160-210)^2] / 2 = 2.500$$

$$\text{MSE}_{>85} = [(300-252)^2 + (180-252)^2 + (320-252)^2 + (220-252)^2 + (240-252)^2] / 5 = 2.656$$

$$\text{MSE}_{m^2,\ 85} = \frac{2}{7}\cdot 2.500 + \frac{5}{7}\cdot 2.656 = \mathbf{2.611{,}4}$$

Ejercicio 3 · m² · corte 95

- **m² ≤ 95**: precios {260, 160, 300} → promedio 240
- **m² > 95**: precios {180, 320, 220, 240} → promedio 240

$$\text{MSE}_{\leq 95} = [(260-240)^2 + (160-240)^2 + (300-240)^2] / 3 = 3.466{,}7$$

$$\text{MSE}_{>95} = [(180-240)^2 + (320-240)^2 + (220-240)^2 + (240-240)^2] / 4 = 2.600$$

$$\text{MSE}_{m^2,\ 95} = \tfrac{3}{7}\cdot 3.466{,}7 + \tfrac{4}{7}\cdot 2.600 = \mathbf{2.971{,}4}$$

Ejercicio 3 · m² · corte 110

- **m² ≤ 110**: precios {260, 160, 300, 180} → promedio 225
- **m² > 110**: precios {320, 220, 240} → promedio 260

$$\text{MSE}_{\leq 110} = [(260-225)^2 + (160-225)^2 + (300-225)^2 + (180-225)^2] / 4 = 3.275$$

$$\text{MSE}_{>110} = [(320-260)^2 + (220-260)^2 + (240-260)^2] / 3 = 1.866{,}7$$

$$\text{MSE}_{m^2,\ 110} = \tfrac{4}{7}\cdot 3.275 + \tfrac{3}{7}\cdot 1.866{,}7 = \mathbf{2.671{,}4}$$

Ejercicio 3 · m² · corte 130

- **m² ≤ 130**: precios {260, 160, 300, 180, 320} → promedio 244
- **m² > 130**: precios {220, 240} → promedio 230

$$MSE_{\leq 130} = [(260-244)^2 + (160-244)^2 + (300-244)^2 + (180-244)^2 + (320-244)^2] / 5 = 4.064$$

$$MSE_{>130} = [(220-230)^2 + (240-230)^2] / 2 = 100$$

$$MSE_{m^2,\ 130} = \frac{5}{7}\cdot 4.064 + \frac{2}{7}\cdot 100 = \mathbf{2.931{,}4}$$

Ejercicio 3 · m² · corte 155

- **m² ≤ 155**: precios {260, 160, 300, 180, 320, 220} → promedio 240
- **m² > 155**: precios {240} → promedio 240

$$MSE_{\leq 155} = [(260-240)^2 + (160-240)^2 + (300-240)^2 + (180-240)^2 + (320-240)^2 + (220-240)^2] / 6 = 3.466{,}7$$

$$MSE_{>155} = 0$$

$$MSE_{m^2,\ 155} = \frac{6}{7}\cdot 3.466{,}7 + \frac{1}{7}\cdot 0 = \mathbf{2.971{,}4}$$

Ejercicio 3 · Antigüedad · ordenamiento

Antigüedad	Precio
4	240
5	320
8	260
12	300
15	180
20	220
22	160

Cortes a probar: 4,5, 6,5, 10, 13,5, 17,5 y 21.

Ejercicio 3 · Antigüedad · corte 4,5

- **Antig. ≤ 4,5**: precios {240} → promedio 240
- **Antig. > 4,5**: precios {320, 260, 300, 180, 220, 160} → promedio 240

$$\text{MSE}_{\leq 4,5} = 0$$

$$\text{MSE}_{>4,5} = [(320-240)^2 + (260-240)^2 + (300-240)^2 + (180-240)^2 + (220-240)^2 + (160-240)^2] / 6 = 3.466,7$$

$$\text{MSE}_{\text{Antig., 4,5}} = \frac{1}{7}\cdot 0 + \frac{6}{7}\cdot 3.466,7 = \mathbf{2.971,4}$$

Ejercicio 3 · Antigüedad · corte 6,5

- **Antig. ≤ 6,5**: precios {240, 320} → promedio 280
- **Antig. > 6,5**: precios {260, 300, 180, 220, 160} → promedio 224

$$\text{MSE}_{\leq 6{,}5} = [(240-280)^2 + (320-280)^2] / 2 = 1.600$$

$$\text{MSE}_{>6{,}5} = [(260-224)^2 + (300-224)^2 + (180-224)^2 + (220-224)^2 + (160-224)^2] / 5 = 2.624$$

$$\text{MSE}_{\text{Antig., 6,5}} = \tfrac{2}{7}\cdot 1.600 + \tfrac{5}{7}\cdot 2.624 = \mathbf{2.331{,}4}$$

Ejercicio 3 · Antigüedad · corte 10

- **Antig. ≤ 10**: precios {240, 320, 260} → promedio 273,333
- **Antig. > 10**: precios {300, 180, 220, 160} → promedio 215

$$MSE_{\leq 10} = [(240-273{,}333)^2 + (320-273{,}333)^2 + (260-273{,}333)^2] / 3 = 1.155{,}6$$

$$MSE_{>10} = [(300-215)^2 + (180-215)^2 + (220-215)^2 + (160-215)^2] / 4 = 2.875$$

$$MSE_{\text{Antig., }10} = \tfrac{3}{7}\cdot 1.155{,}6 + \tfrac{4}{7}\cdot 2.875 = \mathbf{2.138{,}1}$$

Ejercicio 3 · Antigüedad · corte 13,5

- **Antig. ≤ 13,5**: precios {240, 320, 260, 300} → promedio 280
- **Antig. > 13,5**: precios {180, 220, 160} → promedio 186,667

$$\text{MSE}_{\leq 13{,}5} = [(240-280)^2 + (320-280)^2 + (260-280)^2 + (300-280)^2] / 4 = 1.000$$

$$\text{MSE}_{>13{,}5} = [(180-186{,}667)^2 + (220-186{,}667)^2 + (160-186{,}667)^2] / 3 = 622{,}2$$

$$\text{MSE}_{\text{Antig., }13{,}5} = \tfrac{4}{7}\cdot 1.000 + \tfrac{3}{7}\cdot 622{,}2 = \mathbf{838{,}1}$$

Ejercicio 3 · Antigüedad · corte 17,5

- **Antig. ≤ 17,5**: precios {240, 320, 260, 300, 180} → promedio 260
- **Antig. > 17,5**: precios {220, 160} → promedio 190

$$\text{MSE}_{\leq 17{,}5} = [(240-260)^2 + (320-260)^2 + (260-260)^2 + (300-260)^2 + (180-260)^2] / 5 = 2.400$$

$$\text{MSE}_{>17{,}5} = [(220-190)^2 + (160-190)^2] / 2 = 900$$

$$\text{MSE}_{\text{Antig., } 17{,}5} = \tfrac{5}{7}\cdot 2.400 + \tfrac{2}{7}\cdot 900 = \mathbf{1.971{,}4}$$

Ejercicio 3 · Antigüedad · corte 21

- **Antig. ≤ 21**: precios {240, 320, 260, 300, 180, 220} → promedio 253,333
- **Antig. > 21**: precios {160} → promedio 160

$$\text{MSE}_{\leq 21} = [(240-253{,}333)^2 + (320-253{,}333)^2 + (260-253{,}333)^2 + (300-253{,}333)^2 + (180-253{,}333)^2 + (220-253{,}333)^2] / 6 = 2.222{,}2$$

$$\text{MSE}_{>21} = 0$$

$$\text{MSE}_{\text{Antig., 21}} = \frac{6}{7}\cdot 2.222{,}2 + \frac{1}{7}\cdot 0 = \mathbf{1.904{,}8}$$

Ejercicio 3 · partición por Refaccionada

- **Sí**: precios {260, 300, 320} → promedio 293,333
- **No**: precios {160, 180, 220, 240} → promedio 200

$$\text{MSE}_{\text{Sí}} = [(260-293{,}333)^2 + (300-293{,}333)^2 + (320-293{,}333)^2] \,/\, 3 = 622{,}2$$

$$\text{MSE}_{\text{No}} = [(160-200)^2 + (180-200)^2 + (220-200)^2 + (240-200)^2] \,/\, 4 = 1.000$$

$$\text{MSE}_{\text{Refaccionada}} = \tfrac{3}{7}\cdot 622{,}2 + \tfrac{4}{7}\cdot 1.000 = \mathbf{838{,}1}$$

Ejercicio 3 · tabla de MSE

El mejor corte de cada variable, ordenados:

Variable	Partición	MSE ponderado
Refaccionada	Sí vs No	**838,1**
Antigüedad	≤ 13,5	**838,1**
m^2	≤ 85	2.611,4

A ojo, "más m^2 = más caro" parecía la regla, pero el corte por m^2 es el **peor** de los tres: una casa chica refaccionada (60 m^2, 260) vale más que una grande sin refaccionar (140 m^2, 220). Refaccionada y Antigüedad empatan; elegimos **Refaccionada** por ser la más interpretable.

Ejercicio 3 · segunda iteración · datos restantes

El nodo **Refaccionada = Sí** (precios 260, 300, 320) quedó bastante homogéneo. El nodo **Refaccionada = No** sigue disperso (MSE 1.000): seguimos ahí, recalculando solo con esas 4 casas.

m²	Antigüedad	Precio
80	22	160
100	15	180
140	20	220
170	4	240

Ejercicio 3 · 2da iteración · m² · corte 90

- **m² ≤ 90**: precios {160} → promedio 160
- **m² > 90**: precios {180, 220, 240} → promedio 213,333

$$\text{MSE}_{\leq 90} = 0$$

$$\text{MSE}_{>90} = [(180-213{,}333)^2 + (220-213{,}333)^2 + (240-213{,}333)^2] / 3 = 622{,}2$$

$$\text{MSE}_{m^2,\ 90} = \tfrac{1}{4}\cdot 0 + \tfrac{3}{4}\cdot 622{,}2 = \mathbf{466{,}7}$$

Ejercicio 3 · 2da iteración · m² · corte 120

- **m² ≤ 120**: precios {160, 180} → promedio 170
- **m² > 120**: precios {220, 240} → promedio 230

$$\text{MSE}_{\leq 120} = [(160-170)^2 + (180-170)^2] / 2 = 100$$

$$\text{MSE}_{>120} = [(220-230)^2 + (240-230)^2] / 2 = 100$$

$$\text{MSE}_{m^2,\ 120} = \tfrac{2}{4}\cdot 100 + \tfrac{2}{4}\cdot 100 = \mathbf{100}$$

Ejercicio 3 · 2da iteración · m² · corte 155

- **m² ≤ 155**: precios {160, 180, 220} → promedio 186,667
- **m² > 155**: precios {240} → promedio 240

$$\text{MSE}_{\leq 155} = [(160-186{,}667)^2 + (180-186{,}667)^2 + (220-186{,}667)^2] / 3 = 622{,}2$$

$$\text{MSE}_{>155} = 0$$

$$\text{MSE}_{m^2,\ 155} = \tfrac{3}{4}\cdot 622{,}2 + \tfrac{1}{4}\cdot 0 = \mathbf{466{,}7}$$

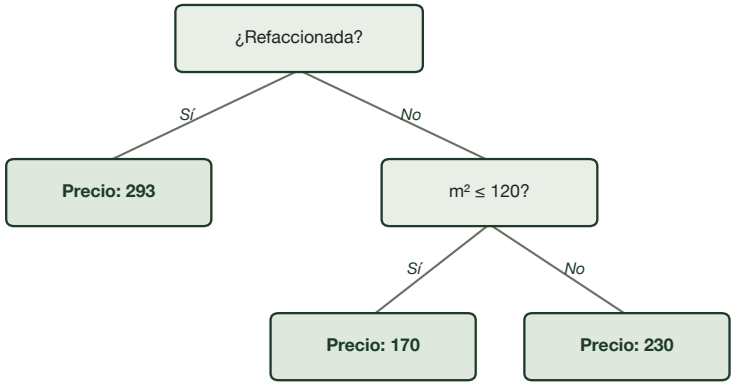
Ejercicio 3 · 2da iteración · Antigüedad

Los cortes por antigüedad sobre las mismas 4 casas (ordenadas 4-240, 15-180, 20-220, 22-160):

Corte	MSE ponderado
Antig. ≤ 9,5	466,7
Antig. ≤ 17,5	900
Antig. ≤ 21	466,7

Ninguno baja de 100. El mejor corte de esta rama es **m² ≤ 120**.

Ejercicio 3 · árbol resultante



Primero se parte por Refaccionada. Las refaccionadas predicen su promedio (293). Las no refaccionadas se vuelven a partir por $m^2 \leq 120$: las chicas predicen 170, las grandes 230.

Cada hoja predice el promedio de su grupo. La predicción de un árbol de regresión es constante dentro de cada región.

Características del algoritmo

- **Greedy:** toma la mejor partición local en cada paso, sin anticipar las siguientes.
- **División binaria:** cada nodo se divide en exactamente dos ramas.
- **Criterio según la tarea:** Gini (o entropía) para clasificación, MSE para regresión. En ambos casos, cada partición minimiza esa medida ponderada en los nodos hijos.
- **Recálculo por rama:** tras cada partición, los Gini se recalculan solo con los datos que llegan a ese nodo.
- CART garantiza el árbol de menor cantidad de nodos si se evalúan todos los cortes.

Ventajas y limitaciones

Ventajas

- Interpretable y visualizable directamente
- Maneja variables categóricas y numéricas
- No requiere estandarización
- Robusto frente a valores atípicos

Limitaciones

- Propenso al sobreajuste
- Inestable ante pequeños cambios en los datos
- Sesgado hacia variables con muchos niveles
- Greedy: puede no alcanzar el óptimo global

Consideraciones prácticas

- **Poda (pruning):** eliminar ramas poco informativas para reducir el sobreajuste.
- **Validación cruzada:** estimar el rendimiento sobre datos no vistos, como en la clase anterior.
- **Métodos de ensamble:** combinar árboles (Random Forest, Gradient Boosting) para mejorar estabilidad y precisión.
- **Balance de clases:** considerar el desbalance cuando una clase es mucho más frecuente.
- **Hiperparámetros:** profundidad máxima y mínimo de muestras por hoja controlan la complejidad.

ANALÍTICA DE DATOS

Hasta acá llegamos

CART · clase práctica 5

Universidad de SanAndrés