

CART

Classification And Regression Trees

Analítica de Datos, Universidad de San Andrés



¿Qué es CART?

CART es una técnica de aprendizaje automático para clasificación y regresión

- Su objetivo es dividir un conjunto de datos en grupos homogéneos
- Utiliza el índice de Gini para evaluar la calidad de las divisiones
- Es un algoritmo **greedy** (voraz)

$$\text{Gini} = 1 - \sum_{k=1}^K p_k^2$$

donde p_k es la proporción de la clase k en el nodo

- **Gini = 0**: Nodo puro (todas las instancias de una clase)
- **Gini = 0.5**: Máxima impureza (distribución uniforme)

Algoritmo Greedy

¿Por qué se dice **greedy**? Porque en cada paso tomamos la mejor decisión localmente, sin importar lo que viene después.

- Chequeamos cada punto de corte
- Determinamos si es útil o no sin tener en cuenta lo que viene después
- Puede llevar a soluciones subóptimas, pero es suficiente en muchos casos

Ejercicio 1 - Datos

Edad	Ingreso	Historial	Deuda Actual	Aprobado
25	3.5	Bueno	10	Sí
40	5.0	Malo	20	No
30	4.2	Bueno	30	Sí
22	2.8	Malo	40	No
35	6.1	Bueno	15	Sí

Queremos predecir si una persona es aprobada o no
para un crédito

Partición por Variable Objetivo

- **Aprobado = Sí:** 3 instancias
- **Aprobado = No:** 2 instancias

$$\text{Gini}_{\text{Aprobado}} = 1 - \left[\left(\frac{3}{5}\right)^2 + \left(\frac{2}{5}\right)^2 \right] = 0,48$$

Este es nuestro benchmark para mejorar

Partición por Edad - Ordenamiento

Edad	Aprobado
22	No
25	Sí
30	Sí
35	Sí
40	No

Para variables continuas, calculamos el Gini en cada punto de corte

Partición por Edad - Punto de Corte 23.5

- **Edad ≤ 23.5 :** 1 instancia (0 aprobados, 1 no aprobado)
- **Edad > 23.5 :** 4 instancias (3 aprobados, 1 no aprobado)

$$\text{Gini}_{\leq 23,5} = 1 - \left[\left(\frac{0}{1} \right)^2 + \left(\frac{1}{1} \right)^2 \right] = 0$$

$$\text{Gini}_{> 23,5} = 1 - \left[\left(\frac{3}{4} \right)^2 + \left(\frac{1}{4} \right)^2 \right] = 0,375$$

$$\text{Gini}_{\text{Edad}, 23.5} = \frac{1}{5} \times 0 + \frac{4}{5} \times 0,375 = 0,3$$

Partición por Edad - Punto de Corte 27.5

- **Edad $\leq$ 27.5:** 2 instancias (1 aprobado, 1 no aprobado)
- **Edad $>$ 27.5:** 3 instancias (2 aprobados, 1 no aprobado)

$$\text{Gini}_{\leq 27,5} = 1 - \left[\left(\frac{1}{2}\right)^2 + \left(\frac{1}{2}\right)^2 \right] = 0,5$$

$$\text{Gini}_{> 27,5} = 1 - \left[\left(\frac{2}{3}\right)^2 + \left(\frac{1}{3}\right)^2 \right] = 0,444$$

$$\text{Gini}_{\text{Edad}, 27.5} = \frac{2}{5} \times 0,5 + \frac{3}{5} \times 0,444 = 0,467$$

Partición por Edad - Punto de Corte 32.5

- **Edad $\leq$ 32.5:** 3 instancias (2 aprobados, 1 no aprobado)
- **Edad $>$ 32.5:** 2 instancias (1 aprobado, 1 no aprobado)

$$\text{Gini}_{\leq 32,5} = 1 - \left[\left(\frac{2}{3} \right)^2 + \left(\frac{1}{3} \right)^2 \right] = 0,444$$

$$\text{Gini}_{> 32,5} = 1 - \left[\left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right] = 0,5$$

$$\text{Gini}_{\text{Edad}, 32.5} = \frac{3}{5} \times 0,444 + \frac{2}{5} \times 0,5 = 0,467$$

Partición por Edad - Punto de Corte 37.5

- **Edad ≤ 37.5 :** 4 instancias (3 aprobados, 1 no aprobado)
- **Edad > 37.5 :** 1 instancia (0 aprobados, 1 no aprobado)

$$\text{Gini}_{\leq 37,5} = 1 - \left[\left(\frac{3}{4}\right)^2 + \left(\frac{1}{4}\right)^2 \right] = 0,375$$

$$\text{Gini}_{> 37,5} = 1 - \left[\left(\frac{0}{1}\right)^2 + \left(\frac{1}{1}\right)^2 \right] = 0$$

$$\text{Gini}_{\text{Edad}, 37.5} = \frac{4}{5} \times 0,375 + \frac{1}{5} \times 0 = 0,3$$

Punto de Corte	Gini
23.5	0.3
27.5	0.467
32.5	0.467
37.5	0.3

Los mejores puntos de corte son 23.5 y 37.5 ($\text{Gini} = 0.3$)

Partición por Historial

- **Historial = Bueno:** 3 instancias (3 aprobados, 0 no aprobados)
- **Historial = Malo:** 2 instancias (0 aprobados, 2 no aprobados)


$$\text{Gini}_{\text{Bueno}} = 1 - \left[\left(\frac{3}{3}\right)^2 + \left(\frac{0}{3}\right)^2 \right] = 0$$

$$\text{Gini}_{\text{Malo}} = 1 - \left[\left(\frac{0}{2}\right)^2 + \left(\frac{2}{2}\right)^2 \right] = 0$$

$$\text{Gini}_{\text{Historial}} = \frac{3}{5} \times 0 + \frac{2}{5} \times 0 = 0$$

¡Gini = 0! División perfecta

Árbol Resultante - Ejercicio 1



Árbol de un solo nodo - división perfecta

Ejercicio 2 - Datos

Depto.	Antigüedad	Cumpl. de Obj.	Recibe Bono
Ventas	2	80	No
Soporte	5	60	No
Logística	3	75	Sí
Ventas	1	50	No
Soporte	4	85	Sí
Logística	6	70	No

Queremos predecir si un empleado recibe bono

$$\text{Gini}_{\text{Recibe Bono}} = 1 - \left[\left(\frac{2}{6}\right)^2 + \left(\frac{4}{6}\right)^2 \right] = 0,444$$

Partición por Departamento - Ventas vs Resto

- **Ventas:** 2 observaciones (0 Sí, 2 No)
- **Soporte y Logística:** 4 observaciones (2 Sí, 2 No)

$$\text{Gini}_{\text{Ventas}} = 1 - \left[\left(\frac{0}{2} \right)^2 + \left(\frac{2}{2} \right)^2 \right] = 0$$

$$\text{Gini}_{\text{Soporte y Logística}} = 1 - \left[\left(\frac{2}{4} \right)^2 + \left(\frac{2}{4} \right)^2 \right] = 0,5$$

$$\text{Gini}_{\text{Departamento, Ventas}} = \frac{2}{6} \times 0 + \frac{4}{6} \times 0,5 = 0,333$$

Partición por Departamento - Soporte vs Resto

- **Soporte:** 2 observaciones (1 Sí, 1 No)
- **Logística:** 4 observaciones (1 Sí, 3 No)

$$\text{Gini}_{\text{Soporte}} = 1 - \left[\left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right] = 0,5$$

$$\text{Gini}_{\text{Logística}} = 1 - \left[\left(\frac{1}{4} \right)^2 + \left(\frac{3}{4} \right)^2 \right] = 0,375$$

$$\text{Gini}_{\text{Departamento, Soporte}} = \frac{2}{6} \times 0,5 + \frac{4}{6} \times 0,375 = 0,4167$$

Partición por Departamento - Logística vs Resto

- **Logística:** 2 observaciones (1 Sí, 1 No)
- **Soporte:** 4 observaciones (1 Sí, 3 No)

$$\text{Gini}_{\text{Logística}} = 1 - \left[\left(\frac{1}{2}\right)^2 + \left(\frac{1}{2}\right)^2 \right] = 0,5$$

$$\text{Gini}_{\text{Soporte}} = 1 - \left[\left(\frac{1}{4}\right)^2 + \left(\frac{3}{4}\right)^2 \right] = 0,375$$

$$\text{Gini}_{\text{Departamento, Logística}} = \frac{2}{6} \times 0,5 + \frac{4}{6} \times 0,375 = 0,4167$$

Partición por Cumplimiento de Objetivos - Ordenamiento

Cumplimiento de Objetivos	Recibe Bono
50	No
60	No
70	No
75	Si
80	No
85	Si

Puntos de corte: 55, 65, 72.5, 77.5, 82.5

Partición por Cumplimiento - Punto 55

- **Cumplimiento ≤ 55 :** 1 instancia (0 Sí, 1 No)
- **Cumplimiento > 55 :** 5 instancias (2 Sí, 3 No)

$$\text{Gini}_{\leq 55} = 1 - \left[\left(\frac{0}{1} \right)^2 + \left(\frac{1}{1} \right)^2 \right] = 0$$

$$\text{Gini}_{> 55} = 1 - \left[\left(\frac{2}{5} \right)^2 + \left(\frac{3}{5} \right)^2 \right] = 0,48$$

$$\text{Gini}_{55} = \frac{1}{6} \times 0 + \frac{5}{6} \times 0,48 = 0,4$$

Partición por Cumplimiento - Punto 65

- **Cumplimiento ≤ 65 :** 2 instancias (0 Sí, 2 No)
- **Cumplimiento > 65 :** 4 instancias (2 Sí, 2 No)

$$\text{Gini}_{\leq 65} = 1 - \left[\left(\frac{0}{2}\right)^2 + \left(\frac{2}{2}\right)^2 \right] = 0$$

$$\text{Gini}_{> 65} = 1 - \left[\left(\frac{2}{4}\right)^2 + \left(\frac{2}{4}\right)^2 \right] = 0,5$$

$$\text{Gini}_{65} = \frac{2}{6} \times 0 + \frac{4}{6} \times 0,5 = 0,333$$

Partición por Cumplimiento - Punto 72.5

- **Cumplimiento ≤ 72.5 :** 3 instancias (0 Sí, 3 No)
- **Cumplimiento > 72.5 :** 3 instancias (2 Sí, 1 No)

$$\text{Gini}_{\leq 72,5} = 1 - \left[\left(\frac{0}{3} \right)^2 + \left(\frac{3}{3} \right)^2 \right] = 0$$

$$\text{Gini}_{> 72,5} = 1 - \left[\left(\frac{2}{3} \right)^2 + \left(\frac{1}{3} \right)^2 \right] = 0,444$$

$$\text{Gini}_{72,5} = \frac{3}{6} \times 0 + \frac{3}{6} \times 0,444 = 0,222$$

Partición por Cumplimiento - Punto 77.5

- **Cumplimiento ≤ 77.5 :** 4 instancias (1 Sí, 3 No)
- **Cumplimiento > 77.5 :** 2 instancias (1 Sí, 1 No)

$$\text{Gini}_{\leq 77.5} = 1 - \left[\left(\frac{1}{4}\right)^2 + \left(\frac{3}{4}\right)^2 \right] = 0,375$$

$$\text{Gini}_{> 77.5} = 1 - \left[\left(\frac{1}{2}\right)^2 + \left(\frac{1}{2}\right)^2 \right] = 0,5$$

$$\text{Gini}_{77.5} = \frac{4}{6} \times 0,375 + \frac{2}{6} \times 0,5 = 0,417$$

Partición por Cumplimiento - Punto 82.5

- **Cumplimiento ≤ 82.5 :** 5 instancias (1 Sí, 4 No)
- **Cumplimiento > 82.5 :** 1 instancia (1 Sí, 0 No)

$$\text{Gini}_{\leq 82,5} = 1 - \left[\left(\frac{1}{5}\right)^2 + \left(\frac{4}{5}\right)^2 \right] = 0,32$$

$$\text{Gini}_{> 82,5} = 1 - \left[\left(\frac{1}{1}\right)^2 + \left(\frac{0}{1}\right)^2 \right] = 0$$

$$\text{Gini}_{82.5} = \frac{5}{6} \times 0,32 + \frac{1}{6} \times 0 = 0,267$$

Partición por Antigüedad - Ordenamiento

Antigüedad	Recibe Bono
1	No
2	No
3	Si
4	Si
5	No
6	No

Puntos de corte: 1.5, 2.5, 3.5, 4.5, 5.5

Partición por Antigüedad - Punto 1.5

- **Antigüedad ≤ 1.5 :** 1 instancia (0 Sí, 1 No)
- **Antigüedad > 1.5 :** 5 instancias (2 Sí, 3 No)

$$\text{Gini}_{\leq 1,5} = 1 - \left[\left(\frac{0}{1} \right)^2 + \left(\frac{1}{1} \right)^2 \right] = 0$$

$$\text{Gini}_{> 1,5} = 1 - \left[\left(\frac{2}{5} \right)^2 + \left(\frac{3}{5} \right)^2 \right] = 0,48$$

$$\text{Gini}_{\text{Antigüedad}, 1.5} = \frac{1}{6} \times 0 + \frac{5}{6} \times 0,48 = 0,4$$

Partición por Antigüedad - Punto 2.5

- **Antigüedad ≤ 2.5 :** 2 instancias (0 Sí, 2 No)
- **Antigüedad > 2.5 :** 4 instancias (2 Sí, 2 No)

$$\text{Gini}_{\leq 2,5} = 1 - \left[\left(\frac{0}{2}\right)^2 + \left(\frac{2}{2}\right)^2 \right] = 0$$

$$\text{Gini}_{> 2,5} = 1 - \left[\left(\frac{2}{4}\right)^2 + \left(\frac{2}{4}\right)^2 \right] = 0,5$$

$$\text{Gini}_{\text{Antigüedad}, 2.5} = \frac{2}{6} \times 0 + \frac{4}{6} \times 0,5 = 0,333$$

Partición por Antigüedad - Punto 3.5

- **Antigüedad ≤ 3.5 :** 3 instancias (2 Sí, 1 No)
- **Antigüedad > 3.5 :** 3 instancias (0 Sí, 3 No)

$$\text{Gini}_{\leq 3,5} = 1 - \left[\left(\frac{2}{3} \right)^2 + \left(\frac{1}{3} \right)^2 \right] = 0,444$$

$$\text{Gini}_{> 3,5} = 1 - \left[\left(\frac{0}{3} \right)^2 + \left(\frac{3}{3} \right)^2 \right] = 0$$

$$\text{Gini}_{\text{Antigüedad}, 3.5} = \frac{3}{6} \times 0,444 + \frac{3}{6} \times 0 = 0,222$$

Partición por Antigüedad - Punto 4.5

- **Antigüedad ≤ 4.5 :** 4 instancias (2 Sí, 2 No)
- **Antigüedad > 4.5 :** 2 instancias (0 Sí, 2 No)

$$\text{Gini}_{\leq 4,5} = 1 - \left[\left(\frac{2}{4}\right)^2 + \left(\frac{2}{4}\right)^2 \right] = 0,5$$

$$\text{Gini}_{> 4,5} = 1 - \left[\left(\frac{0}{2}\right)^2 + \left(\frac{2}{2}\right)^2 \right] = 0$$

$$\text{Gini}_{\text{Antigüedad}, 4.5} = \frac{4}{6} \times 0,5 + \frac{2}{6} \times 0 = 0,333$$

Partición por Antigüedad - Punto 5.5

- **Antigüedad ≤ 5.5 :** 5 instancias (2 Sí, 3 No)
- **Antigüedad > 5.5 :** 1 instancia (0 Sí, 1 No)

$$\text{Gini}_{\leq 5,5} = 1 - \left[\left(\frac{2}{5} \right)^2 + \left(\frac{3}{5} \right)^2 \right] = 0,48$$

$$\text{Gini}_{> 5,5} = 1 - \left[\left(\frac{0}{1} \right)^2 + \left(\frac{1}{1} \right)^2 \right] = 0$$

$$\text{Gini}_{\text{Antigüedad}, 5.5} = \frac{5}{6} \times 0,48 + \frac{1}{6} \times 0 = 0,4$$

Tabla de Ginis - Ejercicio 2

Variable	Partición	Gini
Cumplimiento de Objetivos	72.5	0.222
Antigüedad	3.5	0.222
Departamento	Ventas	0.333
Antigüedad	2.5	0.333
Antigüedad	4.5	0.333
Cumplimiento de Objetivos	65	0.333
Antigüedad	1.5	0.4
Antigüedad	5.5	0.4
Cumplimiento de Objetivos	55	0.4
Cumplimiento de Objetivos	82.5	0.4
Departamento	Soporte	0.4167
Departamento	Logística	0.4167
Cumplimiento de Objetivos	77.5	0.417

2da Iteración - Datos Restantes

Depto.	Antigüedad	Cumpl. de Obj.	Recibe Bono
Ventas	2	80	No
Logística	3	75	Sí
Soporte	4	85	Sí

Solo los datos donde Cumplimiento > 72.5

2da Iteración - Gini por Departamento - Ventas vs Resto

- **Ventas:** 1 observación (0 Sí, 1 No)
- **Soporte y Logística:** 2 observaciones (2 Sí, 0 No)

$$\text{Gini}_{\text{Ventas}} = 1 - \left[\left(\frac{0}{1} \right)^2 + \left(\frac{1}{1} \right)^2 \right] = 0$$

$$\text{Gini}_{\text{Soporte y Logística}} = 1 - \left[\left(\frac{2}{2} \right)^2 + \left(\frac{0}{2} \right)^2 \right] = 0$$

$$\text{Gini}_{\text{Departamento, Ventas}} = \frac{1}{3} \times 0 + \frac{2}{3} \times 0 = 0$$

¡Separación perfecta! Podríamos frenar pero vamos a seguir solo por cuestiones *pedagógicas*

2da Iteración - Gini por Departamento - Soporte vs Resto

- **Soporte:** 1 observación (1 Sí, 0 No)
- **Ventas y Logística:** 2 observaciones (1 Sí, 1 No)

$$\text{Gini}_{\text{Soporte}} = 1 - \left[\left(\frac{1}{1} \right)^2 + \left(\frac{0}{1} \right)^2 \right] = 0$$

$$\text{Gini}_{\text{Ventas y Logística}} = 1 - \left[\left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right] = 0,5$$

$$\text{Gini}_{\text{Departamento, Soporte}} = \frac{1}{3} \times 0 + \frac{2}{3} \times 0,5 = 0,333$$

2da Iteración - Gini por Departamento - Logística vs Resto

- **Logística:** 1 observación (1 Sí, 0 No)
- **Ventas y Soporte:** 2 observaciones (1 Sí, 1 No)

$$\text{Gini}_{\text{Logística}} = 1 - \left[\left(\frac{1}{1} \right)^2 + \left(\frac{0}{1} \right)^2 \right] = 0$$

$$\text{Gini}_{\text{Ventas y Soporte}} = 1 - \left[\left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right] = 0,5$$

$$\text{Gini}_{\text{Departamento, Logística}} = \frac{1}{3} \times 0 + \frac{2}{3} \times 0,5 = 0,333$$

2da Iteración - Antigüedad - Ordenamiento

Antigüedad	Recibe Bono
2	No
3	Sí
4	Sí

Puntos de corte: 2.5, 3.5

2da Iteración - Gini por Antigüedad 2.5

- **Antigüedad ≤ 2.5 :** 1 instancia (0 Sí, 1 No)
- **Antigüedad > 2.5 :** 2 instancias (2 Sí, 0 No)

$$\text{Gini}_{\leq 2.5} = 1 - \left[\left(\frac{0}{1} \right)^2 + \left(\frac{1}{1} \right)^2 \right] = 0$$

$$\text{Gini}_{> 2.5} = 1 - \left[\left(\frac{2}{2} \right)^2 + \left(\frac{0}{2} \right)^2 \right] = 0$$

$$\text{Gini}_{\text{Antigüedad}, 2.5} = \frac{1}{3} \times 0 + \frac{2}{3} \times 0 = 0$$

2da Iteración - Gini por Antigüedad 3.5

- **Antigüedad ≤ 3.5 :** 2 instancias (1 Sí, 1 No)
- **Antigüedad > 3.5 :** 1 instancia (1 Sí, 0 No)

$$\text{Gini}_{\leq 3,5} = 1 - \left[\left(\frac{1}{2}\right)^2 + \left(\frac{1}{2}\right)^2 \right] = 0,5$$

$$\text{Gini}_{> 3,5} = 1 - \left[\left(\frac{1}{1}\right)^2 + \left(\frac{0}{1}\right)^2 \right] = 0$$

$$\text{Gini}_{\text{Antigüedad}, 3.5} = \frac{2}{3} \times 0,5 + \frac{1}{3} \times 0 = 0,333$$

2da Iteración - Cumplimiento de Objetivos - Ordenamiento

Cumplimiento de Objetivos	Recibe Bono
75	Sí
80	No
85	Sí

Puntos de corte: 77.5, 82.5

2da Iteración - Gini por Cumplimiento 77.5

- **Cumplimiento ≤ 77.5 :** 1 instancia (1 Sí, 0 No)
- **Cumplimiento > 77.5 :** 2 instancias (1 Sí, 1 No)

$$\text{Gini}_{\leq 77,5} = 1 - \left[\left(\frac{1}{1}\right)^2 + \left(\frac{0}{1}\right)^2 \right] = 0$$

$$\text{Gini}_{> 77,5} = 1 - \left[\left(\frac{1}{2}\right)^2 + \left(\frac{1}{2}\right)^2 \right] = 0,5$$

$$\text{Gini}_{\text{Cumplimiento}, 77.5} = \frac{1}{3} \times 0 + \frac{2}{3} \times 0,5 = 0,333$$

2da Iteración - Gini por Cumplimiento 82.5

- **Cumplimiento ≤ 82.5 :** 1 instancia (1 Sí, 1 No)
- **Cumplimiento > 82.5 :** 2 instancias (1 Sí, 0 No)

$$\text{Gini}_{\leq 82,5} = 1 - \left[\left(\frac{1}{1}\right)^2 + \left(\frac{1}{1}\right)^2 \right] = 0,5$$

$$\text{Gini}_{> 82,5} = 1 - \left[\left(\frac{1}{2}\right)^2 + \left(\frac{0}{2}\right)^2 \right] = 0$$


$$\text{Gini}_{\text{Cumplimiento}, 82.5} = \frac{1}{3} \times 0,5 + \frac{2}{3} \times 0 = 0,167$$

2da Iteración - Gini

Variable	Partición	Gini
Antigüedad	2.5	0
Departamento	Ventas	0
Cumplimiento de Objetivos	82.5	0.167
Departamento	Soporte	0.333
Departamento	Logística	0.333
Antigüedad	3.5	0.333
Cumplimiento de Objetivos	77.5	0.333

Elegimos $\text{Antigüedad} \leq 2.5$ ($\text{Gini} = 0$)

Árbol Resultante - Ejercicio 2



Características de CART

- **Algoritmo greedy:** Toma la mejor decisión local en cada paso
- **División binaria:** Cada nodo se divide en exactamente dos ramas
- **Índice de Gini:** Minimiza la impureza en cada división
- **Árbol óptimo:** CART garantiza el árbol con menos nodos

Ventajas de CART

- Fácil de interpretar y visualizar
- Maneja variables categóricas y numéricas
- No requiere normalización de datos
- Maneja valores faltantes automáticamente
- No es sensible a valores atípicos

Desventajas de CART

- Propenso al sobreajuste (overfitting)
- Inestable con pequeños cambios en los datos
- Sesgado hacia variables con muchos niveles
- No funciona bien con relaciones no lineales complejas
- Algoritmo greedy puede no encontrar la solución óptima global

Consideraciones Prácticas

- **Pruning:** Técnica para reducir el sobreajuste eliminando ramas poco importantes
- **Validación cruzada:** Para evaluar el rendimiento real del modelo
- **Ensemble methods:** Combinar múltiples árboles (Random Forest, Gradient Boosting) para mejorar el rendimiento
- **Balance de clases:** Considerar técnicas de balanceo cuando las clases están desbalanceadas
- **Selección de hiperparámetros:** Ajustar parámetros como profundidad máxima y número mínimo de muestras por hoja

¿Dudas?
¿Consultas?