

Validación de Modelos

Analítica de Datos, Universidad de San Andrés

Si encuentran algún error en el documento o hay alguna duda, mandenme un mail a rodriguezf@udesa.edu.ar y lo revisamos.

1. Introducción a la Validación de Modelos

La validación de modelos es un paso crucial en el desarrollo de modelos de machine learning. No solo necesitamos que nuestros modelos funcionen bien en los datos de entrenamiento, sino que también deben generalizar adecuadamente a nuevos datos. Para esto, es fundamental entender y utilizar las métricas apropiadas según el contexto del problema.

En machine learning, distinguimos principalmente entre dos tipos de problemas:

- **Regresión:** Cuando queremos predecir un valor numérico continuo (ej: precio de una casa, temperatura, salario)
- **Clasificación:** Cuando queremos predecir una categoría o clase (ej: spam/no spam, enfermedad/sano, compra/no compra)

Cada tipo de problema requiere métricas de validación específicas y diferentes enfoques para evaluar el rendimiento del modelo.

2. Validación para Regresión

En problemas de regresión, nuestro objetivo es predecir un valor numérico continuo. Las métricas de validación para regresión se enfocan en medir qué tan cerca están nuestras predicciones de los valores reales.

2.1. Error Cuadrático Medio (MSE)

El Error Cuadrático Medio (Mean Squared Error) es una de las métricas más utilizadas en regresión. Penaliza más los errores grandes debido a la función cuadrática:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

donde:

- y_i es el valor real
- $\hat{y}_i$ es el valor predicho
- n es el número de observaciones

2.2. Raíz del Error Cuadrático Medio (RMSE)

El RMSE es simplemente la raíz cuadrada del MSE, lo que nos da una métrica en las mismas unidades que la variable objetivo:

$$\text{RMSE} = \sqrt{\text{MSE}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

2.3. Error Absoluto Medio (MAE)

El Error Absoluto Medio (Mean Absolute Error) es menos sensible a valores atípicos que el MSE, ya que no eleva al cuadrado los errores:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

2.4. Coeficiente de Determinación (R^2)

El R^2 mide qué proporción de la varianza en la variable dependiente es explicada por el modelo. Su valor va de 0 a 1:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

donde $\bar{y}$ es la media de los valores reales.

- $R^2 = 1$: El modelo explica perfectamente la varianza
- $R^2 = 0$: El modelo no es mejor que predecir la media
- $R^2 < 0$: El modelo es peor que predecir la media

2.5. Error Porcentual Absoluto Medio (MAPE)

El MAPE expresa el error como porcentaje del valor real, lo que facilita la interpretación:

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Problema con valores cero: Cuando $y_i = 0$, la fórmula tiene una división por cero que causa error. Soluciones comunes:

- Reemplazar ceros por un valor muy pequeño (ej: 0.0000001)
- Usar un porcentaje del valor promedio (ej: 1 % de la media)
- Filtrar los valores cero antes del cálculo
- Usar MAPE simétrico (sMAPE): $\text{sMAPE} = \frac{100\%}{n} \sum_{i=1}^n \frac{2|y_i - \hat{y}_i|}{|y_i| + |\hat{y}_i|}$

2.6. Ejemplo Práctico de Regresión

Consideremos un modelo que predice el precio de casas. Tenemos los siguientes datos:

Casa	Precio Real	Precio Predicho
1	30	28
2	45	47
3	20	19
4	60	62
5	35	33

$$\begin{aligned}
\text{MSE} &= \frac{1}{5}[(30 - 28)^2 + (45 - 47)^2 + (20 - 19)^2 + (60 - 62)^2 + (35 - 33)^2] \\
&= \frac{1}{5}[4 + 4 + 1 + 4 + 4] \\
&= 18 \\
\text{RMSE} &= \sqrt{18} = 4,24 \\
\text{MAE} &= \frac{1}{5}[20 + 20 + 10 + 20 + 20] = 18000 \\
\text{MAPE} &= \frac{100\%}{5}[\frac{20}{30} + \frac{20}{45} + \frac{10}{20} + \frac{20}{60} + \frac{20}{35}] \\
&= 4,95\%
\end{aligned}$$

3. Validación para Clasificación

En problemas de clasificación, nuestro objetivo es predecir una categoría o clase. Las métricas de validación para clasificación se enfocan en medir la precisión de las predicciones categóricas.

3.1. Matriz de Confusión Binaria

La matriz de confusión más común es cuando tenemos un problema binario de clasificación. En este caso, tenemos dos clases: positiva y negativa. La matriz puede mostrarse de cualquiera de las siguientes formas, siempre indicando cuales son los reales y cuales son los predichos.

	Real			Predicho	
	VP	FP		VP	FN
Predicho	FN	VN	Real	FP	VN

Notar que la ubicación del falso positivo y el falso negativo cambia según donde pongamos el real y el predicho. Hay una cierta convención en la que se considera que el real está en las filas y el predicho en las columnas pero van a ver que prácticamente nunca se usa y queda siempre a discreción del analista o de la biblioteca que estemos usando.

3.2. Matriz de Confusión Multiclase

La matriz de confusión multiclase es una extensión de la matriz de confusión binaria. En este caso, tenemos más de dos clases. Notar que en estos casos no tenemos falsos positivos o falsos negativos, sino que tenemos **múltiples** tipos de errores. A continuación se muestra una matriz de confusión multiclase para un problema de clasificación de lluvia, nublado y soleado.

		R		
		L	N	S
P	L	85	10	5
	N	8	82	10
	S	7	12	81

3.3. Métricas Básicas

3.4. Accuracy (Exactitud)

La exactitud es simplemente la proporción de predicciones correctas sobre el total. En cualquier caso de matriz, sea binaria o multiclase sumamos la diagonal y dividimos por el total. Esta métrica es útil cuando las clases están

balanceadas, los costos de falsos positivos y falsos negativos son similares, y el problema no tiene una necesidad crítica.

$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FP + FN}$$

3.5. Precision (Precisión)

La precisión mide la proporción de predicciones positivas correctas. Esta métrica es especialmente útil cuando el costo de falsos positivos es alto y queremos estar seguros de nuestras predicciones positivas.

$$\text{Precision} = \frac{VP}{VP + FP}$$

3.6. Specificity (Especificidad) / True Negative Rate (TNR)

La especificidad mide la proporción de predicciones negativas correctas. Esta métrica es especialmente útil cuando el costo de falsos negativos es alto, no queremos perder casos negativos, y en algo de justicia presumimos inocencia.

$$\text{Specificity} = \frac{VN}{VN + FP}$$

3.7. Recall (Sensibilidad) / True Positive Rate (TPR)

El recall mide la proporción de casos positivos reales que fueron identificados correctamente. Es importante cuando el costo de falsos negativos es alto, no queremos perder casos positivos, y en detección de enfermedades (es importante no perder ningún caso positivo).

$$\text{Recall} = \frac{VP}{VP + FN}$$

3.8. Fall-out / False Positive Rate (FPR)

La tasa de falsos positivos mide la proporción de predicciones positivas incorrectas. Es útil mirar cuando queremos controlar la proporción de errores tipo I y el costo de falsos positivos es alto.

$$\text{False Positive Rate} = \frac{FP}{FP + VN}$$

3.9. Miss Rate / False Negative Rate (FNR)

La tasa de falsos negativos mide la proporción de predicciones negativas incorrectas. Es útil mirar cuando queremos controlar la proporción de errores tipo II y el costo de falsos negativos es alto.

$$\text{False Negative Rate} = \frac{FN}{FN + VP}$$

3.10. F1-Score

El F1-Score es la media armónica entre precisión y recall, y es útil cuando las clases están desbalanceadas (que una clase sea mucho más frecuente que la otra).

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

3.11. False Discovery Rate (FDR)

La tasa de descubrimiento falso mide la proporción de falsos positivos entre todas las predicciones positivas. Es útil cuando necesitamos controlar la proporción de errores tipo I y el costo de falsos positivos es alto.

$$FDR = \frac{FP}{FP + VP}$$

3.12. False Omission Rate (FOR)

La tasa de omisión falsa mide la proporción de falsos negativos entre todas las predicciones negativas. Esta métrica es fundamental cuando el costo de falsos negativos es alto y necesitamos controlar la proporción de errores tipo II.

$$\text{FOR} = \frac{FN}{FN + VN}$$

3.13. Negative Predictive Value (NPV)

El valor predictivo negativo mide la proporción de verdaderos negativos entre todas las predicciones negativas. Es relevante cuando necesitamos confiar en las predicciones negativas, como en pruebas diagnósticas o control de calidad.


$$\text{NPV} = \frac{VN}{VN + FN}$$

3.14. Métricas Avanzadas

3.15. ROC y AUC

La curva ROC (Receiver Operating Characteristic) muestra la relación entre la tasa de verdaderos positivos (recall) y la tasa de falsos positivos a **diferentes umbrales de clasificación**. El AUC (Area Under the Curve) es el área bajo esta curva:

- $\text{AUC} = 1.0$: Clasificación perfecta
- $\text{AUC} = 0.5$: Clasificación aleatoria
- $\text{AUC} < 0.5$: Peor que aleatorio



La curva ROC es una herramienta muy útil para evaluar el rendimiento de clasificadores binarios. En el gráfico podemos observar que:

- El eje X representa la Tasa de Falsos Positivos (FPR)
- El eje Y representa la Tasa de Verdaderos Positivos (TPR) o Recall
- La línea punteada diagonal representa el clasificador aleatorio ($AUC = 0.5$)
- Las curvas de colores representan diferentes clasificadores

Cuanto más cerca esté la curva del punto (0,1), mejor será el rendimiento del clasificador. Un clasificador perfecto tendría un AUC de 1.0, mientras que un clasificador aleatorio tendría un AUC de 0.5.

3.16. ¿Cómo entiendo la curva ROC?

Lo importante es pensar que para cada punto de umbral, existe una tasa de falsos positivos y una tasa de verdaderos positivos.

3.17. Para un umbral de 0

Para un umbral de 0, todos los casos son positivos y ninguno es negativo. Tendríamos una matriz de confusión de la siguiente forma:

		R	
P		α (VP)	β (FP)
		0 (FN)	0 (VN)

Cuando queramos ahora calcular para umbral 0, fijemonos bien que nunca va a importar cuando vale α o β , porque siempre lo otro va a ser 0.

3.17.1. Punto que voy a poner en el eje X: FPR

Recordemos que la FPR es:

$$FPR = \frac{FP}{FP + VN}$$

Remplazando con los valores que podemos tener con un umbral 0, donde todos los casos son positivos y ninguno es negativo, tenemos que:

$$FPR = \frac{FP}{FP + VN} = \frac{FP}{FP + 0} = 1$$

3.17.2. Punto que voy a poner en el eje Y: TPR

Recordemos que la TPR es:

$$TPR = \frac{VP}{VP + FN}$$

Remplazando con los valores que podemos tener con un umbral 0, donde todos los casos son positivos y ninguno es negativo, tenemos que:

$$TPR = \frac{VP}{VP + FN} = \frac{VP}{VP + 0} = 1$$

3.18. Para un umbral de 1

Para un umbral de 1, todos los casos son negativos y ninguno es positivo. Tendríamos una matriz de confusión de la siguiente forma:

		R	
P		0 (VP)	0 (FP)
		α (FN)	β (VN)

Cuando queramos ahora calcular para umbral 1, fijemonos de vuelta bien que nunca va a importar cuanto vale α o β , porque siempre lo otro va a ser 0.

3.18.1. Punto que voy a poner en el eje X: FPR

Recordemos que la FPR es:

$$FPR = \frac{FP}{FP + VN}$$

Remplazando con los valores que podemos tener con un umbral 1, donde ninguno es positivo y todos son negativos, tenemos que:

$$FPR = \frac{FP}{FP + VN} = \frac{FP}{FP + 0} = 1$$

3.18.2. Punto que voy a poner en el eje Y: TPR

Recordemos que la TPR es:

$$TPR = \frac{VP}{VP + FN}$$

Remplazando con los valores que podemos tener con un umbral 1, donde ninguno es positivo y todos son negativos, tenemos que:

$$TPR = \frac{VP}{VP + FN} = \frac{0}{0 + FN} = 0$$

3.18.3. Para un umbral U

Para un umbral U , tengo que calcular la FPR y la TPR para cada valor de umbral. Para obtener la curva ROC completa, necesito calcular estos valores para todos los posibles umbrales. Una curva perfecta es aquella en la que existe al menos un umbral tal que la separación entre clases es perfecta, es decir, no hay falsos positivos ni falsos negativos.

3.19. Curva PR

La curva PR es prácticamente igual a la curva ROC, solo que en el eje X tenemos la precisión y en el eje Y tenemos el recall. Todo se calcula igual que con la curva ROC, solo que en vez de usar la FPR y la TPR, usamos la precisión y el recall. Tendremos que agarrar un umbral U y calcular la precisión y el recall para ese umbral, y así con todos.

3.20. Casos de Uso y Recomendaciones

3.21. Salud

En el ámbito de la salud, las consecuencias de un falso negativo (no detectar una enfermedad) son mucho más graves que las de un falso positivo. Por lo tanto:

- Priorizar el recall sobre la precisión
- Usar curvas PR en lugar de ROC
- No usar accuracy como métrica principal

3.22. Justicia

En el sistema judicial, debemos considerar que es mejor dejar libre a un culpable que condenar a un inocente, entonces:

- Usar curvas ROC para evaluar el balance
- Considerar el impacto social de los errores
- Evaluar la transparencia y explicabilidad del modelo

3.23. Ejemplo Práctico de Clasificación

Consideremos un modelo de detección de enfermedades cardíacas con los siguientes resultados:

	R	
P	80	20
	10	90

Calculemos todas las métricas:

$$\text{Accuracy} = \frac{80 + 90}{200} = 0,85$$

$$\text{Precision} = \frac{80}{90} = 0,89$$

$$\text{Specificity (TNR)} = \frac{90}{100} = 0,90$$

$$\text{Recall (TPR)} = \frac{80}{100} = 0,80$$

$$\text{Fall-out (FPR)} = \frac{10}{100} = 0,10$$

$$\text{Miss Rate (FNR)} = \frac{20}{100} = 0,20$$

$$\text{F1} = 2 \times \frac{0,89 \times 0,80}{0,89 + 0,80} = 0,84$$

$$\text{FDR} = \frac{10}{90} = 0,11$$

$$\text{FOR} = \frac{20}{110} = 0,18$$

$$\text{NPV} = \frac{90}{110} = 0,82$$

En este caso, aunque la accuracy es alta (0.85), el recall de 0.80 significa que estamos perdiendo el 20% de los casos positivos, lo cual no está bueno en

un problema médico. La tasa de falsos positivos (FPR) es del 10 %, lo que significa que estamos clasificando incorrectamente como enfermos al 10 % de las personas sanas.

3.24. Implementación en Python

```
1 # Para regresion
2 from sklearn.metrics import mean_squared_error,
   mean_absolute_error
3 from sklearn.metrics import r2_score
4
5 # Metricas de regresion
6 mse = mean_squared_error(y_true, y_pred)
7 rmse = np.sqrt(mse)
8 mae = mean_absolute_error(y_true, y_pred)
9 r2 = r2_score(y_true, y_pred)
10
11 # Para clasificacion
12 from sklearn.metrics import accuracy_score, precision_score
13 from sklearn.metrics import recall_score, f1_score
14 from sklearn.metrics import confusion_matrix
15 from sklearn.metrics import roc_curve, auc
16 from sklearn.metrics import precision_recall_curve
17
18 # Metricas basicas de clasificacion
19 accuracy = accuracy_score(y_true, y_pred)
20 precision = precision_score(y_true, y_pred)
21 recall = recall_score(y_true, y_pred)
22 f1 = f1_score(y_true, y_pred)
23
24 # Matriz de confusion
25 conf_matrix = confusion_matrix(y_true, y_pred)
26
27 # Curva ROC
28 fpr, tpr, _ = roc_curve(y_true, y_pred_proba)
29 roc_auc = auc(fpr, tpr)
30
31 # Curva PR
32 precision, recall, _ = precision_recall_curve(
33     y_true, y_pred_proba
34 )
```

4. Cross Validation

La validación cruzada es una técnica de evaluación de modelos que nos permite estimar qué tan bien un modelo de aprendizaje automático se generalizará a datos nuevos e independientes. Es especialmente útil cuando:


- La cantidad de datos disponibles es limitada
- Queremos evitar el sobreajuste (overfitting)
- Necesitamos una estimación más robusta del rendimiento del modelo

4.1. K-Fold Cross Validation

La técnica más común de validación cruzada es k-fold CV, donde:

1. Los datos se dividen en k partes iguales (folds)
2. Se realizan k iteraciones donde:
 - Se usa una parte como conjunto de validación
 - Se usan las k-1 partes restantes como conjunto de entrenamiento
3. Se promedian los resultados de las k iteraciones

A continuación se muestra una representación visual de cómo funciona la validación cruzada con 5 folds. En cada iteración, un fold diferente (marcado en rojo) se utiliza como conjunto de validación, mientras que los demás folds (en gris) se utilizan para entrenar el modelo.



4.2. Ejemplo Práctico

Consideremos un conjunto de datos con 100 observaciones y $k=5$:

Iteración	Error de Entrenamiento	Error de Validación
1	0.15	0.18
2	0.14	0.19
3	0.16	0.17
4	0.15	0.20
5	0.14	0.18
Promedio	0.148	0.184

El error promedio de validación (0.184) es una estimación más robusta del error de generalización que si hubiéramos usado una única división train-test.

- El error de entrenamiento es consistentemente menor que el error de validación, lo que indica un leve overfitting del modelo.
- La variación en los errores de validación (entre 0.17 y 0.20) sugiere que el modelo es relativamente estable.
- La diferencia promedio entre el error de entrenamiento y validación (0.036) nos da una idea de cuánto podría estar el modelo sobreajustándose a los datos.

4.3. Consideraciones Importantes

4.3.1. Elección del número de folds (k)

La elección del número de folds (k) es crucial y presenta diferentes trade-offs:

- $k=5$:
 - Mayor sesgo pero menor varianza
 - Más rápido computacionalmente
 - Útil cuando el conjunto de datos es grande
- $k=10$:

- Menor sesgo pero mayor varianza
- Más preciso en la estimación del error
- Recomendado para conjuntos de datos más pequeños

4.3.2. Ordenamiento y mezcla de datos

- El orden de los datos puede afectar significativamente los resultados de la validación cruzada, hay que mezclar aleatoriamente los datos antes de realizar las divisiones
- Para garantizar la reproducibilidad de los resultados, utilizar un valor fijo de *random_state*

4.3.3. Preprocesamiento de datos

- Realizar preprocesamiento **dentro de cada fold** para evitar data leakage (que el conjunto de entrenamiento tenga información del conjunto de validación)
- Incluir: escalado, normalización, codificación categórica, manejo de faltantes y selección de features

4.4. Implementación en Python

```

1 from sklearn.model_selection import KFold, cross_val_score
2 from sklearn.linear_model import LogisticRegression
3
4 # Crear el modelo
5 model = LogisticRegression()
6
7 # Configurar 5-fold CV
8 kfold = KFold(n_splits=5, shuffle=True, random_state=42)
9
10 # Calcular scores
11 scores = cross_val_score(model, X, y, cv=kfold)
12
13 # Imprimir resultados
14 print(f"Scores por fold: {scores}")
15 print(f"Score promedio: {scores.mean():.3f}")
16 print(f"Desviacion estandar: {scores.std():.3f}")

```