

Validación de Modelos

Analítica de Datos, Universidad de San Andrés



Tipos de Problemas en Machine Learning

Regresión

- Predecir números
- Ejemplos:
 - Precio de casas
 - Temperatura
 - Salario

Clasificación

- Predecir categorías o clases
- Ejemplos:
 - Spam/No spam
 - Enfermedad/Sano
 - Compra/No compra

¡Cada tipo requiere métricas de validación específicas!

En regresión medimos qué tan **cerca** están nuestras predicciones de los valores reales

En regresión medimos qué tan **cerca** están nuestras predicciones de los valores reales

- **MSE:** Mean Squared Error

En regresión medimos qué tan **cerca** están nuestras predicciones de los valores reales

- **MSE**: Mean Squared Error
- **RMSE**: Root Mean Squared Error

En regresión medimos qué tan **cerca** están nuestras predicciones de los valores reales

- **MSE**: Mean Squared Error
- **RMSE**: Root Mean Squared Error
- **MAE**: Mean Absolute Error

En regresión medimos qué tan **cerca** están nuestras predicciones de los valores reales

- **MSE**: Mean Squared Error
- **RMSE**: Root Mean Squared Error
- **MAE**: Mean Absolute Error
- **R²**: R-squared

En regresión medimos qué tan **cerca** están nuestras predicciones de los valores reales

- **MSE**: Mean Squared Error
- **RMSE**: Root Mean Squared Error
- **MAE**: Mean Absolute Error
- **R²**: R-squared
- **MAPE**: Mean Absolute Percentage Error

MSE - Mean Squared Error

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Penaliza más los errores grandes
- Sensible a valores atípicos
- Unidades al cuadrado de la variable objetivo

RMSE - Root Mean Squared Error

$$\text{RMSE} = \sqrt{\text{MSE}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- Mismas unidades que la variable objetivo
- Más fácil de interpretar que MSE
- Mantiene la penalización por errores grandes

MAE - Mean Absolute Error

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- Menos sensible a valores atípicos
- Mismas unidades que la variable objetivo
- Trata todos los errores por igual

R² - R-squared

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- $R^2 = 1$: Modelo perfecto
- $R^2 = 0$: Modelo no mejor que la media
- $R^2 < 0$: Modelo peor que la media

MAPE - Mean Absolute Percentage Error

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

- Error expresado como porcentaje
- Fácil de interpretar

. Podemos
solucionar reemplazando los que sean cero por un valor tipo
0.0000001, filtrar ceros, entre otras cosas.

MAPE - Mean Absolute Percentage Error

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

- Error expresado como porcentaje
- Fácil de interpretar
- **Problema:** División por cero cuando $y_i = 0$. Podemos solucionar reemplazando los que sean cero por un valor tipo 0.0000001, filtrar ceros, entre otras cosas.

Ejemplo Práctico de Regresión

Casa	Precio Real	Precio Predicho
1	30	28
2	45	47
3	20	19
4	60	62
5	35	33

Ejemplo Práctico de Regresión

Casa	Precio Real	Precio Predicho
1	30	28
2	45	47
3	20	19
4	60	62
5	35	33

- MSE

Ejemplo Práctico de Regresión

Casa	Precio Real	Precio Predicho
1	30	28
2	45	47
3	20	19
4	60	62
5	35	33

- $MSE = 18$

Ejemplo Práctico de Regresión

Casa	Precio Real	Precio Predicho
1	30	28
2	45	47
3	20	19
4	60	62
5	35	33

- $MSE = 18$
- RMSE

Ejemplo Práctico de Regresión

Casa	Precio Real	Precio Predicho
1	30	28
2	45	47
3	20	19
4	60	62
5	35	33

- $MSE = 18$
- $RMSE = 4.24$

Ejemplo Práctico de Regresión

Casa	Precio Real	Precio Predicho
1	30	28
2	45	47
3	20	19
4	60	62
5	35	33

- $MSE = 18$
- $RMSE = 4.24$
- MAE

Ejemplo Práctico de Regresión

Casa	Precio Real	Precio Predicho
1	30	28
2	45	47
3	20	19
4	60	62
5	35	33

- $MSE = 18$
- $RMSE = 4.24$
- $MAE = 3.6$

Ejemplo Práctico de Regresión

Casa	Precio Real	Precio Predicho
1	30	28
2	45	47
3	20	19
4	60	62
5	35	33

- $MSE = 18$
- $RMSE = 4.24$
- $MAE = 3.6$
- R^2

Ejemplo Práctico de Regresión

Casa	Precio Real	Precio Predicho
1	30	28
2	45	47
3	20	19
4	60	62
5	35	33

- $MSE = 18$
- $RMSE = 4.24$
- $MAE = 3.6$
- $R^2 = 0.95$

Ejemplo Práctico de Regresión

Casa	Precio Real	Precio Predicho
1	30	28
2	45	47
3	20	19
4	60	62
5	35	33

- $MSE = 18$
- $RMSE = 4.24$
- $MAE = 3.6$
- $R^2 = 0.95$
- $MAPE$

Ejemplo Práctico de Regresión

Casa	Precio Real	Precio Predicho
1	30	28
2	45	47
3	20	19
4	60	62
5	35	33

- $MSE = 18$
- $RMSE = 4.24$
- $MAE = 3.6$
- $R^2 = 0.95$
- $MAPE = 4.95\%$

En clasificación medimos la precisión de las predicciones categóricas

- Matriz de Confusión
- Métricas básicas (Accuracy, Precision, Recall, etc.)
- Métricas avanzadas (ROC, AUC, PR)
- Casos de uso específicos

Matriz de Confusión Binaria

		Real	
Predicho	Real	VP	FP
	Predicho	FN	VN

		Predicho	
Real	Predicho	VP	FN
	Real	FP	VN

- VP: Verdaderos Positivos
- VN: Verdaderos Negativos
- FP: Falsos Positivos
- FN: Falsos Negativos

Matriz de Confusión Multiclase

		R		
		L	N	S
P	L	85	10	5
	N	8	82	10
	S	7	12	81

- L: Lluvia
- N: Nublado
- S: Soleado

Accuracy (Exactitud)

$$\text{Accuracy} = \frac{\text{VP} + \text{VN}}{\text{VP} + \text{VN} + \text{FP} + \text{FN}}$$

Es el porcentaje total de predicciones correctas que hace nuestro modelo.

Precision (Precisión)

$$\text{Precision} = \frac{\text{VP}}{\text{VP} + \text{FP}}$$

Es qué tan confiables son nuestras predicciones positivas.

Specificity (Especificidad) / True Negative Rate (TNR)

$$\text{Specificity} = \frac{\text{VN}}{\text{VN} + \text{FP}}$$

Es qué tan bien identificamos los casos negativos correctamente.

Recall (Sensibilidad) / True Positive Rate (TPR)

$$\text{Recall (TPR)} = \frac{\text{VP}}{\text{VP} + \text{FN}}$$

Es qué tan bien detectamos todos los casos positivos que existen.

Fall-out / False Positive Rate (FPR)

$$\text{Fall-out (FPR)} = \frac{\text{FP}}{\text{FP} + \text{VN}}$$

Es qué tan seguido nos equivocamos prediciendo casos positivos.

Miss Rate / False Negative Rate (FNR)

$$\text{Miss Rate (FNR)} = \frac{\text{FN}}{\text{FN} + \text{VP}}$$

Es qué tan seguido nos perdemos casos positivos que deberíamos haber detectado.

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Es un balance entre la precisión y el recall, útil cuando las clases están desbalanceadas.

False Discovery Rate (FDR)

$$\text{FDR} = \frac{\text{FP}}{\text{FP} + \text{VP}}$$

Es qué tan seguido nos equivocamos cuando hacemos predicciones positivas.

False Omission Rate (FOR)

$$\text{FOR} = \frac{\text{FN}}{\text{FN} + \text{VN}}$$


Es qué tan seguido nos equivocamos cuando hacemos predicciones negativas.

Negative Predictive Value (NPV)

$$\text{NPV} = \frac{\text{VN}}{\text{VN} + \text{FN}}$$

Es qué tan confiables son nuestras predicciones negativas.

Curva ROC



La curva ROC muestra la relación entre TPR y FPR para diferentes umbrales. El área bajo la curva (AUC) indica el rendimiento del modelo.

¿Cómo entender la curva ROC?

Para cada punto de umbral existe una tasa de falsos positivos y una tasa de verdaderos positivos. Las coordenadas que trazamos son (FPR, TPR) en el eje X e Y respectivamente. Recordamos que:

$$\text{Fall-out (FPR)} = \frac{\text{FP}}{\text{FP} + \text{VN}}$$

$$\text{Recall (TPR)} = \frac{\text{VP}}{\text{VP} + \text{FN}}$$

Umbral 0 - Clasificar todo como positivo (1/2)

En el caso de un umbral 0, todo esta siendo calificado como positivo porque esta a la derecha del umbral, entonces:

		R	
P		α (VP)	β (FP)
		0 (FN)	0 (VN)

Umbral 0 - Clasificar todo como positivo (2/2)

$$\text{Fall-out (FPR)} = \frac{\text{FP}}{\text{FP} + \text{VN}} = \frac{\beta}{\beta + 0} = 1$$

$$\text{Recall (TPR)} = \frac{\text{VP}}{\text{VP} + \text{FN}} = \frac{\alpha}{\alpha + 0} = 0$$

Umbral 1 - Clasificar todo como negativo (1/2)

En el caso de un umbral 1, todo esta siendo calificado como negativo porque esta a la izquierda del umbral, entonces:

		R	
P		0 (VP)	0 (FP)
		α (FN)	β (VN)

Umbral 1 - Clasificar todo como negativo (2/2)

$$\text{Fall-out (FPR)} = \frac{\text{FP}}{\text{FP} + \text{VN}} = \frac{0}{0 + \beta} = 0$$

$$\text{Recall (TPR)} = \frac{\text{VP}}{\text{VP} + \text{FN}} = \frac{0}{0 + \alpha} = 0$$

Curva PR

La curva PR (Precision-Recall) es similar a la ROC pero con métricas diferentes:

- Eje X: Precisión
- Eje Y: Recall

Para cada umbral U:

- Calculamos precisión = $\frac{VP}{VP + FP}$
- Calculamos recall = $\frac{VP}{VP + FN}$

¿Cuándo usar la curva PR?

La curva PR es especialmente útil cuando:

- Tenemos clases desbalanceadas
- Nos interesa más la precisión que los falsos positivos
- El costo de los falsos negativos es alto

Salud

- Priorizar recall sobre precisión
- Usar curvas PR
- No usar accuracy como métrica principal

Justicia

- Usar curvas ROC
- Considerar impacto social
- Evaluar transparencia

Ejemplo Práctico

		R	
P		80	20
		10	90

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy

Ejemplo Práctico

	R	
P	80	20
	10	90

- $\text{Accuracy} = \frac{80+90}{200}$

Ejemplo Práctico

	R	
P	80	20
	10	90

- $\text{Accuracy} = \frac{80+90}{200} = 0.85$

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90}$

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR)

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100}$

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR)

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100}$

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$
- Fall-out (FPR)

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$
- Fall-out (FPR) = $\frac{10}{100}$

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$
- Fall-out (FPR) = $\frac{10}{100} = 0.10$

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$
- Fall-out (FPR) = $\frac{10}{100} = 0.10$
- Miss Rate (FNR)

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$
- Fall-out (FPR) = $\frac{10}{100} = 0.10$
- Miss Rate (FNR) = $\frac{20}{100}$

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$
- Fall-out (FPR) = $\frac{10}{100} = 0.10$
- Miss Rate (FNR) = $\frac{20}{100} = 0.20$

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$
- Fall-out (FPR) = $\frac{10}{100} = 0.10$
- Miss Rate (FNR) = $\frac{20}{100} = 0.20$
- F1

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$
- Fall-out (FPR) = $\frac{10}{100} = 0.10$
- Miss Rate (FNR) = $\frac{20}{100} = 0.20$
- F1 = $2 \times \frac{0.89 \times 0.80}{0.89 + 0.80}$

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$
- Fall-out (FPR) = $\frac{10}{100} = 0.10$
- Miss Rate (FNR) = $\frac{20}{100} = 0.20$
- F1 = $2 \times \frac{0.89 \times 0.80}{0.89 + 0.80} = 0.84$

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$
- Fall-out (FPR) = $\frac{10}{100} = 0.10$
- Miss Rate (FNR) = $\frac{20}{100} = 0.20$
- F1 = $2 \times \frac{0.89 \times 0.80}{0.89 + 0.80} = 0.84$
- FDR

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$
- Fall-out (FPR) = $\frac{10}{100} = 0.10$
- Miss Rate (FNR) = $\frac{20}{100} = 0.20$
- F1 = $2 \times \frac{0.89 \times 0.80}{0.89 + 0.80} = 0.84$
- FDR = $\frac{10}{90}$

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$
- Fall-out (FPR) = $\frac{10}{100} = 0.10$
- Miss Rate (FNR) = $\frac{20}{100} = 0.20$
- F1 = $2 \times \frac{0.89 \times 0.80}{0.89 + 0.80} = 0.84$
- FDR = $\frac{10}{90} = 0.11$

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$
- Fall-out (FPR) = $\frac{10}{100} = 0.10$
- Miss Rate (FNR) = $\frac{20}{100} = 0.20$
- F1 = $2 \times \frac{0.89 \times 0.80}{0.89 + 0.80} = 0.84$
- FDR = $\frac{10}{90} = 0.11$
- FOR

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$
- Fall-out (FPR) = $\frac{10}{100} = 0.10$
- Miss Rate (FNR) = $\frac{20}{100} = 0.20$
- F1 = $2 \times \frac{0.89 \times 0.80}{0.89 + 0.80} = 0.84$
- FDR = $\frac{10}{90} = 0.11$
- FOR = $\frac{20}{110}$

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$
- Fall-out (FPR) = $\frac{10}{100} = 0.10$
- Miss Rate (FNR) = $\frac{20}{100} = 0.20$
- F1 = $2 \times \frac{0.89 \times 0.80}{0.89 + 0.80} = 0.84$
- FDR = $\frac{10}{90} = 0.11$
- FOR = $\frac{20}{110} = 0.18$

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$
- Fall-out (FPR) = $\frac{10}{100} = 0.10$
- Miss Rate (FNR) = $\frac{20}{100} = 0.20$
- F1 = $2 \times \frac{0.89 \times 0.80}{0.89 + 0.80} = 0.84$
- FDR = $\frac{10}{90} = 0.11$
- FOR = $\frac{20}{110} = 0.18$
- NPV

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$
- Fall-out (FPR) = $\frac{10}{100} = 0.10$
- Miss Rate (FNR) = $\frac{20}{100} = 0.20$
- F1 = $2 \times \frac{0.89 \times 0.80}{0.89 + 0.80} = 0.84$
- FDR = $\frac{10}{90} = 0.11$
- FOR = $\frac{20}{110} = 0.18$
- NPV = $\frac{90}{110}$

Ejemplo Práctico

	R	
P	80	20
	10	90

- Accuracy = $\frac{80+90}{200} = 0.85$
- Precision = $\frac{80}{90} = 0.89$
- Specificity (TNR) = $\frac{90}{100} = 0.90$
- Recall (TPR) = $\frac{80}{100} = 0.80$
- Fall-out (FPR) = $\frac{10}{100} = 0.10$
- Miss Rate (FNR) = $\frac{20}{100} = 0.20$
- F1 = $2 \times \frac{0.89 \times 0.80}{0.89 + 0.80} = 0.84$
- FDR = $\frac{10}{90} = 0.11$
- FOR = $\frac{20}{110} = 0.18$
- NPV = $\frac{90}{110} = 0.82$

Implementación en Python - Regresión

```
1 # Para regresion
2 from sklearn.metrics import mean_squared_error, mean_absolute_error
3 from sklearn.metrics import r2_score
4
5 # Metricas de regresion
6 mse = mean_squared_error(y_true, y_pred)
7 rmse = np.sqrt(mse)
8 mae = mean_absolute_error(y_true, y_pred)
9 r2 = r2_score(y_true, y_pred)
```

Implementación en Python - Clasificación

```
1 # Para clasificacion
2 from sklearn.metrics import accuracy_score, precision_score
3 from sklearn.metrics import recall_score, f1_score
4 from sklearn.metrics import confusion_matrix
5 from sklearn.metrics import roc_curve, auc
6 from sklearn.metrics import precision_recall_curve
7
8 # Metricas basicas de clasificacion
9 accuracy = accuracy_score(y_true, y_pred)
10 precision = precision_score(y_true, y_pred)
11 recall = recall_score(y_true, y_pred)
12 f1 = f1_score(y_true, y_pred)
13
14 # Matriz de confusion
15 conf_matrix = confusion_matrix(y_true, y_pred)
16
17 # Curva ROC
18 fpr, tpr, _ = roc_curve(y_true, y_pred_proba)
19 roc_auc = auc(fpr, tpr)
20
21 # Curva PR
22 precision, recall, _ = precision_recall_curve(y_true, y_pred_proba)
```


La validación cruzada es una técnica de evaluación de modelos que nos permite estimar qué tan bien un modelo se generalizará a datos nuevos

- Especialmente útil cuando tenemos datos limitados
- Evita el sobreajuste (overfitting)
- Proporciona una estimación más robusta del rendimiento

K-Fold Cross Validation

1. Dividimos los datos en k partes iguales (folds)

K-Fold Cross Validation

1. Dividimos los datos en k partes iguales (folds)
2. En cada iteración, usamos un fold como validación

K-Fold Cross Validation

1. Dividimos los datos en k partes iguales (folds)
2. En cada iteración, usamos un fold como validación
3. Los $k-1$ folds restantes se usan para entrenar


K-Fold Cross Validation

1. Dividimos los datos en k partes iguales (folds)
2. En cada iteración, usamos un fold como validación
3. Los $k-1$ folds restantes se usan para entrenar
4. Repetimos k veces

K-Fold Cross Validation

1. Dividimos los datos en k partes iguales (folds)
2. En cada iteración, usamos un fold como validación
3. Los $k-1$ folds restantes se usan para entrenar
4. Repetimos k veces
5. Promediamos los resultados

Visualización de 5-Fold CV



Rojo = Validación, Gris = Entrenamiento

Ejemplo Práctico de CV

Iteración	Error Entrenamiento	Error Validación
1	0.15	0.18
2	0.14	0.19
3	0.16	0.17
4	0.15	0.20
5	0.14	0.18
Promedio	0.148	0.184

- Error promedio de validación: estimación robusta
- Diferencia entre entrenamiento y validación: indica overfitting
- Variación en validación: estabilidad del modelo

Consideraciones Importantes

Elección de k:

- $k=5$: Más rápido, mayor sesgo, menor varianza
- $k=10$: Más preciso, menor sesgo, mayor varianza

Mezcla de datos:

- Siempre mezclar aleatoriamente antes de dividir
- Usar `random_state` para reproducibilidad

Preprocesamiento:

- Hacer preprocesamiento dentro de cada fold
- Evitar data leakage

Implementación en Python - Cross Validation

```
1 from sklearn.model_selection import KFold, cross_val_score
2 from sklearn.linear_model import LogisticRegression
3
4 # Crear el modelo
5 model = LogisticRegression()
6
7 # Configurar 5-fold CV
8 kfold = KFold(n_splits=5, shuffle=True, random_state=42)
9
10 # Calcular scores
11 scores = cross_val_score(model, X, y, cv=kfold)
12
13 # Imprimir resultados
14 print(f"Scores por fold: {scores}")
15 print(f"Score promedio: {scores.mean():.3f}")
16 print(f"Desviacion estandar: {scores.std():.3f}")
```

¿Dudas?
¿Consultas?



Universidad de
SanAndrés