

Guía de Ejercicios - Naive Bayes

Analítica de Datos, Universidad de San Andrés

Si encuentran algún error en el documento o hay alguna duda, mandenme un mail a rodriguezf@udesa.edu.ar y lo revisamos.

1. Ejercicios Conceptuales

1.1. Verdadero o Falso

1. Es necesario escalar los datos antes de entrenar un modelo de Naive Bayes.
2. Naive Bayes asume independencia condicional entre las características.
3. Multinomial Naive Bayes es apropiado para clasificación de texto.
4. Gaussian Naive Bayes puede manejar características continuas.
5. Laplace smoothing se usa para evitar probabilidades cero.
6. Naive Bayes siempre tiene mejor rendimiento que otros algoritmos de clasificación.
7. La suposición de independencia nunca se cumple en datos reales.
8. Bernoulli Naive Bayes es útil para características binarias.
9. Naive Bayes es un algoritmo de aprendizaje discriminativo.
10. Naive Bayes puede usarse tanto para clasificación como para regresión.

1.2. Opción Múltiple

1. ¿Por qué se llama “Naive” (ingenuo) al algoritmo Naive Bayes?
 - a) Porque es un algoritmo simple
 - b) Porque asume independencia entre características
 - c) Porque solo funciona con datos pequeños

- d) Porque no es muy preciso
2. ¿Cuál es la ventaja principal de Naive Bayes sobre otros algoritmos?
 - a) Mayor precisión
 - b) Manejo automático de missing values
 - c) Velocidad de entrenamiento y predicción
 - d) No requiere normalización
3. ¿Qué tipo de Naive Bayes usarías para clasificación de emails spam?
 - a) Gaussian
 - b) Multinomial
 - c) Bernoulli
 - d) Cualquiera de los anteriores
4. ¿Cuándo aplicarías Laplace smoothing?
 - a) Siempre
 - b) Solo con datos grandes
 - c) Solo con Gaussian Naive Bayes
 - d) Cuando hay probabilidades cero
5. ¿Qué sucede si la suposición de independencia se viola severamente?
 - a) Puede reducir el rendimiento
 - b) El algoritmo no funciona
 - c) No hay impacto
 - d) Mejora el rendimiento

2. Ejercicios Prácticos

2.1. Ejercicio 1 - Cálculo Manual de Probabilidades

El siguiente conjunto de datos brinda información de las condiciones climáticas de 10 días diferentes junto a una etiqueta que nos indica si Juan sale

a correr ese día o no. Va a ser nuestro set de entrenamiento para un modelo de clasificación.

Obs	Lluvia	Temperatura	Viento	¿Entrena?
1	SI	Frío	Fuerte	NO
2	NO	Templado	Débil	SI
3	SI	Cálido	Fuerte	SI
4	SI	Templado	Fuerte	NO
5	NO	Templado	Débil	SI
6	NO	Cálido	Fuerte	NO
7	NO	Frío	Fuerte	SI
8	SI	Frío	Débil	NO
9	NO	Cálido	Débil	NO
10	SI	Templado	Fuerte	SI

- Entrenar un modelo de Naive Bayes
- Considerando la siguiente muestra de test, calcular las probabilidades de entrenar y no entrenar para cada observación, elegir una métrica de bondad de ajuste del modelo y reportar su valor:

Obs	Lluvia	Temperatura	Viento	¿Entrena?
11	NO	Templado	Débil	SI
12	SI	Frío	Fuerte	NO
13	SI	Cálido	Débil	SI

2.2. Ejercicio 2 - Clasificación de Spam

Considerar el siguiente dataset para clasificar emails como “Spam” o “No Spam” basándose en la presencia de ciertas palabras:

Email	Gratis	Dinero	Oferta	Clase
1	1	0	1	Spam
2	0	1	0	Spam
3	1	1	1	Spam
4	0	0	0	No Spam
5	0	0	1	No Spam
6	1	0	0	Spam

- a. Calcular las probabilidades a priori de cada clase
- b. Calcular las probabilidades condicionales para cada característica
- c. Clasificar un nuevo email con características: Gratis=1, Dinero=0, Oferta=0
- d. ¿Qué sucede si aplicamos Laplace smoothing con $\alpha = 1$? Recalcular la clasificación del inciso c.

2.3. Ejercicio 3 - Bag of Words y NLP

Cuando usamos la técnica Bag of Words para preprocesar los datos previo al entrenamiento de un modelo de NLP (Natural Language Processing o Procesamiento de Lenguaje Natural), ¿Qué características tiene el dataset luego de ese preprocesamiento? Supongamos que queremos clasificar artículos periodísticos en cuatro categorías diferentes (Economía, Deportes, Cultura y Ciencia), ¿Cómo funciona un modelo de Naive Bayes en este caso?

2.4. Ejercicio 4 - Implementación en Python

Implementar en Python un modelo de Naive Bayes para el dataset del Ejercicio 1 usando scikit-learn. El código debe incluir:

- a. Preprocesamiento de datos categóricos
- b. División en entrenamiento y prueba
- c. Entrenamiento del modelo
- d. Evaluación con métricas apropiadas
- e. Matriz de confusión

```

1 # Código base para completar
2 import pandas as pd
3 from sklearn.naive_bayes import GaussianNB
4 from sklearn.preprocessing import LabelEncoder
5 from sklearn.model_selection import train_test_split
6 from sklearn.metrics import classification_report,
   confusion_matrix
7
8 # Completar la implementacion...
```

2.5. Ejercicio 5 - Problema Médico

Un médico quiere usar Naive Bayes para diagnosticar una enfermedad basándose en síntomas. Los datos históricos muestran:

- $P(\text{Enfermedad}) = 0.01$ (1 % de la población tiene la enfermedad)
 - $P(\text{Síntoma}|\text{Enfermedad}) = 0.9$ (90 % de los enfermos presenta el síntoma)
 - $P(\text{Síntoma}|\text{Sano}) = 0.05$ (5 % de los sanos presenta el síntoma)
- a. Si un paciente presenta el síntoma, ¿cuál es la probabilidad de que tenga la enfermedad?
 - b. ¿Por qué este resultado puede ser contraintuitivo?
 - c. ¿Qué implicaciones tiene esto para el uso de Naive Bayes en medicina?

2.6. Ejercicio 6 - Clasificación de Texto Avanzada

Para un problema de clasificación de texto, tienes un corpus con las siguientes características:

- 10,000 documentos de entrenamiento
 - 50,000 palabras únicas en el vocabulario
 - 3 clases diferentes
 - Algunos documentos muy cortos (2-3 palabras) y otros muy largos (1000+ palabras)
- a. ¿Qué variante de Naive Bayes usarías y por qué?
 - b. ¿Cómo manejarías el problema de palabras que aparecen en test pero no en entrenamiento?
 - c. ¿Aplicarías algún preprocesamiento adicional? ¿Cuál?
 - d. ¿Cómo evaluarías el modelo considerando que las clases podrían estar desbalanceadas?

3. Soluciones

3.1. Soluciones - Verdadero o Falso

1. **Falso.** Naive Bayes no requiere escalado de datos porque trabaja con probabilidades, no con distancias.
2. **Verdadero.** Esta es la suposición fundamental del algoritmo.
3. **Verdadero.** Es ideal para datos de conteo de palabras.
4. **Verdadero.** Asume distribución gaussiana para características continuas.
5. **Verdadero.** Evita el problema de probabilidades cero en datos de entrenamiento.
6. **Falso.** El rendimiento depende del problema y los datos específicos.
7. **Falso.** Aunque rara vez se cumple perfectamente, el algoritmo puede funcionar bien incluso con dependencias moderadas.
8. **Verdadero.** Especialmente útil para características de presencia/ausencia.
9. **Falso.** Es un algoritmo generativo, no discriminativo.
10. **Falso.** Principalmente se usa para clasificación.

3.2. Soluciones - Opción Múltiple

1. **b)** Porque asume independencia entre características, lo cual rara vez es cierto en la realidad.
2. **c)** Velocidad de entrenamiento y predicción - es muy eficiente computacionalmente.
3. **b)** Multinomial - apropiado para conteos de palabras en documentos.
4. **d)** Cuando hay probabilidades cero que pueden causar problemas en el cálculo.
5. **a)** Puede reducir el rendimiento, pero el algoritmo sigue siendo robusto.

3.3. Soluciones - Ejercicios 1

- Contar observaciones por clase para calcular probabilidades a priori
- Para cada característica, calcular $P(\text{característica}|\text{clase})$ dividiendo conteos
- Para predecir: aplicar teorema de Bayes multiplicando probabilidades
- Accuracy final: 2 de 3 predicciones correctas

3.4. Soluciones - Ejercicio 2

- $P(\text{Spam}) = 4/6$, $P(\text{No Spam}) = 2/6$
- Calcular probabilidades condicionales para cada palabra
- Cuidado con probabilidades cero en No Spam
- Con Laplace smoothing: agregar 1 al numerador y k al denominador
- El smoothing evita multiplicar por cero

3.5. Soluciones - Ejercicio 3

Bag of Words convierte texto en matriz numérica dispersa. Multinomial Naive Bayes es ideal para conteos de palabras en clasificación de documentos.

3.6. Soluciones - Ejercicio 4

- Usar LabelEncoder para variables categóricas
- Aplicar train_test_split para división de datos
- Entrenar con CategoricalNB o MultinomialNB según el tipo de datos
- Evaluar con accuracy, precision, recall y matriz de confusión

3.7. Soluciones - Ejercicio 5

Aplicar teorema de Bayes: $P(\text{Enfermedad}|\text{Síntoma}) \approx 0.154$ (15.4 %). La baja prevalencia (1 %) hace que sea menos probable tener la enfermedad incluso con síntoma positivo.

3.8. Soluciones - Ejercicio 6

Usar Multinomial Naive Bayes para texto. Aplicar Laplace smoothing para palabras nuevas. Preprocesar con tokenización, remoción de stopwords y stemming. Evaluar con F1-score macro para clases desbalanceadas.