

Naive Bayes

Analítica de Datos



¿Qué es Naive Bayes?

Definición:

- Algoritmo de aprendizaje automático basado en el teorema de Bayes
- Asume independencia condicional entre características
- “Ingenuo” por esta suposición simplificadora

¿Por qué funciona bien?

- Simple y rápido de entrenar
- Efectivo en muchas situaciones reales
- Maneja bien datos faltantes

Fórmula fundamental:

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

$P(Y|X)$ Probabilidad posterior

$P(X|Y)$ Verosimilitud


$P(Y)$ Probabilidad a priori

$P(X)$ Evidencia

Suposición de Independencia

Naive Bayes asume que las características son independientes:

$$P(X|Y) = P(X_1|Y) \times P(X_2|Y) \times \dots \times P(X_n|Y)$$



Tipos de Naive Bayes

- **BernoulliNB**: para variables binarias (presencia/ausencia de una característica).
- **CategoricalNB**: para datos categóricos o discretos.
- **MultinomialNB**: para conteos y frecuencias (por ejemplo, clasificación de texto).
- **ComplementNB**: para situaciones con clases desbalanceadas.
- **GaussianNB**: para variables continuas (asume distribución normal).

Ejemplo Práctico: Predicción de Aprobación

¿Va a aprobar el estudiante el examen?

Tiempo de estudio	Método de estudio	Puntuación	Resultado
Bajo	Lectura	Bajo	Desaprobó
Bajo	Práctica	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Alto	L y P	Alta	Aprobó
Alto	Lectura	Alta	Desaprobó
Bajo	L y P	Baja	Desaprobó
Alto	Práctica	Alta	Aprobó
Moderado	Lectura	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Moderado	Práctica	Bajo	Desaprobó

Tablas de Frecuencia

Tiempo de Estudio:

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

Método de Estudio:

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Tabla de Frecuencia - Puntuación

Puntuación en exámenes anteriores:

Puntuación	Aprobó	Desaprobó	Total
Bajo	0	3	3
Promedio	2	0	2
Alto	4	1	5
Total	6	4	10

Aplicación del Teorema de Bayes

Probabilidades a priori:

$$P(\text{Aprobó}) = \frac{6}{10} = 0,6$$

$$P(\text{Desaprobó}) = \frac{4}{10} = 0,4$$

Nuevo caso: Alto tiempo, L y P método, Alta puntuación

$$P(\text{Aprobó}|X) = 0,6 \times \frac{2}{6} \times \frac{3}{6} \times \frac{4}{6} = 0,13$$

$$P(\text{Desaprobó}|X) = 0,4 \times \frac{1}{4} \times \frac{1}{4} \times \frac{1}{4} = 0,006$$

Predicción: Aprobó (0.13 > 0.006)

Ventajas y Desventajas

Ventajas:

- ✓ Simple y rápido de entrenar
- ✓ Funciona bien con datos pequeños
- ✓ Maneja datos faltantes
- ✓ Fácil de interpretar

Desventajas:

- ✗ Suposición de independencia
- ✗ Sensible a características irrelevantes
- ✗ No captura relaciones complejas
- ✗ Problemas con probabilidades cero

Si bien no es un algoritmo de clasificación perfecto, Naive Bayes es útil en muchas aplicaciones prácticas como por ejemplo:

- Filtrado de correos spam.
- Análisis de sentimientos y opiniones.
- Diagnóstico médico automático.
- Detección de fraude.
- Clasificación de malware.

Problema: Probabilidades condicionales cero

Solución: Suavizado de Laplace

$$P(x_i|y) = \frac{\text{count}(x_i, y) + \alpha}{\text{count}(y) + \alpha \times n}$$

Ejemplo:

- $\alpha = 1$ (suavizado de Laplace)
- $\text{count}(x_i, y) = 0$ (palabra nunca apareció)
- $\text{count}(y) = 10$ (total documentos en clase)
- $n = 1000$ (cantidad características)

$$P(x_i|y) = \frac{0 + 1}{10 + 1 \times 1000} = \frac{1}{1010} \approx 0,001$$

Implementación en Python

```
1 from sklearn.naive_bayes import GaussianNB
2 from sklearn.naive_bayes import MultinomialNB
3 from sklearn.naive_bayes import BernoulliNB
4 from sklearn.naive_bayes import CategoricalNB
5 from sklearn.naive_bayes import ComplementNB
6
7 # Para datos continuos (distribucion normal)
8 model = GaussianNB()
9
10 # Para datos discretos (conteos)
11 model = MultinomialNB()
12
13 # Para datos binarios (presencia/ausencia)
14 model = BernoulliNB()
15
16 # Para datos categoricos
17 model = CategoricalNB()
18
19 # Para datos desbalanceados
20 model = ComplementNB()
21
22 # Entrenamiento
23 model.fit(X_train, y_train)
24
25 # Prediccion
26 y_pred = model.predict(X_test)
```

¿Dudas?
¿Consultas?



Universidad de
SanAndrés