

Naive Bayes

Analítica de Datos



¿Qué es Naive Bayes?

Definición:

- Algoritmo de aprendizaje automático basado en el teorema de Bayes
- Asume independencia condicional entre características
- “Ingenuo” por esta suposición simplificadora

¿Por qué funciona bien?

- Simple y rápido de entrenar
- Efectivo en muchas situaciones reales
- Maneja bien datos faltantes

Fórmula fundamental:

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

$P(Y|X)$ Probabilidad posterior

$P(X|Y)$ Verosimilitud


$P(Y)$ Probabilidad a priori

$P(X)$ Evidencia

Suposición de Independencia

Naive Bayes asume que las características son independientes:

$$P(X|Y) = P(X_1|Y) \times P(X_2|Y) \times \dots \times P(X_n|Y)$$



Tipos de Naive Bayes

- **BernoulliNB**: para variables binarias (presencia/ausencia de una característica).
- **CategoricalNB**: para datos categóricos o discretos.
- **MultinomialNB**: para conteos y frecuencias (por ejemplo, clasificación de texto).
- **ComplementNB**: para situaciones con clases desbalanceadas.
- **GaussianNB**: para variables continuas (asume distribución normal).

Variables Categóricas vs Continuas

¿Cuál es la diferencia?

Variables Categóricas

- Valores discretos
- Ej: Bajo, Medio, Alto
- Método: Contar frecuencias
- Fórmula simple: $\frac{\text{count}}{\text{total}}$

Variables Continuas

- Valores reales
- Ej: 25.3, 70.5, 1.78
- Método: Calcular μ y σ
- Fórmula: Dist. Normal

Gaussian Naive Bayes

Para variables continuas:

En lugar de contar frecuencias, calculamos dos parámetros por característica y clase:

- **Media (μ):** Promedio de los valores
- **Desviación estándar (σ):** Dispersión de los valores

Función de densidad de probabilidad gaussiana:

$$P(x|y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

Pasos para clasificar:

1. Para cada característica y cada clase, calcular μ y σ
2. Para un nuevo dato, aplicar la fórmula gaussiana usando los parámetros de cada clase
3. Multiplicar las probabilidades de todas las características
4. Elegir la clase con mayor probabilidad posterior

Ejercicio 1: Clasificación de Estudiantes

¿Va a aprobar el estudiante el examen?

Tiempo de estudio	Método de estudio	Puntuación	Resultado
Bajo	Lectura	Bajo	Desaprobó
Bajo	Práctica	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Alto	L y P	Alta	Aprobó
Alto	Lectura	Alta	Desaprobó
Bajo	L y P	Baja	Desaprobó
Alto	Práctica	Alta	Aprobó
Moderado	Lectura	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Moderado	Práctica	Bajo	Desaprobó

Tablas de Frecuencia

Tiempo de Estudio:

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

Método de Estudio:

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Tabla de Frecuencia - Puntuación

Puntuación en exámenes anteriores:

Puntuación	Aprobó	Desaprobó	Total
Bajo	0	3	3
Promedio	2	0	2
Alto	4	1	5
Total	6	4	10

Aplicación del Teorema de Bayes

Probabilidades a priori:

$$P(\text{Aprobó}) = \frac{6}{10} = 0,6$$

$$P(\text{Desaprobó}) = \frac{4}{10} = 0,4$$

Nuevo caso: Alto tiempo, L y P método, Alta puntuación

$$P(\text{Aprobó}|X) = 0,6 \times \frac{2}{6} \times \frac{3}{6} \times \frac{4}{6} = 0,13$$

$$P(\text{Desaprobó}|X) = 0,4 \times \frac{1}{4} \times \frac{1}{4} \times \frac{1}{4} = 0,006$$

Predicción: Aprobó (0.13 > 0.006)

Problema: Probabilidades condicionales cero

Solución: Suavizado de Laplace

$$P(x_i|y) = \frac{\text{count}(x_i, y) + \alpha}{\text{count}(y) + \alpha \times n}$$

Ejemplo:

- $\alpha = 1$ (suavizado de Laplace)
- $\text{count}(x_i, y) = 0$ (palabra nunca apareció)
- $\text{count}(y) = 10$ (total documentos en clase)
- $n = 1000$ (cantidad características)

$$P(x_i|y) = \frac{0 + 1}{10 + 1 \times 1000} = \frac{1}{1010} \approx 0,001$$

Ejercicio 2: Clasificación de Riesgo Crediticio

Problema: Clasificar clientes en 3 categorías de riesgo

Riesgo: Bajo, Medio, Alto

Características:

- Nivel de Ingreso: Bajo, Medio, Alto
- Historial Crediticio: Malo, Regular, Bueno
- Tipo de Empleo: Temporal, Permanente
- Nivel de Deudas: Bajo, Alto

Datos: 15 clientes

- 4 con Riesgo Bajo
- 6 con Riesgo Medio
- 5 con Riesgo Alto

Ejercicio 2: Datos de Entrenamiento

Tabla completa de datos (15 clientes):

Ingreso	Historial	Empleo	Deudas	Riesgo
Alto	Bueno	Permanente	Bajo	Bajo
Alto	Bueno	Permanente	Bajo	Bajo
Medio	Bueno	Permanente	Bajo	Bajo
Alto	Regular	Permanente	Bajo	Bajo
Medio	Bueno	Temporal	Bajo	Medio
Medio	Regular	Permanente	Alto	Medio
Bajo	Regular	Temporal	Alto	Medio
Medio	Regular	Temporal	Bajo	Medio
Bajo	Malo	Temporal	Alto	Alto
Bajo	Malo	Temporal	Alto	Alto
Bajo	Regular	Temporal	Alto	Alto
Medio	Malo	Temporal	Alto	Alto
Bajo	Malo	Permanente	Alto	Alto
Alto	Malo	Temporal	Alto	Medio
Medio	Bueno	Permanente	Alto	Medio

Ejercicio 2: Tablas de Frecuencia

Nivel de Ingreso:

Ingreso	Bajo	Medio	Alto	Total
Alto	3	1	0	4
Medio	1	4	1	6
Bajo	0	1	4	5
Total	4	6	5	15

Historial Crediticio:

Historial	Bajo	Medio	Alto	Total
Bueno	3	2	0	5
Regular	1	2	1	4
Malo	0	2	4	6
Total	4	6	5	15

Tipo de Empleo:

Empleo	Bajo	Medio	Alto	Total
Permanente	4	2	1	7
Temporal	0	4	4	8
Total	4	6	5	15

Nivel de Deudas:

Deudas	Bajo	Medio	Alto	Total
Bajo	4	2	0	6
Alto	0	4	5	9
Total	4	6	5	15

Ejercicio 2: Nuevo Cliente a Clasificar

Clasificar un cliente con:

- Ingreso: Medio
- Historial: Bueno
- Empleo: Temporal
- Deudas: Bajo

Ejercicio 2: Probabilidades a Priori

Probabilidades a priori:

$$P(\text{Riesgo Bajo}) = \frac{4}{15} \approx 0,267$$

$$P(\text{Riesgo Medio}) = \frac{6}{15} = 0,4$$

$$P(\text{Riesgo Alto}) = \frac{5}{15} \approx 0,333$$

Ejercicio 2: ¡Problema con Probabilidad Cero!

Calculando para Riesgo Bajo (sin suavizado):

$$\begin{aligned}P(\text{Bajo}|X) &= P(\text{Bajo}) \times P(\text{Medio}|\text{Bajo}) \\&\quad \times P(\text{Bueno}|\text{Bajo}) \times P(\text{Temporal}|\text{Bajo}) \\&\quad \times P(\text{Bajo deudas}|\text{Bajo}) \\&= \frac{4}{15} \times \frac{1}{4} \times \frac{3}{4} \times \frac{0}{4} \times \frac{4}{4} \\&= 0\end{aligned}$$

¡La probabilidad es cero!

Ningún cliente de Riesgo Bajo tiene empleo Temporal

Ejercicio 2: Solución con Laplace Smoothing

Aplicamos suavizado de Laplace ($\alpha = 1$):

$$P(x_i|y) = \frac{\text{count}(x_i, y) + 1}{\text{count}(y) + n}$$

Recalculando probabilidades para Riesgo Bajo:

$$P(\text{Medio}|\text{Bajo}) = \frac{1 + 1}{4 + 3} = \frac{2}{7} \approx 0,286$$

$$P(\text{Bueno}|\text{Bajo}) = \frac{3 + 1}{4 + 3} = \frac{4}{7} \approx 0,571$$

$$P(\text{Temporal}|\text{Bajo}) = \frac{0 + 1}{4 + 2} = \frac{1}{6} \approx 0,167$$

$$P(\text{Bajo deudas}|\text{Bajo}) = \frac{4 + 1}{4 + 2} = \frac{5}{6} \approx 0,833$$

$$P(\text{Bajo}|X) \approx 0,00303 \text{ (ya no es cero!)}$$

Ejercicio 2: Resultado Final

Comparando las tres clases (con Laplace):

Clase	Probabilidad Posterior
Riesgo Bajo	0.00303
Riesgo Medio	0.01736 ← Mayor
Riesgo Alto	0.00106

Clasificación: Riesgo Medio

Sin Laplace smoothing habríamos tenido un error!

Ejercicio 3: Gaussian NB - Actividad Física

Problema: ¿Hace ejercicio regularmente?

Clase: Sí / No

Variables continuas:

- Edad (años)
- Peso (kg)
- Horas de sueño (horas/día)

Datos: 12 personas

- 6 que hacen ejercicio
- 6 que no hacen ejercicio

Ejercicio 3: Datos de Entrenamiento

Tabla completa de datos (12 personas):

Edad	Peso	Horas de sueño	Hace Ejercicio
22	65	7.5	Sí
25	70	8.0	Sí
23	68	7.0	Sí
28	72	7.5	Sí
24	66	8.5	Sí
26	69	7.8	Sí
45	85	6.0	No
50	90	5.5	No
48	88	6.2	No
52	92	5.8	No
49	87	6.5	No
47	86	5.9	No

Ejercicio 3: Parámetros Calculados

Para cada clase, calculamos μ y σ de cada variable:

Característica	Clase	μ	σ
Edad	Sí	24.67	1.97
Edad	No	48.5	2.22
Peso	Sí	68.33	2.36
Peso	No	88.0	2.38
Sueño	Sí	7.72	0.47
Sueño	No	5.98	0.31

Estos parámetros se usan en la fórmula gaussiana para calcular probabilidades

Ejercicio 3: Clasificar Nueva Persona

Persona con:

Edad: 30 años, Peso: 75 kg, Sueño: 7 horas

Aplicando la fórmula gaussiana:

$$P(x|y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

Probabilidad	Valor
$P(30 \text{Sí})$	0.0053
$P(75 \text{Sí})$	0.0031
$P(7 \text{Sí})$	0.261
$P(\text{Sí} X)$	0.0000021

Ejercicio 3: Resultado Final

Comparando ambas clases:

Clase	Probabilidad Posterior
Hace ejercicio: Sí	0.0000021 ← Mayor
Hace ejercicio: No	$2,25 \times 10^{-16}$

Clasificación: SÍ hace ejercicio

Persona de 30 años está mucho más cerca del perfil de quienes hacen ejercicio (jóvenes) que de quienes no (mayores de 45)

Ventajas y Desventajas

Ventajas:

- ✓ Simple y rápido de entrenar
- ✓ Funciona bien con datos pequeños
- ✓ Maneja datos faltantes
- ✓ Fácil de interpretar

Desventajas:

- ✗ Suposición de independencia
- ✗ Sensible a características irrelevantes
- ✗ No captura relaciones complejas
- ✗ Problemas con probabilidades cero

Si bien no es un algoritmo de clasificación perfecto, Naive Bayes es útil en muchas aplicaciones prácticas como por ejemplo:

- Filtrado de correos spam.
- Análisis de sentimientos y opiniones.
- Diagnóstico médico automático.
- Detección de fraude.
- Clasificación de malware.

Implementación en Python

```
1 from sklearn.naive_bayes import GaussianNB
2 from sklearn.naive_bayes import MultinomialNB
3 from sklearn.naive_bayes import BernoulliNB
4 from sklearn.naive_bayes import CategoricalNB
5 from sklearn.naive_bayes import ComplementNB
6
7 # Para datos continuos (distribucion normal)
8 model = GaussianNB()
9
10 # Para datos discretos (conteos)
11 model = MultinomialNB()
12
13 # Para datos binarios (presencia/ausencia)
14 model = BernoulliNB()
15
16 # Para datos categoricos
17 model = CategoricalNB()
18
19 # Para datos desbalanceados
20 model = ComplementNB()
21
22 # Entrenamiento
23 model.fit(X_train, y_train)
24
25 # Prediccion
26 y_pred = model.predict(X_test)
```

¿Dudas?
¿Consultas?