ANALÍTICA DE DATOS

# Aprendizaje no supervisado

## K-means, clustering jerárquico y PCA

Clase práctica · 2do cuatrimestre 2026

Universidad de San Andrés

# Hasta ahora: aprendizaje supervisado

## Supervisado

*CART, KNN, RF, Naive Bayes*

- Hay una columna respuesta: ¿pagó?, ¿compró?
- El modelo aprende a **predecirla**
- Podemos medir si acierta

## No supervisado (hoy)

*K-means, jerárquico, PCA*

- No hay respuesta: solo características
- Buscamos **estructura**: grupos, patrones
- La utilidad la decide el negocio

# Tres preguntas de negocio, tres técnicas

## K-means

¿Qué tipos de clientes tengo?

*200 clientes de un shopping*

## Jerárquico

¿Qué países se parecen entre sí?

*193 países (ONU)*

## PCA

¿Cómo resumo 12 métricas en un mapa?

*93 modelos de autos*

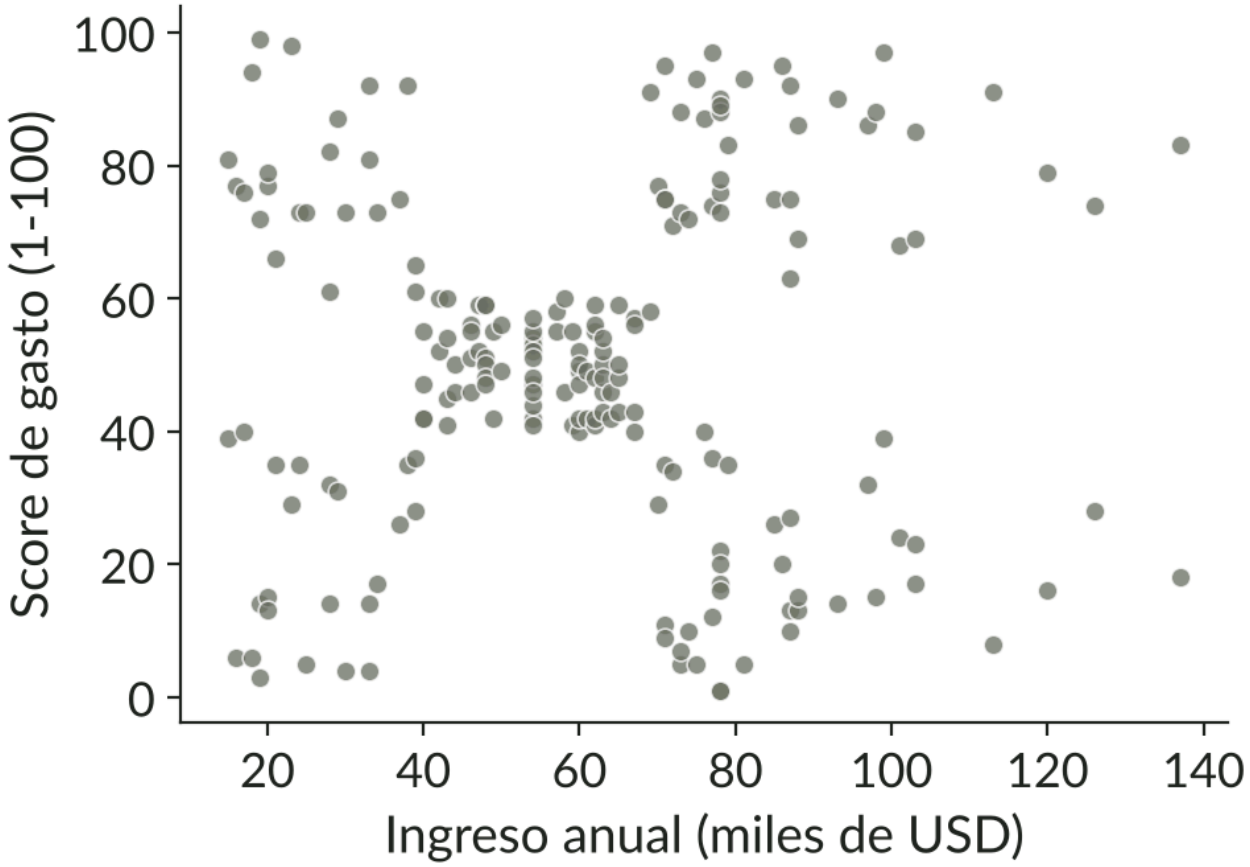
Las dos primeras **agrupan filas**. PCA **resume columnas**.

PARTE 1

# K-means

Segmentar clientes

# El problema

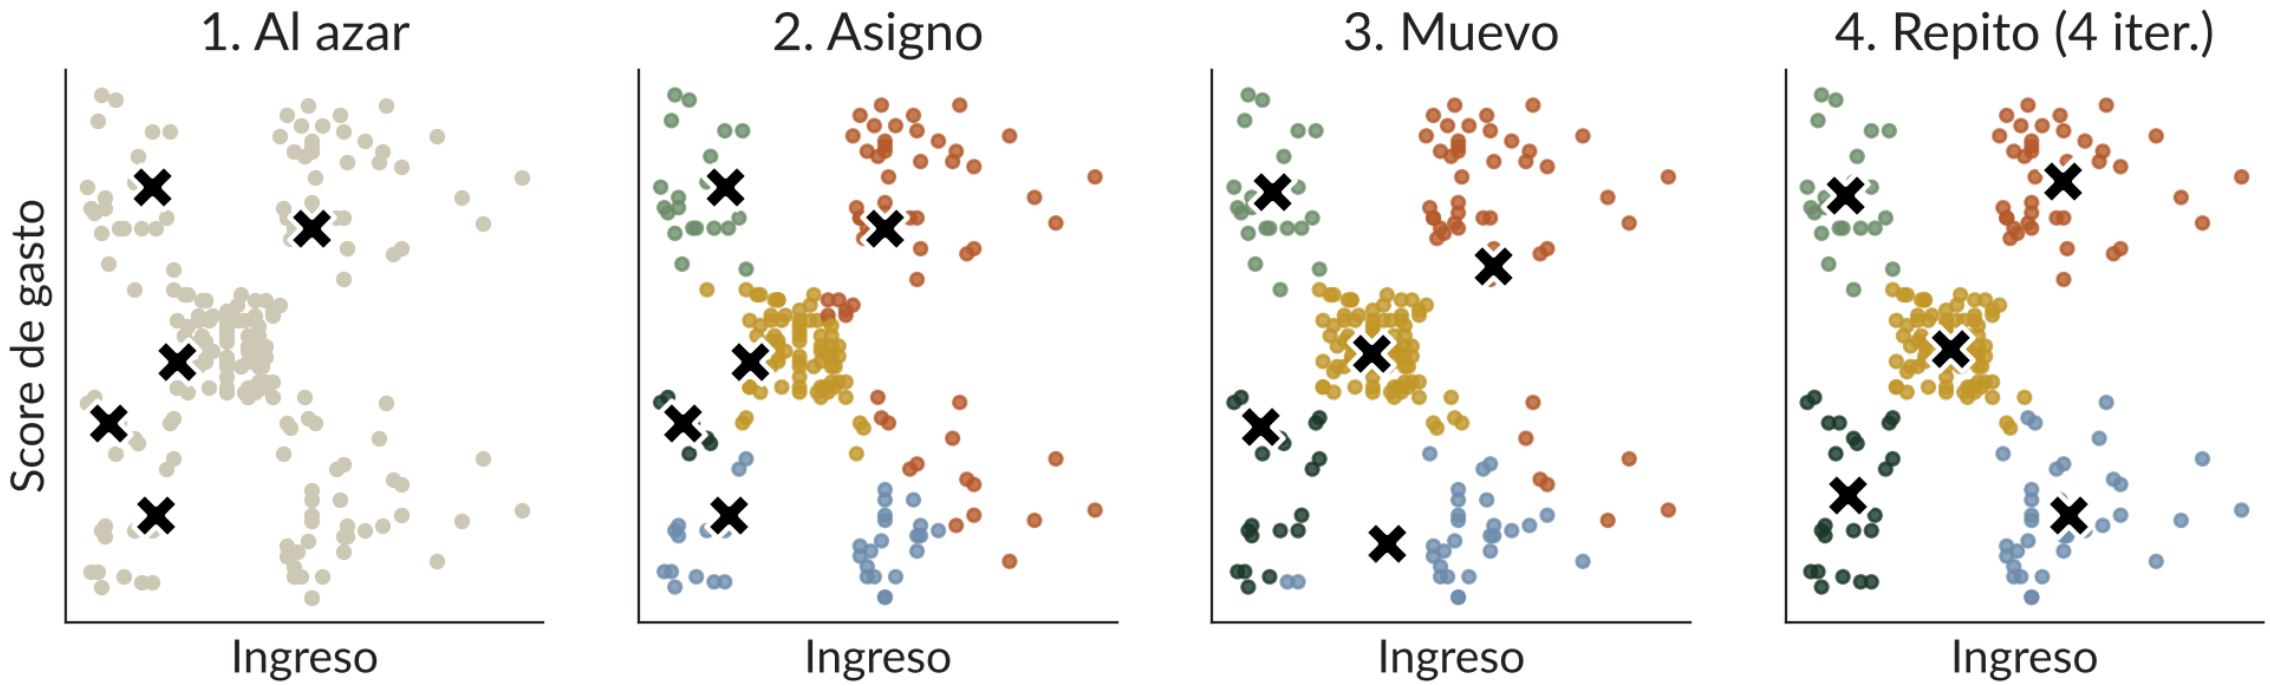



Marketing de un shopping: **ingreso** y **score de gasto** de cada cliente.

Queremos campañas para distintos tipos de clientes, pero nadie nos dijo cuáles son.

**¿Cuántos grupos ves?**

# La idea: K "clientes representantes"




K centroides al azar → cada cliente al **más cercano** → cada centroide al **promedio** → repetir.

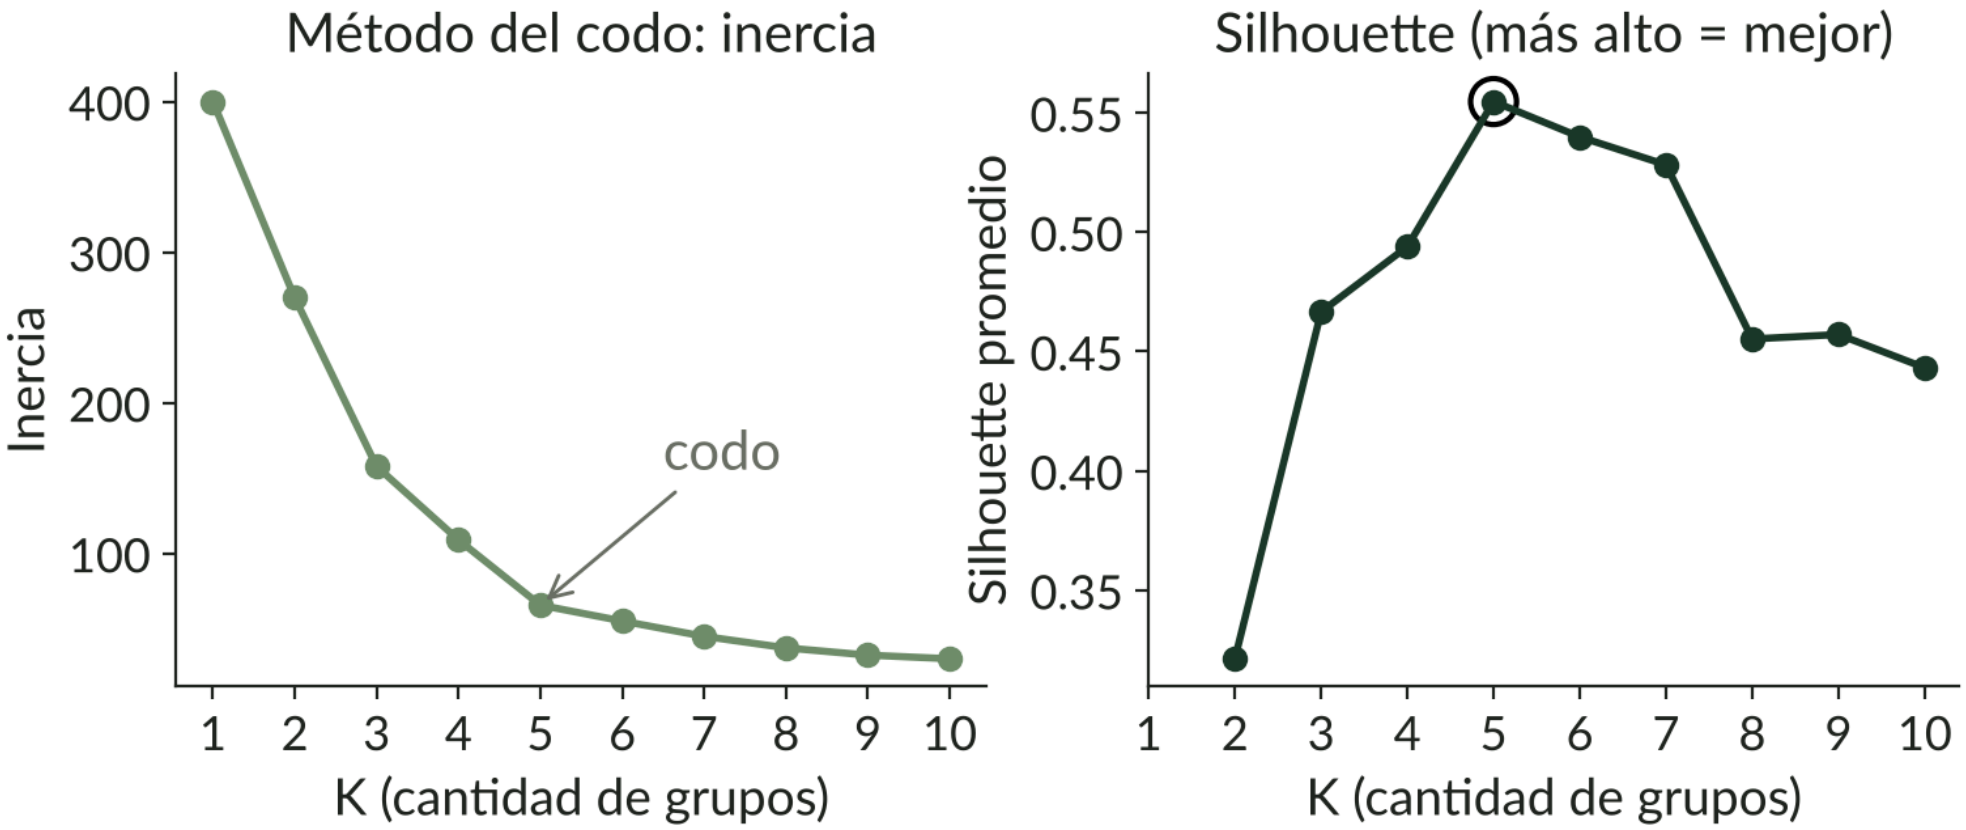
# La matemática, muy por arriba

K-means minimiza la inercia:

$$\Sigma \text{ distancia(cliente, su centroide)}^2$$

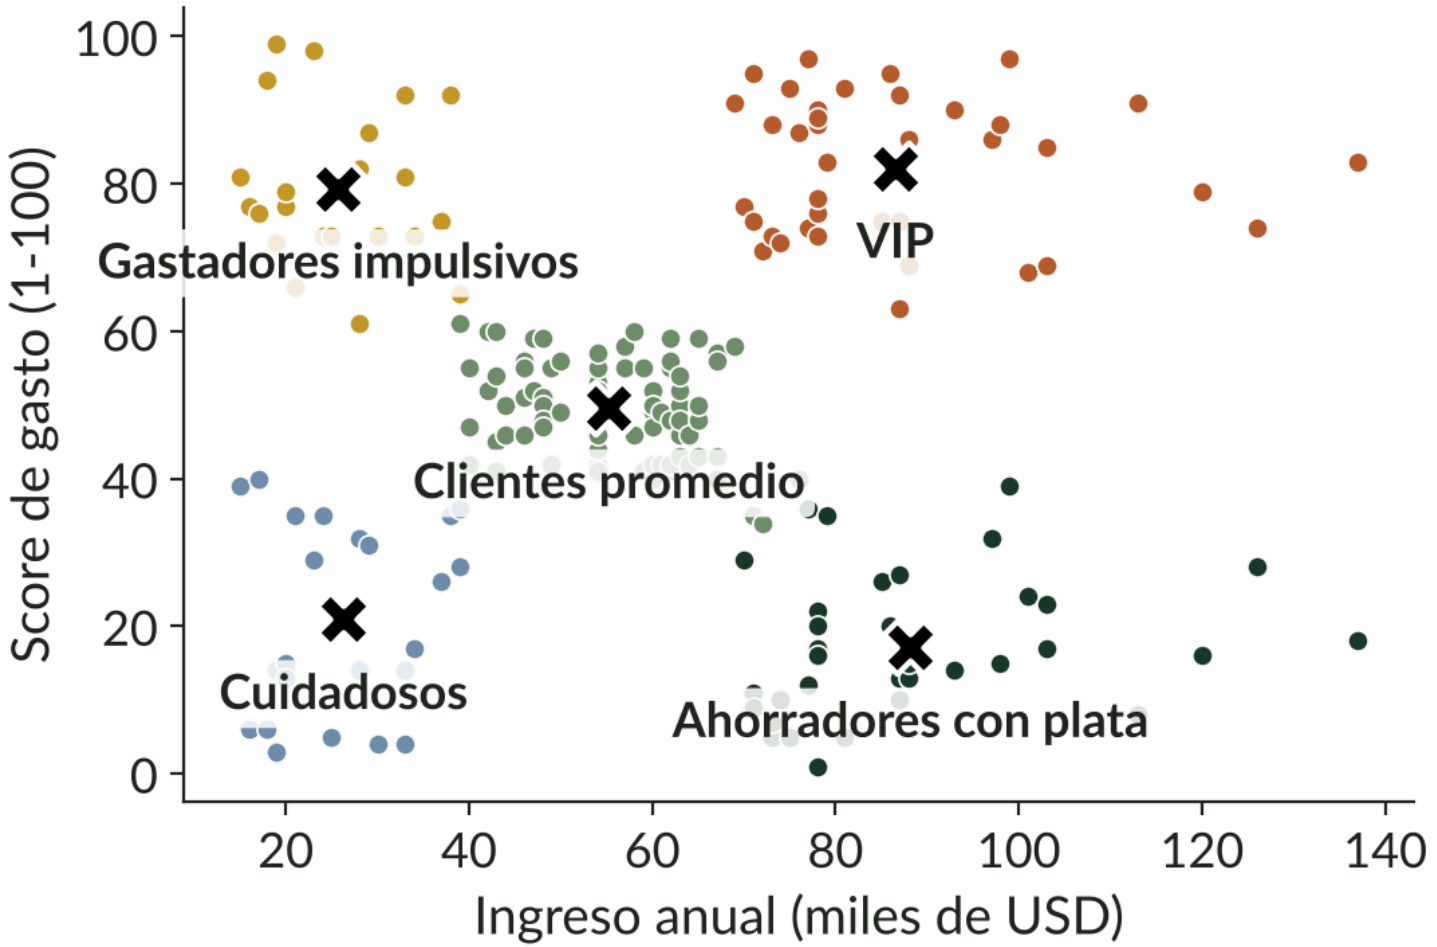
- Traducción: **grupos lo más "apretados" posible**.
- Por eso hay que **estandarizar**: si no, la variable con números grandes domina.
- Depende del arranque al azar: se corre varias veces.

# ¿Cuántos grupos? K lo elegimos nosotros




- **Codo:** dónde la inercia deja de bajar mucho. **Silhouette:** más alto = grupos más separados.
- Y una pregunta de negocio: ¿cuántas campañas podemos manejar?

# El nombre lo ponemos nosotros




| Segmento | Acción |
|---|---|
| VIP | Fidelizar |
| Ahorradores con plata | Mayor potencial |
| Impulsivos | Promos, cuotas |
| Cuidadosos | Descuentos |
| Promedio | Masiva |

# Cuidado con K-means

- **Siempre devuelve K grupos**, aunque los datos no tengan grupos.
- **Estandarizar** las variables antes.
- Le gustan los grupos **redondos y de tamaño parecido**.
- Los **outliers** tiran de los centroides.
- Escala muy bien: funciona con millones de clientes.

PARTE 2

# Clustering jerárquico

¿Qué países se parecen?

# El problema

Una **fintech argentina** quiere expandirse:

## ¿Qué países se parecen entre sí?

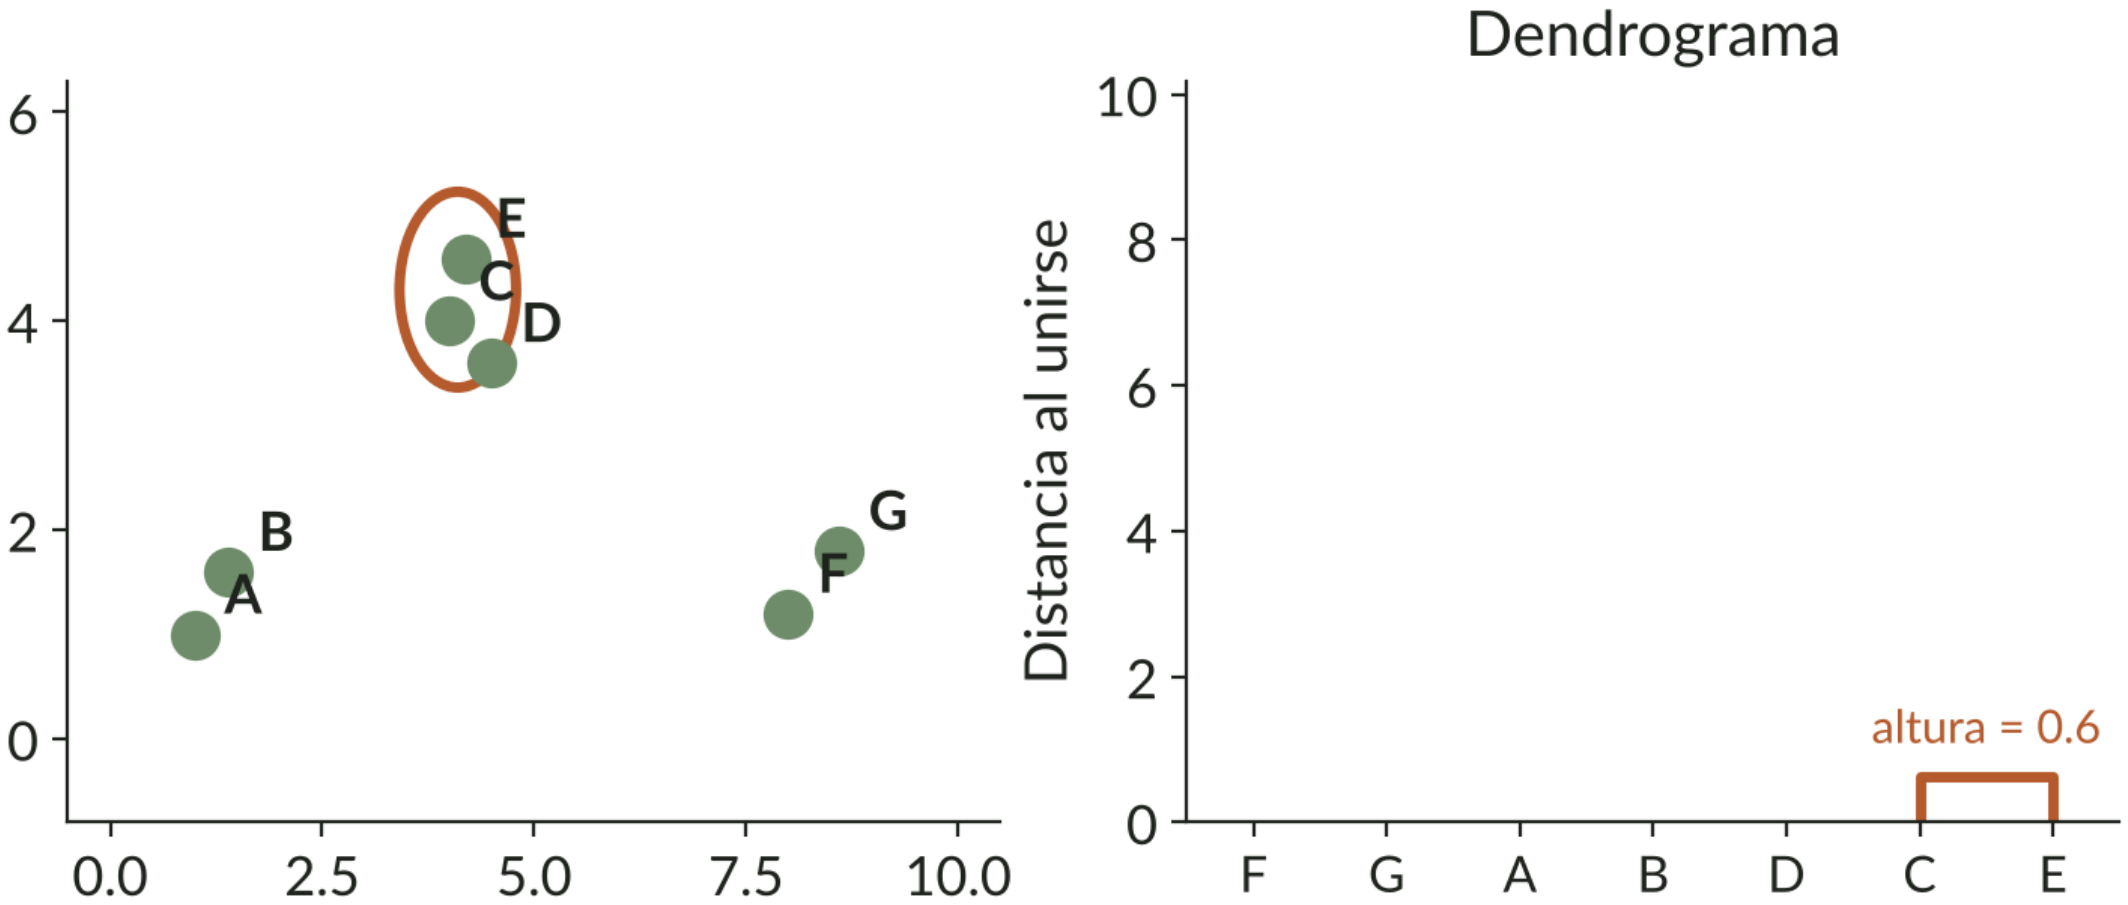
- 193 países, 5 indicadores de la ONU.
- No sabemos cuántos grupos hay.
- Si algo funciona en un país, probablemente funcione en sus "vecinos".

# La idea en una frase

Arranco con cada país solo y voy juntando de a dos a los más parecidos, hasta que queda un solo grupo.

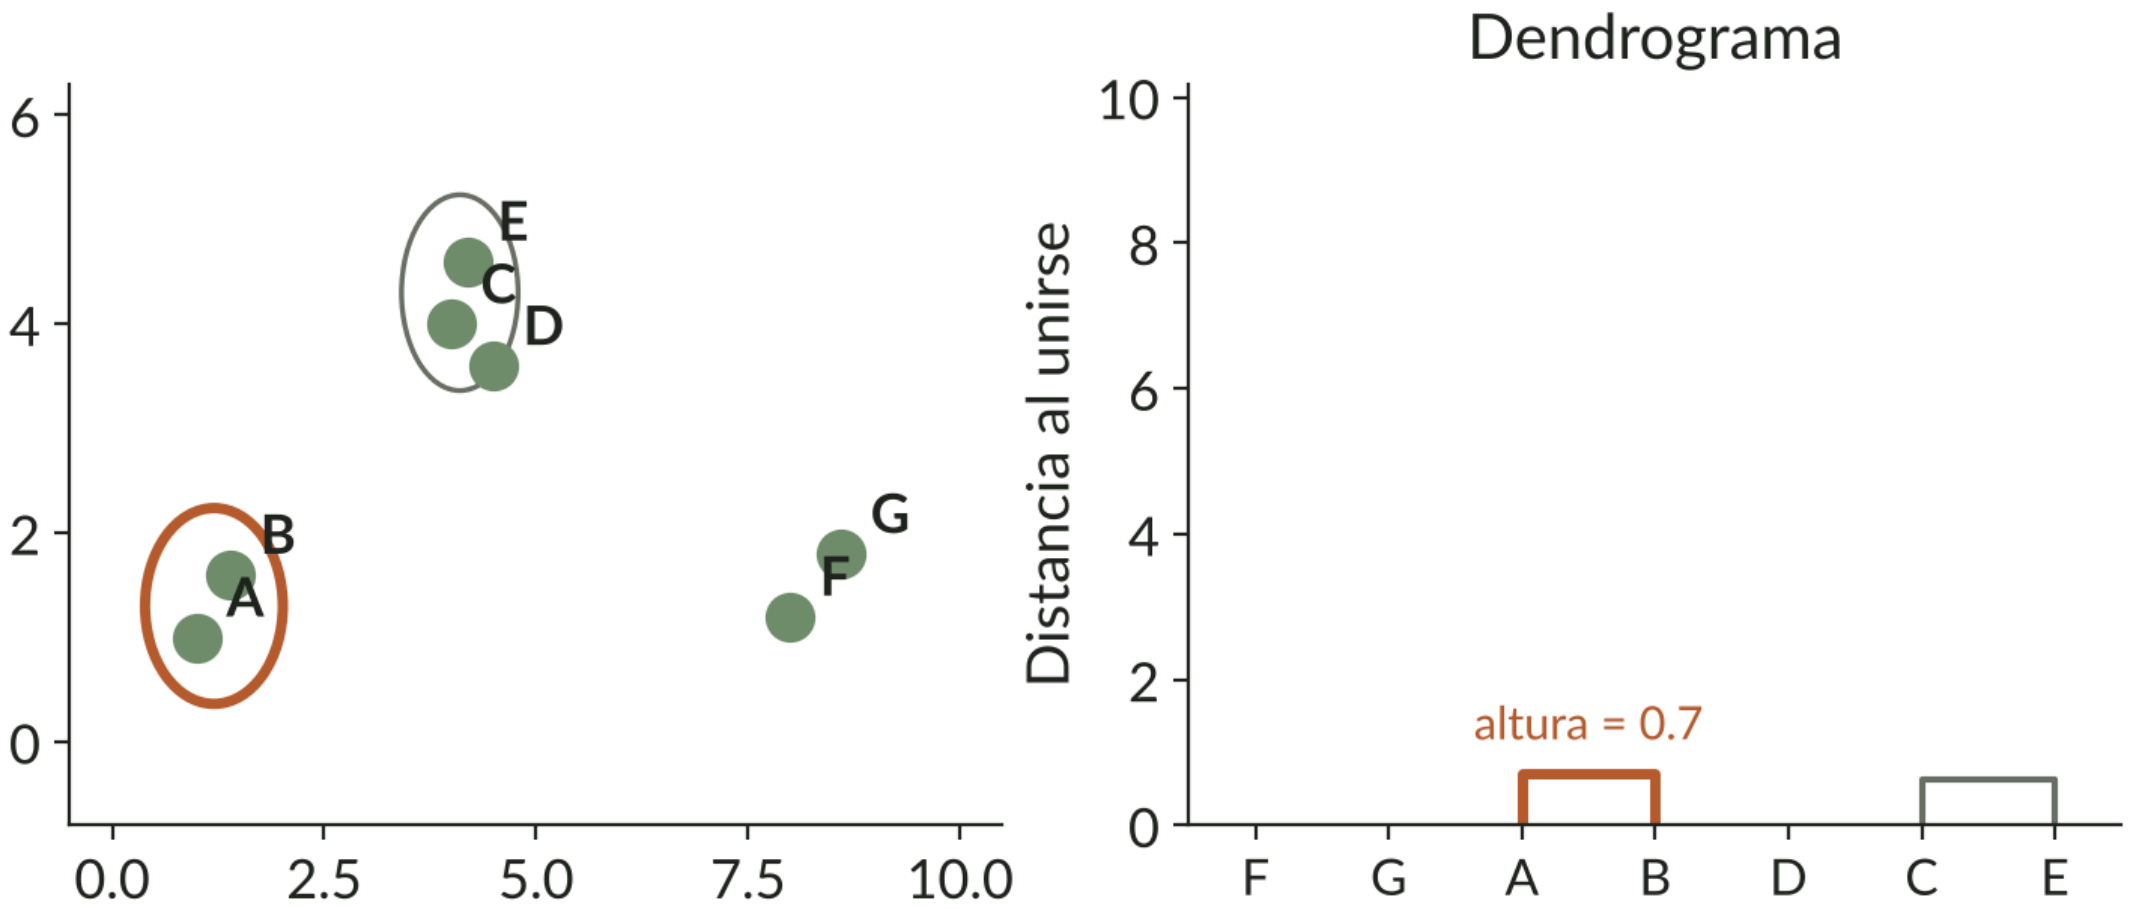
- Como un **árbol genealógico** de parecidos.
- El **dendrograma** dibuja ese árbol.
- No hace falta elegir K antes.

# Paso a paso · 1



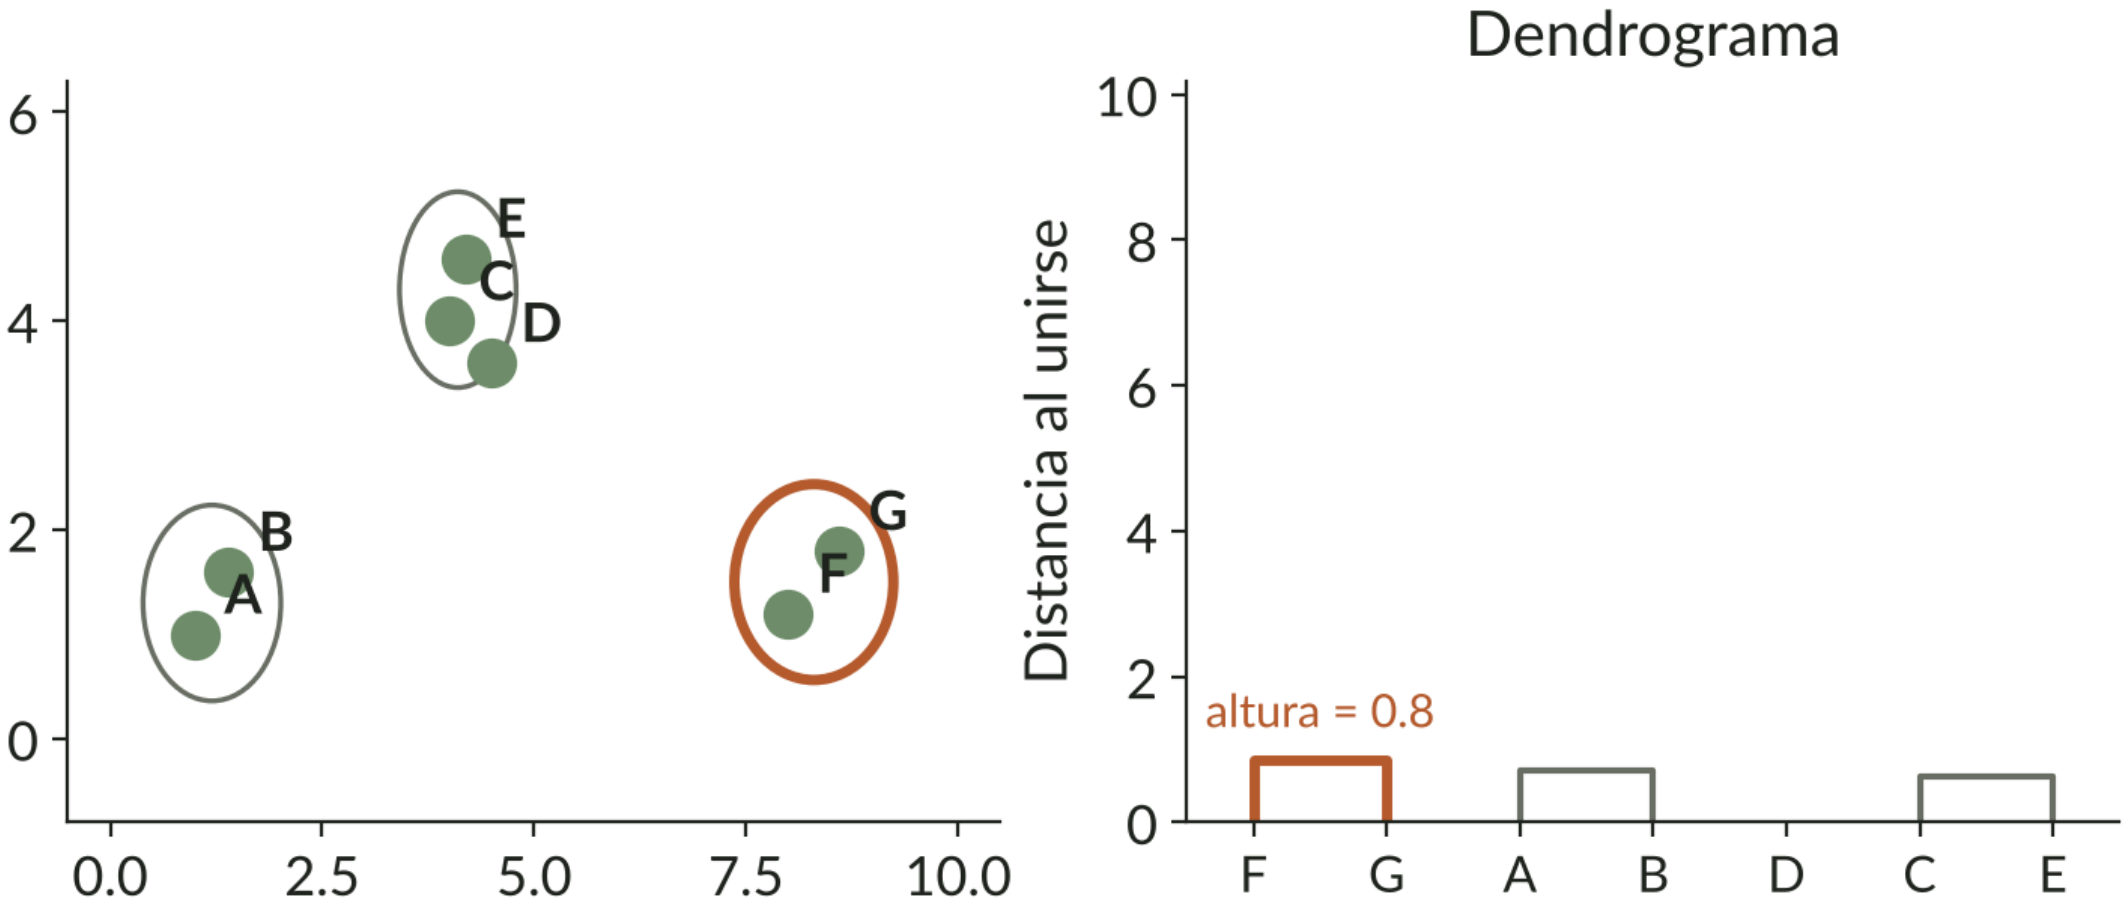

C y E son los más cercanos: se juntan primero. "U" **bajita**.

# Paso a paso · 2



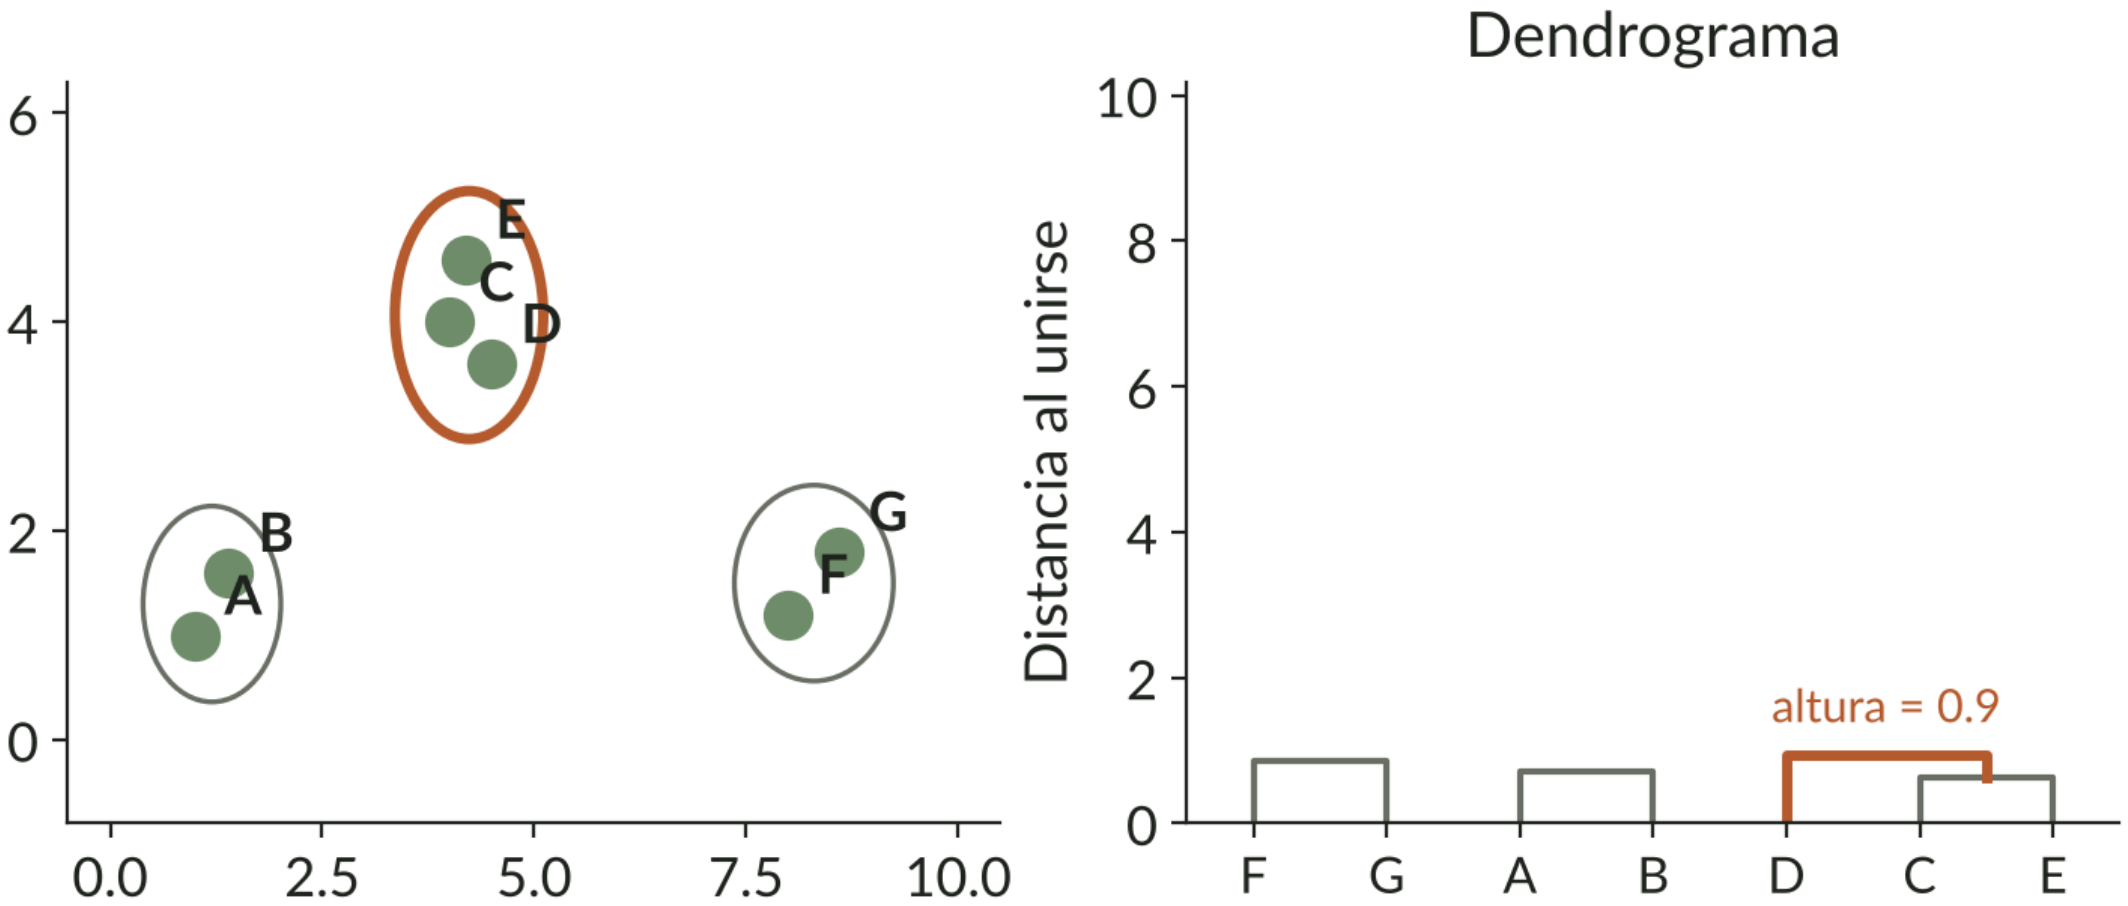

Siguiente par más cercano: A y B.

# Paso a paso · 3



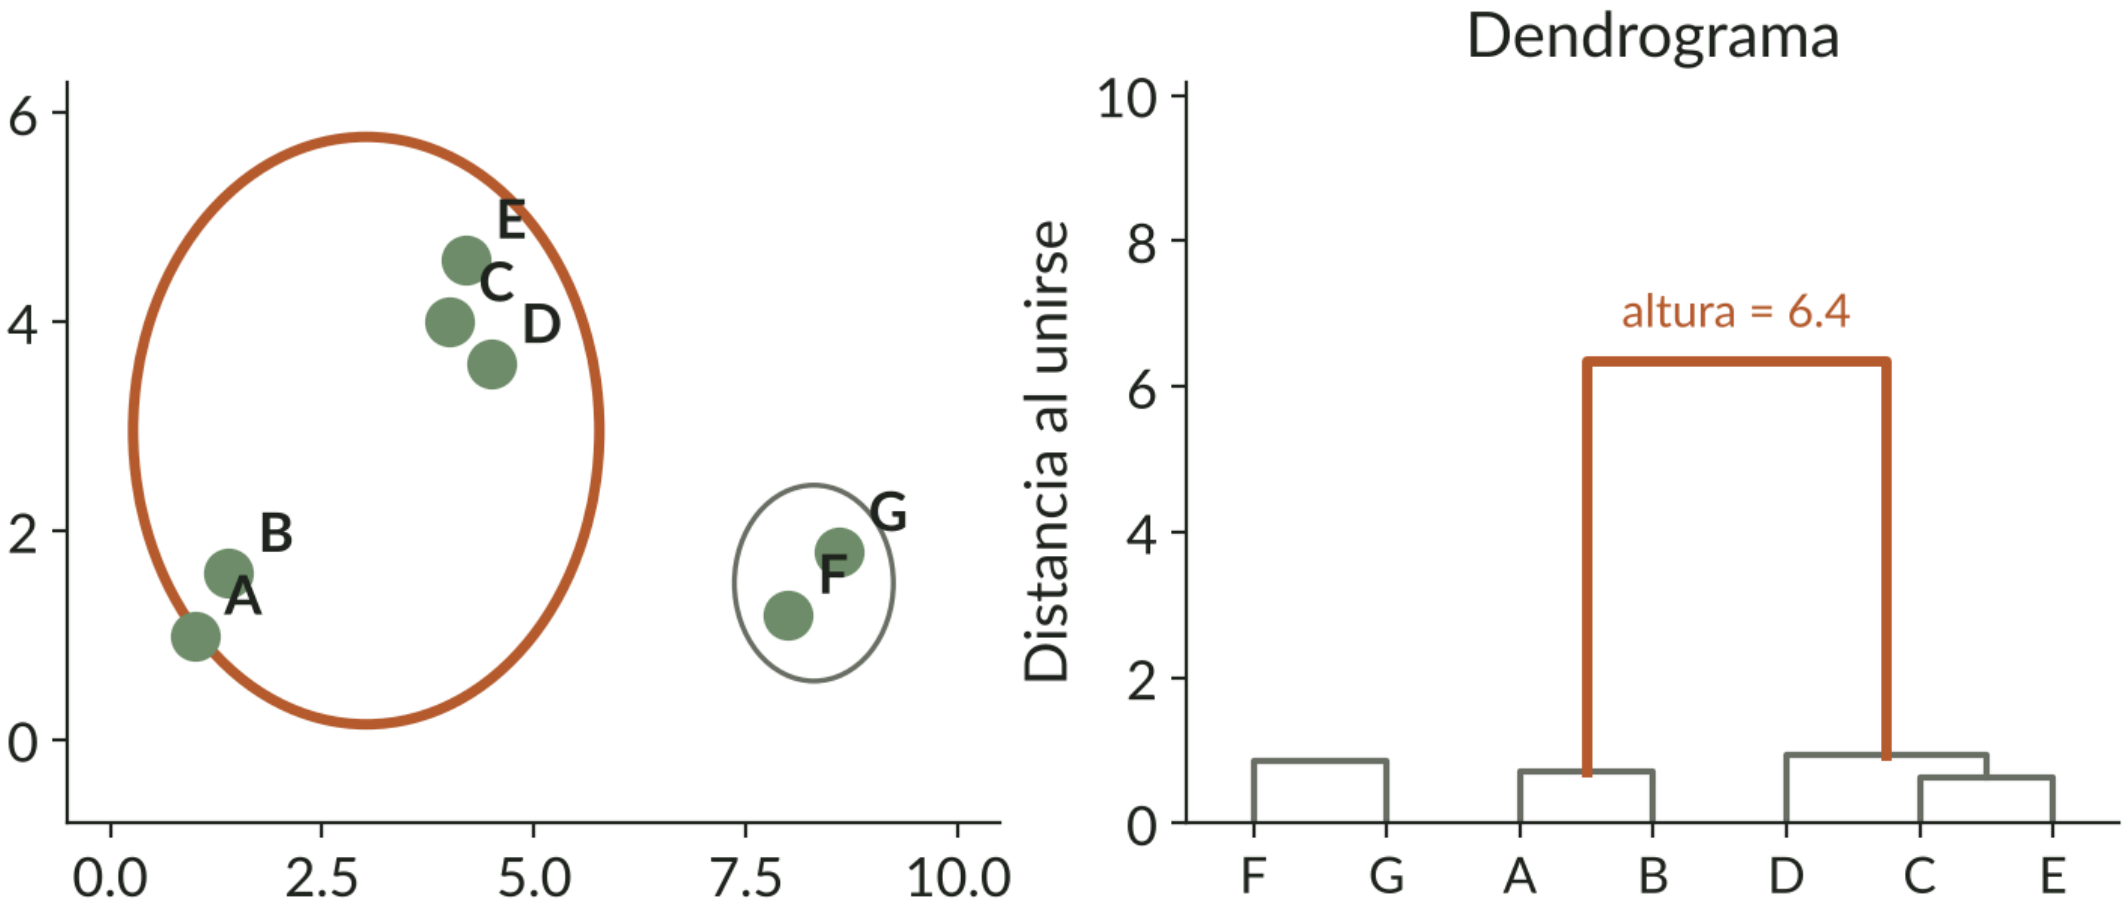

F y G. Tres grupitos bien apretados.

# Paso a paso · 4



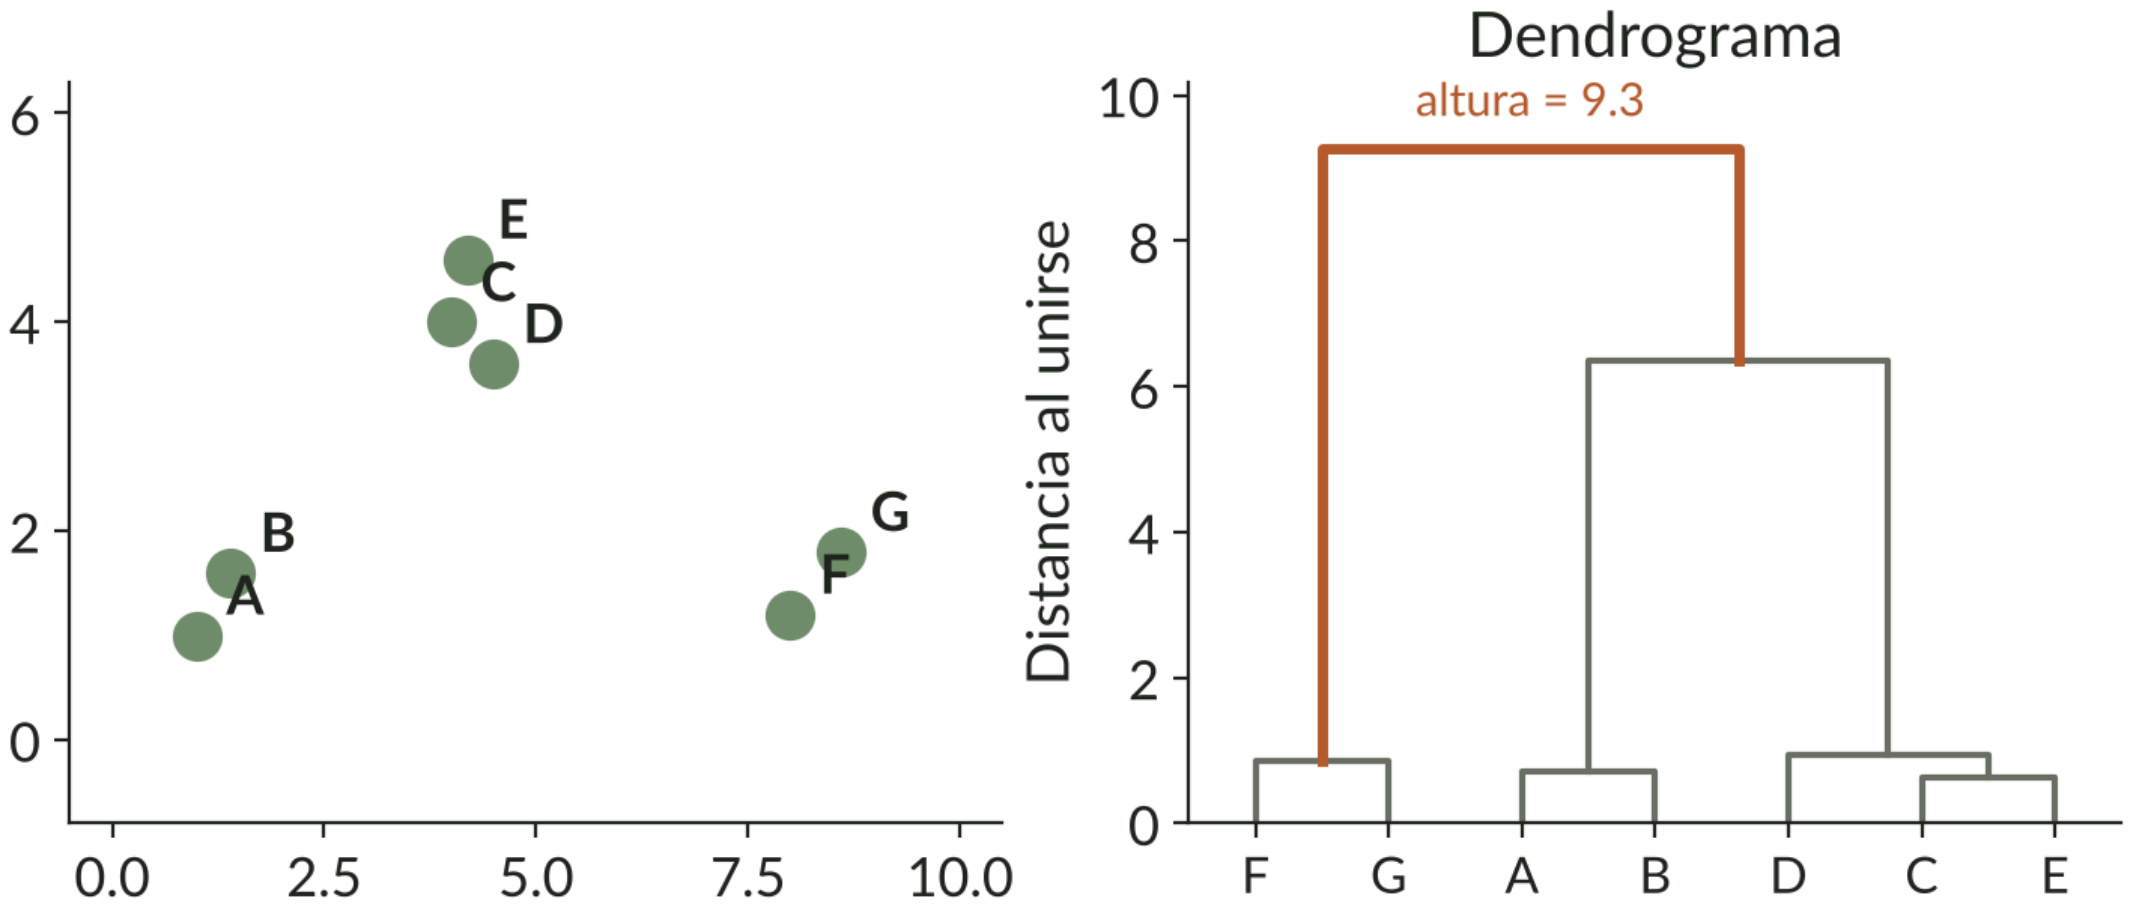

D se suma a C y E.

# Paso a paso · 5



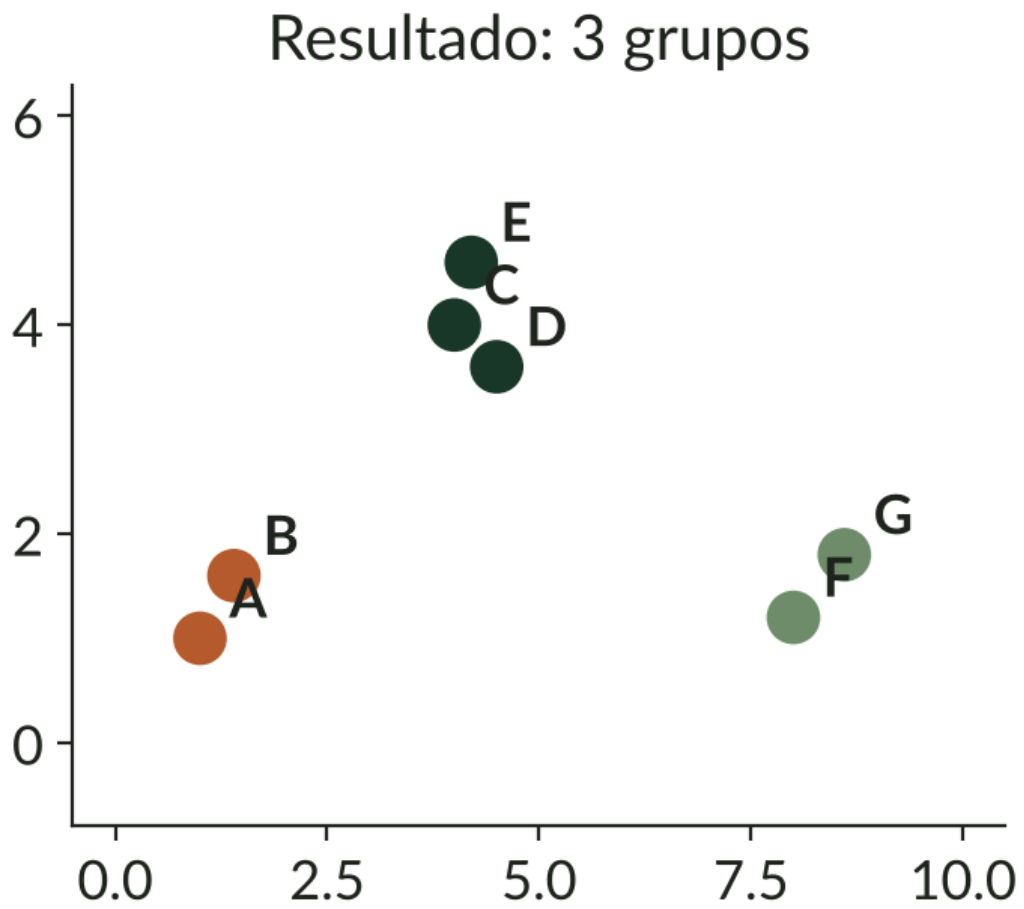

Grupos lejanos: la "U" pega un **salto**.

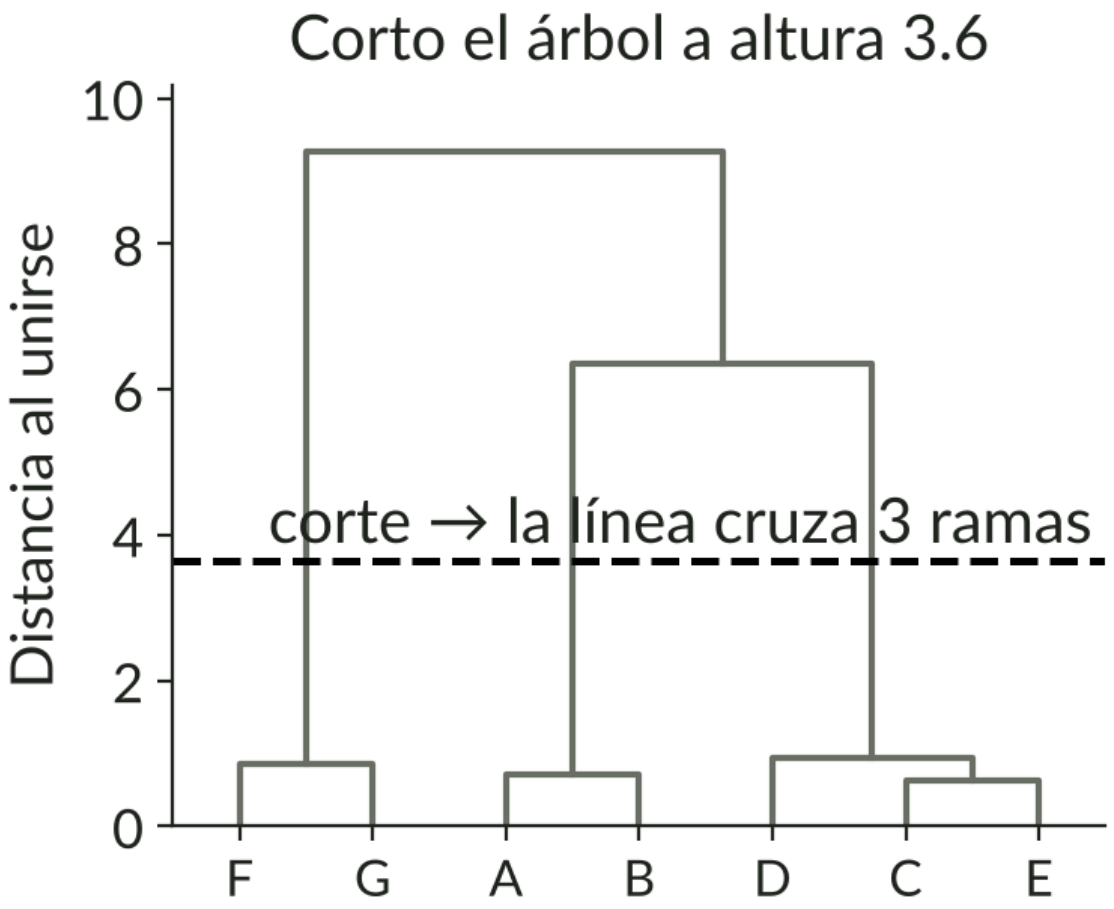
# Paso a paso · 6




Todo en un solo grupo: el árbol está completo.

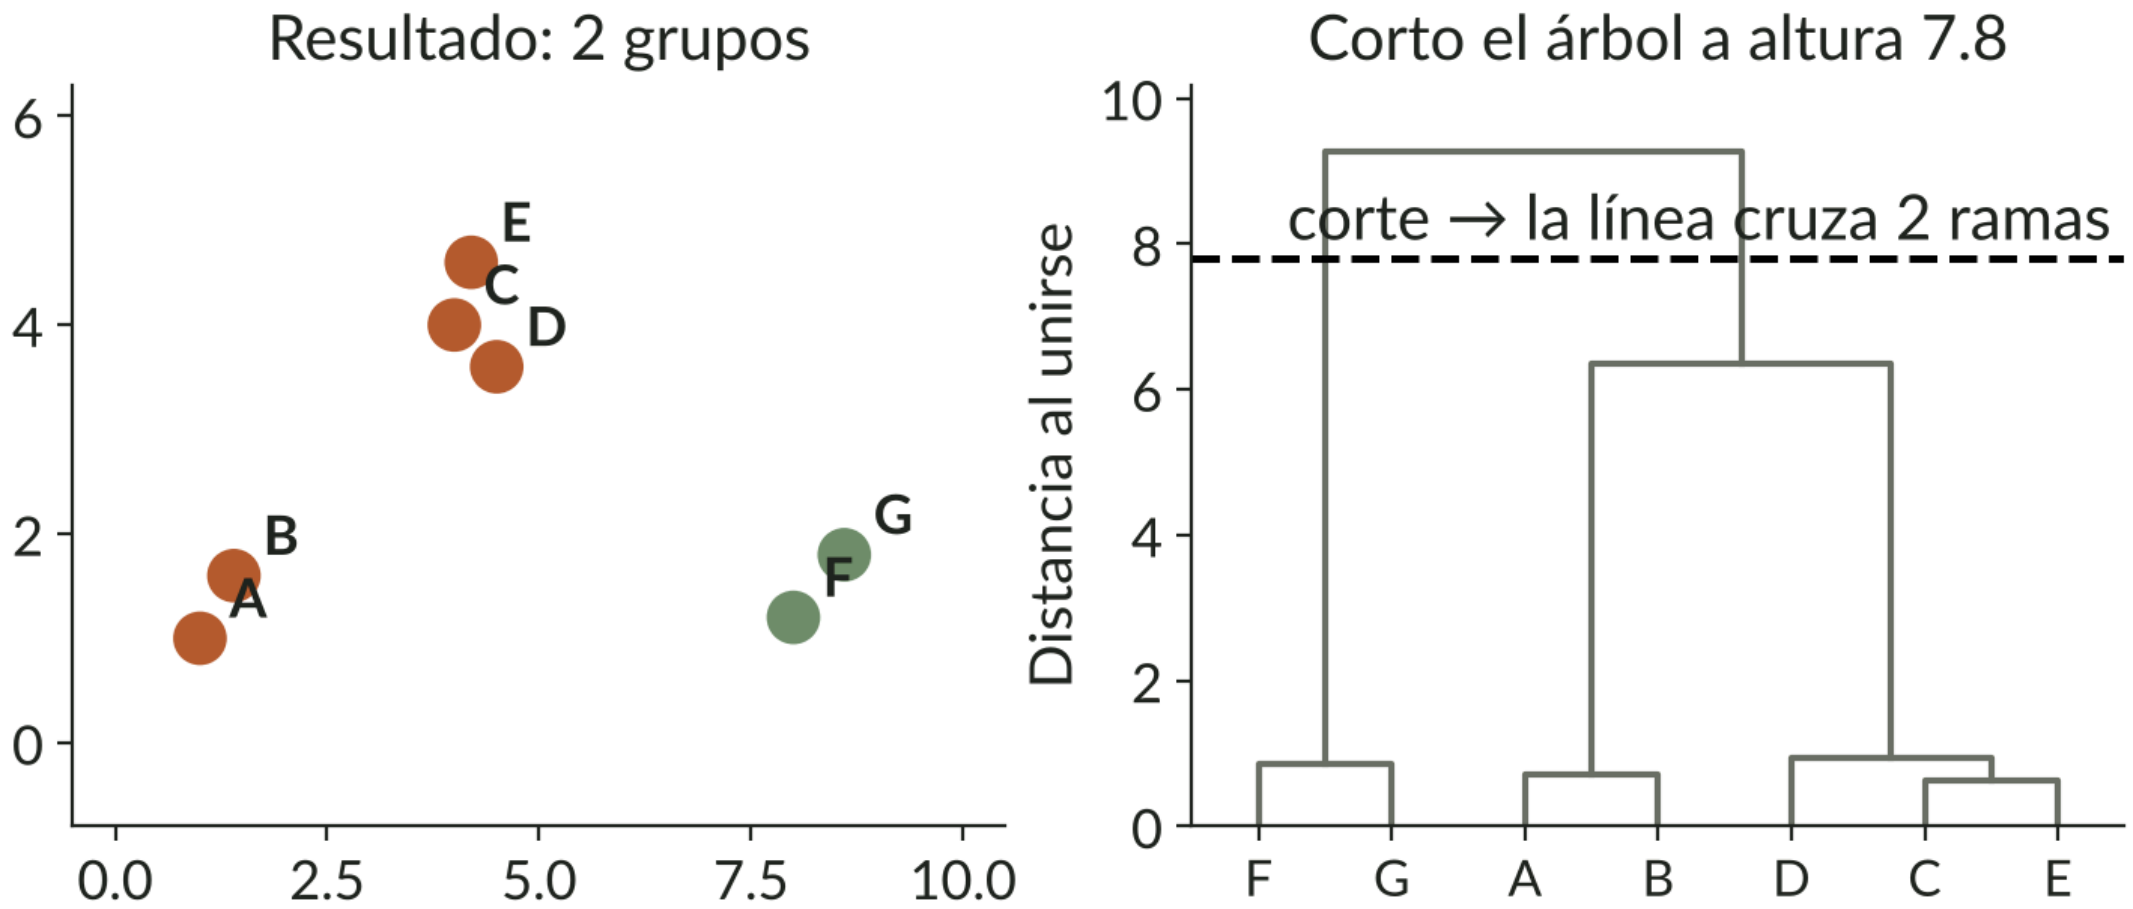
# ¿Cuántos grupos? Corto el árbol



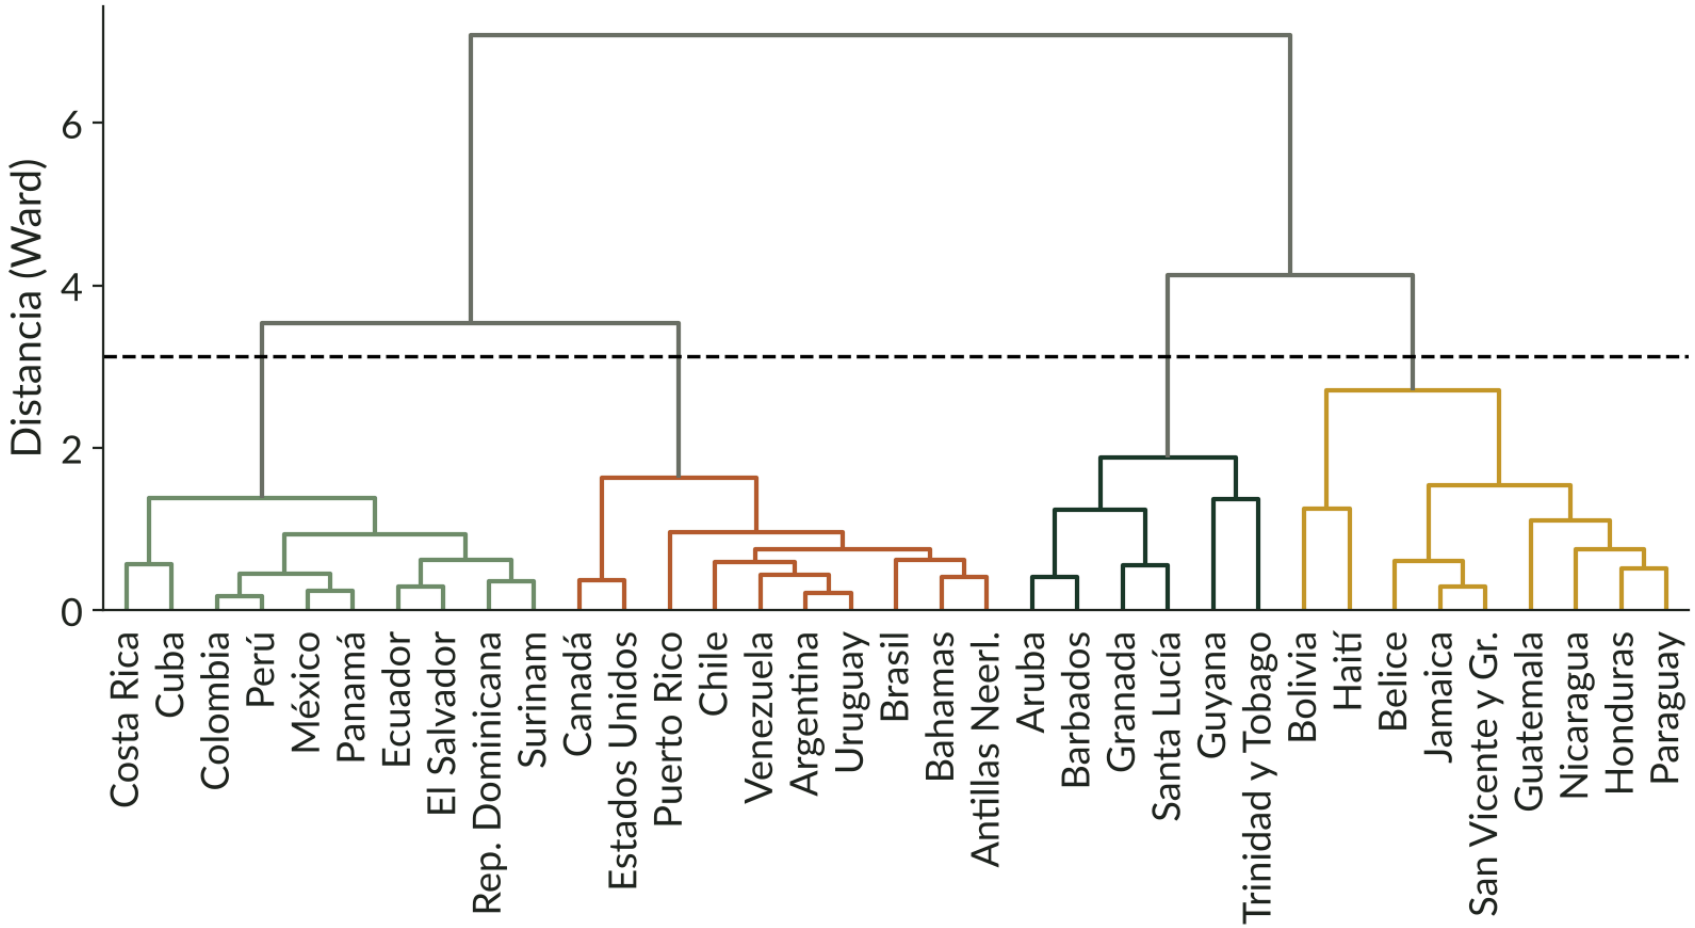

Ramas que cruza la línea = grupos. Corto **debajo del salto**: 3 grupos.

# ¿Cuántos grupos? Corto el árbol




Más arriba: 2 grupos. ¿Cuál conviene? Depende del negocio.

# Con datos reales: países de América




Argentina y Uruguay se juntan **muy abajo**. Cortando en el salto: 4 grupos.

# ¿Distancia entre grupos? (linkage)

| Linkage | Compara los grupos por... |
|---|---|
| **single** | los dos **más cercanos** → arma "cadenas" |
| **complete** | los dos **más lejanos** |
| **average** | el **promedio** de las distancias |
| **ward** | que queden **más apretados** (como K-means) |

En la práctica: **Ward**.

# Con todos los países

| Grupo (mediana) | Países | PBI p/c | Esp. vida | Hijos |
|---|---|---|---|---|
| **Alto desarrollo** (Argentina) | 66 | 20.556 | 80,7 | 1,9 |
| **Medio-alto** | 55 | 4.496 | 77,3 | 2,0 |
| **Medio-bajo** | 53 | 1.240 | 64,4 | 3,8 |
| **Bajo desarrollo** | 19 | 451 | 53,1 | 5,5 |

Cortando el árbol de los 193 países en 4 grupos.

# K-means vs. jerárquico

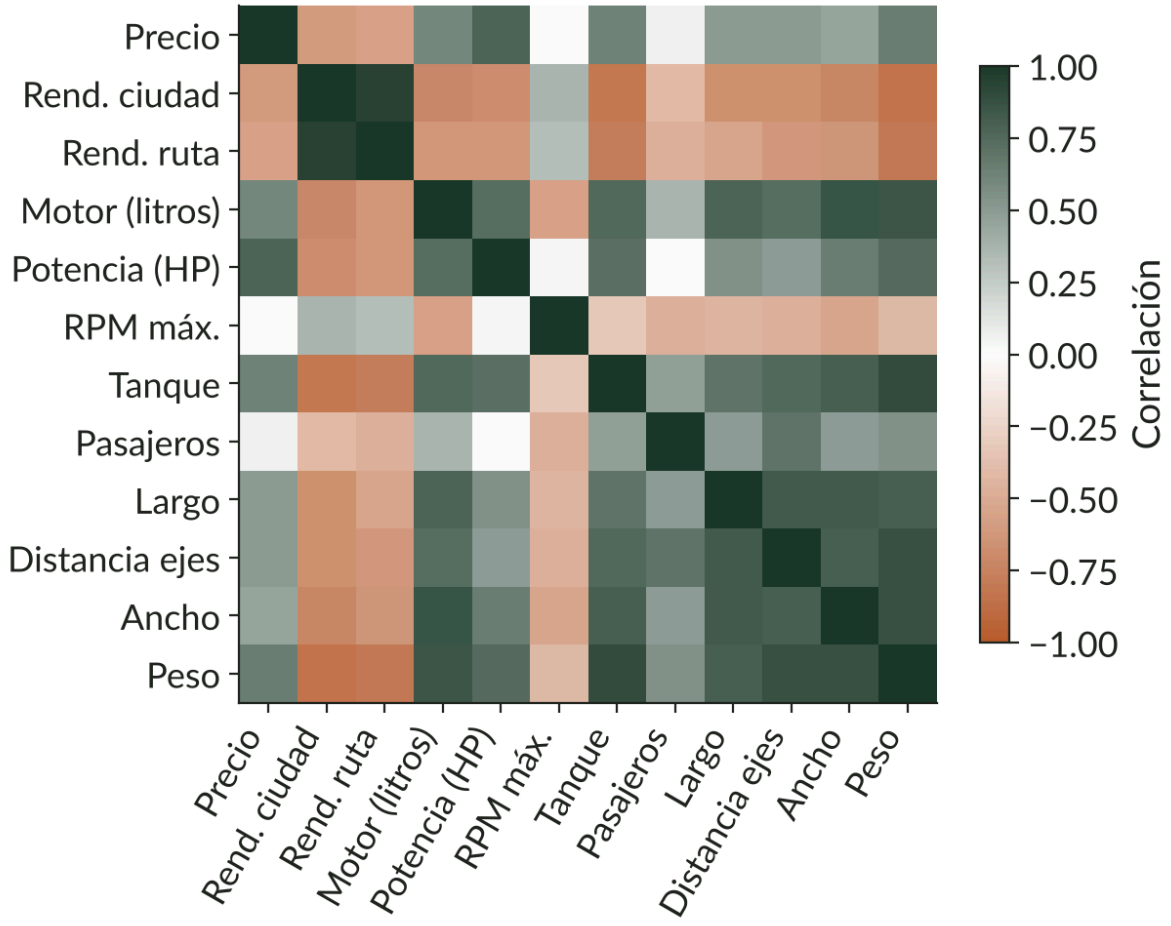
| | K-means | Jerárquico |
|---|---|---|
| **¿Elijo K antes?** | Sí | No: corto después |
| **Resultado** | Grupos + centroides | Árbol (dendrograma) |
| **Datos** | Millones | Hasta miles |
| **Se explica** | "Estos son los perfiles" | "Quién se parece a quién" |
| **¿Siempre igual?** | Depende del arranque | Sí |

PARTE 3

# PCA

Resumir muchas variables en un mapa

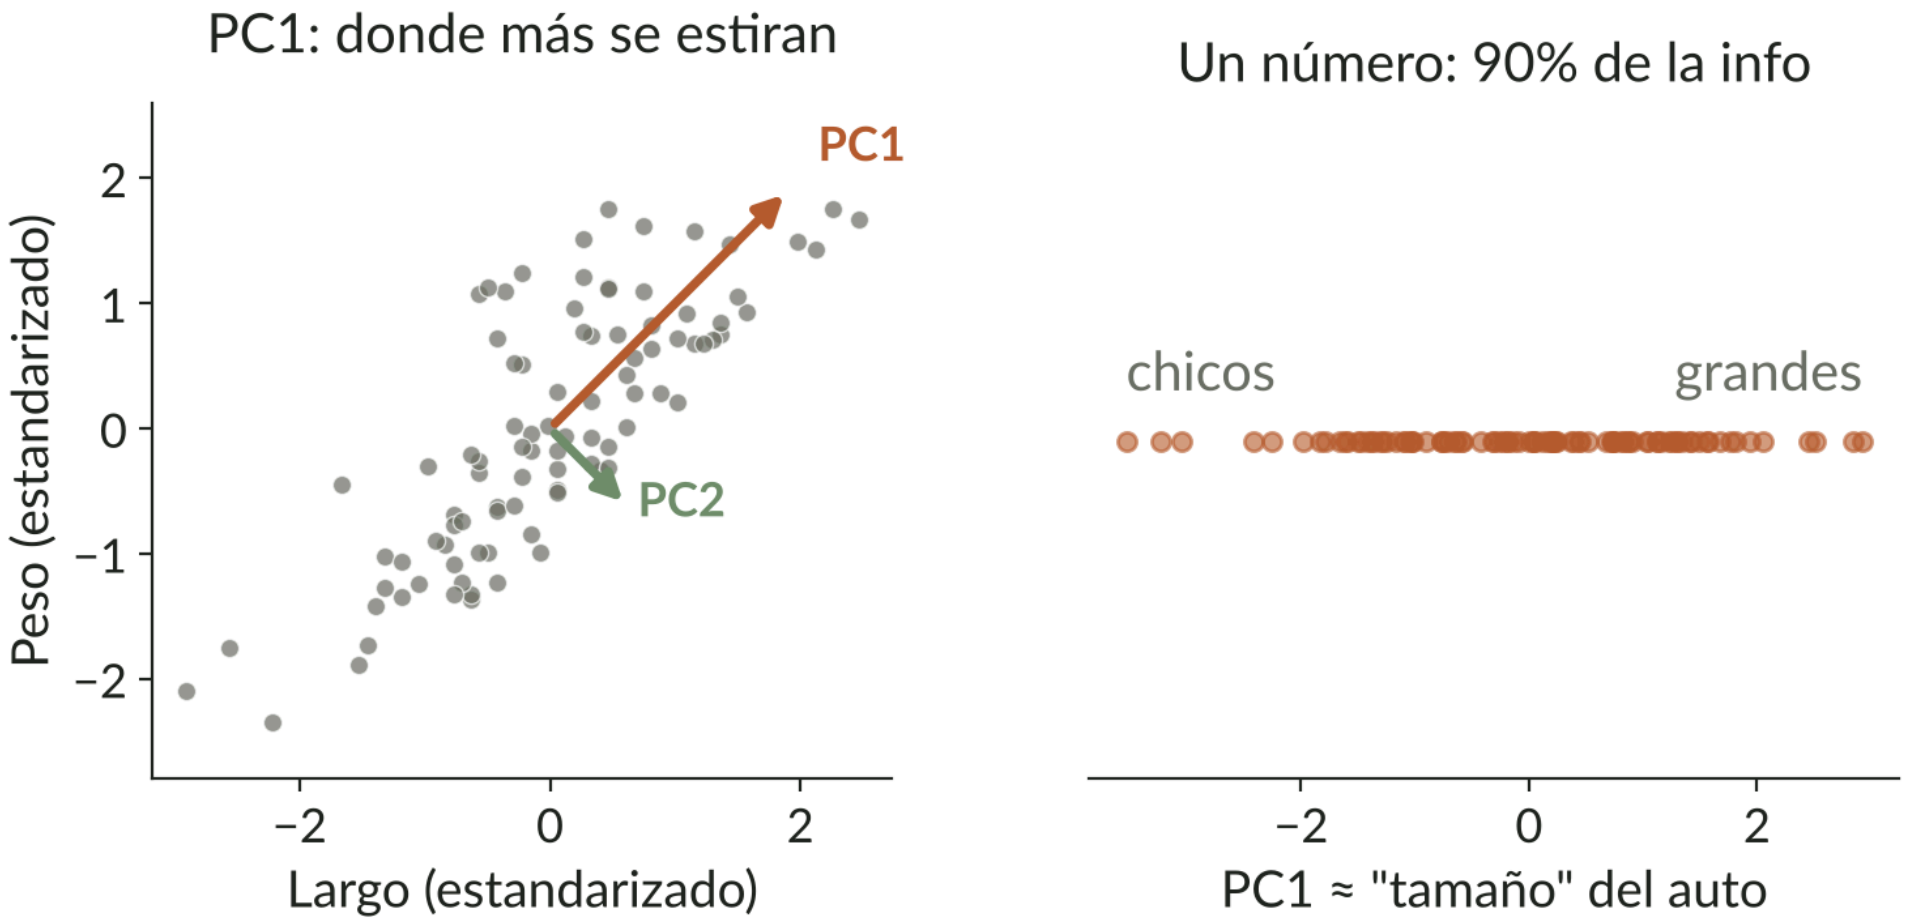
# El problema




Automotriz: ¿cómo están **posicionados** los 93 modelos del mercado?

- 12 características: no se pueden graficar.
- Muchas dicen lo mismo: todas miden "qué tan grande es".

# La idea: la dirección donde más varían




Giro los ejes: con **un número** (PC1 = "tamaño") conservo casi todo.

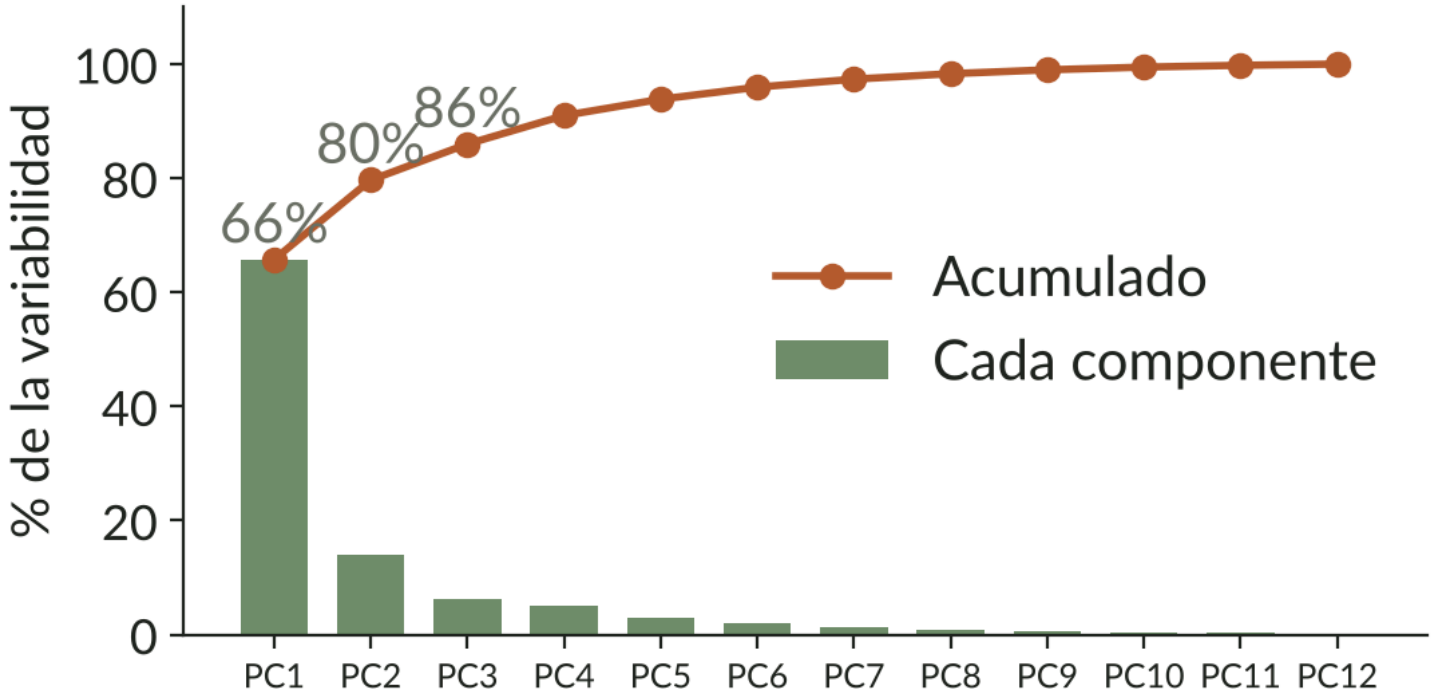
# La matemática, muy por arriba

Cada componente es una receta: una suma ponderada de las variables.

$$PC1 = w_1 \cdot \text{precio} + w_2 \cdot \text{rendimiento} + \ldots + w_{12} \cdot \text{peso}$$

- Los pesos *w* (**loadings**) maximizan la varianza de PC1.
- PC2 hace lo mismo con lo que sobra, **sin repetir**.
- Igual que en clustering: **estandarizar antes**.

# ¿Cuántas componentes me quedo?

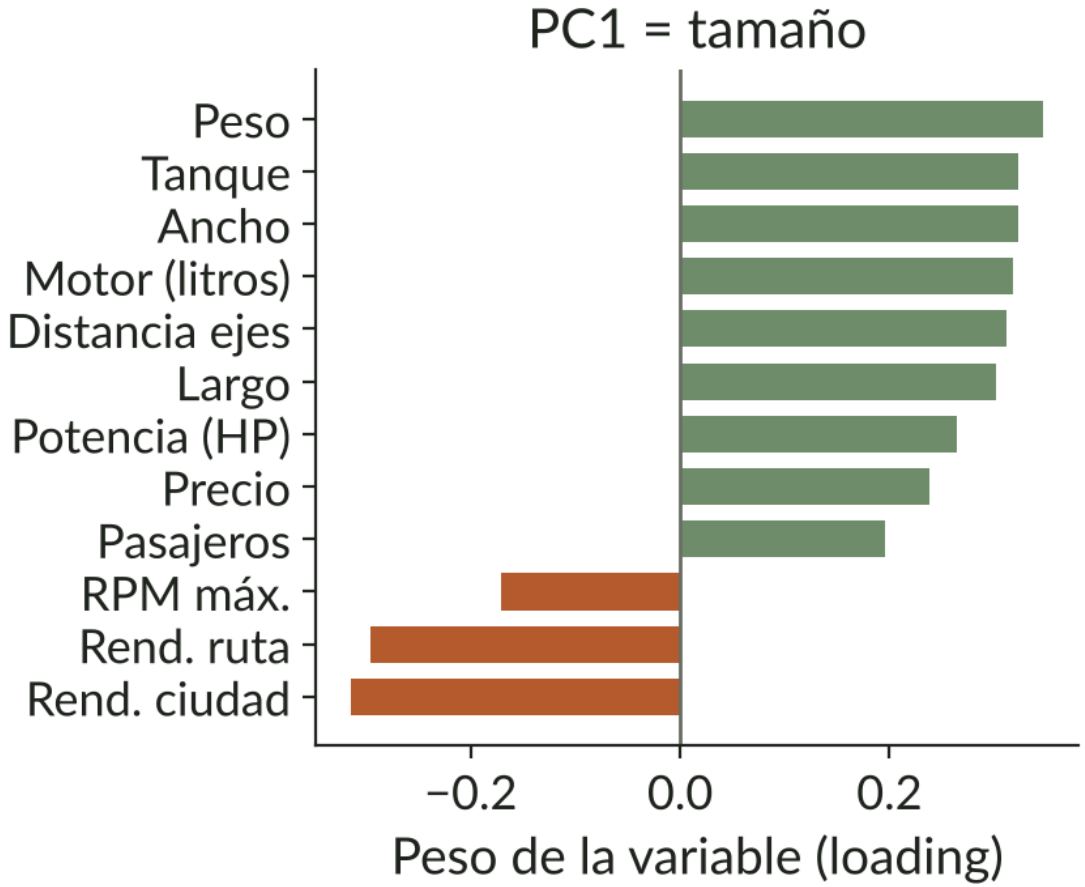


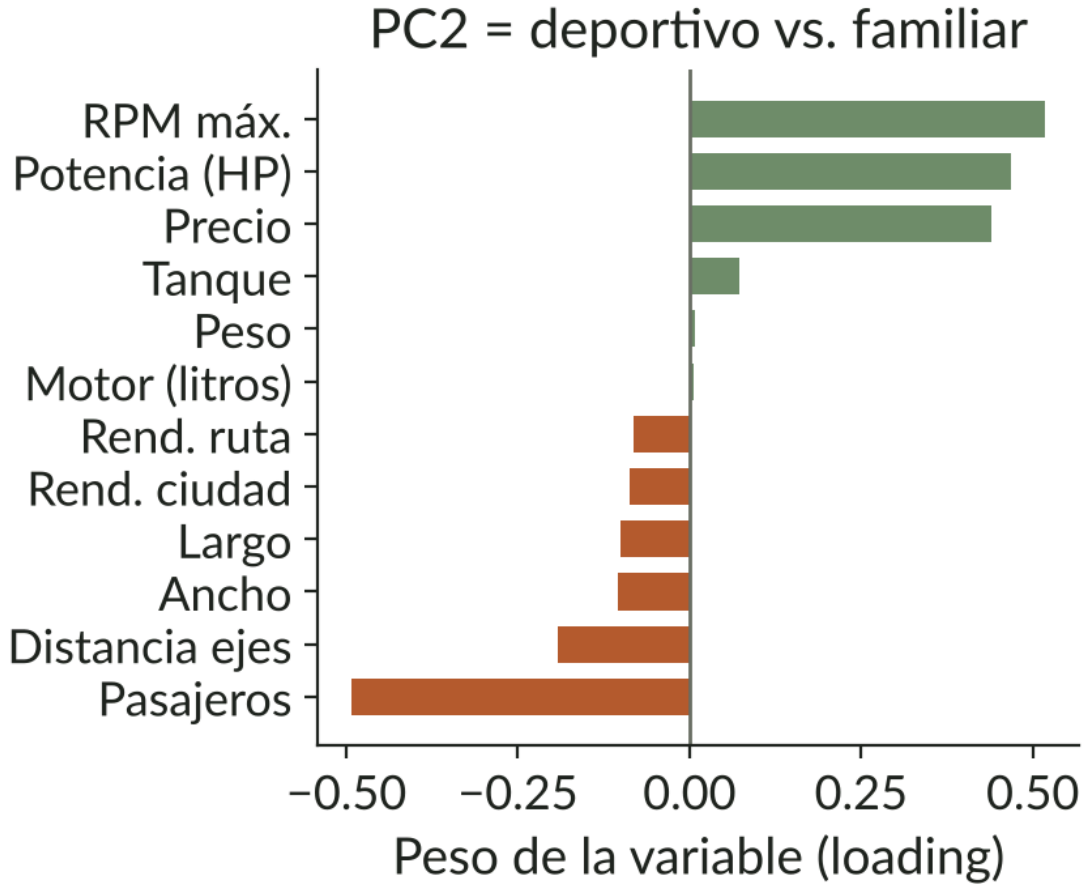

Mirar el **acumulado**: ¿80–90%?

Para **visualizar**: 2.

Para **modelar**: las que hagan falta.

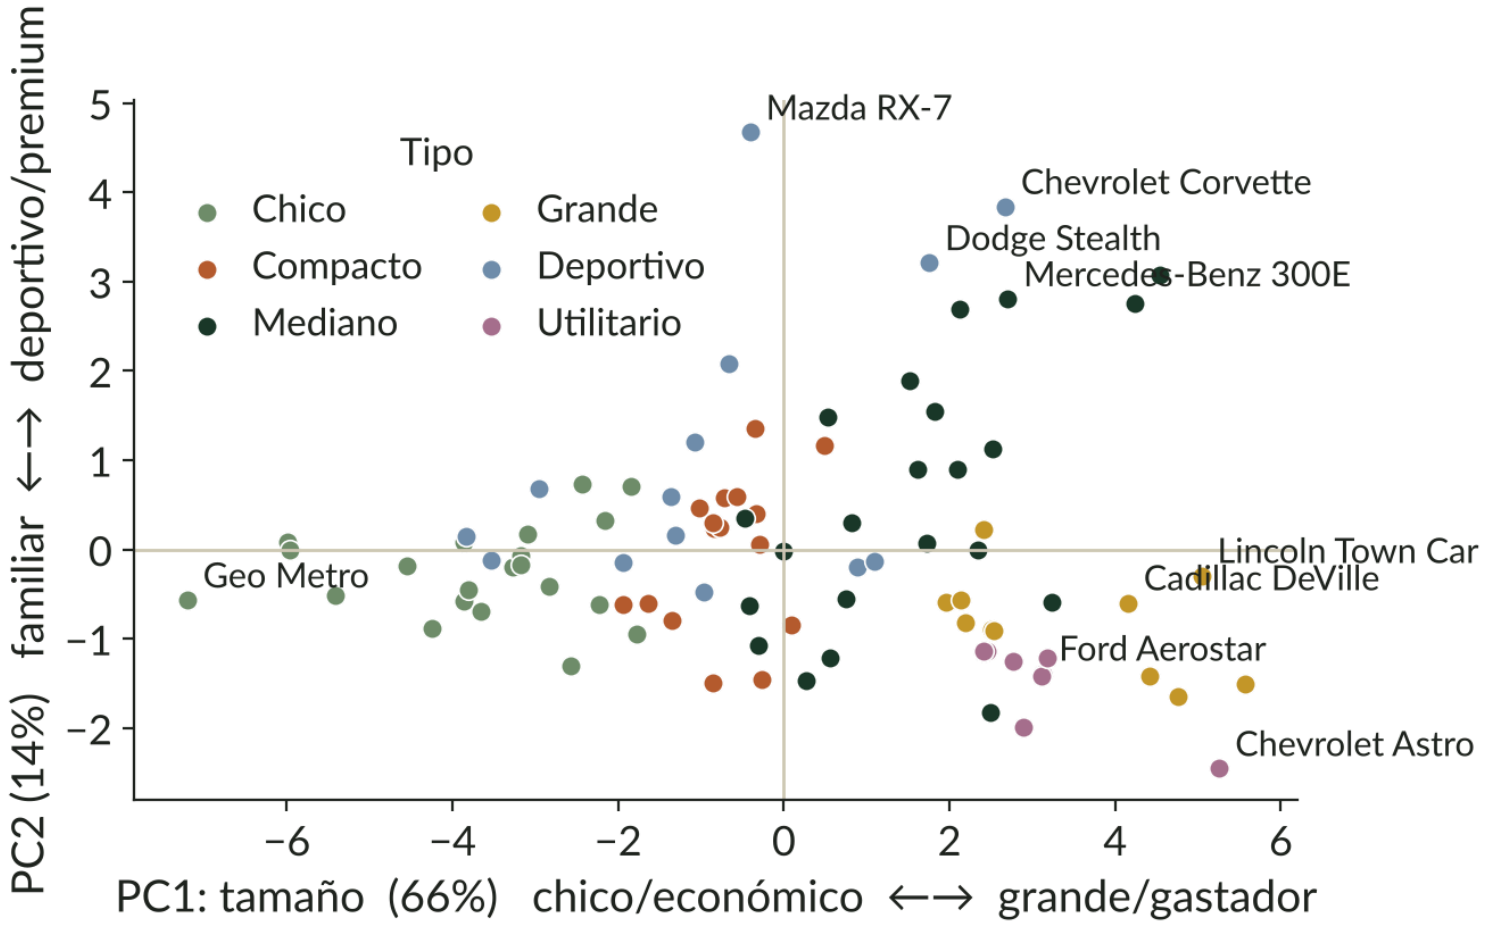
# PCA no le pone nombre: lo hacemos nosotros




**PC1 = tamaño · PC2 = deportivo/premium vs. familiar**

# Un mapa de posicionamiento




Vecinos = **competidores** · ¿Hueco? Grande *y* deportivo

# Cuidado con PCA

- **Estandarizar** antes.
- Las componentes son **difíciles de explicar**: "subió PC3" no le dice nada a nadie.
- Solo relaciones **lineales**.
- Muy útil para **visualizar**, armar **índices** y antes de clustering.

# Resumen

| | K-means | Jerárquico | PCA |
|---|---|---|---|
| **Hace** | Agrupa filas | Árbol de parecidos | Resume columnas |
| **Usalo para** | Muchos clientes | Pocos casos, sin K | Mapas, índices |
| **Decidís vos** | K | Dónde cortar | Cuántas componentes |

Siempre: **estandarizar** · **ponerle nombre** · **validar con el negocio**

# ¿Dudas? ¿Consultas?