ANALÍTICA DE DATOS

Aprendizaje no supervisado

K-means, clustering jerárquico y PCA

Clase práctica · 2do cuatrimestre 2026

Universidad de San Andrés

Hasta ahora: aprendizaje supervisado

Supervisado

CART, KNN, RF, Naive Bayes

- Hay una columna respuesta: ¿pagó?, ¿compró?
- El modelo aprende a **predecirla**
- Podemos medir si acierta

No supervisado (hoy)

K-means, jerárquico, PCA

- No hay respuesta: solo características
- Buscamos **estructura**: grupos, patrones
- La utilidad la decide el negocio

Tres preguntas de negocio, tres técnicas

K-means

¿Qué tipos de clientes tengo?

200 clientes de un shopping

Jerárquico

¿Qué países se parecen entre sí?

193 países (ONU)

PCA

¿Cómo resumo 12 métricas en un mapa?

93 modelos de autos

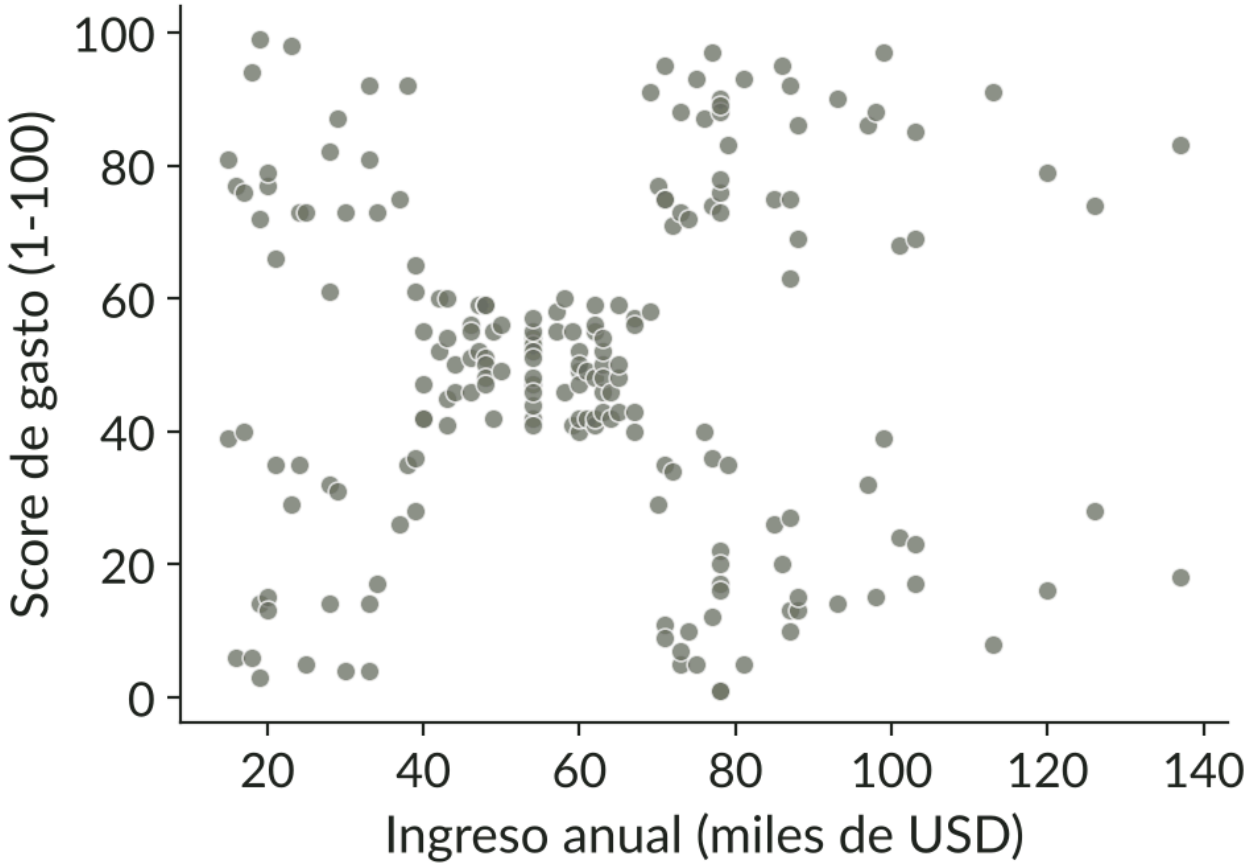
Las dos primeras **agrupan filas**. PCA **resume columnas**.

PARTE 1

K-means

Segmentar clientes

El problema

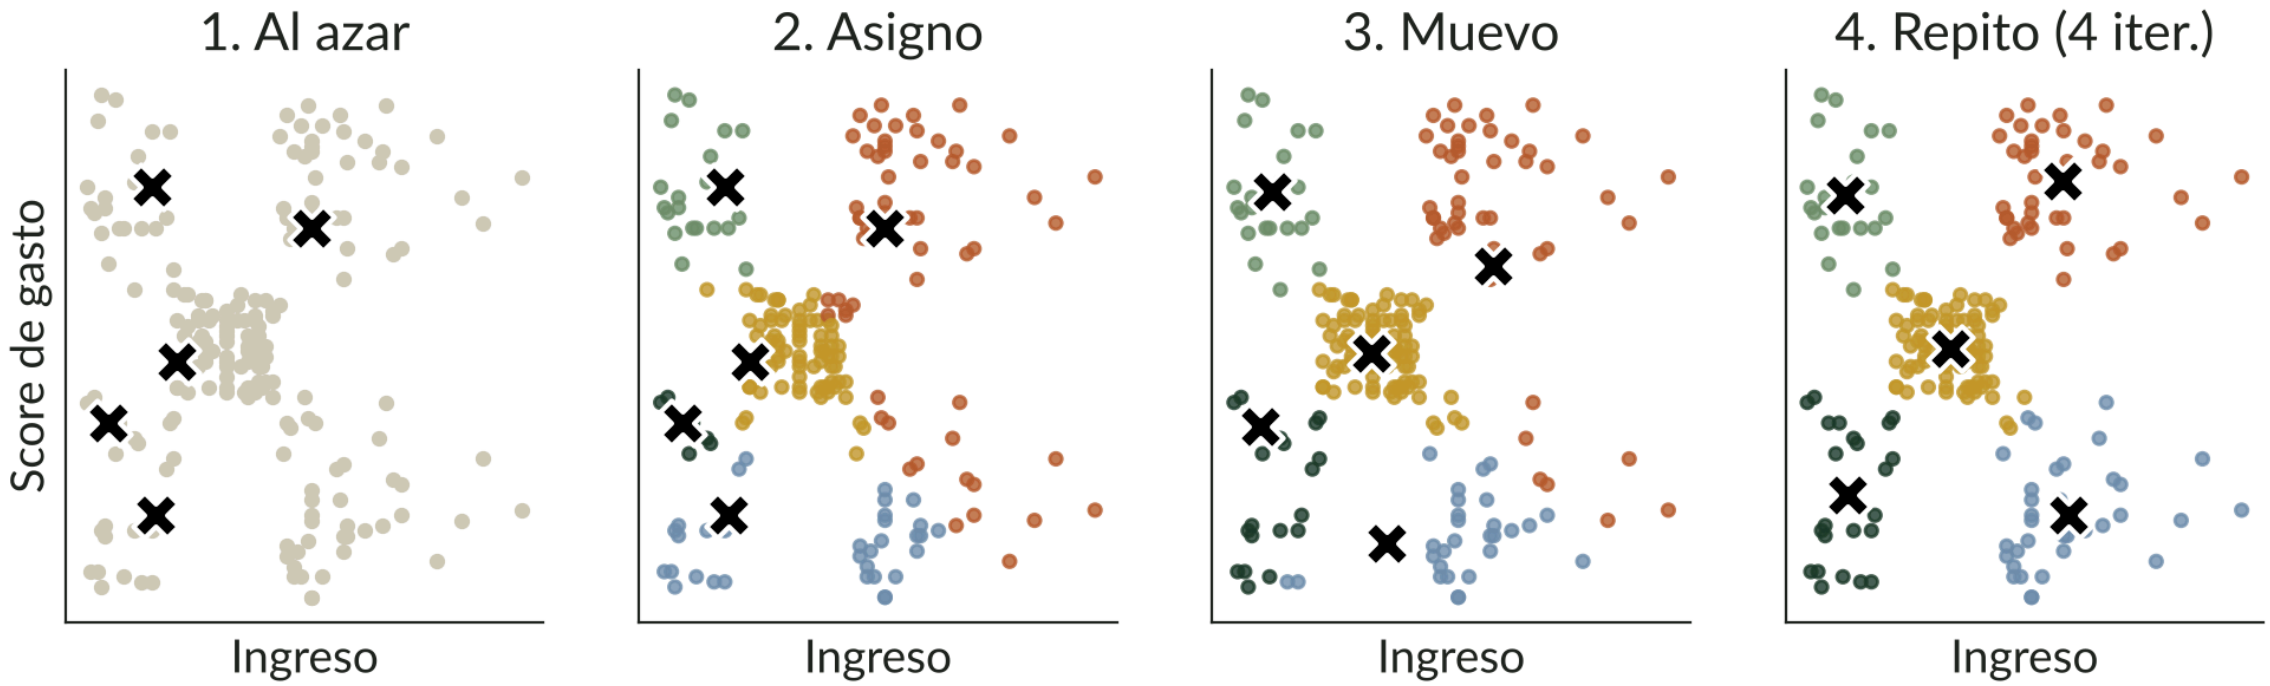


Marketing de un shopping: **ingreso** y **score de gasto** de cada cliente.

Queremos campañas para distintos tipos de clientes, pero nadie nos dijo cuáles son.

¿Cuántos grupos ves?

La idea: K "clientes representantes"



K centroides al azar → cada cliente al **más cercano** → cada centroide al **promedio** → repetir.

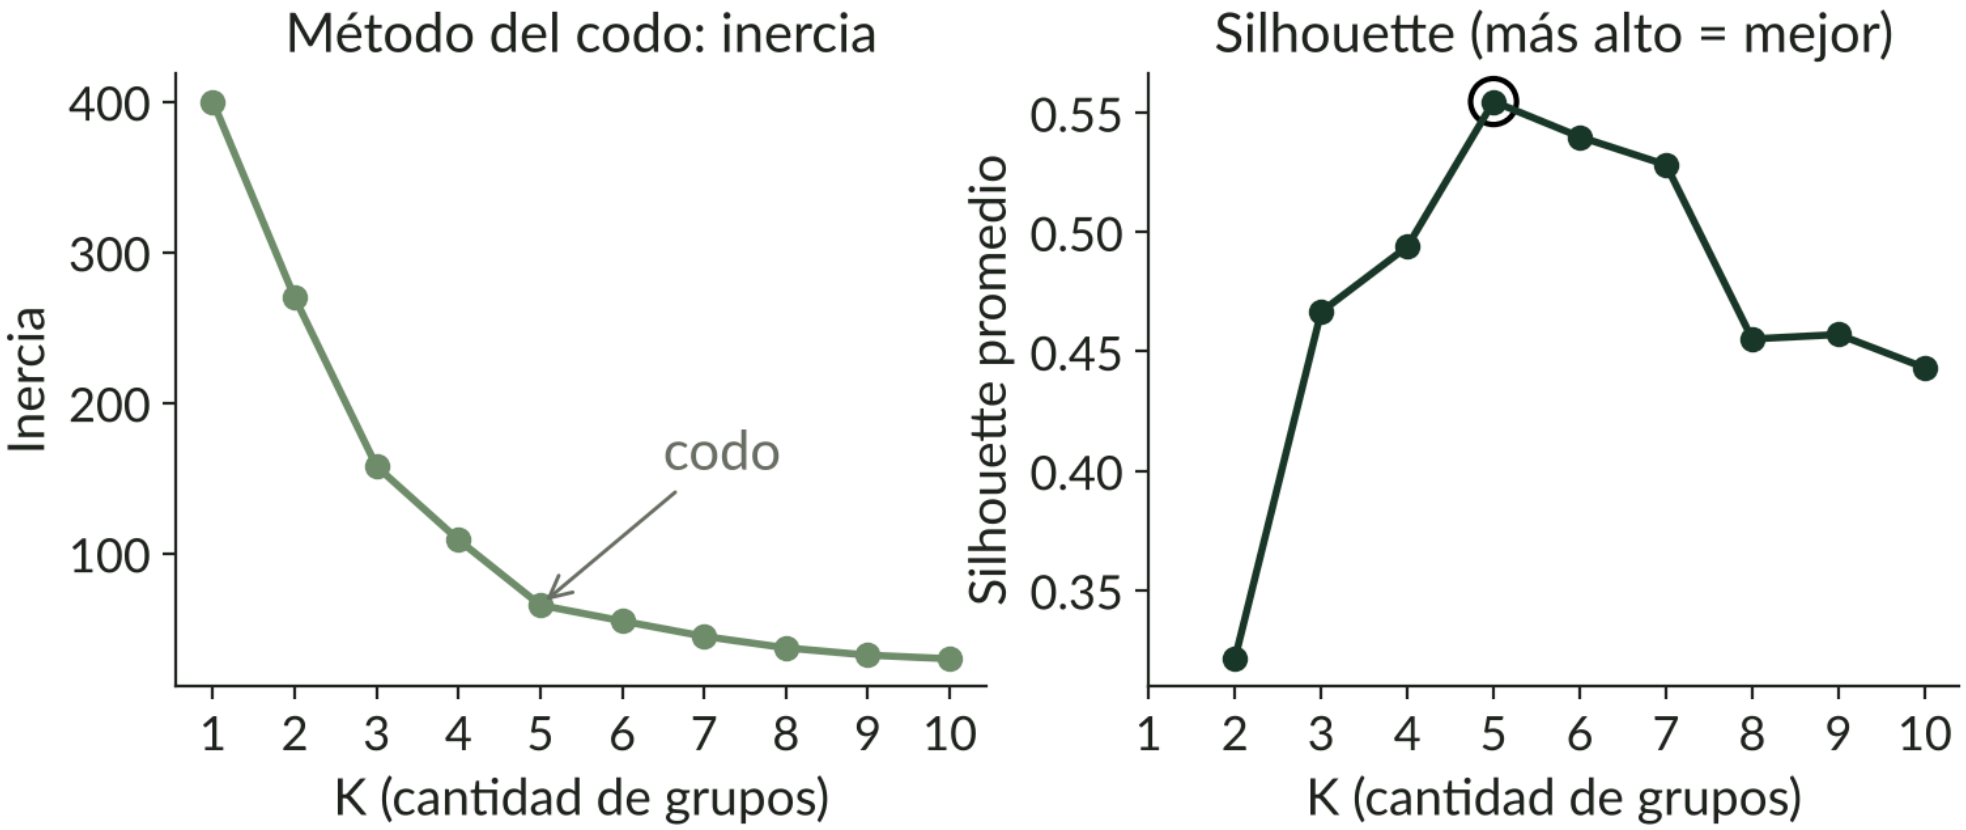
La matemática, muy por arriba

K-means minimiza la inercia:

$$\Sigma \text{ distancia(cliente, su centroide)}^2$$

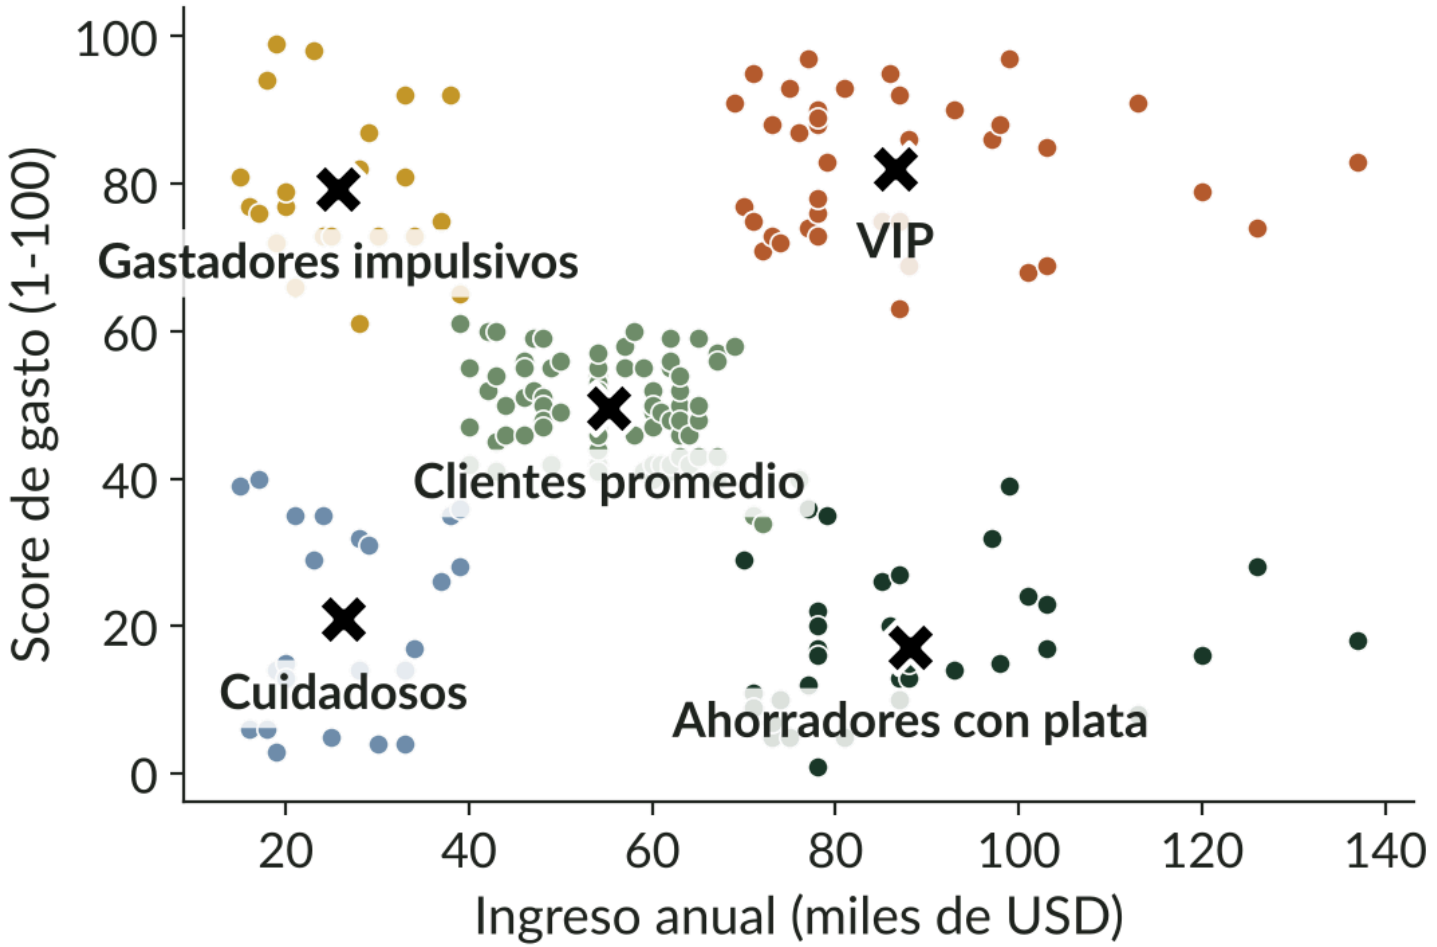
- Traducción: **grupos lo más "apretados" posible**.
- Por eso hay que **estandarizar**: si no, la variable con números grandes domina.
- Depende del arranque al azar: se corre varias veces.

¿Cuántos grupos? K lo elegimos nosotros



- **Codo:** dónde la inercia deja de bajar mucho. **Silhouette:** más alto = grupos más separados.
- Y una pregunta de negocio: ¿cuántas campañas podemos manejar?

El nombre lo ponemos nosotros



Segmento	Acción
VIP	Fidelizar
Ahorradores con plata	Mayor potencial
Impulsivos	Promos, cuotas
Cuidadosos	Descuentos
Promedio	Masiva

Cuidado con K-means

- **Siempre devuelve K grupos**, aunque los datos no tengan grupos.
- **Estandarizar** las variables antes.
- Le gustan los grupos **redondos y de tamaño parecido**.
- Los **outliers** tiran de los centroides.
- Escala muy bien: funciona con millones de clientes.

PARTE 2

Clustering jerárquico

¿Qué países se parecen?

El problema

Una **fintech argentina** quiere expandirse:

¿Qué países se parecen entre sí?

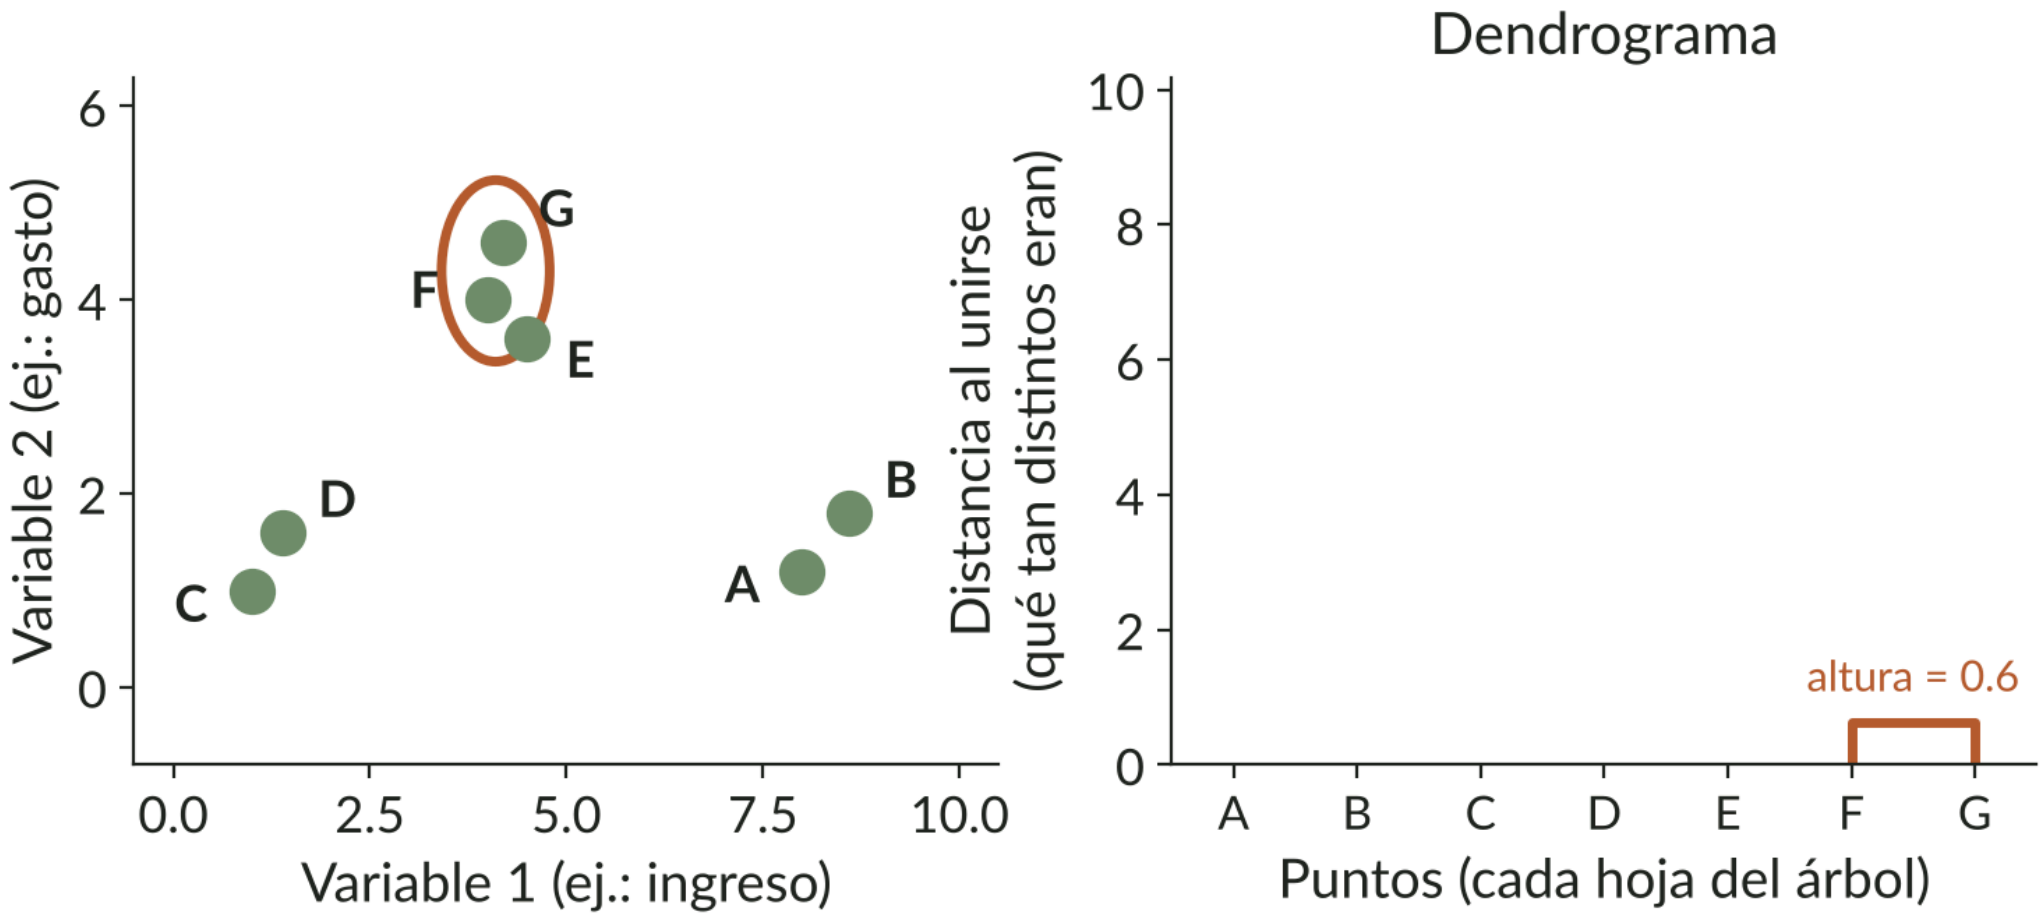
- 193 países, 5 indicadores de la ONU.
- No sabemos cuántos grupos hay.
- Si algo funciona en un país, probablemente funcione en sus "vecinos".

La idea en una frase

Arranco con cada país solo y voy juntando de a dos a los más parecidos, hasta que queda un solo grupo.

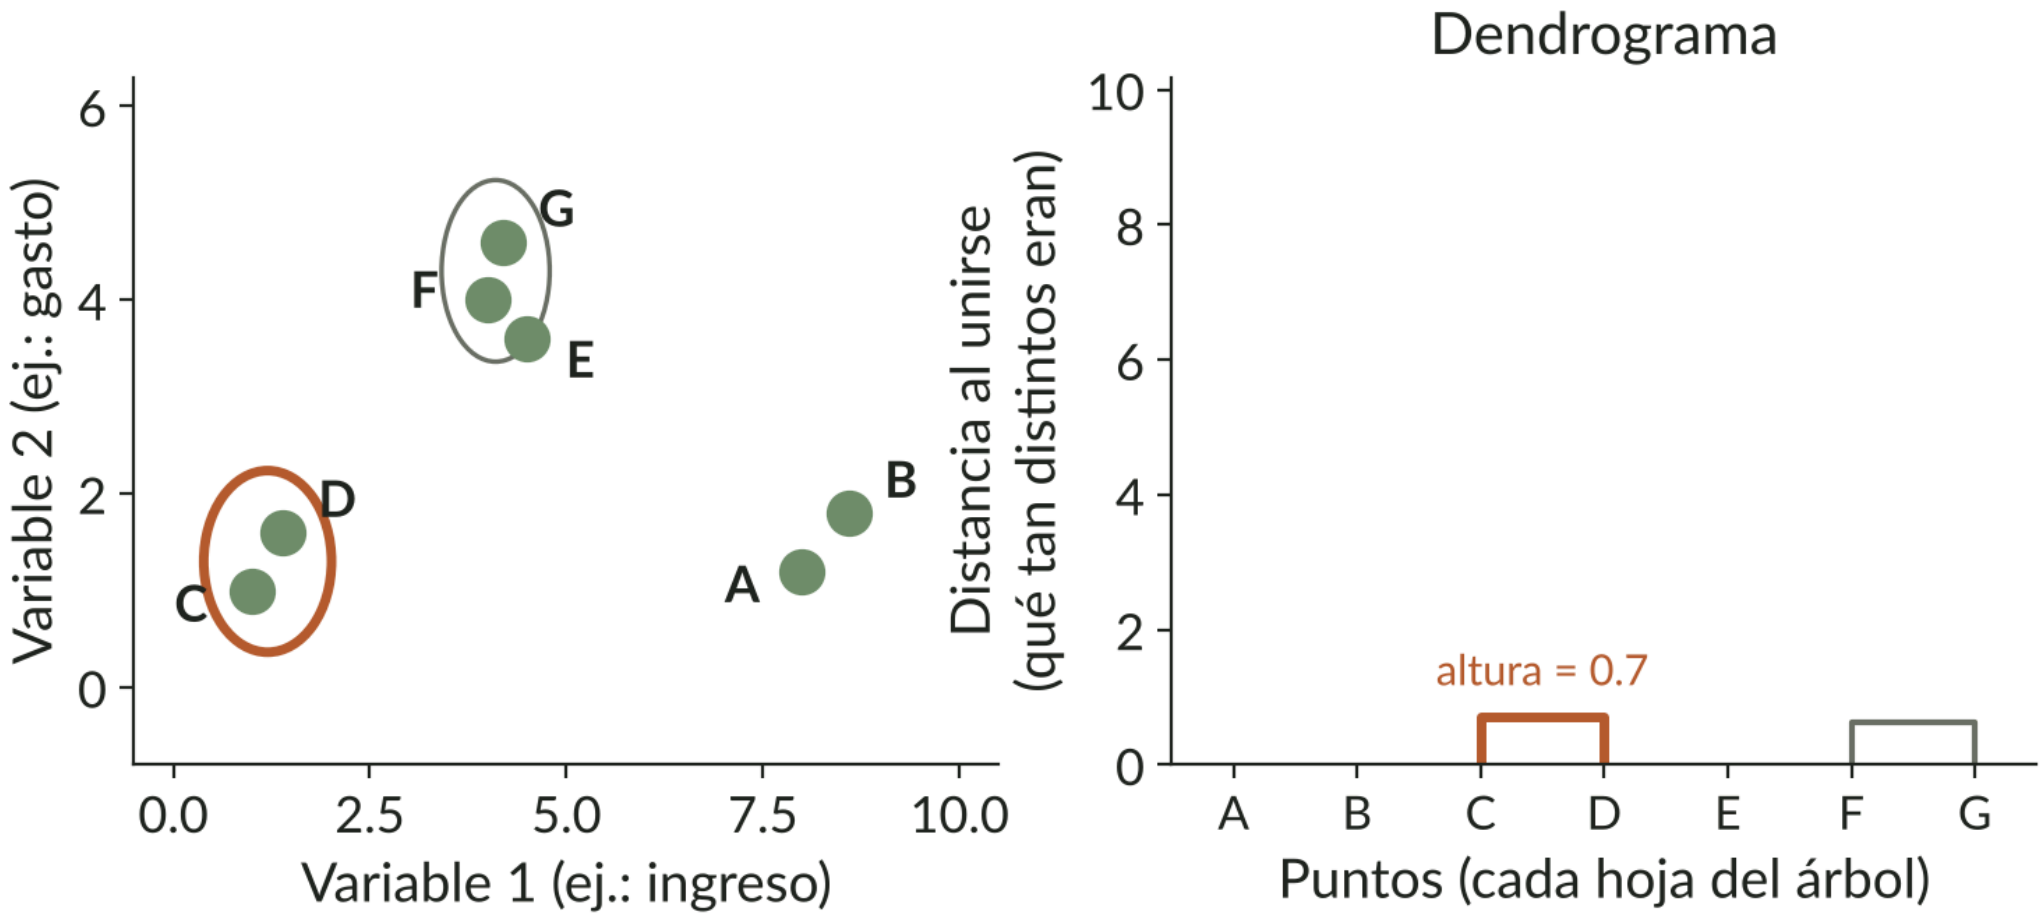
- Como un **árbol genealógico** de parecidos.
- El **dendrograma** dibuja ese árbol. **Abajo**: cada punto. **Altura**: qué tan distintos eran al unirse.
- No hace falta elegir K antes.

Paso a paso · 1



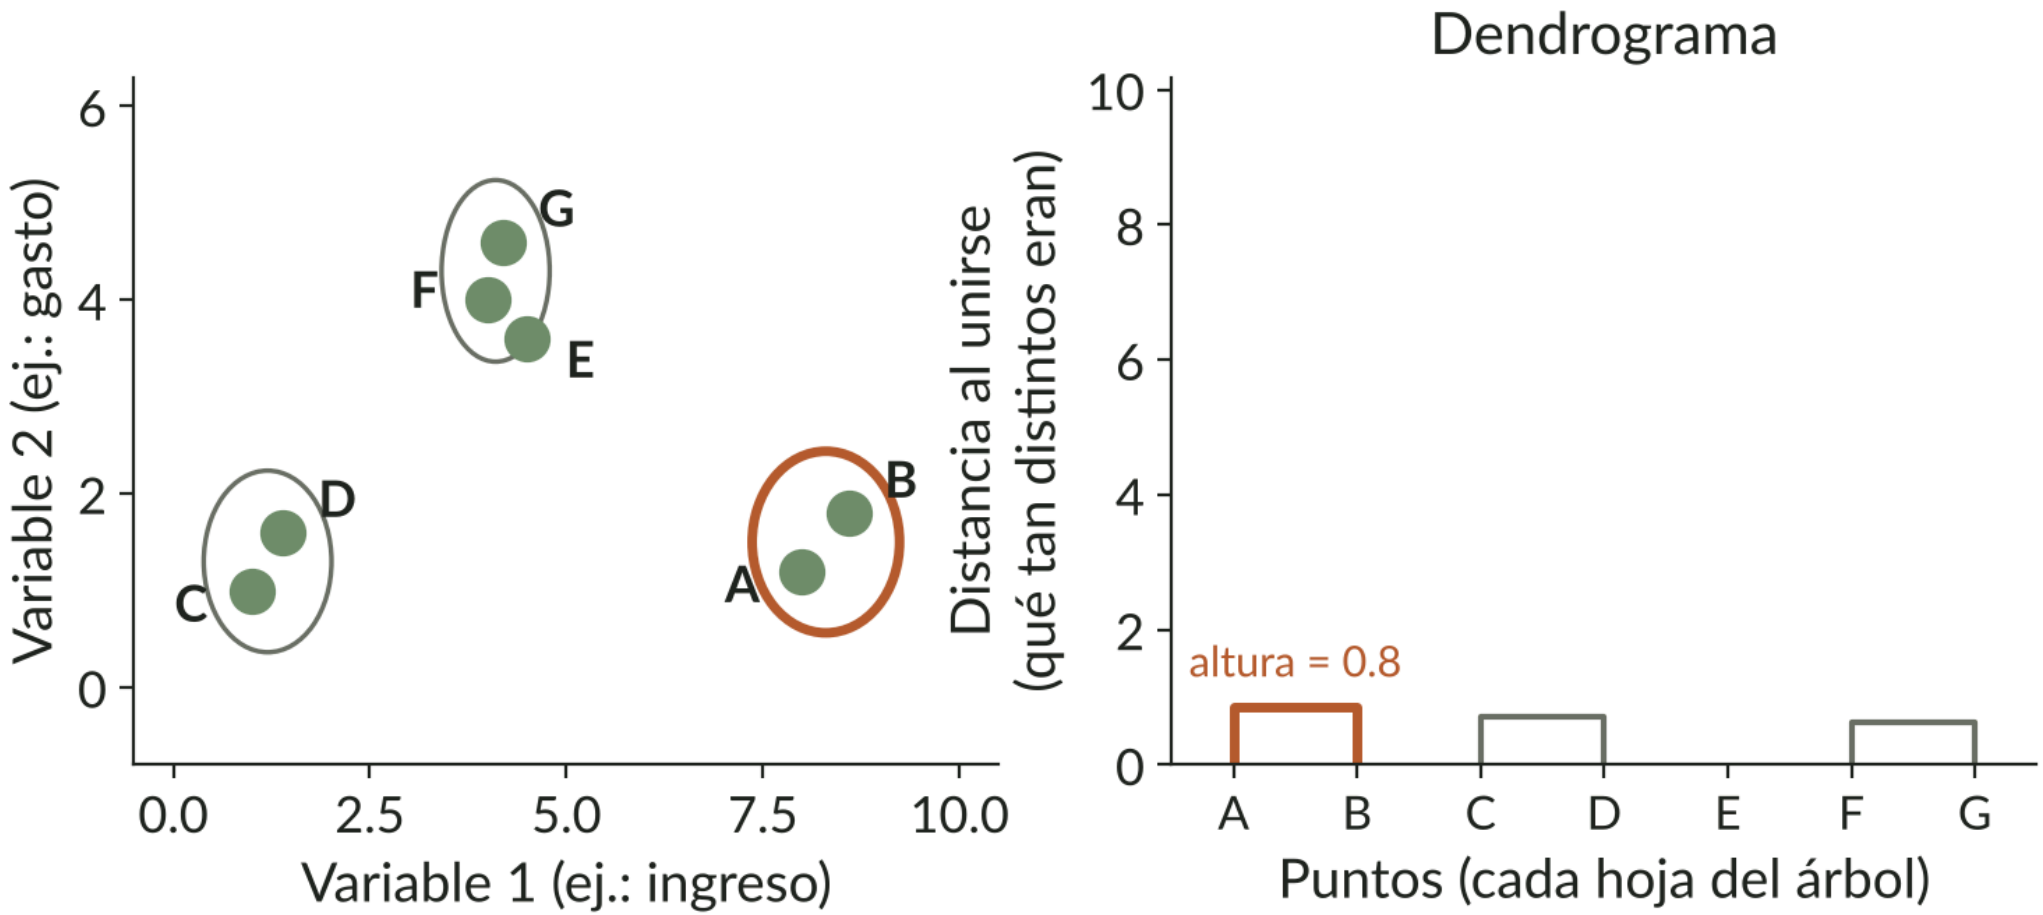
F y G son los más cercanos: se juntan primero. "U" **bajita** = muy parecidos.

Paso a paso · 2



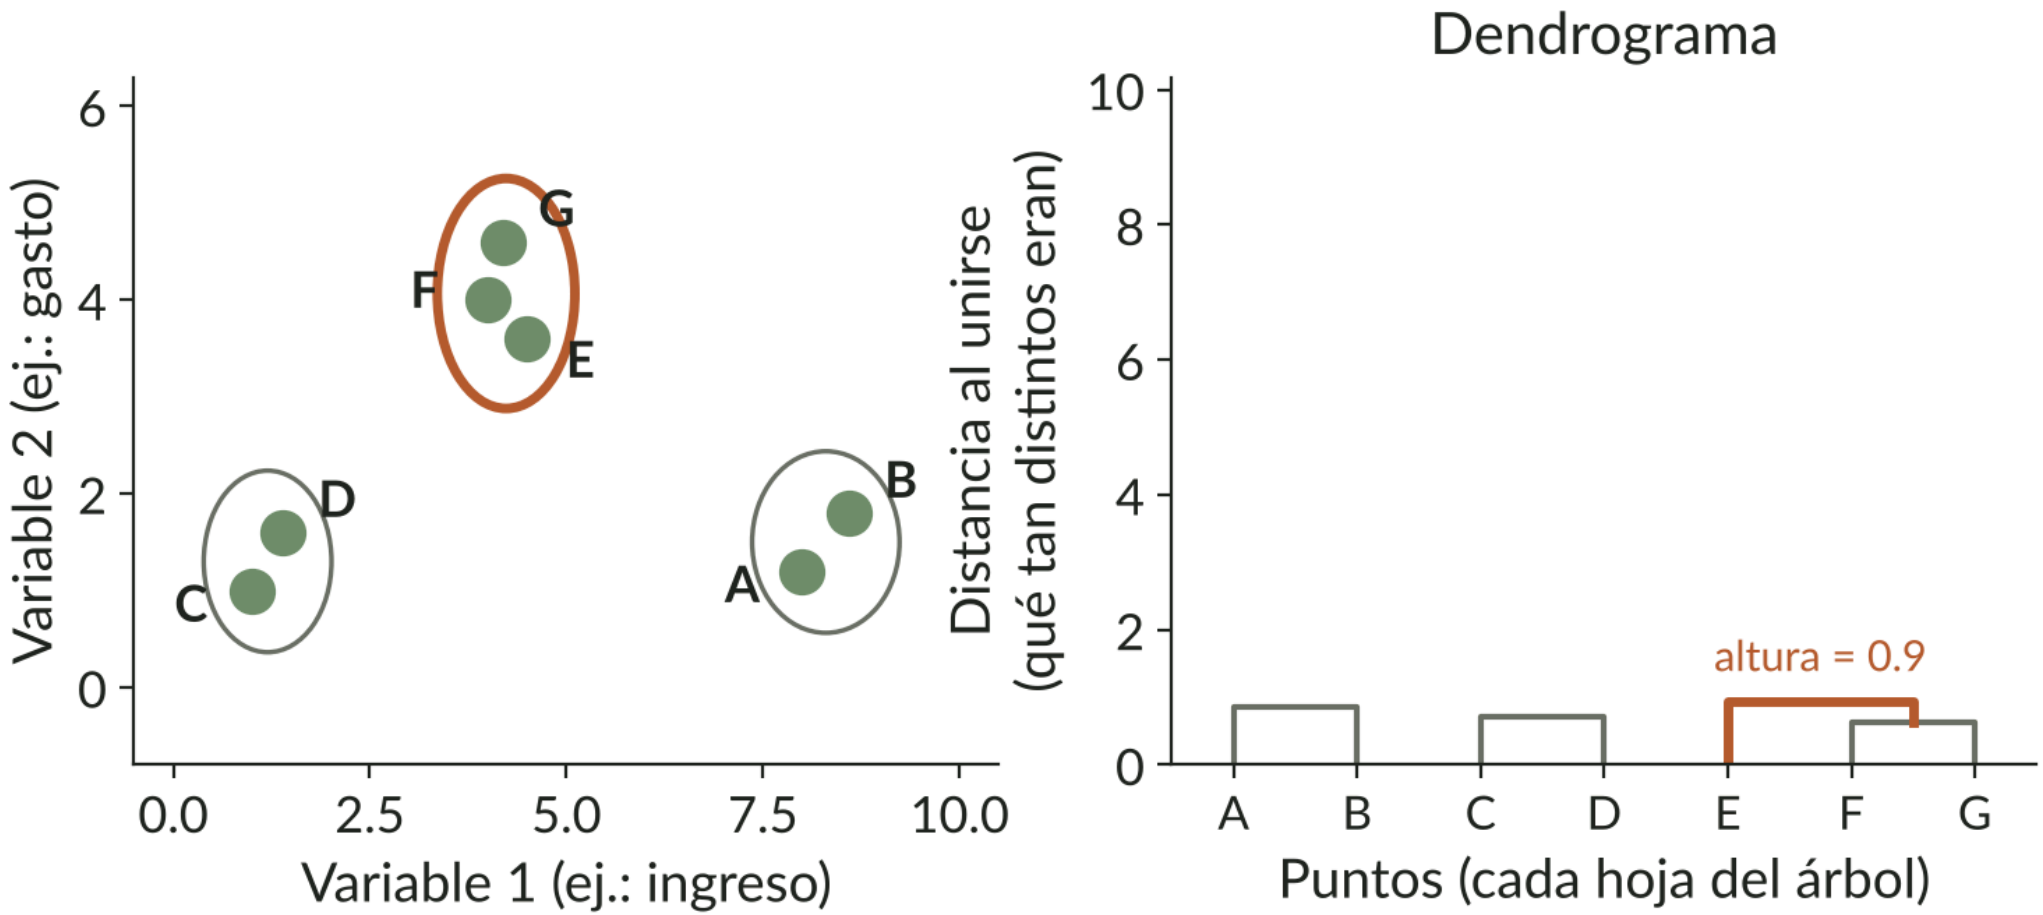
Siguiente par más cercano: C y D.

Paso a paso · 3



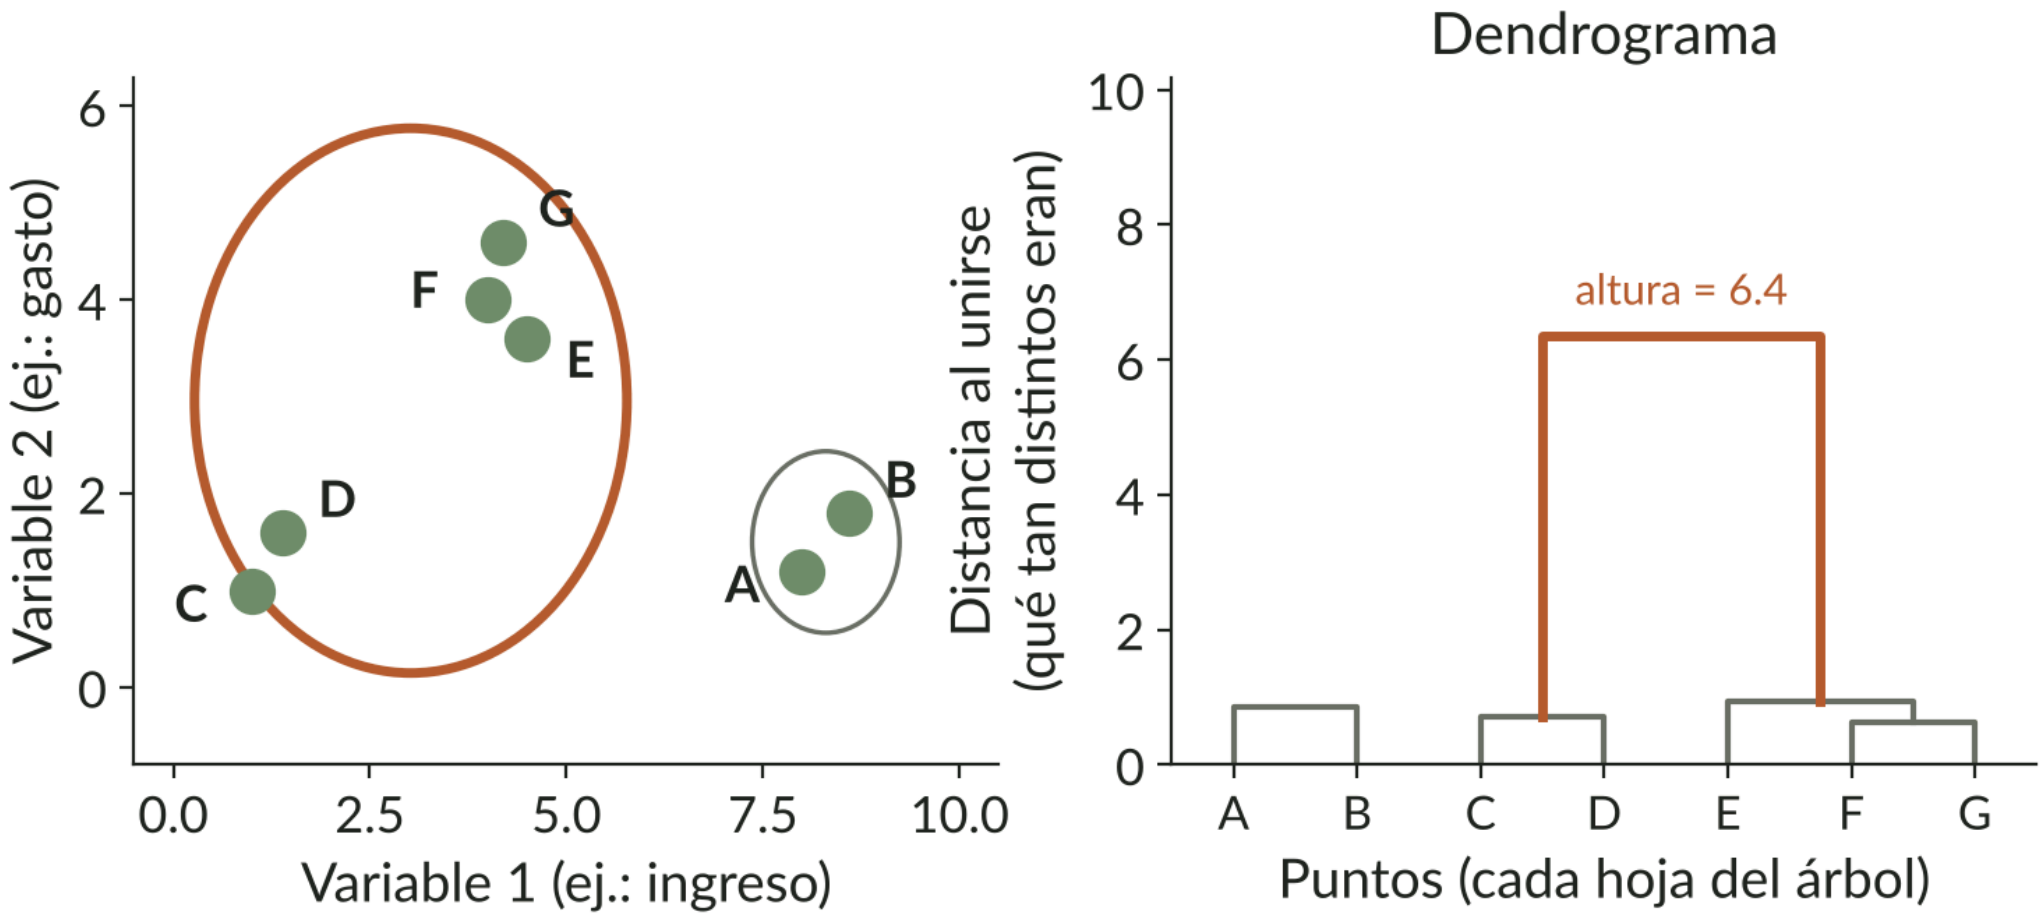
A y B.

Paso a paso · 4



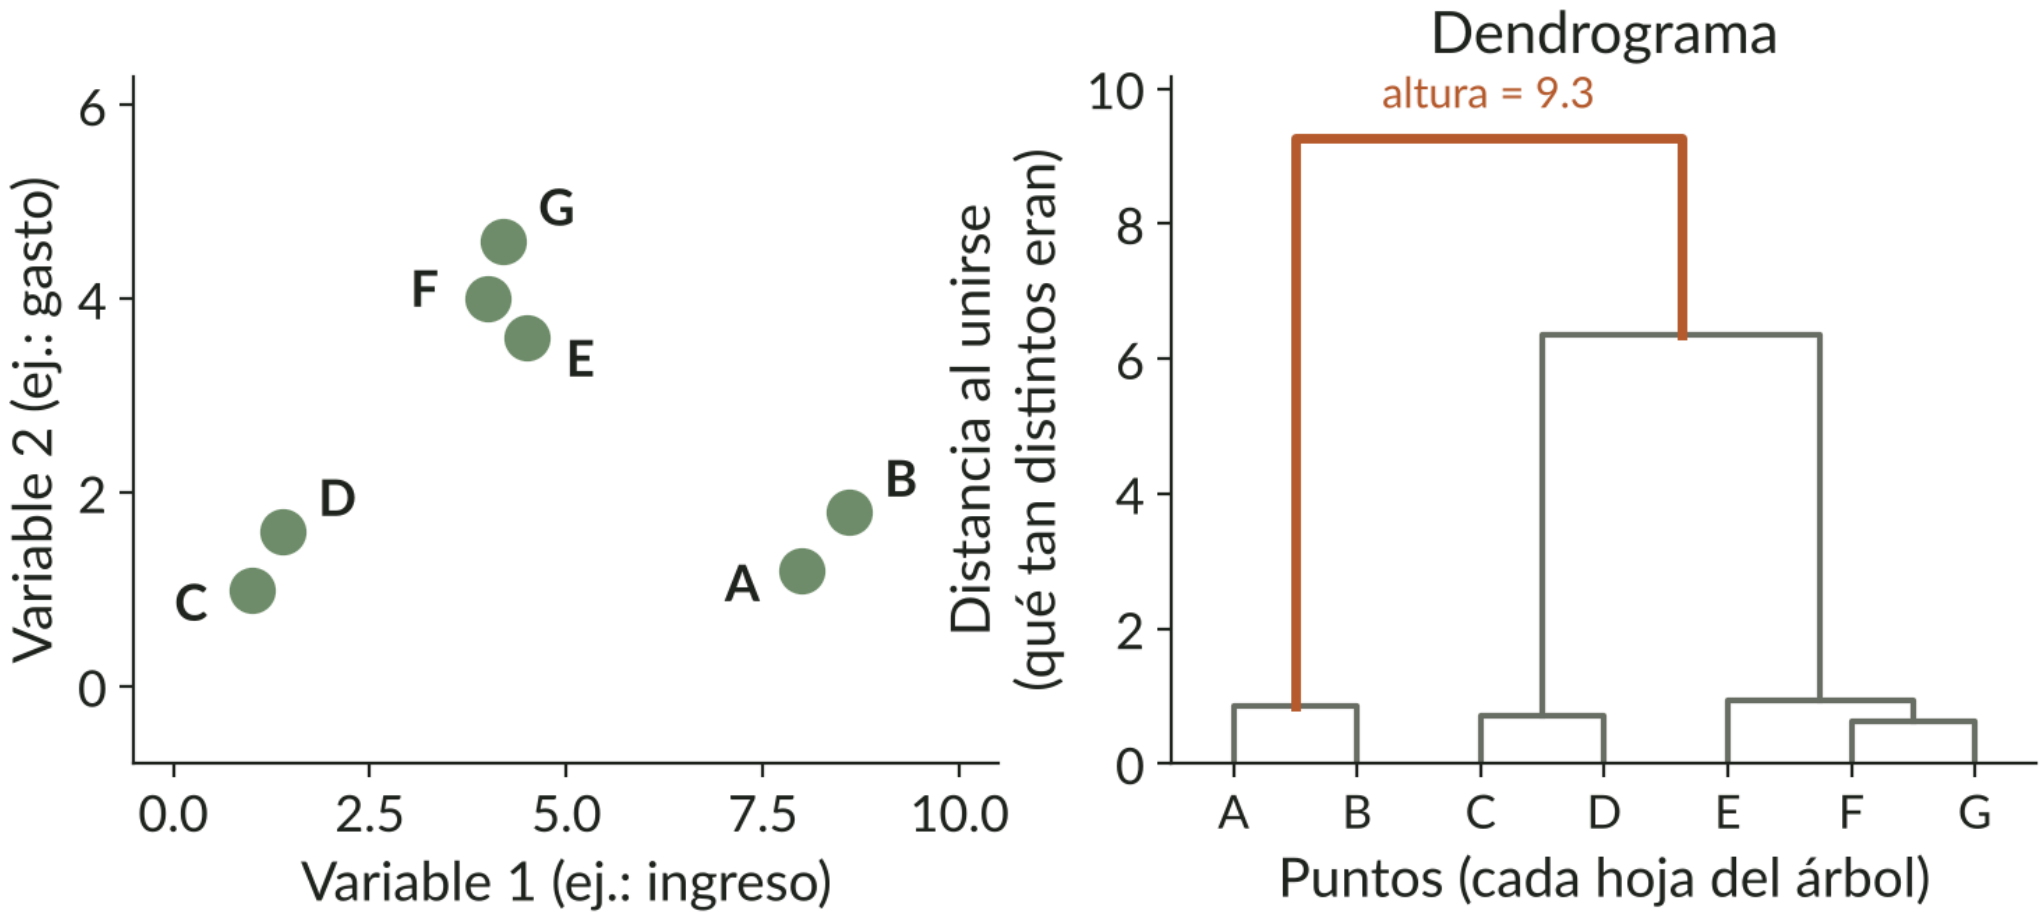
E se suma a F y G. Tres grupitos bien apretados.

Paso a paso · 5



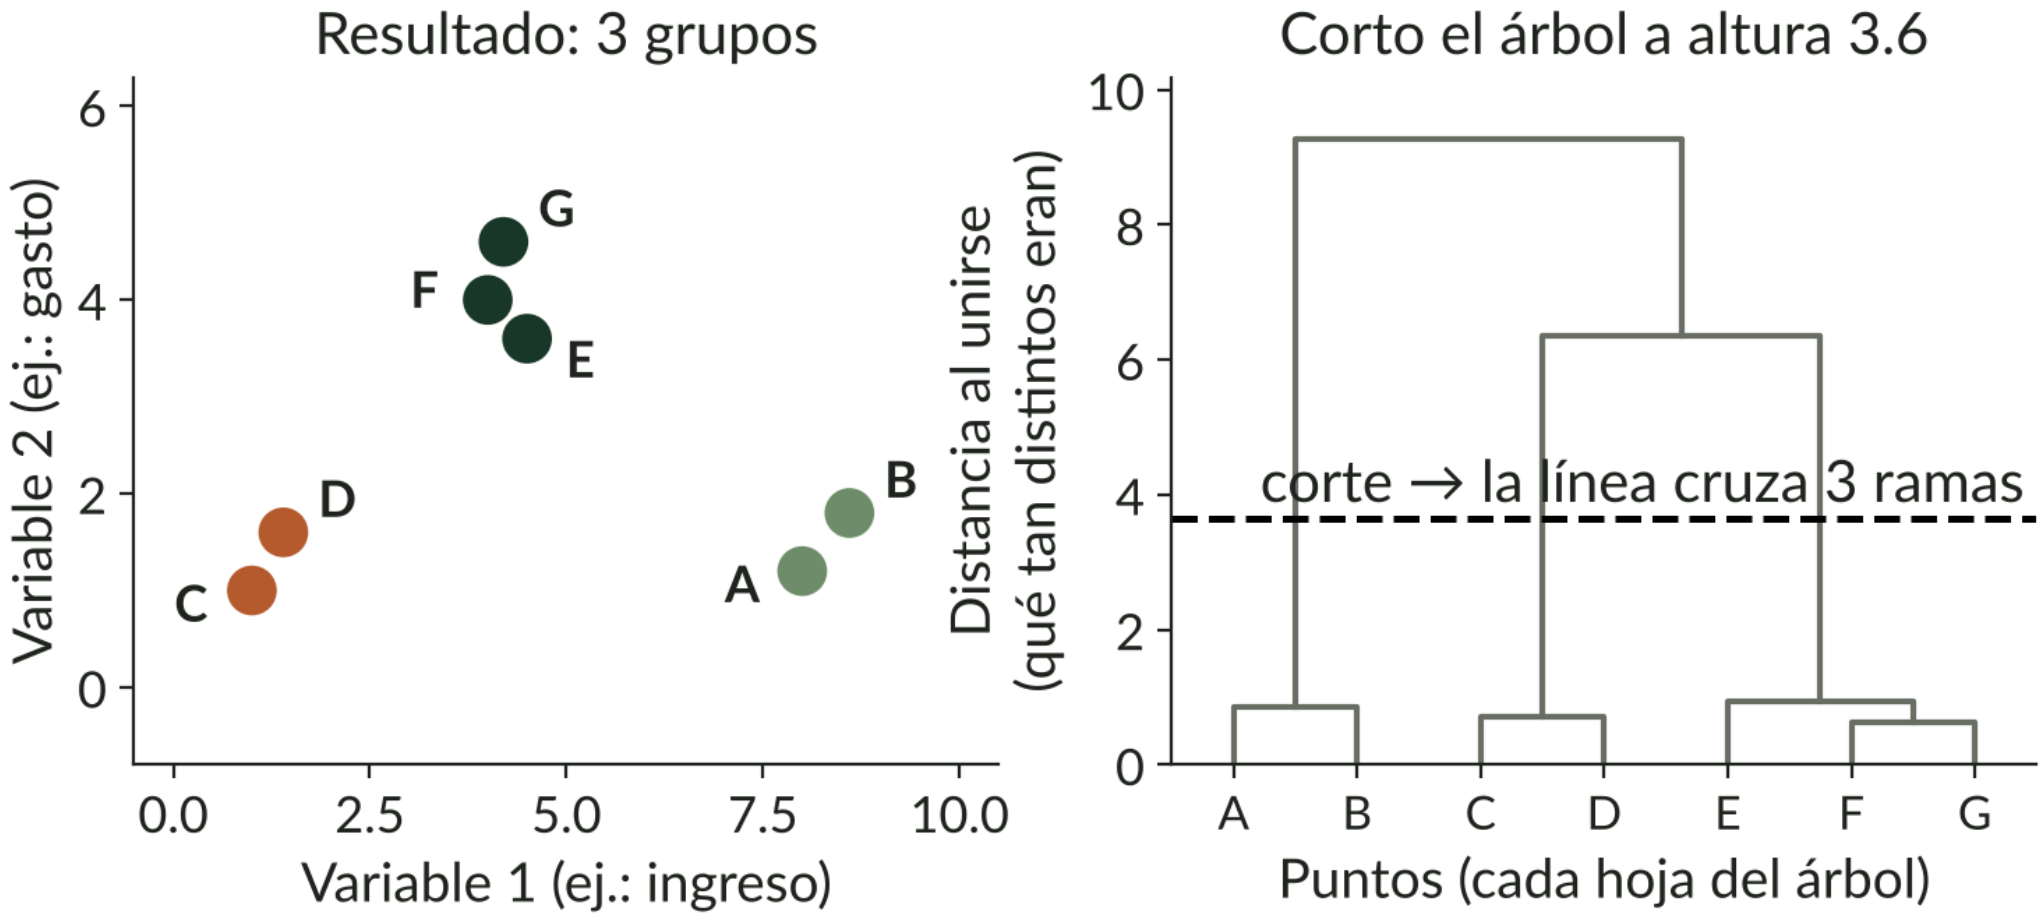
Grupos lejanos: la "U" pega un **salto**.

Paso a paso · 6



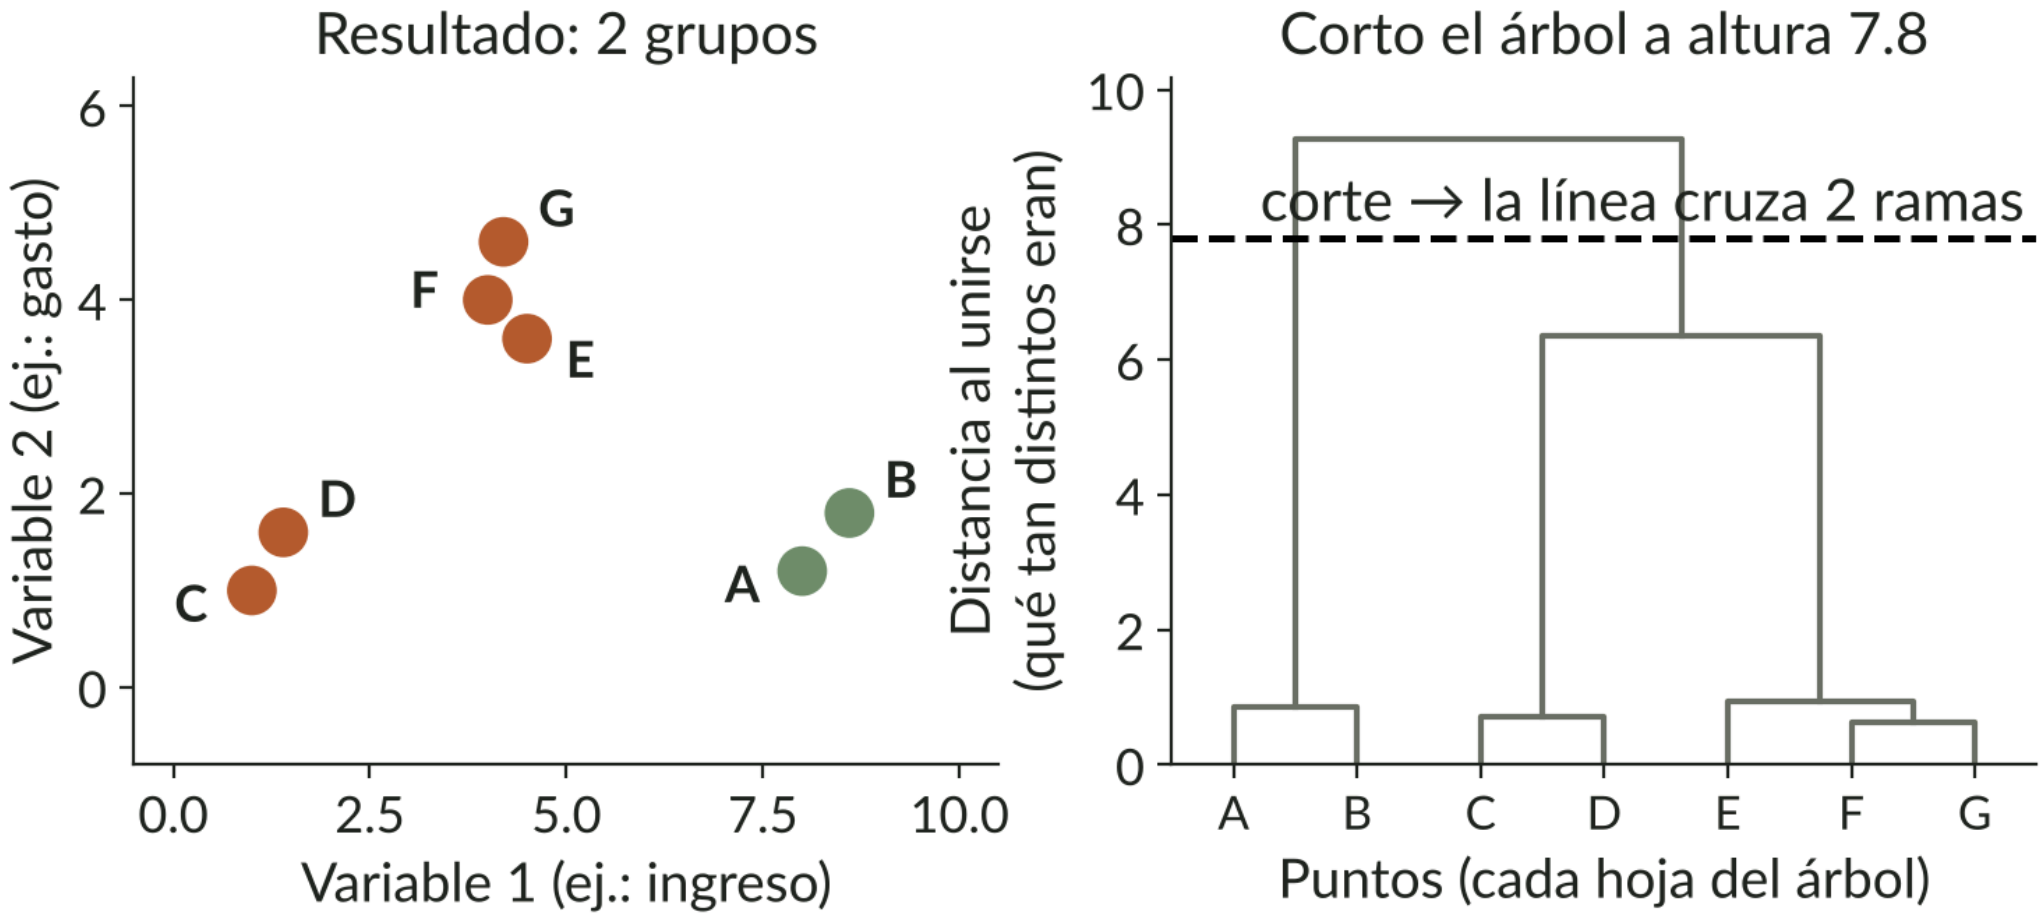
Todo en un solo grupo: el árbol está completo.

¿Cuántos grupos? Corto el árbol



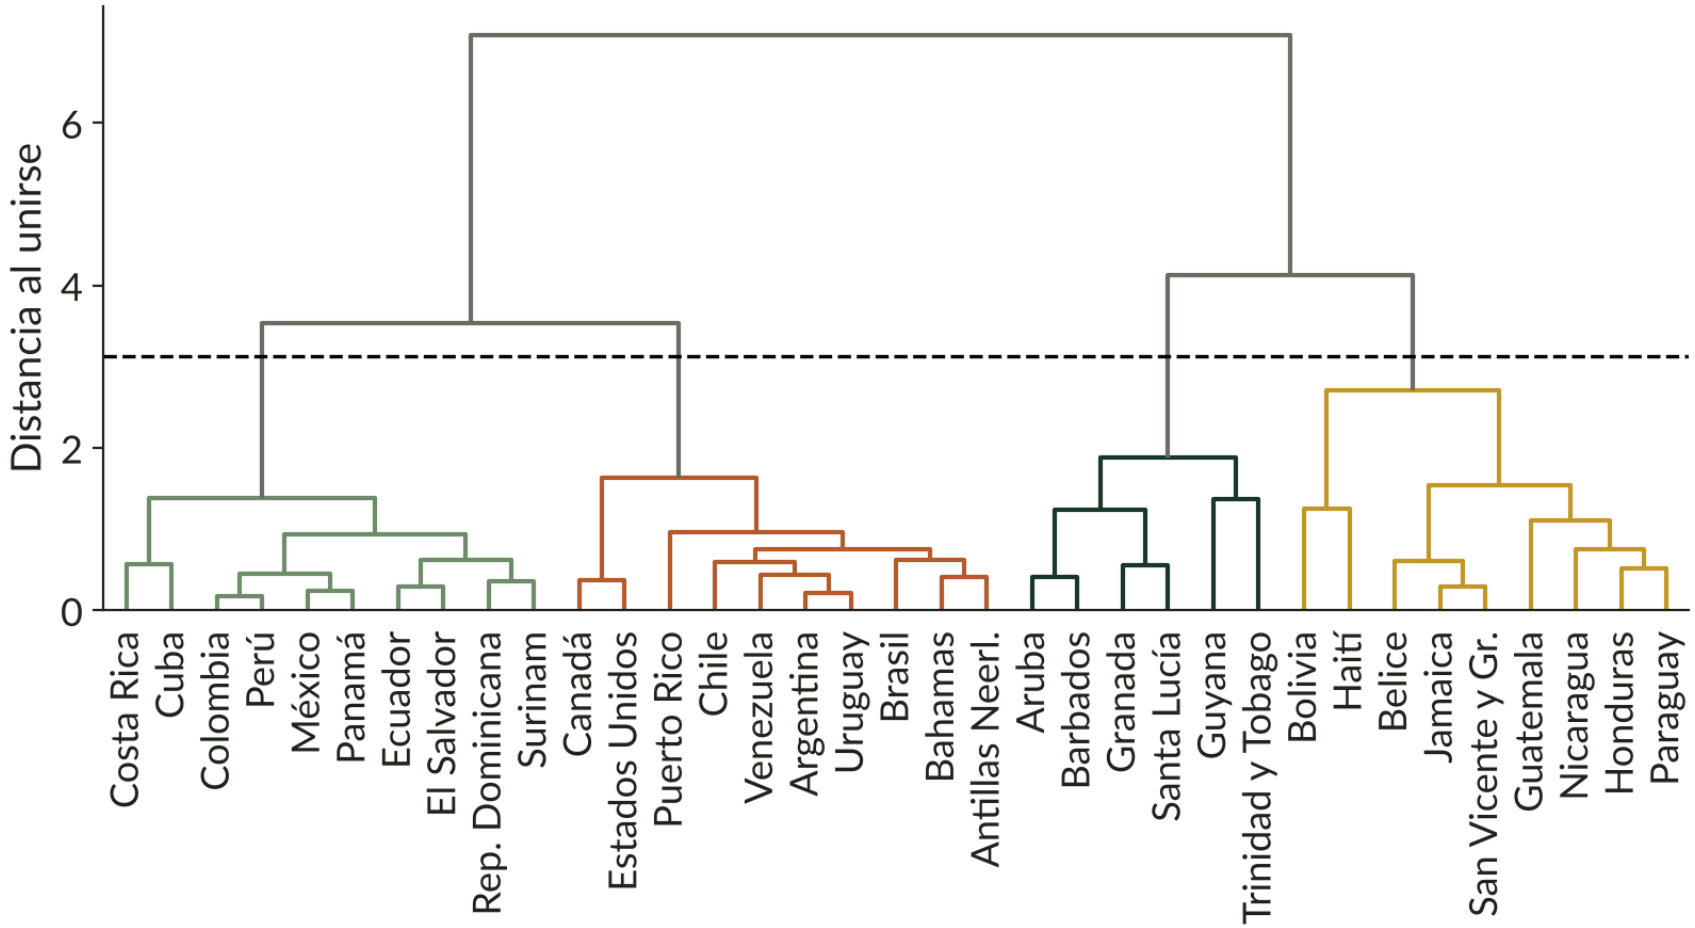
Ramas que cruza la línea = grupos. Corto **debajo del salto**: 3 grupos.

¿Cuántos grupos? Corto el árbol



Más arriba: 2 grupos. ¿Cuál conviene? Depende del negocio.

Con datos reales: países de América



Argentina y Uruguay se juntan **muy abajo**. Cortando en el salto: 4 grupos.

¿Distancia entre grupos? (linkage)

Linkage	Compara los grupos por...
single	los dos **más cercanos** → arma "cadenas"
complete	los dos **más lejanos**
average	el **promedio** de las distancias
ward	que queden **más apretados** (como K-means)

En la práctica: **Ward**.

Con todos los países

Grupo (mediana)	Países	PBI p/c	Esp. vida	Hijos
Alto desarrollo (Argentina)	66	20.556	80,7	1,9
Medio-alto	55	4.496	77,3	2,0
Medio-bajo	53	1.240	64,4	3,8
Bajo desarrollo	19	451	53,1	5,5

Cortando el árbol de los 193 países en 4 grupos.

K-means vs. jerárquico

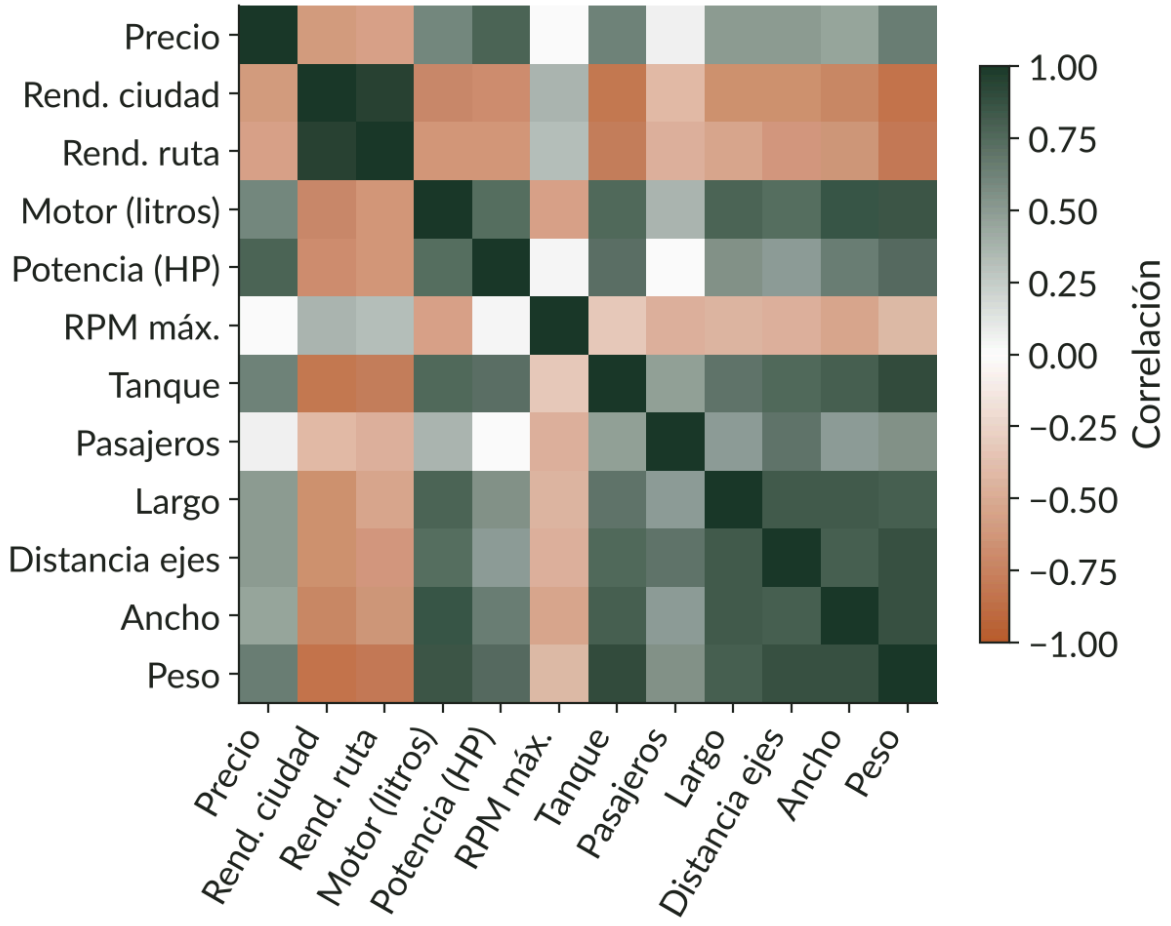
	K-means	Jerárquico
¿Elijo K antes?	Sí	No: corto después
Resultado	Grupos + centroides	Árbol (dendrograma)
Datos	Millones	Hasta miles
Se explica	"Estos son los perfiles"	"Quién se parece a quién"
¿Siempre igual?	Depende del arranque	Sí

PARTE 3

PCA

Resumir muchas variables en un mapa

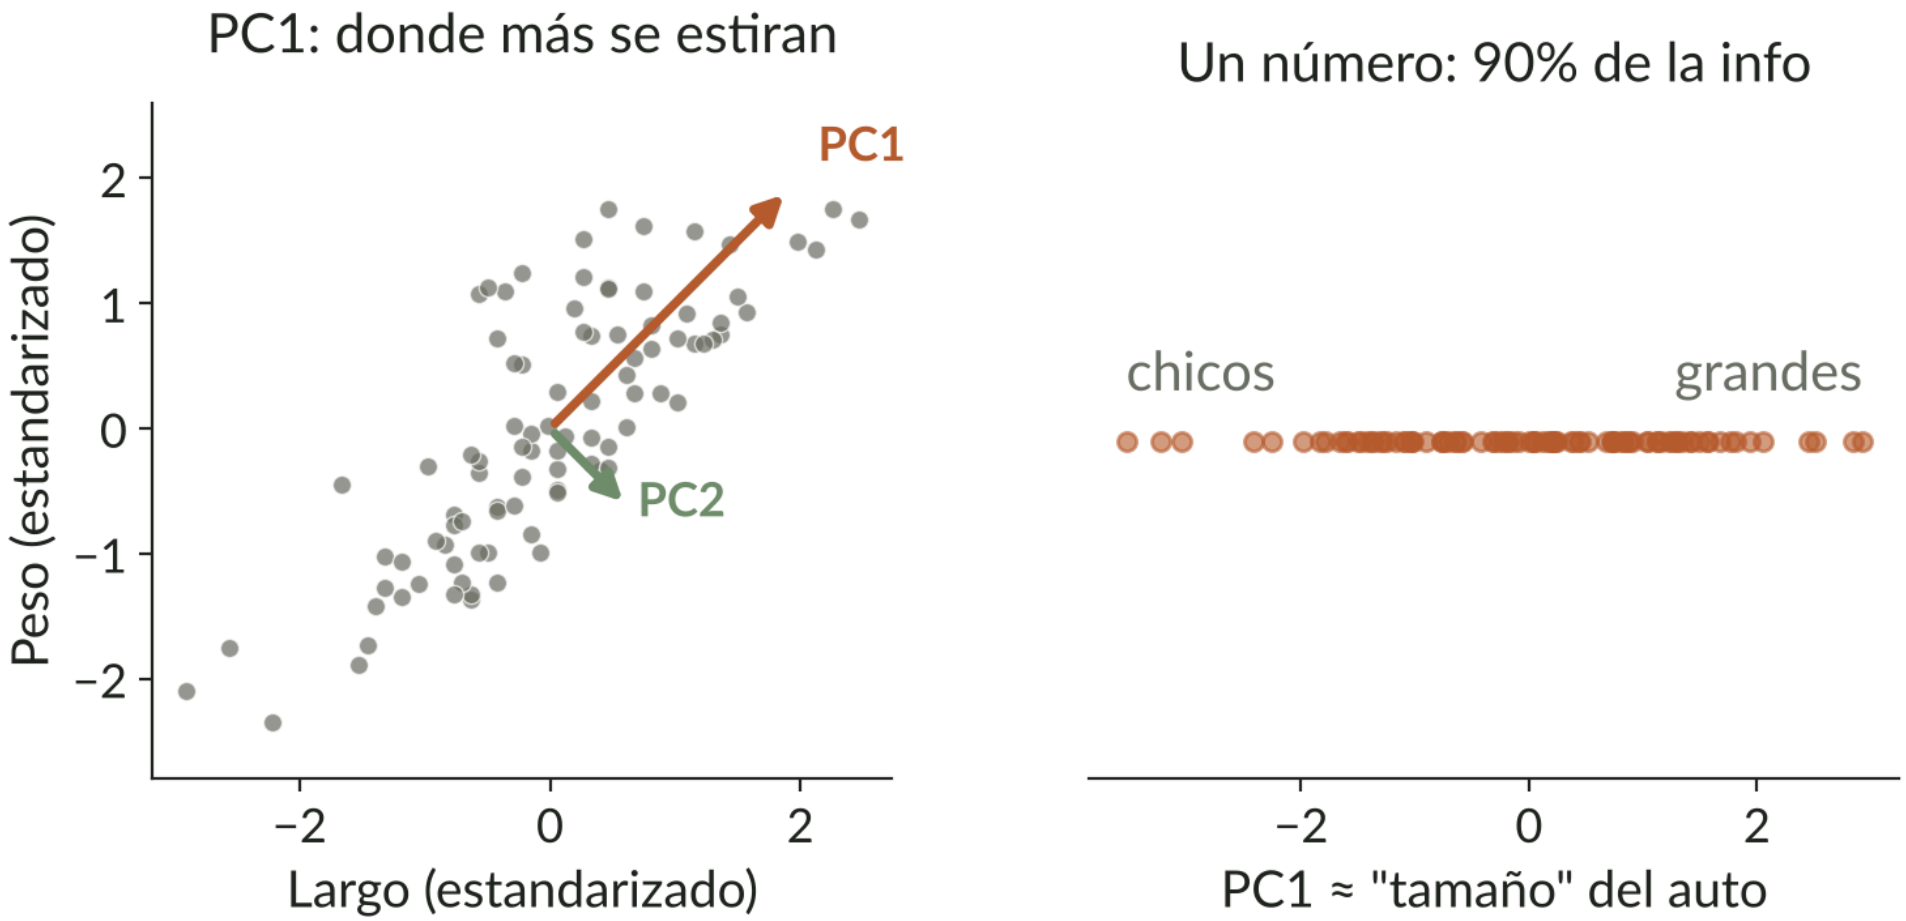
El problema



Automotriz: ¿cómo están **posicionados** los 93 modelos del mercado?

- 12 características: no se pueden graficar.
- Muchas dicen lo mismo: todas miden "qué tan grande es".

La idea: la dirección donde más varían



Giro los ejes: con **un número** (PC1 = "tamaño") conservo casi todo.

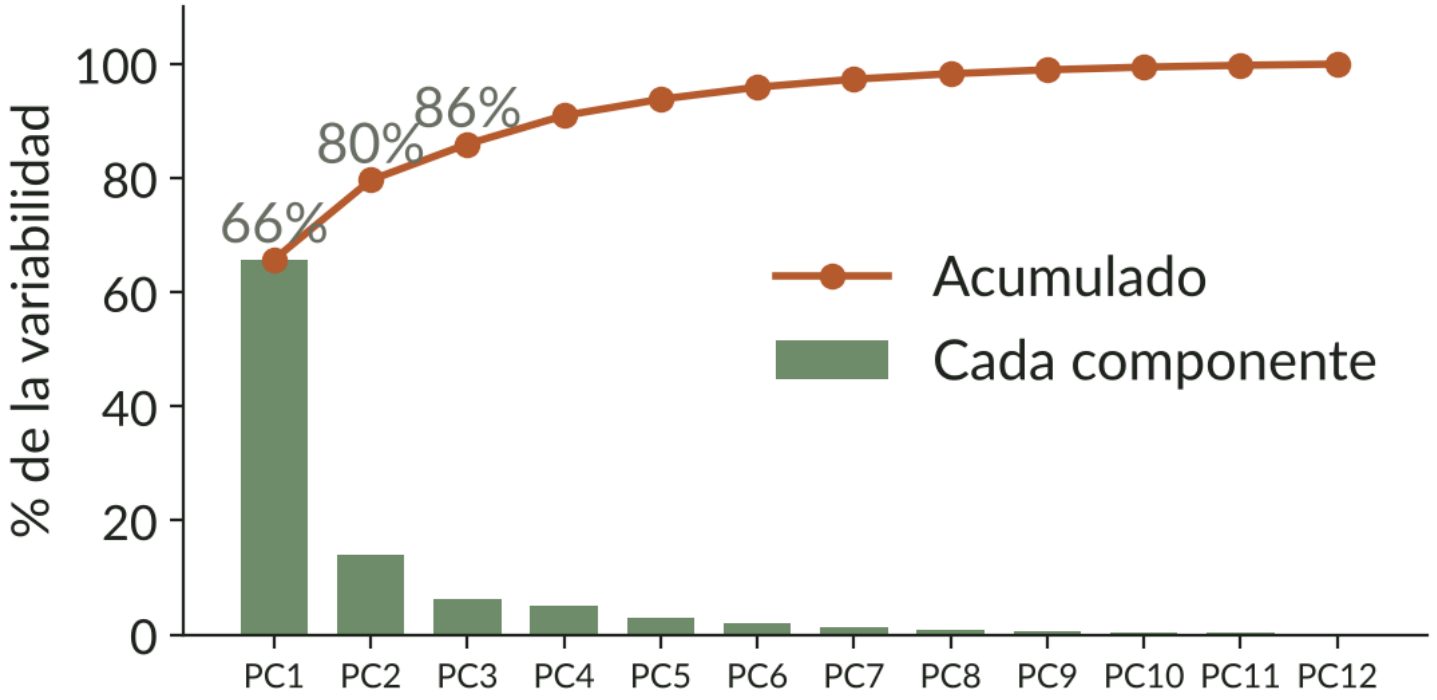
La matemática, muy por arriba

Cada componente es una receta: una suma ponderada de las variables.

$$PC1 = w_1 \cdot \text{precio} + w_2 \cdot \text{rendimiento} + \ldots + w_{12} \cdot \text{peso}$$

- Los pesos *w* (**loadings**) maximizan la varianza de PC1.
- PC2 hace lo mismo con lo que sobra, **sin repetir**.
- Igual que en clustering: **estandarizar antes**.

¿Cuántas componentes me quedo?

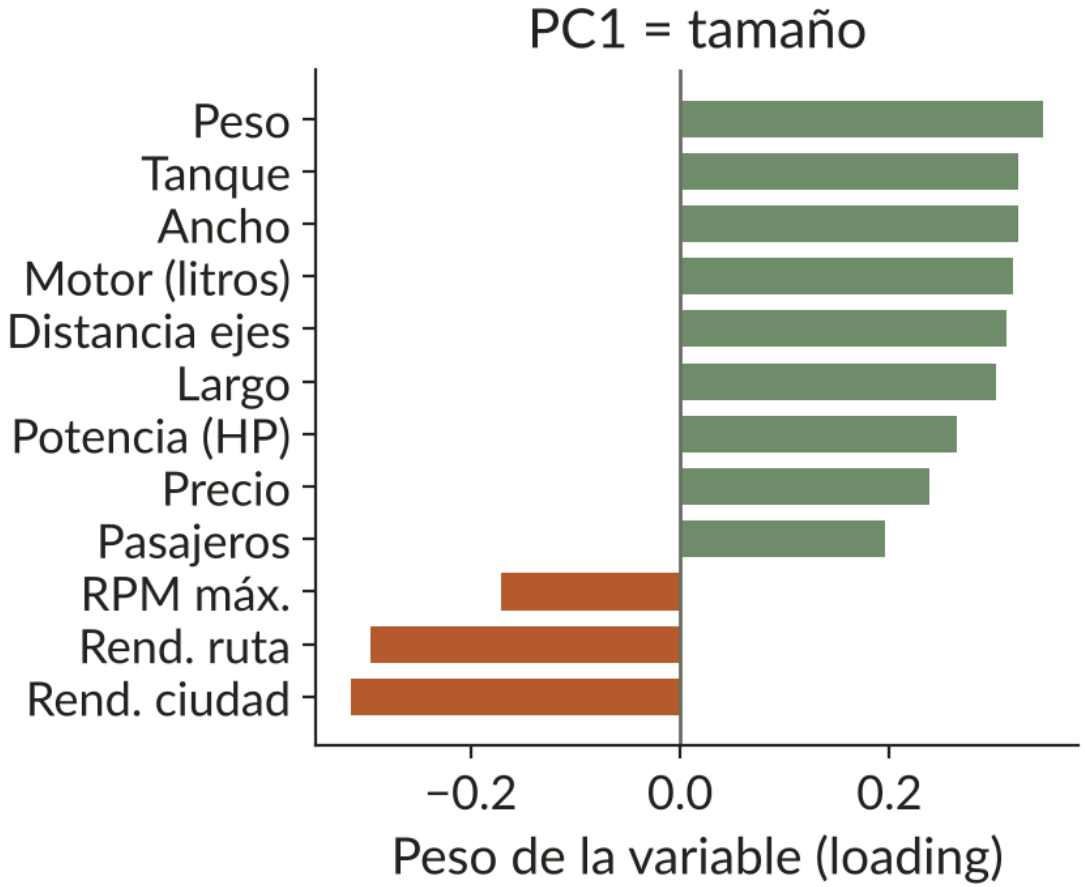


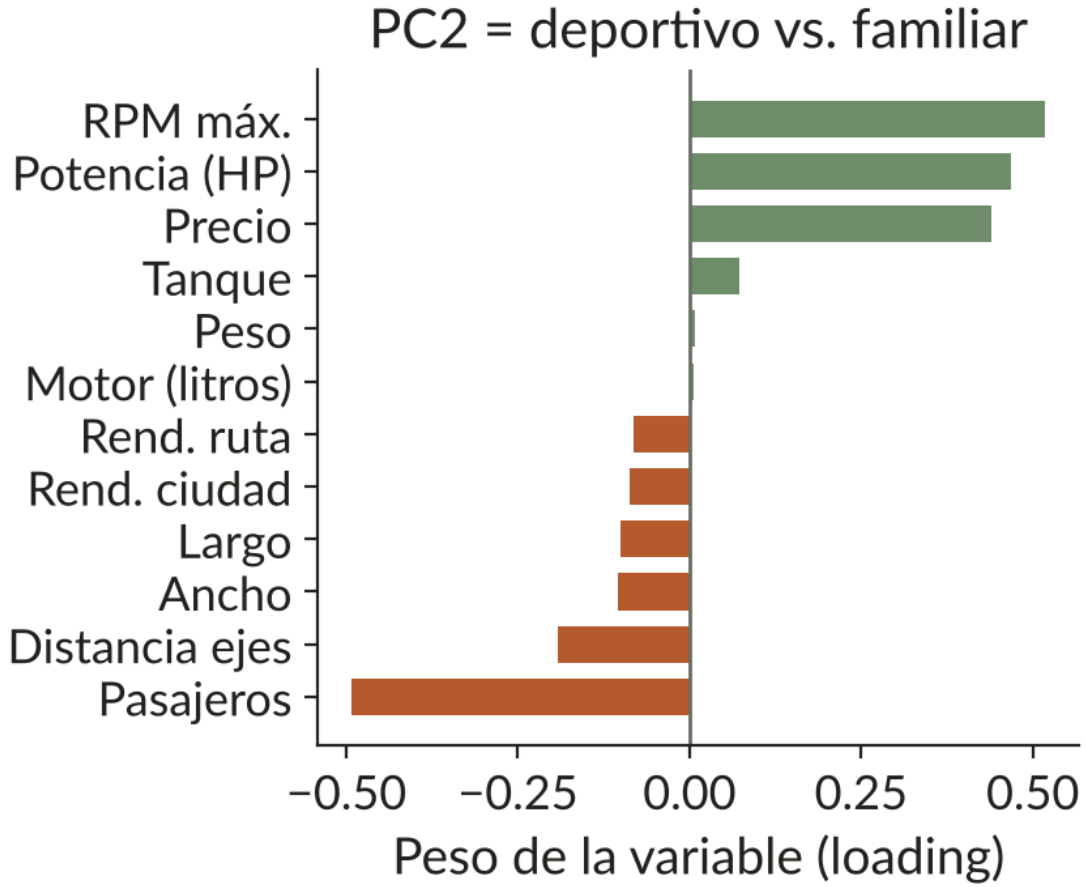
Mirar el **acumulado**: ¿80–90%?

Para **visualizar**: 2.

Para **modelar**: las que hagan falta.

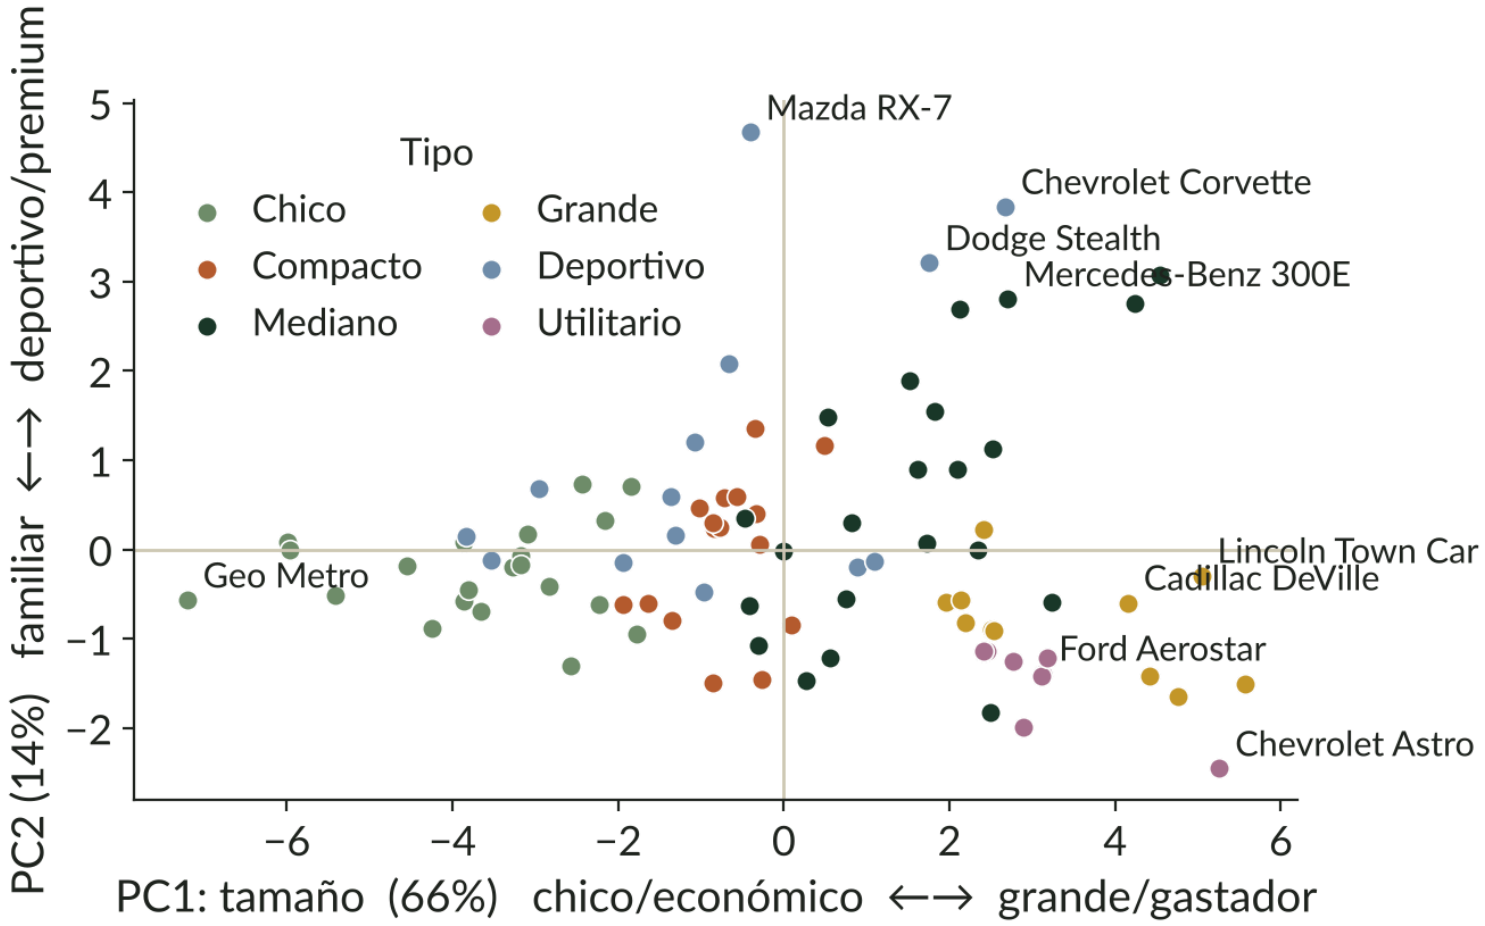
PCA no le pone nombre: lo hacemos nosotros





PC1 = tamaño · PC2 = deportivo/premium vs. familiar

Un mapa de posicionamiento



Vecinos = **competidores** · ¿Hueco? Grande *y* deportivo

Cuidado con PCA

- **Estandarizar** antes.
- Las componentes son **difíciles de explicar**: "subió PC3" no le dice nada a nadie.
- Solo relaciones **lineales**.
- Muy útil para **visualizar**, armar **índices** y antes de clustering.

Resumen

	K-means	Jerárquico	PCA
Hace	Agrupa filas	Árbol de parecidos	Resume columnas
Usalo para	Muchos clientes	Pocos casos, sin K	Mapas, índices
Decidís vos	K	Dónde cortar	Cuántas componentes

Siempre: **estandarizar** · **ponerle nombre** · **validar con el negocio**

¿Dudas? ¿Consultas?