ANALÍTICA DE DATOS

Aprendizaje no supervisado

K-means · clustering jerárquico · PCA

Clase práctica · 2do cuatrimestre 2026

Universidad de SanAndrés

Dónde estás parado hoy

Hasta ahora todos los modelos fueron **supervisados** (KNN, CART, Random Forest, Naive Bayes): había una columna **respuesta** (¿pagó?, ¿compró?, ¿cuánto gastó?) y el modelo aprendía a predecirla. Y podíamos medir si acertaba.

Hoy no hay respuesta. Solo tenemos las características de cada caso y buscamos **estructura**: grupos, patrones, resúmenes. No hay "acierto": si sirve o no lo decide el negocio.

Supervisado

"Sé quién se fue: quiero predecir quién se va a ir."

No supervisado

"No sé qué tipos de clientes tengo: quiero descubrirlos."

Tres preguntas de negocio, tres técnicas

K-means

¿Qué tipos de clientes tengo? ¿A quién le mando qué campaña?

Demo 1 · 200 clientes de un shopping

Clustering jerárquico

¿Qué países se parecen entre sí, para decidir dónde expandirme?

Demo 2 · 193 países (ONU)

PCA

Tengo 12 métricas que dicen casi lo mismo: ¿cómo las resumo en un mapa?

Demo 3 · 93 modelos de autos

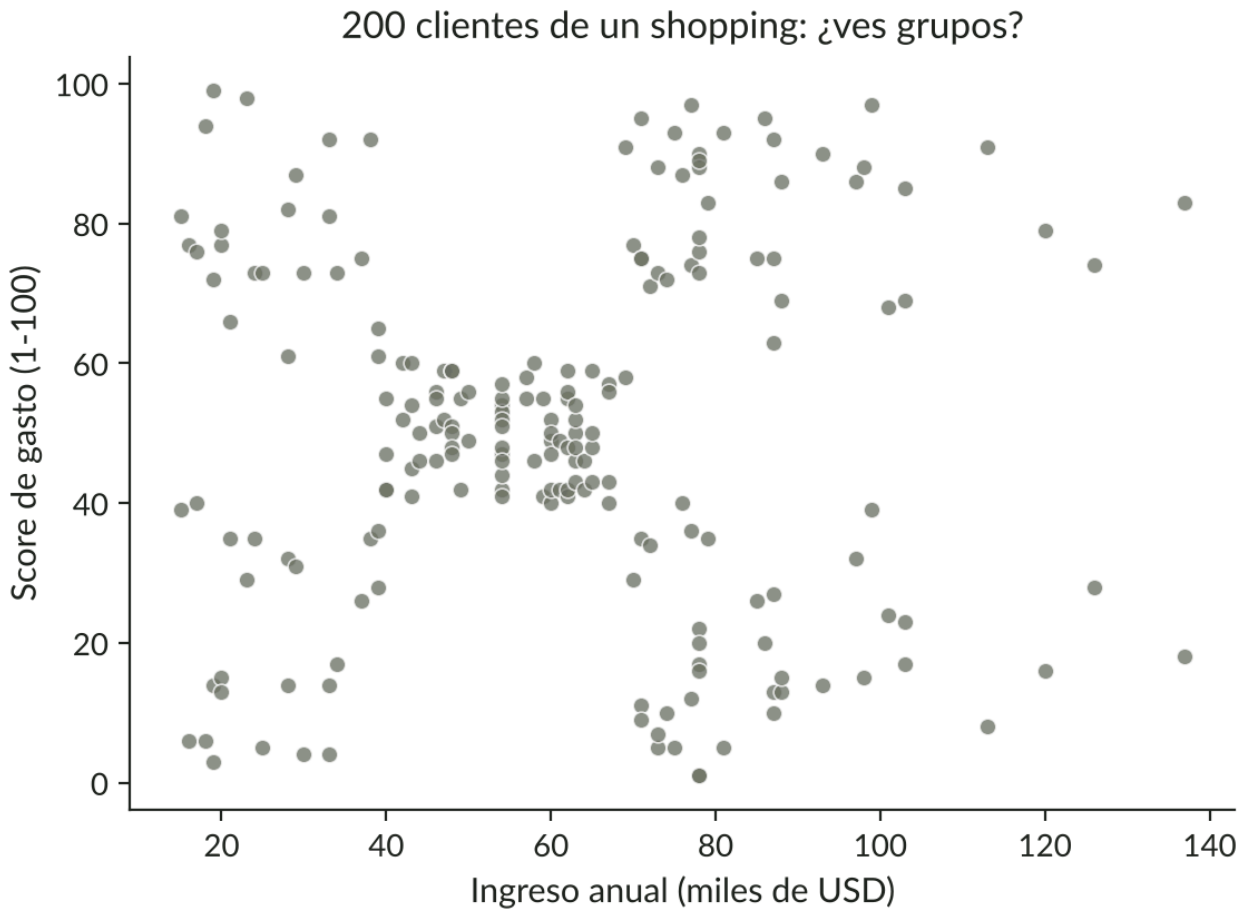
Las dos primeras **agrupan filas** (clientes, países). PCA **resume columnas** (variables).

PARTE 1

K-means

Segmentar clientes

El problema

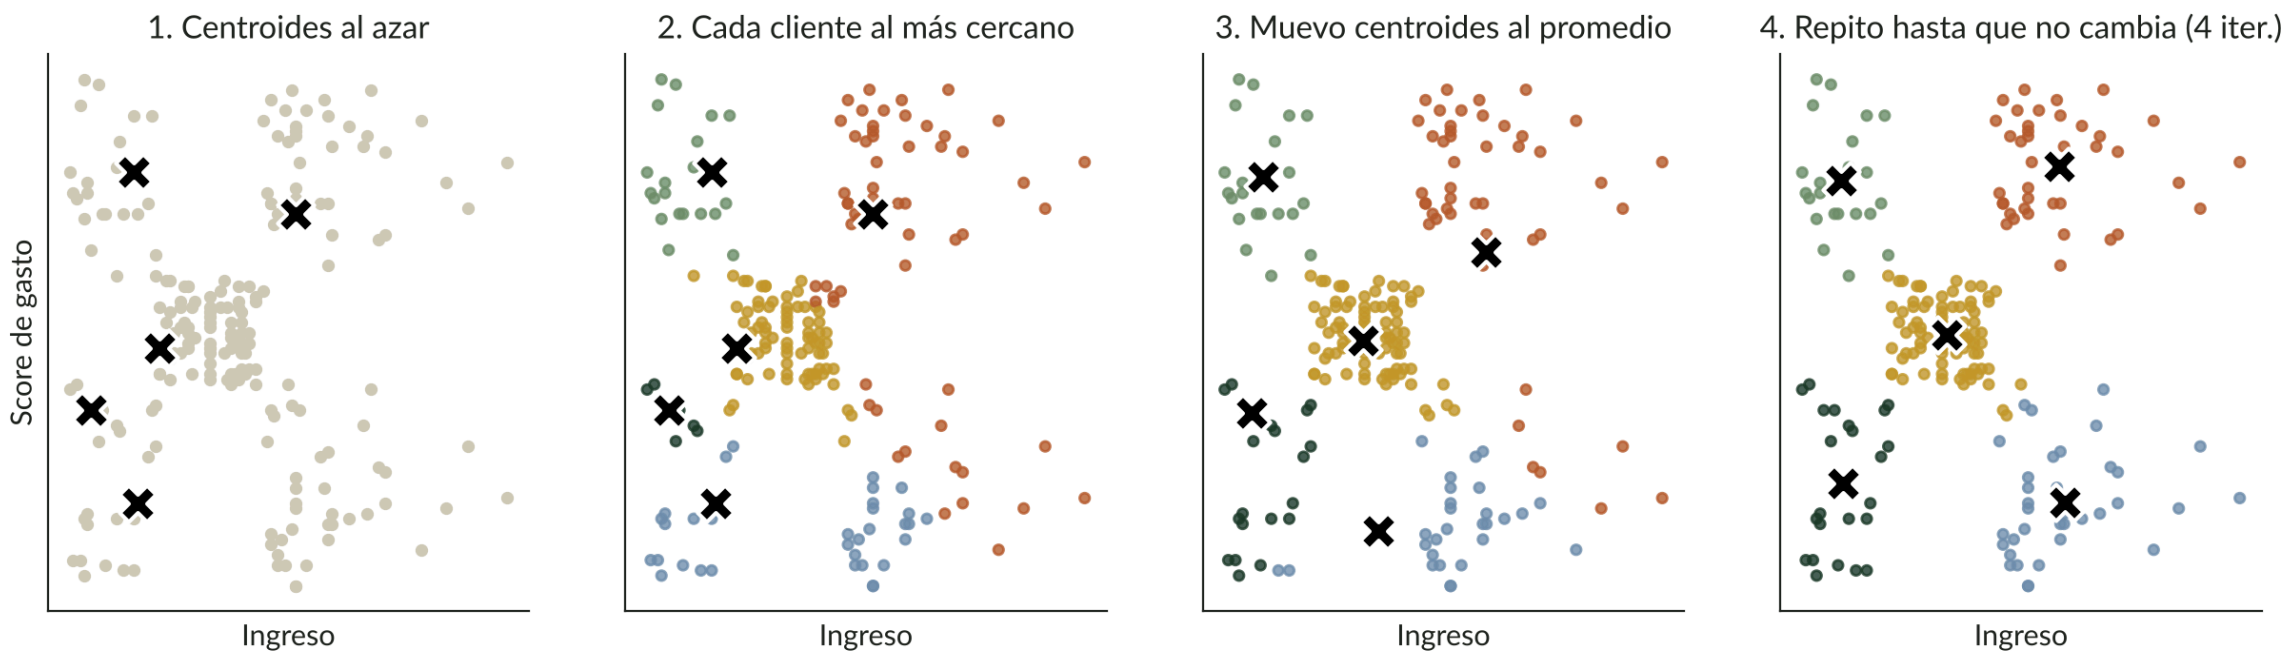


Somos marketing de un shopping. Por cada cliente de la tarjeta de fidelidad tenemos su **ingreso anual** y un **score de gasto** (1 a 100).

Queremos armar campañas para **distintos tipos de clientes**, pero nadie nos dijo cuáles son.

¿Cuántos grupos ves?

La idea: K "clientes representantes"



Elegimos **K** y tiramos K centroides al azar. Cada cliente se asigna al centroide **más cercano**, cada centroide se mueve al **promedio** de sus clientes, y repetimos hasta que nada cambia.

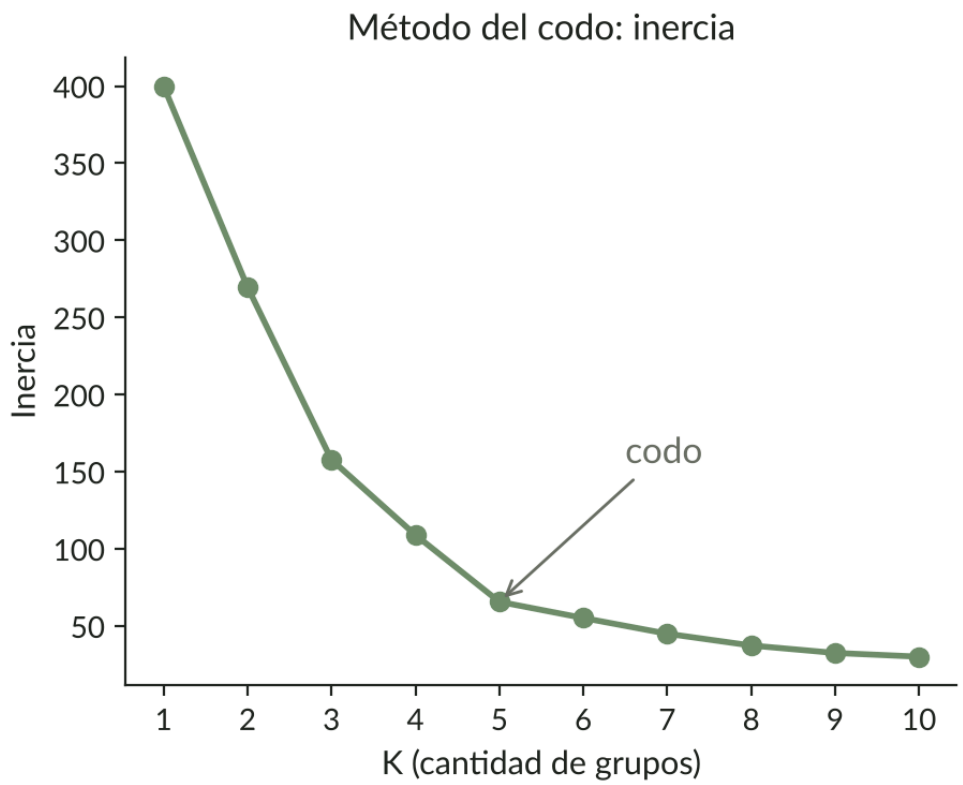
La matemática, muy por arriba

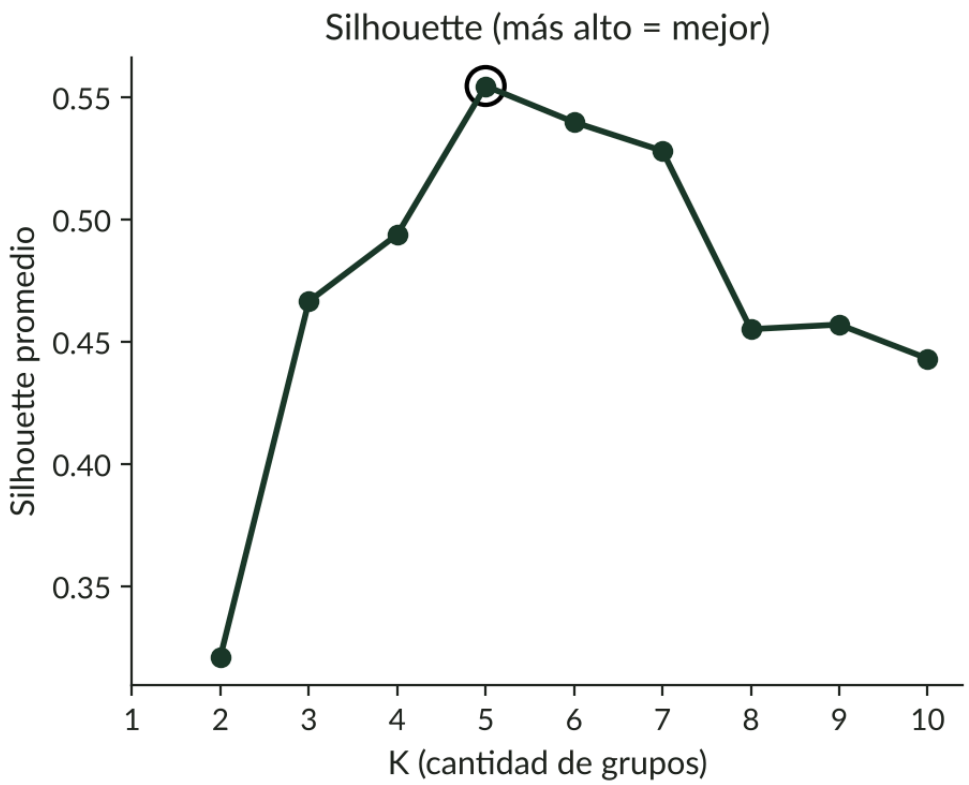
K-means busca los grupos que minimizan la **inercia**:

$$\text{Inercia} = \Sigma_{\text{grupos}} \, \Sigma_{\text{clientes del grupo}} \, \text{distancia}(\text{cliente}, \text{centroide})^2$$

- Traducción: **grupos lo más "apretados" posible** alrededor de su representante.
- "Distancia" = la línea recta (euclídea) entre los valores de las variables, como en KNN.
- Por eso hay que **estandarizar**: si el ingreso está en pesos y el score en 1–100, el ingreso domina la distancia.
- El resultado depende del arranque al azar: se corre varias veces y se queda con el mejor (`n_init=10`).

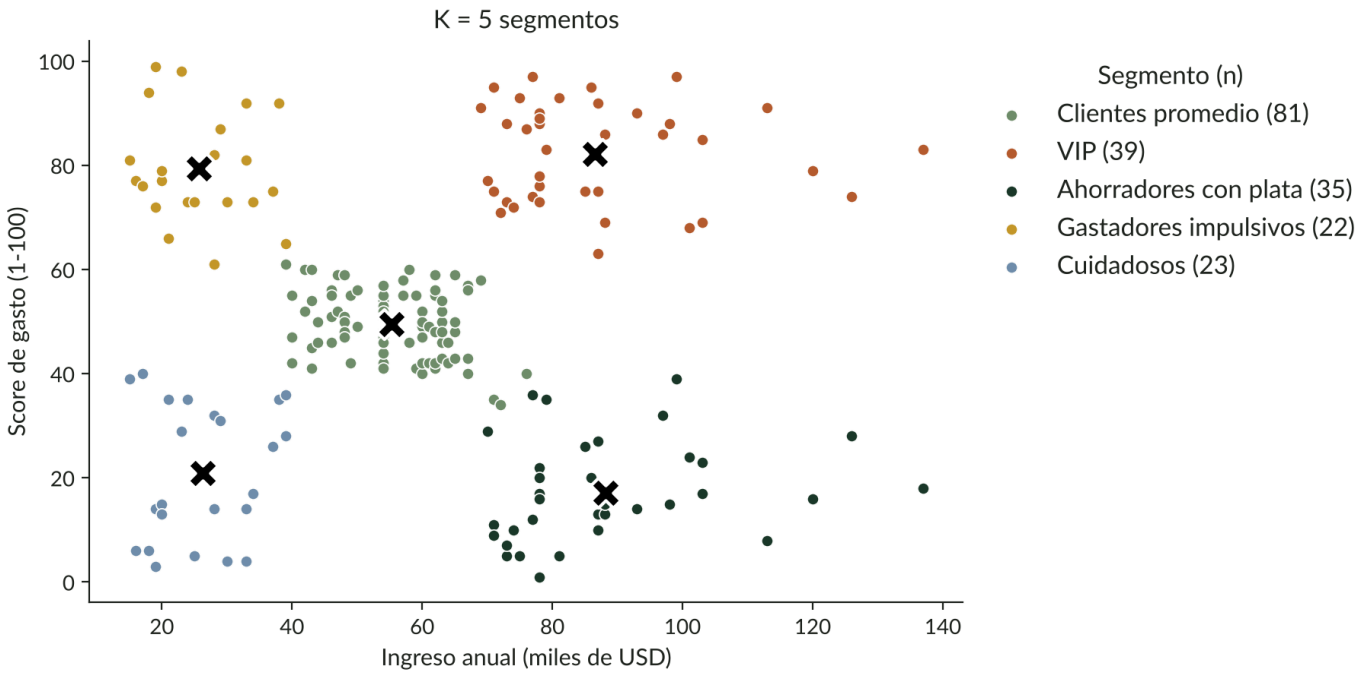
¿Cuántos grupos? K lo elegimos nosotros





- **Codo:** la inercia siempre baja al agregar grupos; buscamos dónde *deja de bajar mucho*.
- **Silhouette:** ¿cada cliente está más cerca de su grupo que del grupo vecino? (de −1 a 1).
- Y una pregunta de negocio: ¿cuántas campañas distintas puede manejar el equipo?

El algoritmo da números; el nombre lo ponemos nosotros



K-means devuelve "cluster 0, 1, 2...". Mirando el **centroide** de cada grupo le ponemos un nombre que el equipo de marketing entienda.

La **edad** no se usó para agrupar, y aun así distingue a los grupos: los "impulsivos" son los más jóvenes. Eso es un hallazgo.

¿Y qué hacemos con cada segmento?

Segmento	Perfil	Acción
VIP	Ingreso alto, gasta mucho	Fidelizar, eventos exclusivos. No perderlos.
Ahorradores con plata	Ingreso alto, gasta poco	Mayor potencial: ¿por qué no compran acá?
Gastadores impulsivos	Ingreso bajo, gasta mucho, jóvenes	Promos y cuotas. Ojo con el riesgo crediticio.
Cuidadosos	Ingreso bajo, gasta poco	Descuentos puntuales, baja prioridad.
Promedio	El grupo más grande	Comunicación masiva estándar.

K-means en perspectiva

Lo bueno

Simple de entender y de explicar ("estos son los 5 perfiles"). Escala muy bien: funciona con millones de clientes.

Los límites

Siempre devuelve K grupos, aunque los datos no tengan grupos. Le gustan los grupos redondos y de tamaño parecido. Los outliers tiran de los centroides. Solo variables numéricas, y hay que estandarizar.

DEMO 1

Segmentación de clientes

`01_kmeans_clientes.ipynb`

PARTE 2

Clustering jerárquico

¿Qué países se parecen?

El problema

Una **fintech argentina** quiere expandirse. Antes de estudiar mercado por mercado, quiere saber:

¿Qué países se parecen entre sí?

- 193 países, 5 indicadores de la ONU: fertilidad, PBI per cápita, esperanza de vida, % urbano, mortalidad infantil.
- No sabemos cuántos grupos hay y queremos algo fácil de mostrarle al directorio.
- Si una estrategia funciona en un país, probablemente funcione en sus "vecinos".

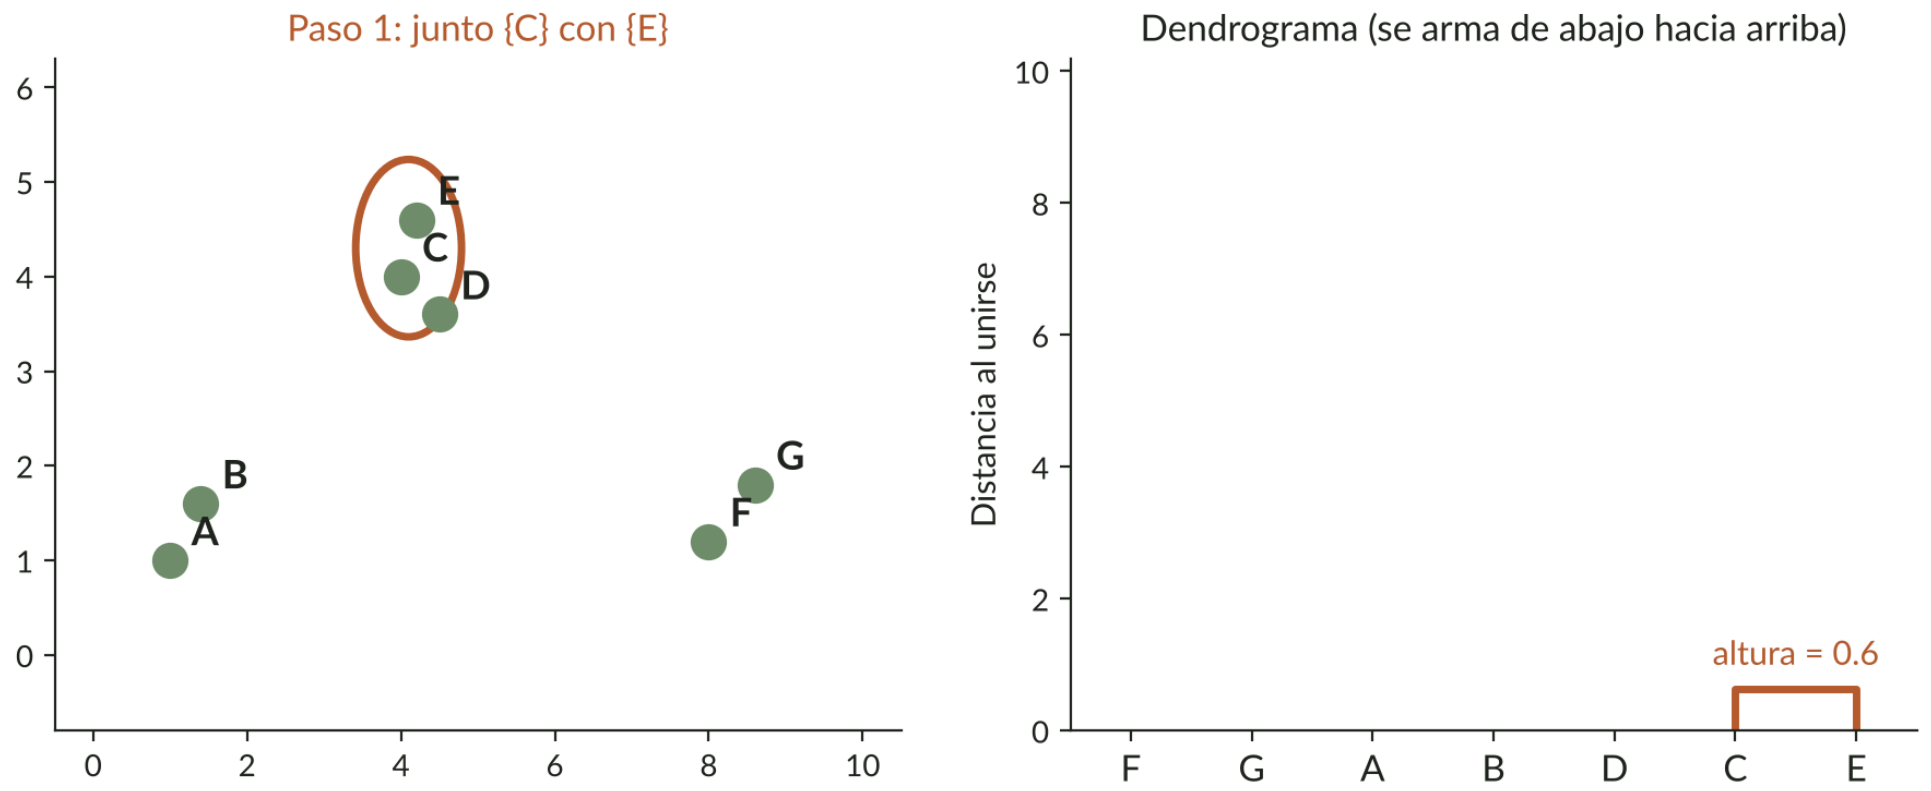
La idea en una frase

Arranco con cada país solo y voy juntando de a dos
a los más parecidos, hasta que queda un solo grupo.

- Es como armar un **árbol genealógico** de parecidos: primero se juntan los "hermanos", después los "primos", y así.
- El **dendrograma** es el dibujo de ese árbol: anota **quién** se juntó con quién y **qué tan distintos** eran cuando se juntaron.
- No hace falta elegir K antes: la cantidad de grupos se decide **al final**, mirando el árbol.

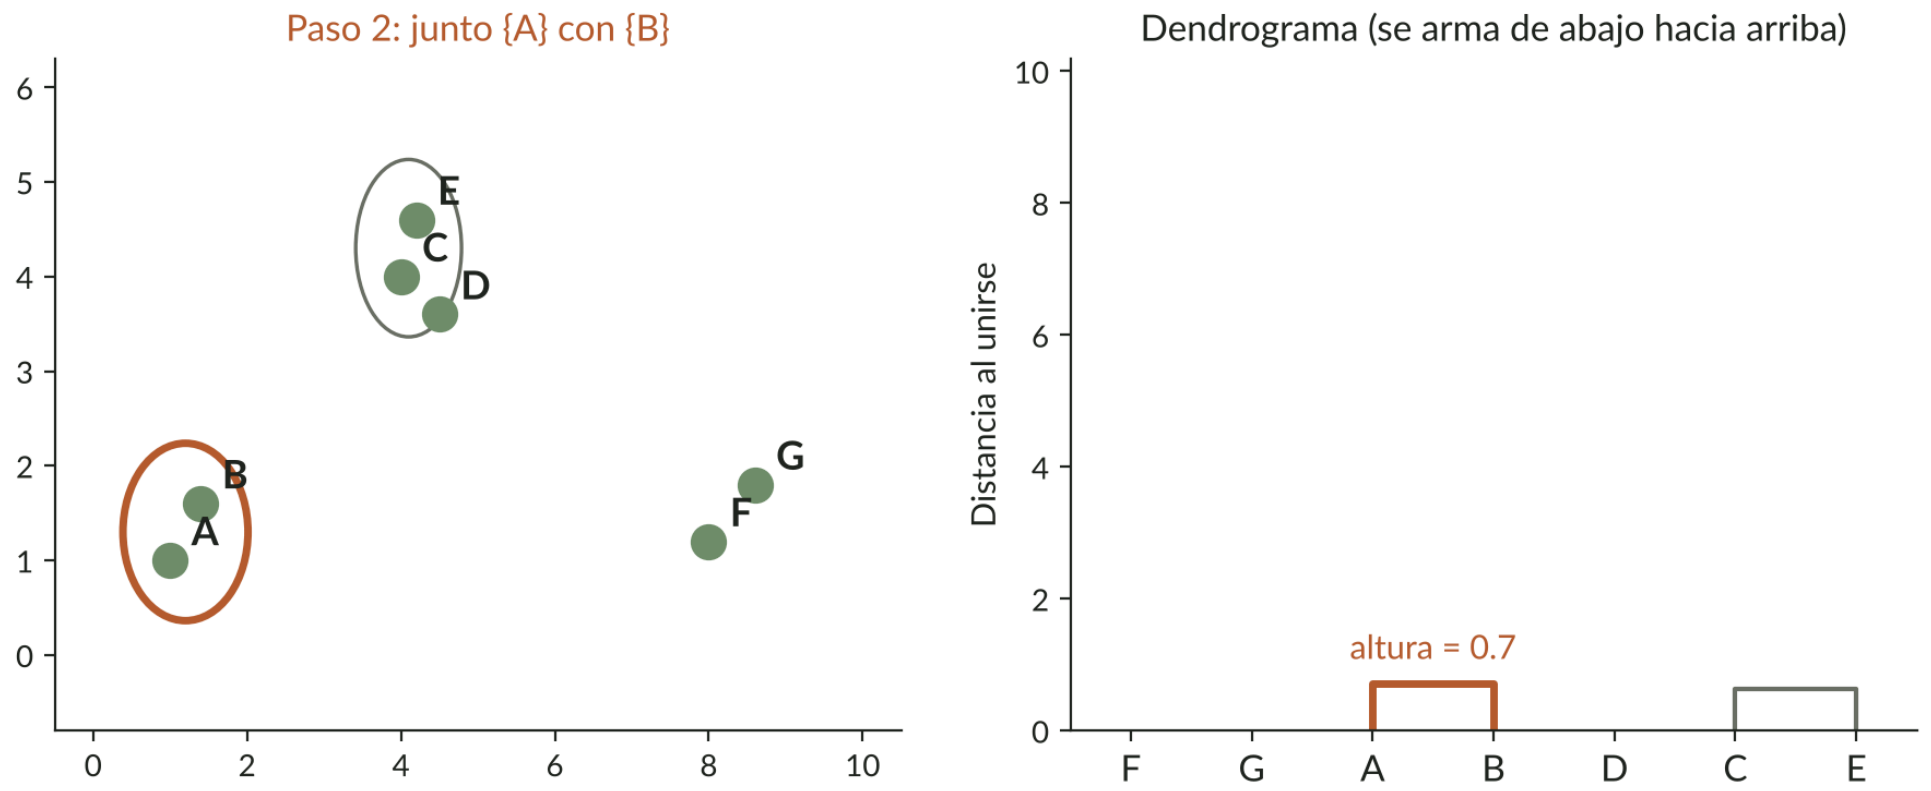
Veámoslo con 7 puntos, paso por paso.

Paso a paso · 1



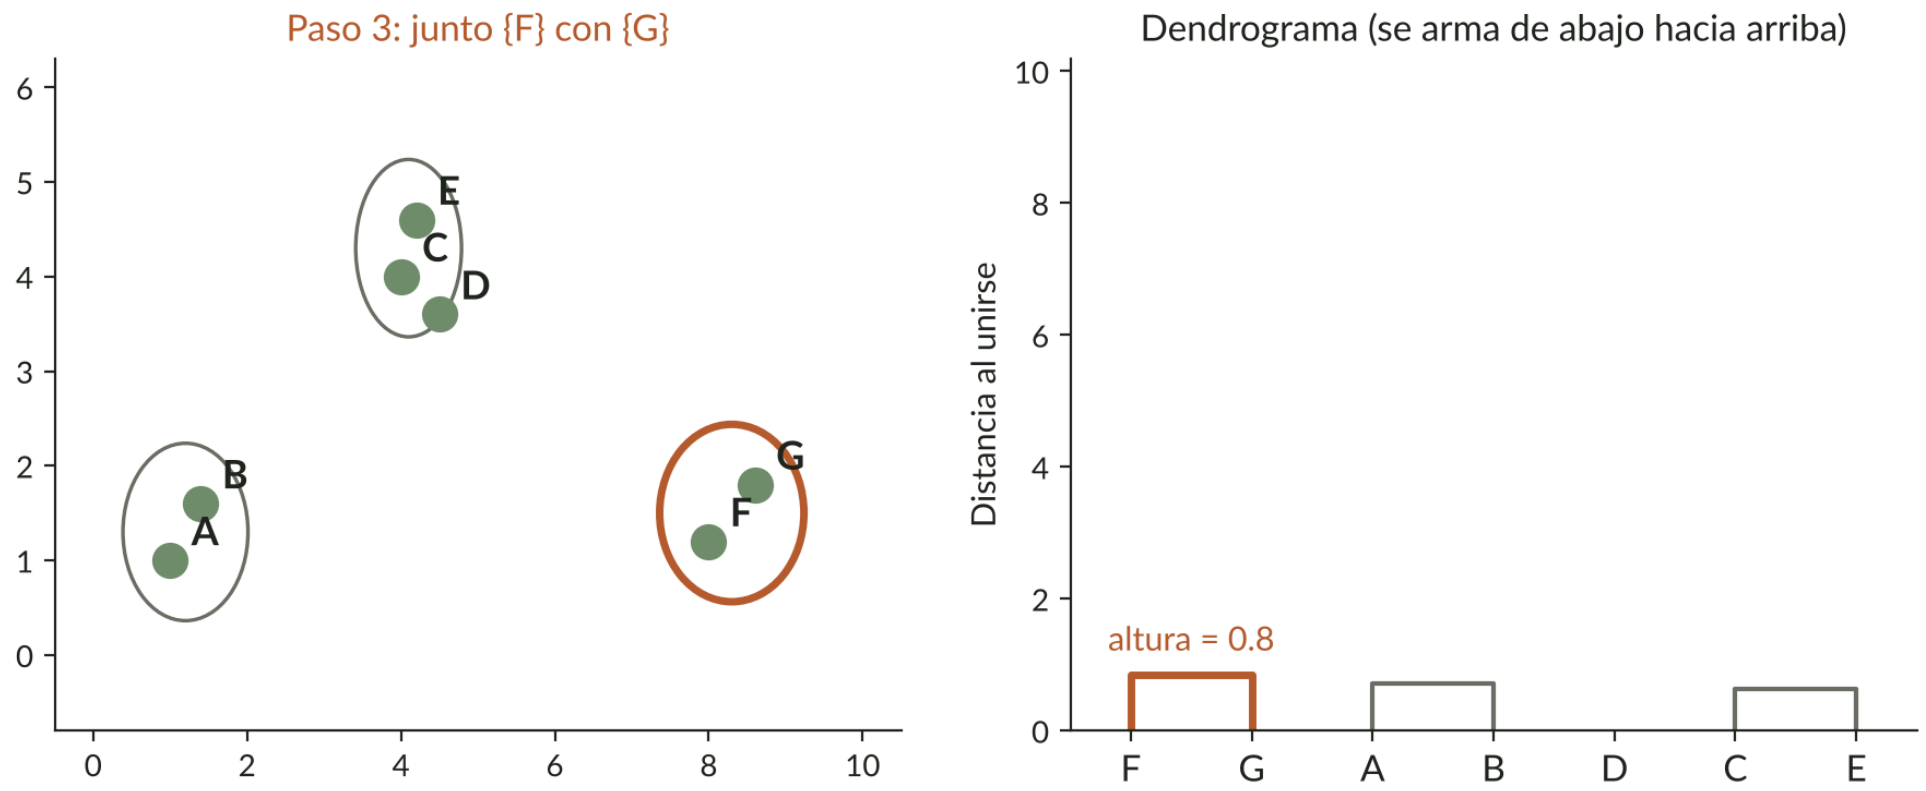
Los dos puntos **más cercanos** (C y E) se juntan primero. En el árbol aparece una "U" **bajita**: eran muy parecidos.

Paso a paso · 2



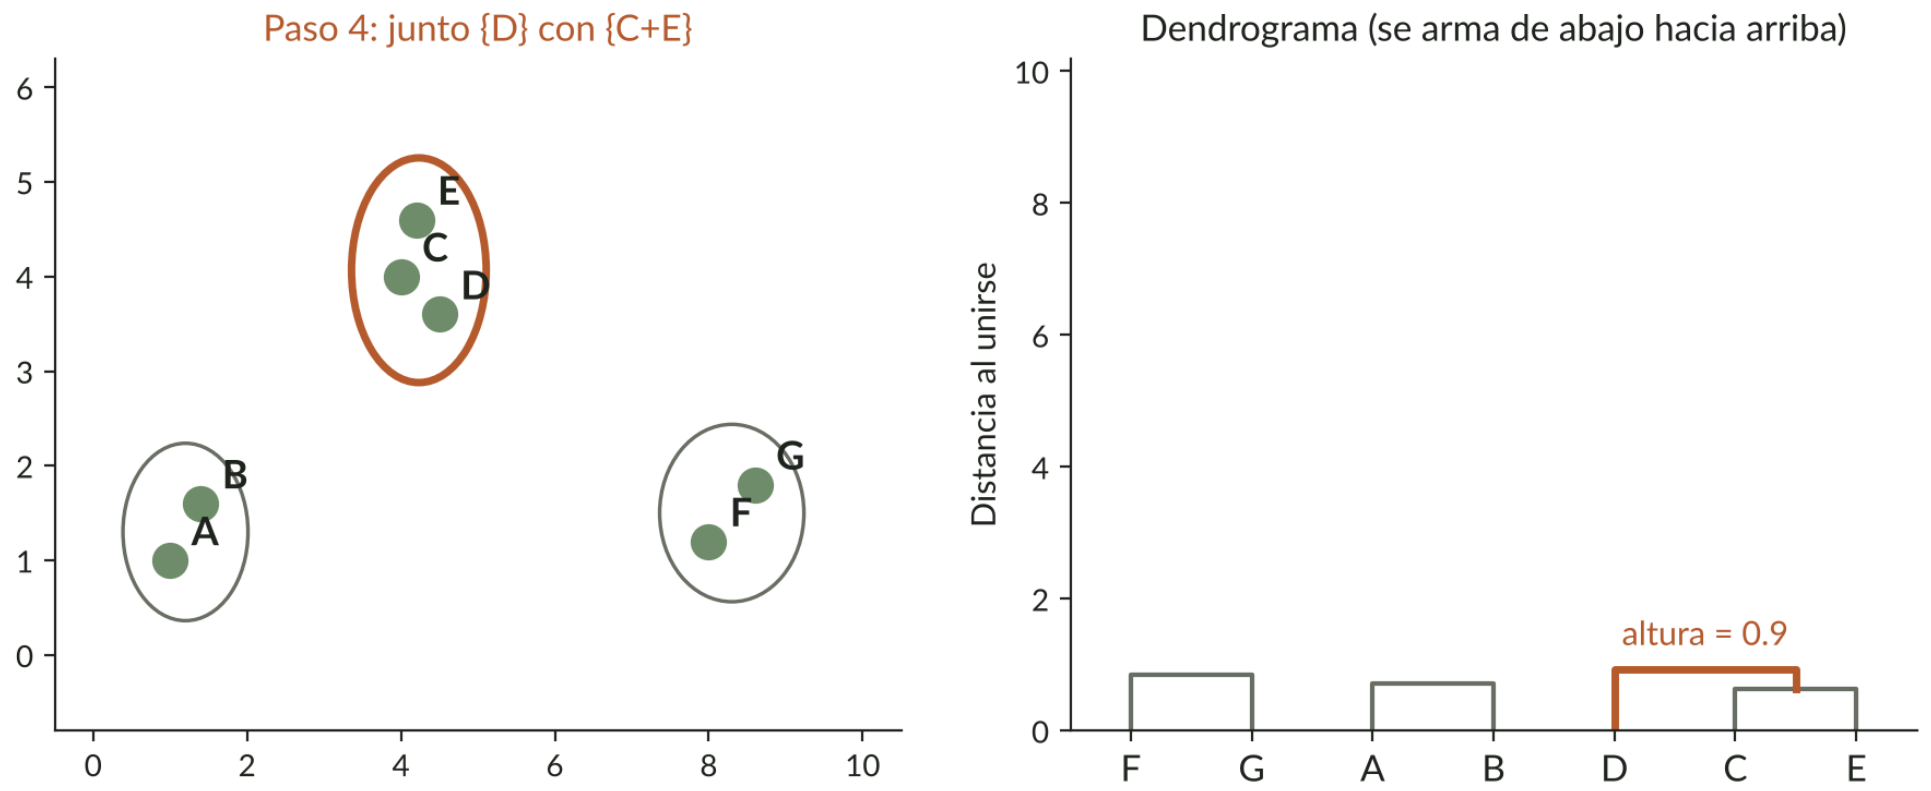
Siguiente par más cercano: A y B. Otra "U" bajita.

Paso a paso · 3



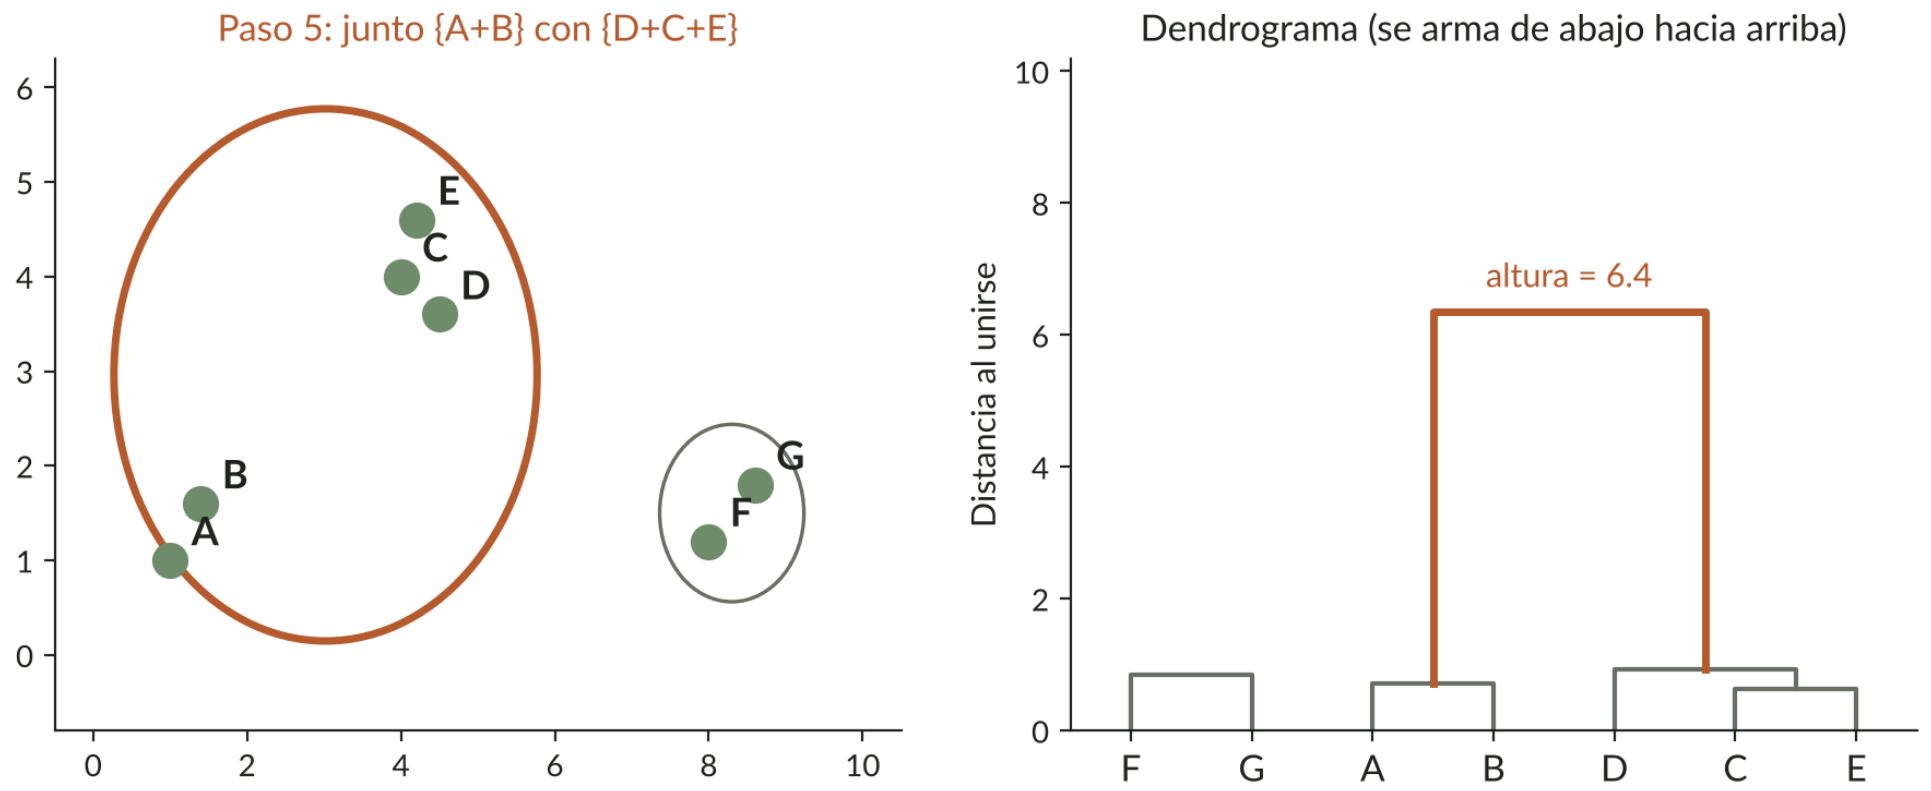
F y G. Ya tenemos tres grupitos bien apretados.

Paso a paso · 4



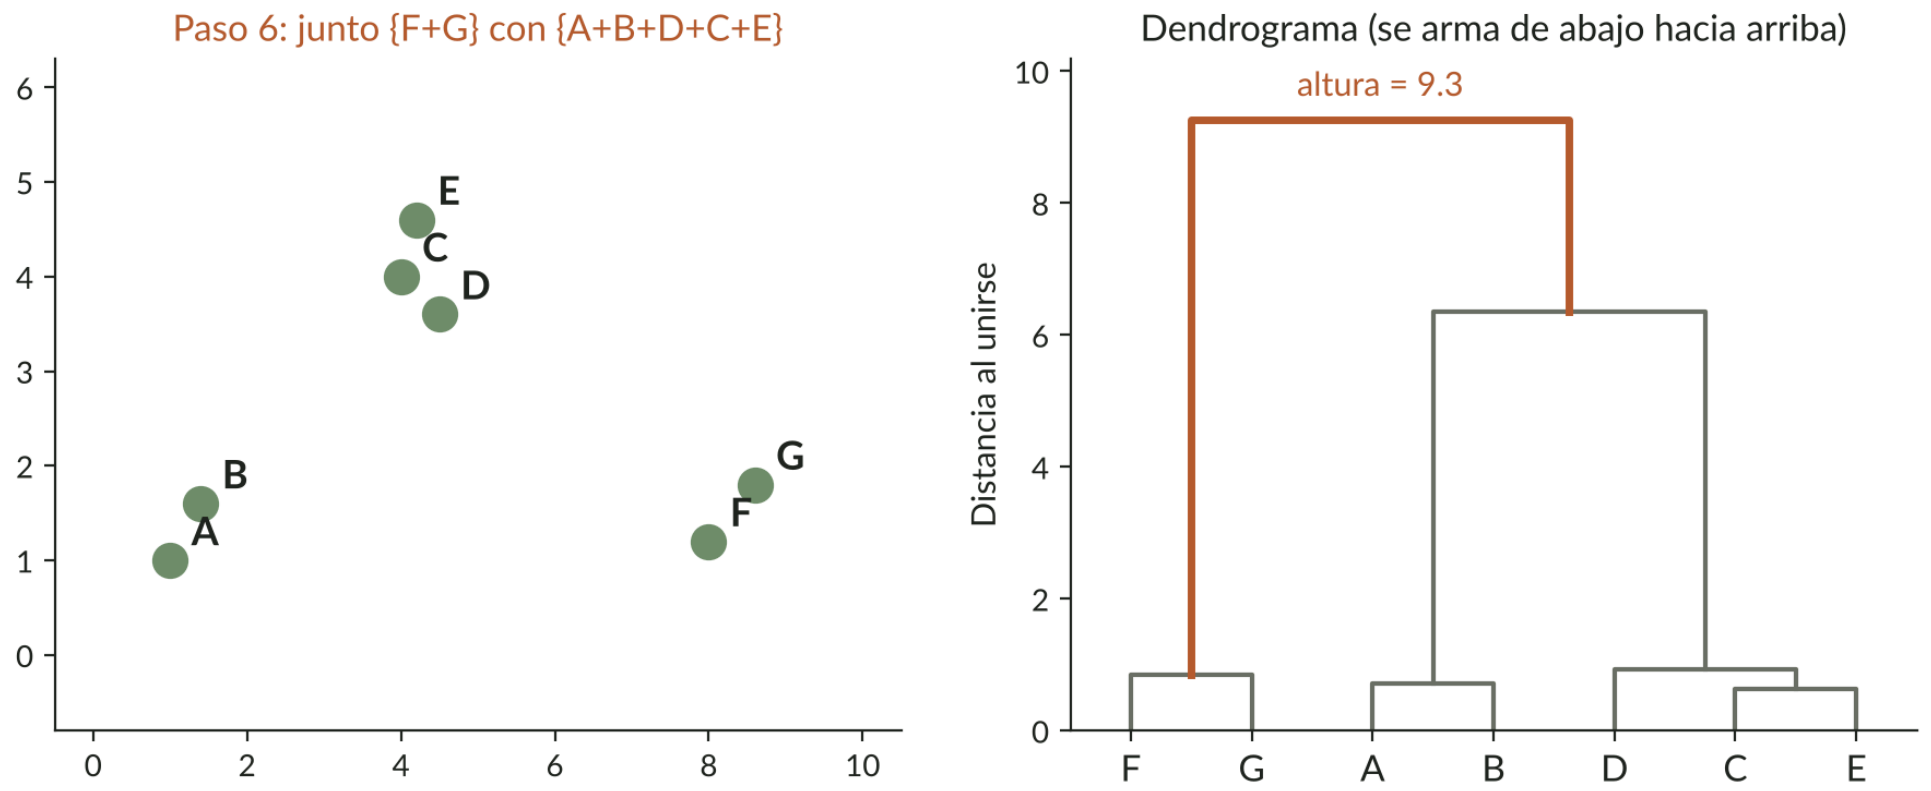
D se suma al grupo de C y E. Quedan 3 grupos: {A, B}, {C, D, E} y {F, G}.

Paso a paso · 5



Ahora sí hay que juntar grupos lejanos: la "U" sube mucho. Ese **salto** es la señal de que estamos mezclando cosas distintas.

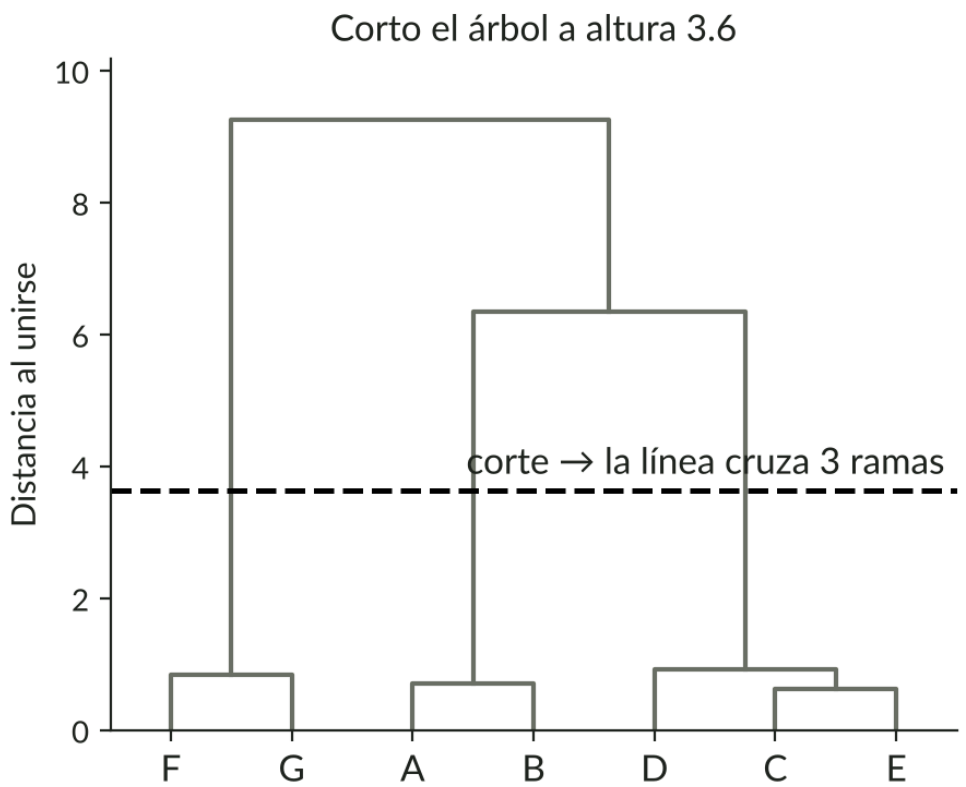
Paso a paso · 6



Última unión: todo queda en un solo grupo. El árbol está completo.

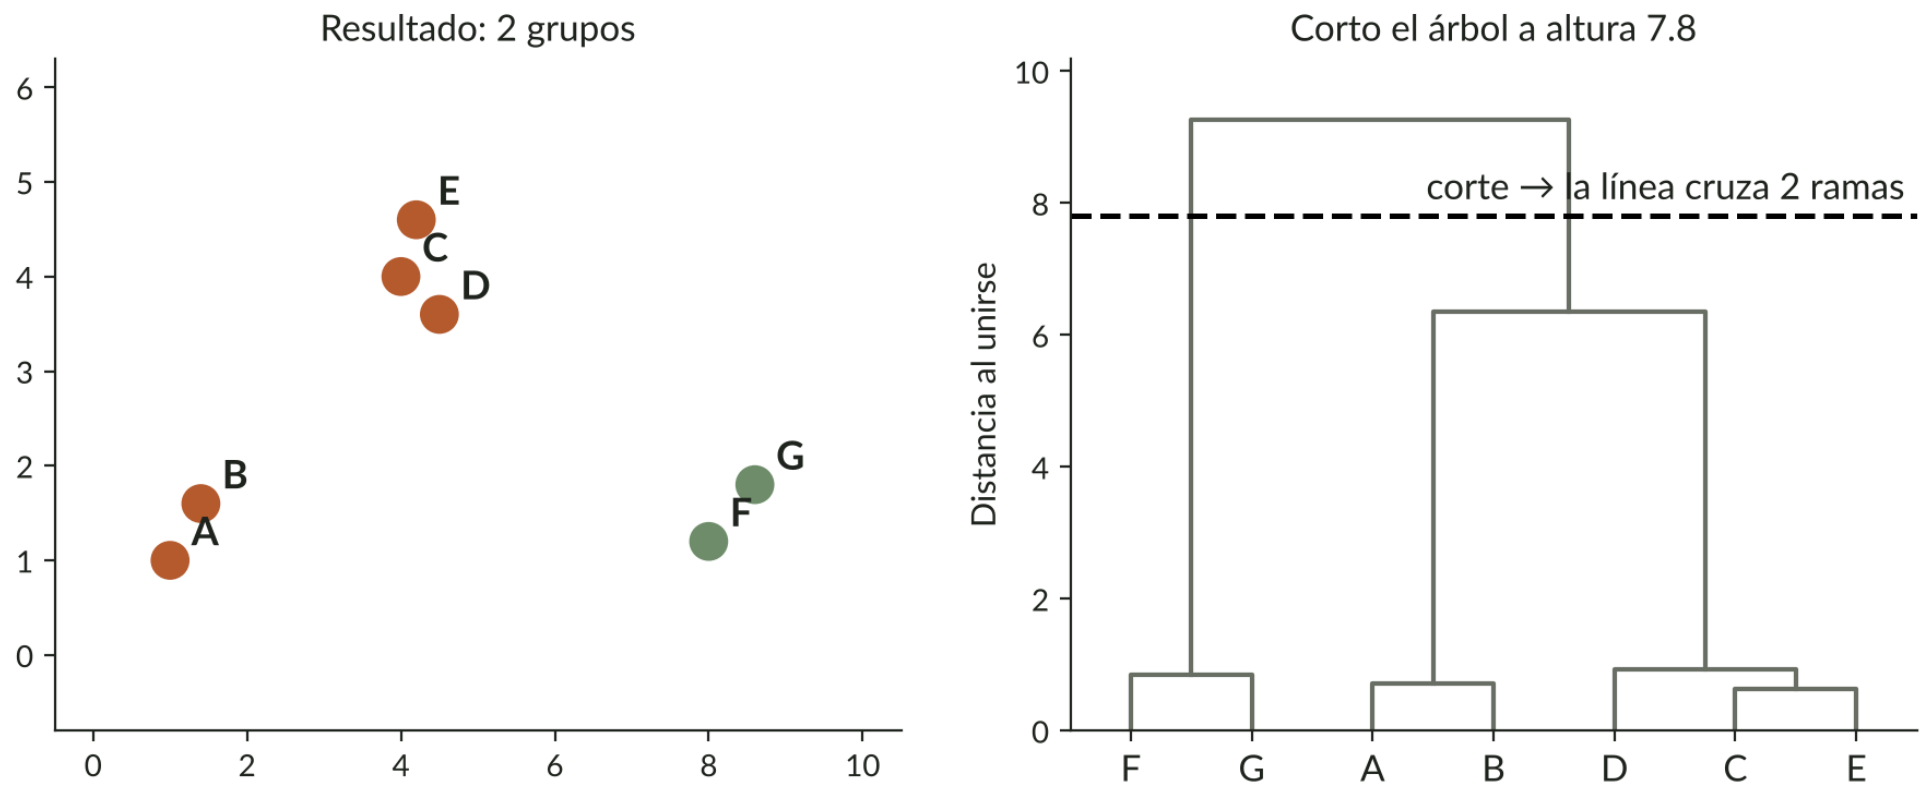
¿Cuántos grupos? Corto el árbol





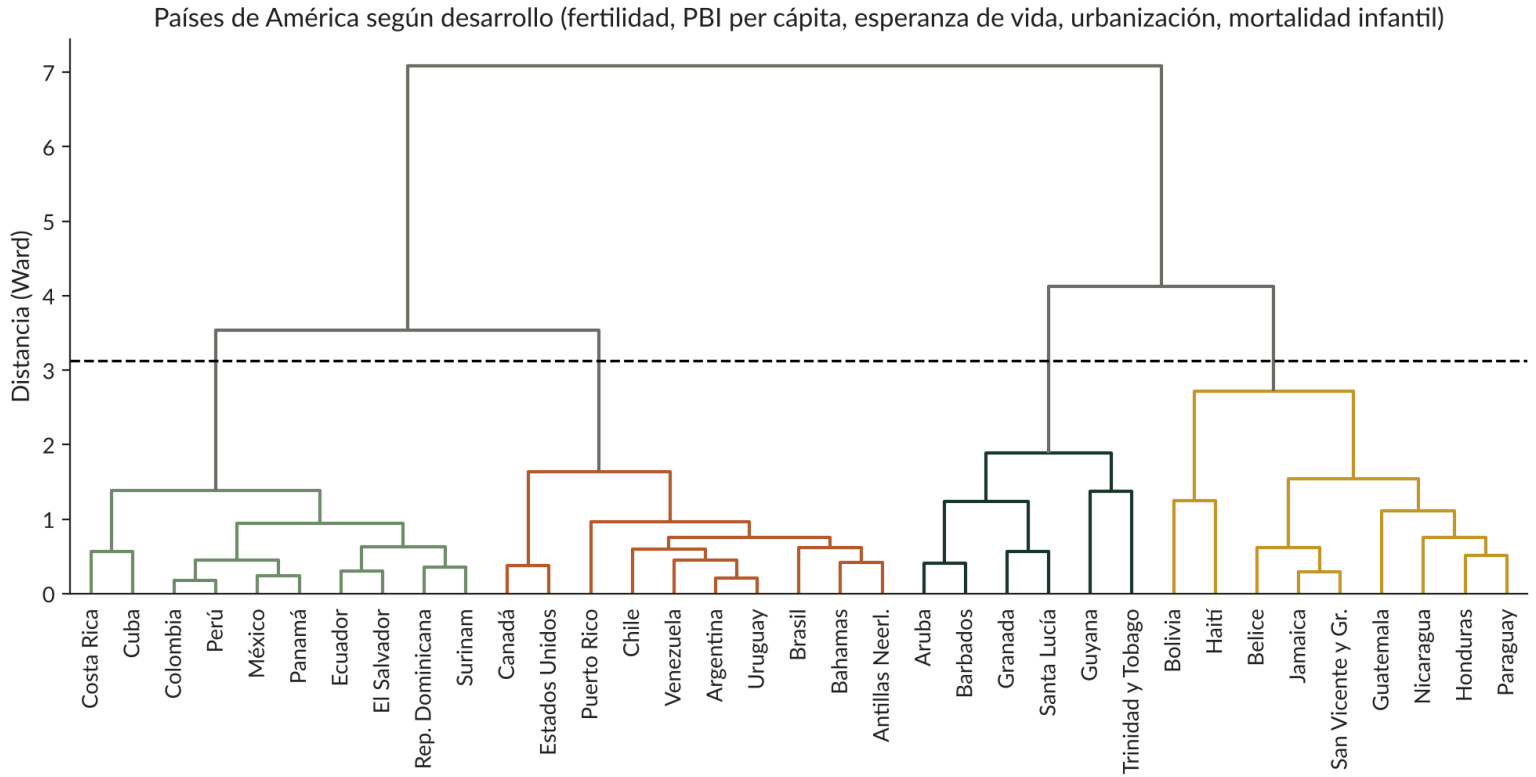
Trazo una **línea horizontal**: la cantidad de ramas que cruza es la cantidad de grupos. Cortando por **debajo del gran salto** quedan 3 grupos que tienen sentido.

¿Cuántos grupos? Corto el árbol



Si corto más arriba quedan 2 grupos más "gruesos". ¿Cuál conviene? Depende de la pregunta de negocio.

Ahora con datos reales: países de América



- Argentina y Uruguay se juntan **muy abajo**: son muy parecidos en estos indicadores.
- El salto grande está alrededor de 3: si corto ahí (línea punteada) quedan 4 grupos de países.

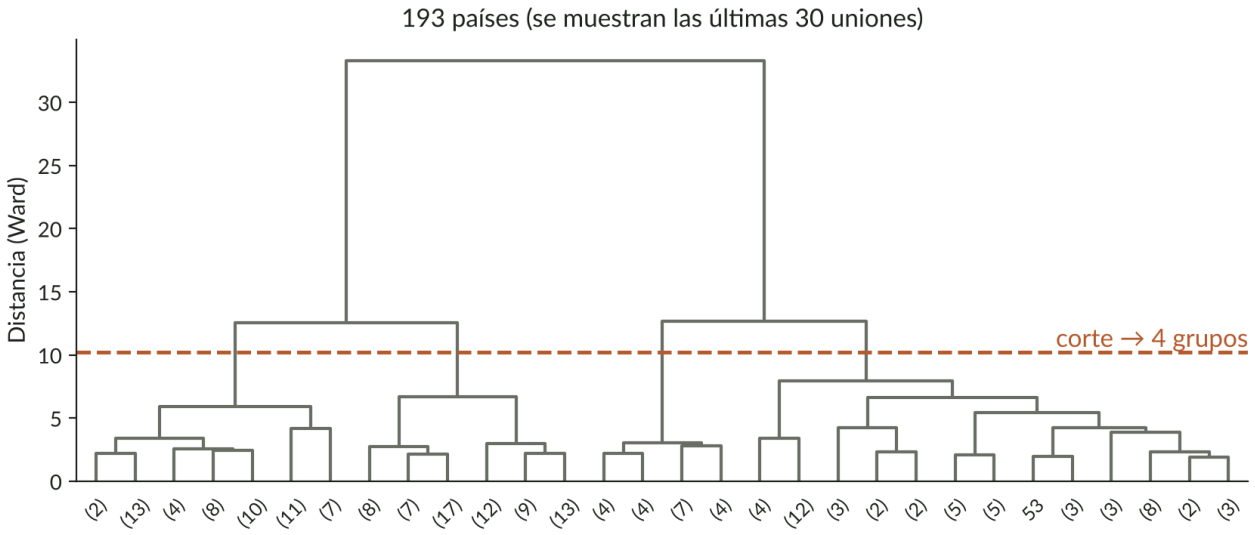
¿Cómo se mide la distancia entre grupos?

Entre dos países es fácil: la misma distancia en línea recta que en K-means. Pero cuando ya tengo **grupos**, hay que decidir cómo compararlos. A eso se le dice **linkage**:

Linkage	Mide la distancia entre grupos como...
single	los dos miembros **más cercanos**. Arma "cadenas": no sirve para segmentar.
complete	los dos miembros **más lejanos**.
average	el **promedio** de todas las distancias.
ward	junta los grupos que quedan **más apretados** (la misma idea que K-means).

En la práctica usamos **Ward**. En la demo se ve qué pasa con los otros.

Con todos los países



Grupo (medianas)	Países	PBI p/c	Esp. vida
Alto desarrollo	66	20.556	80,7
Medio-alto	55	4.496	77,3
Medio-bajo	53	1.240	64,4
Bajo desarrollo	19	451	53,1

Argentina queda en **alto desarrollo**, junto con Uruguay, Chile y buena parte de Europa.

K-means vs. jerárquico

	K-means	Jerárquico
¿Elijo K antes?	Sí	No: corto el árbol después
Resultado	Grupos + centroides	Árbol completo (dendrograma)
Cantidad de datos	Millones, sin problema	Hasta miles (es lento)
Cómo se explica	"Estos son los 5 perfiles"	"Mirá quién se parece a quién"
¿Mismo resultado si lo corro de nuevo?	Depende del arranque	Sí, siempre

DEMO 2

¿Qué países se parecen?

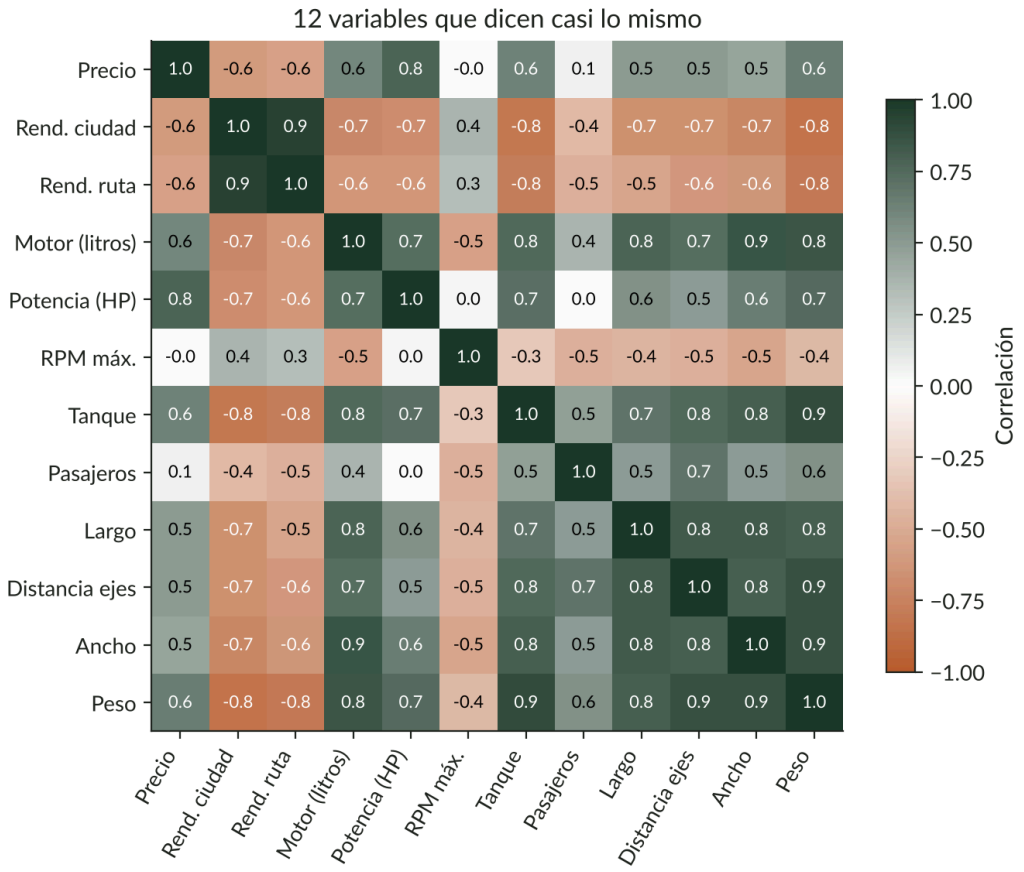
`02_jerarquico_paises.ipynb`

PARTE 3

PCA

Resumir muchas variables en un mapa

El problema

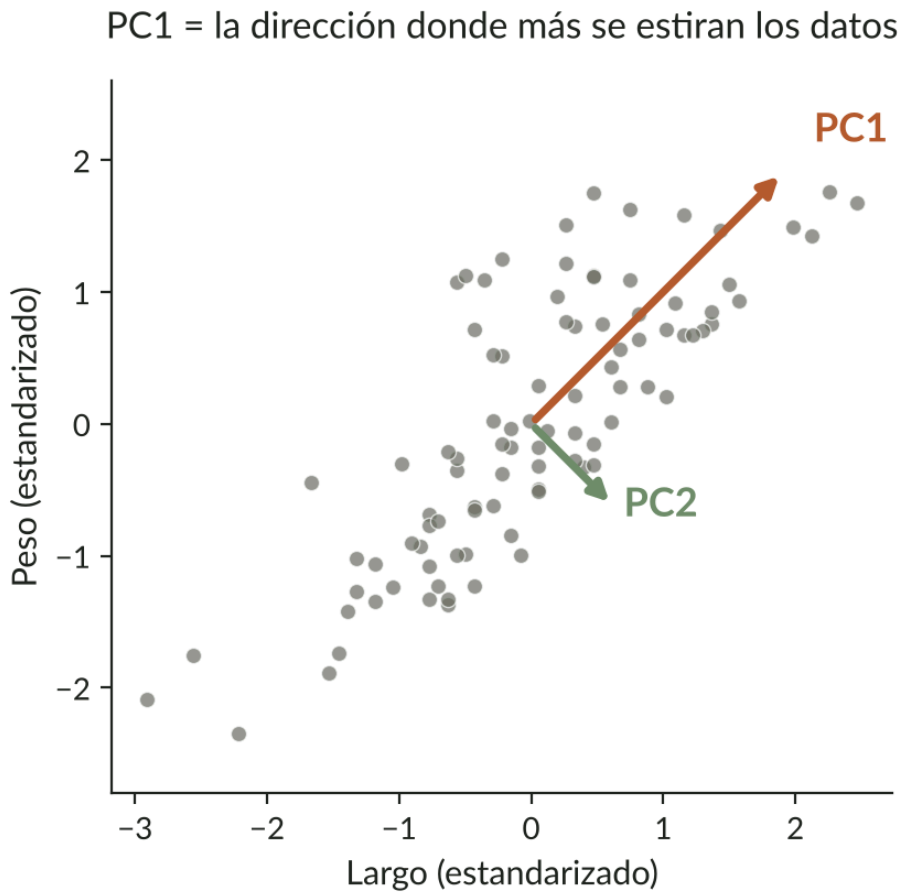


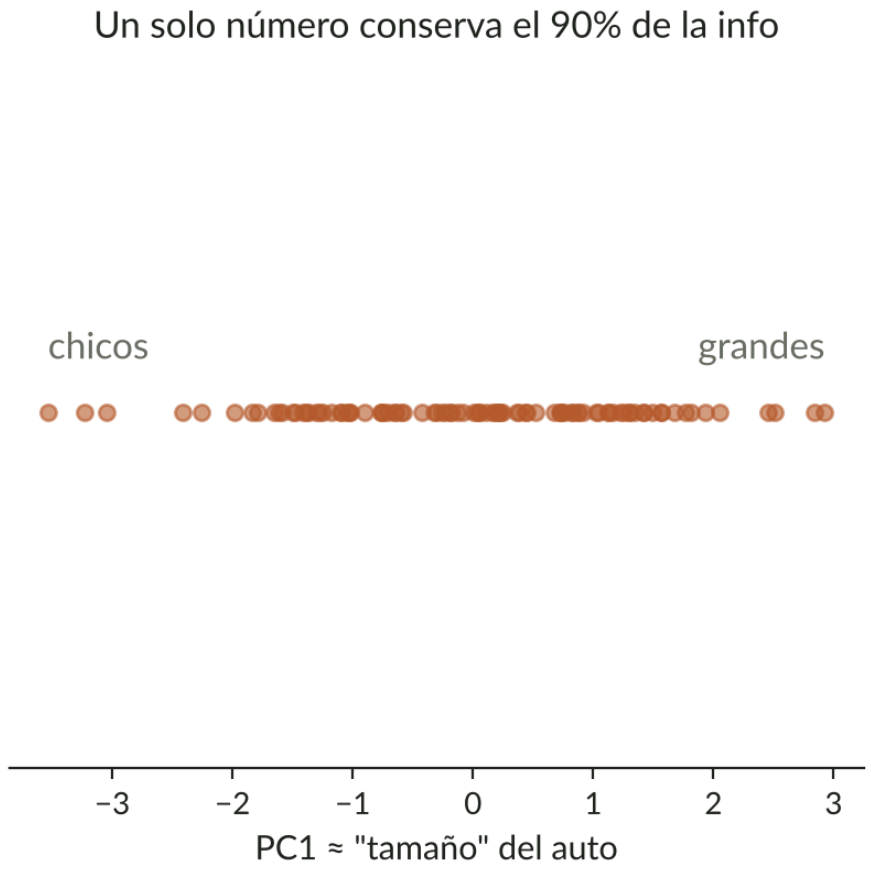
Trabajamos en una automotriz. Queremos ver **cómo están posicionados** los 93 modelos del mercado: ¿dónde hay competencia?, ¿hay huecos?

Tenemos 12 características por modelo, pero:

- No se pueden graficar 12 dimensiones.
- Muchas dicen lo mismo: peso, largo, ancho, motor... todas miden "qué tan grande es".

La idea: buscar la dirección donde los datos más varían





Largo y peso van juntos. Si giro los ejes y miro solo **PC1**, con **un número** conservo casi toda la información. Ese número es, en la práctica, el "tamaño" del auto.

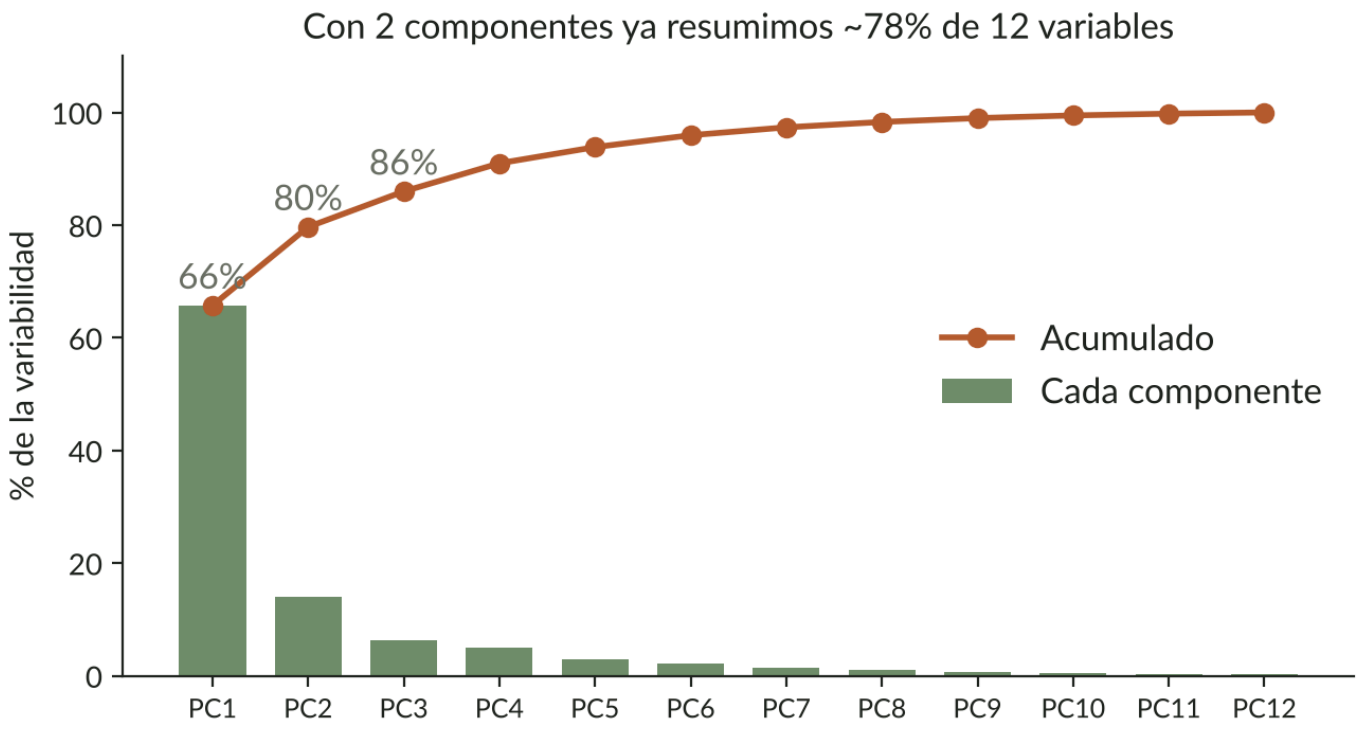
La matemática, muy por arriba

Cada componente principal es una **receta**: una suma ponderada de las variables originales (estandarizadas).

$$PC1 = w_1 \cdot \text{precio} + w_2 \cdot \text{rendimiento} + \ldots + w_{12} \cdot \text{peso}$$

- PCA elige los pesos *w* (**loadings**) para que PC1 tenga la **mayor varianza posible**.
- PC2 hace lo mismo con lo que sobra, **sin repetir** información de PC1. Y así sucesivamente.
- Hay tantas componentes como variables, pero las primeras concentran casi todo.
- Igual que en clustering: **estandarizar antes**, si no gana la variable con números más grandes.

¿Cuántas componentes me quedo?

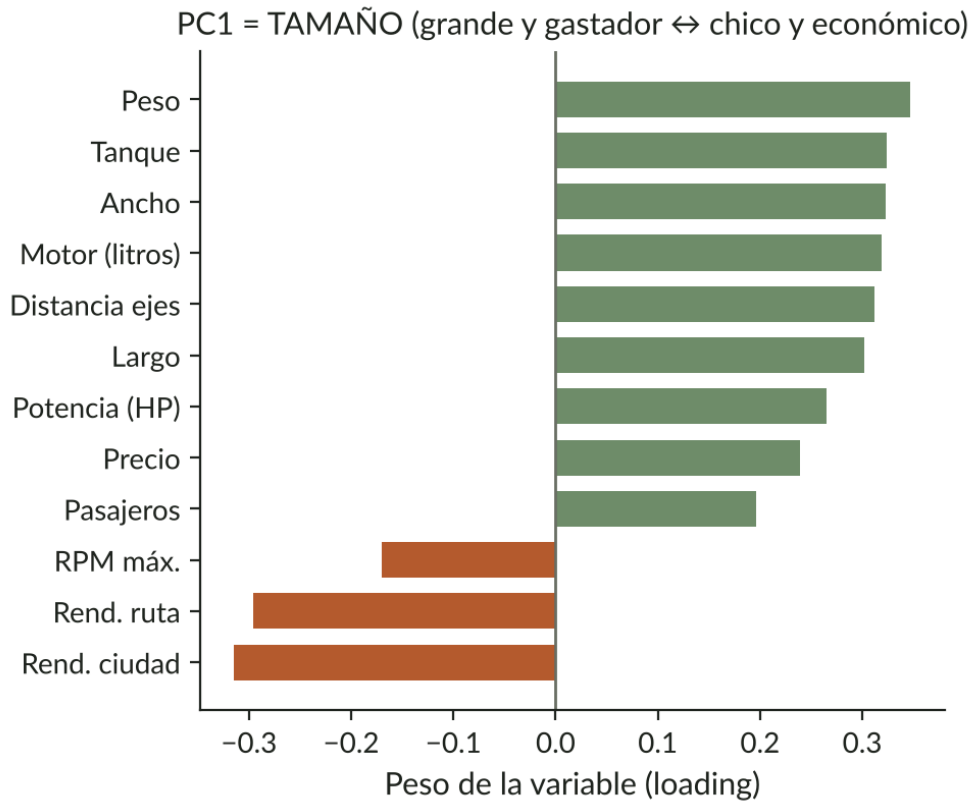


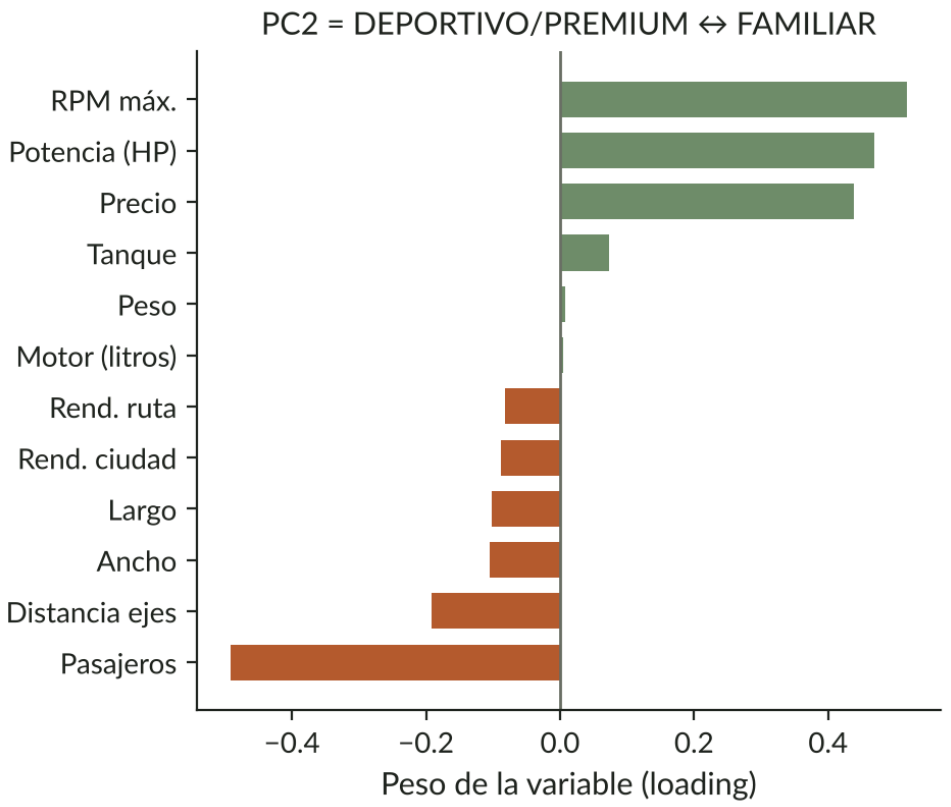
Mirar el **acumulado**: ¿con cuántas llego a 80–90%?

Para **visualizar**: 2 (o 3). Para **modelar**: las que hagan falta.

Acá, con 2 componentes ya resumimos ~80% de 12 variables.

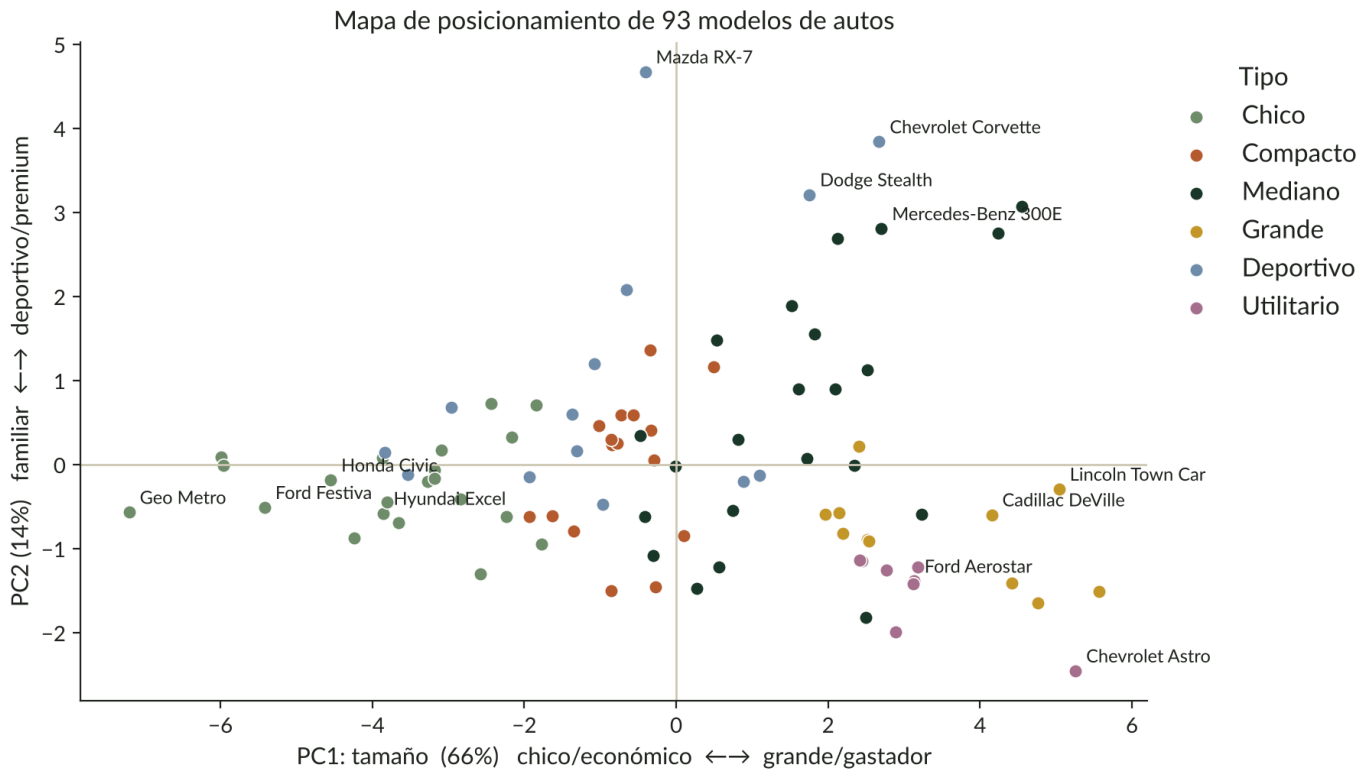
PCA no le pone nombre: lo hacemos nosotros





Mirando los loadings: **PC1** = **tamaño** (todo lo "grande" suma, el rendimiento resta). **PC2** = **deportivo/premium vs. familiar** (potencia y precio suman, pasajeros resta).

El resultado: un mapa de posicionamiento



- El **tipo de auto no se usó**, y aun así queda ordenado: las componentes capturan algo real.
- Vecinos en el mapa = **competidores directos**.
- ¿Huecos? Grande *y* deportivo: casi vacío.

PCA en perspectiva

Lo bueno

Muy útil para **visualizar**, armar **índices** (por ejemplo, un "índice de desarrollo") y como paso previo a clustering.

Los límites

Las componentes son **difíciles de explicar**: "subió PC3" no le dice nada a nadie, y en un modelo predictivo perdés explicabilidad. Solo captura relaciones lineales. Solo variables numéricas, y hay que estandarizar.

DEMO 3

Mapa de posicionamiento

`03_pca_autos.ipynb`

Resumen

	K-means	Jerárquico	PCA
Hace	Agrupa filas en K grupos	Arma un árbol de parecidos	Resume columnas
Usalo para	Segmentar muchos clientes	Pocos casos, sin K claro	Mapas, índices, quitar redundancia
Decidís vos	K	Dónde cortar, linkage	Cuántas componentes
Siempre	Estandarizar · interpretar y ponerle nombre · validar con el negocio		

Se combinan: PCA para resumir → clustering sobre las componentes (bonus en la demo 3).