

Exámen Parcial Analítica de Datos

Segundo Semestre 2025

Universidad de San Andrés

¡RESUELTO PARA USTED!

1. Pregunta 1

Aspectos a mejorar pueden incluir ordenamiento de las barras de menor a mayor o de mayor a menor para que tengan un orden lógico. Mover la ubicación de la leyenda, usar una paleta de colores que deje distinguir más las regiones, agregar título explicativo, nombre de las regiones sobre las barras para evitar referencia a leyenda, sin distinción de colores porque no agrega nada o un color para los negativos y otro para los positivos, entre otras.

2. Pregunta 2

uso_promedio_minutos, antigüedad_meses e ingreso_mensual. Los boxplots muestran diferencias claras entre grupos de churn para estas variables, no están altamente correlacionadas entre sí y capturan aspectos clave: engagement, retención y poder adquisitivo. ingreso_mensual_reportado se excluye por cantidad de nulls.

3. Pregunta 3

1. Sensibilidad (Recall). En diagnóstico médico es crítico no perder casos de tumores malignos, ya que un falso negativo puede tener consecuencias graves para el paciente.

2. KNN-3 ($K=3$). Tiene la mejor sensibilidad en test (0.87) manteniendo buena especificidad (0.90) y accuracy (0.89). Además, muestra menor overfitting comparado con KNN-1 que tiene gran diferencia entre train y test.

4. Pregunta 4

1. Árbol con `max_depth=2`:

Raíz en `frecuencia_palabras`.

- Si `frecuencia_palabras = baja` → no (hoja pura en train).
- Si `frecuencia_palabras != baja` → sí (hoja pura en train).

2. Accuracy en test: 50 %. Predice correctamente ID8 (baja→no) y falla ID7 (baja es *sí* en test, pero el árbol aprendido con train predice *no*).

5. Pregunta 5

1. Con $\alpha = 0$: No podar el árbol. Tiene el menor error de clasificación (0.2) y sin penalización por complejidad.

2. Con $\alpha = 0.2$: No podar. Costo total $= 0.2 + 0.2 \times 8 = 1.8$ vs Opción 1 $= 0.28 + 0.2 \times 5 = 1.28$ vs Opción 2 $= 0.23 + 0.2 \times 7 = 1.63$. La opción 1 tiene menor costo total.

6. Pregunta 6

4375 modelos. Combinaciones: $7 \times 5 \times 5 \times 5 = 875$ configuraciones de hiperparámetros. Cada configuración se entrena 5 veces (5 folds), total: $875 \times 5 = 4375$ modelos.

7. Pregunta Extra

Error de Bayes $= 0.095$. Contando los puntos mal clasificados por la frontera óptima (línea magenta): 9 puntos naranjas en región azul + 10 puntos azules en región naranja = 19 puntos mal clasificados de 200 total. $19/200 = 0.095$.