

Nombre y Apellido _____


CONSIDERANDO LA IMPORTANCIA DEL EXAMEN PARCIAL COMO DOCUMENTO DE EVALUACIÓN SE SOLICITA LEER ATENTAMENTE LO SIGUIENTE:

- Responder claramente y con precisión lo solicitado.
- No cometer faltas de ortografía.
- En las preguntas que requieran justificación, la justificación es obligatoria para considerar la respuesta como adecuada.
- Se puede utilizar como apoyo durante el examen todos los documentos de la materia subidos en el Campus Virtual. En caso de detectar la utilización de material indebido, chats, o plagio bajo cualquier forma se retirará el examen y se procederá a la ejecución del procedimiento contemplado para estos casos por la Universidad.
- El examen se deberá responder únicamente en las hojas provistas.
- No se podrá tipear en PC o Tablet durante el examen. Solo está permitido utilizar pad o mouse.
- Condiciones de aprobación: 60 puntos de respuestas completamente correctas sobre 100, lo cual determina una nota de 4. A partir de allí la calificación es proporcional.
- Duración máxima del examen: 3 horas, sin excepción. Hacer una buena administración del tiempo siendo breve en las respuestas respondiéndolas concretamente.

Pregunta 1. (10 puntos).

La siguiente visualización muestra la evolución en la cantidad de clientes entre dos puntos en el tiempo para diferentes regiones de una misma empresa

Nombrar, por lo menos, 3 aspectos a mejorar teniendo en cuenta las buenas prácticas vistas en clase.



<https://www.perceptualedge.com/example1.php>

Pregunta 2. (10 puntos)

A continuación se muestran resultados de un análisis exploratorio de datos (EDA) hecho sobre un conjunto de datos correspondientes a clientes de una aplicación digital con modelo de suscripción. La muestra es un **corte al cierre de 2024**: cada fila representa un cliente activo en esa fecha. La variable objetivo (churn) indica si el cliente **canceló o no renovó** su suscripción durante los **30 días posteriores** al corte. El resto de las variables resume comportamiento reciente en la app, interacción con soporte y características económicas declaradas o estimadas.

Diccionario de variables

- **id_cliente** (*cadena*): identificador único y anonimizado de cada cliente.
- **churn** (*binaria: 0/1*): variable objetivo. Vale **1** si el cliente canceló/no renovó dentro de los 30 días posteriores al corte; **0** en caso contrario.
- **uso_promedio_minutos** (*numérica continua*): minutos de uso **promedio mensual** de la app en la ventana de 90 días previa.
- **recencia_dias** (*numérica entera*): cantidad de días transcurridos desde la **última sesión** registrada hasta el día del corte.
- **n_tickets_soporte** (*numérica entera*): número de tickets/incidencias abiertos por el cliente en los **últimos 30 días**.
- **ingreso_mensual** (*numérica continua*): ingreso mensual **estimado** por modelos internos, expresado en moneda constante de 2024.
- **ingreso_mensual_reportado** (*numérica continua, con valores faltantes*): ingreso mensual **autodeclarado** por el cliente en encuestas; puede no estar presente si no respondió.
- **score_socioeconomico** (*numérica continua, rango 0–100*): índice que resume el perfil socioeconómico del cliente a partir de múltiples señales.
- **fidelidad_meses** (*numérica entera*): antigüedad del cliente en meses desde su alta en el servicio.
- **anio_corte** (*numérica/categorica*): año de referencia en el cual fueron medidas las diferentes variables.
- **ruido_operativo** (*numérica continua*): métrica técnica general capturada por sistemas internos; se incluye como referencia operacional.

1. A partir de los resultados del análisis exploratorio, seleccionar 3 variables de entrada (x) que usarías para entrenar un modelo de clasificación que predice si un cliente abandonará su suscripción a la aplicación digital. Justificar la elección.

```
df.head()
```



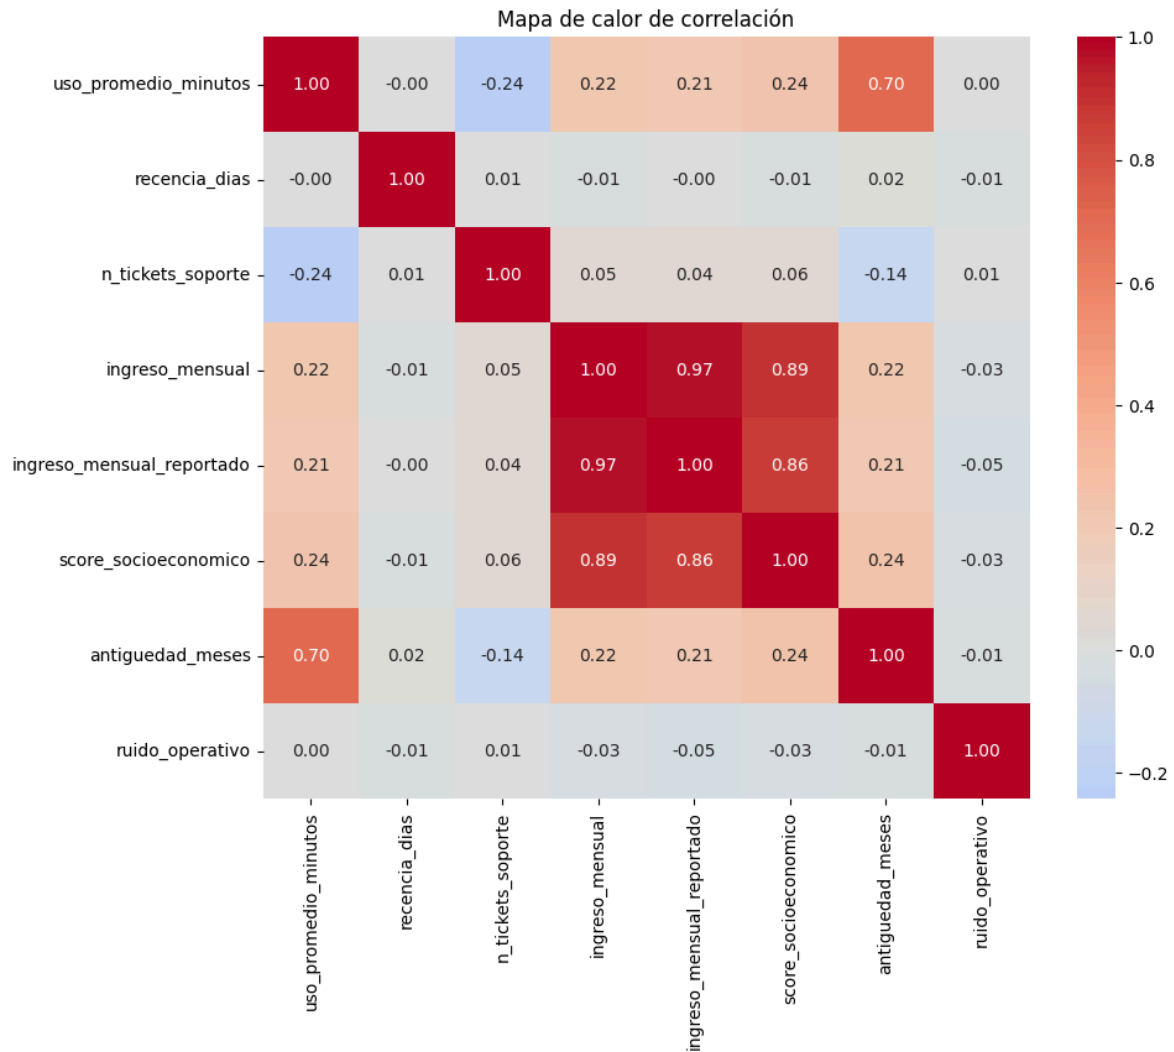
	id_cliente	uso_promedio_minutos	recencia_dias	n_tickets_soporte	ingreso_mensual	ingreso_mensual_reportado	score_socioeconomico	antigüedad_meses	ruido_operativo	anio_corte	churn
0	CUST000001	404.311146	30	1	1102.134372	NaN	50.983988	3.720604	-0.869951	2024	1
1	CUST000002	479.246345	31	3	1559.551163	NaN	62.295152	20.794701	-1.768256	2024	0
2	CUST000003	802.453915	30	0	1945.534180	NaN	70.748004	19.958549	-0.235404	2024	0
3	CUST000004	356.672241	30	3	1071.432334	NaN	43.256577	14.719974	-0.142805	2024	1
4	CUST000005	749.911942	30	1	1475.068479	NaN	55.696020	30.409946	-1.105233	2024	0







df.info()

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 6000 entries, 0 to 5999
Data columns (total 11 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   id_cliente                            6000 non-null   object
1   uso_promedio_minutos                  6000 non-null   float64
2   recencia_dias                         6000 non-null   int64
3   n_tickets_soporte                    6000 non-null   int64
4   ingreso_mensual                      6000 non-null   float64
5   ingreso_mensual_reportado            2380 non-null   float64
6   score_socioeconomico                 6000 non-null   float64
7   antiguedad_meses                     6000 non-null   float64
8   ruido_operativo                      6000 non-null   float64
9   anio_corte                           6000 non-null   int64
10  churn                                6000 non-null   int64
dtypes: float64(6), int64(4), object(1)
memory usage: 515.8+ KB
```

df.describe()

	uso_promedio_minutos	recencia_dias	n_tickets_soporte	ingreso_mensual	ingreso_mensual_reportado	score_socioeconomico	antiguedad_meses	ruido_operativo	anio_corte	churn
count	6000.000000	6000.000000	6000.000000	6000.000000	2380.000000	6000.000000	6000.000000	6000.000000	6000.0	6000.000000
mean	540.431540	30.497667	2.028500	1495.710048	1496.718577	54.718343	14.047678	0.009601	2024.0	0.449833
std	116.382758	0.500036	1.112307	339.861558	353.231937	10.493413	6.255965	1.011338	0.0	0.497518
min	99.445101	30.000000	0.000000	300.000000	262.801592	18.532901	0.100000	-3.382803	2024.0	0.000000
25%	461.040944	30.000000	1.000000	1259.549483	1248.144883	47.464907	9.801457	-0.700099	2024.0	0.000000
50%	541.786470	30.000000	2.000000	1492.249103	1501.039116	54.567403	14.078523	0.031657	2024.0	0.000000
75%	616.510795	31.000000	3.000000	1725.765970	1735.638600	61.831657	18.256845	0.687415	2024.0	1.000000
max	933.614421	31.000000	6.000000	2602.249017	2636.692209	91.142856	38.986392	3.566681	2024.0	1.000000





Pregunta 3 (30 puntos)

Estás trabajando en un sistema de apoyo al diagnóstico médico, específicamente en la detección temprana de tumores malignos a partir de estudios de imágenes. El objetivo del sistema es ayudar a los profesionales médicos a decidir si un paciente debe realizar estudios complementarios o tratamientos preventivos.

Se entrenaron 5 modelos KNN con diferentes valores de k , y se evaluaron con las métricas accuracy, sensibilidad (recall) y especificidad, tanto en los conjuntos de entrenamiento como de prueba. Los resultados se muestran a continuación:

Modelo	K	Dataset	Accuracy	Sensibilidad (Recall)	Especificidad
KNN-1	1	Train	0.96	0.98	0.94
		Test	0.85	0.80	0.88
KNN-2	2	Train	0.88	0.84	0.86
		Test	0.82	0.78	0.83
KNN-3	3	Train	0.93	0.91	0.92
		Test	0.89	0.87	0.90
KNN-4	4	Train	0.85	0.83	0.84
		Test	0.80	0.76	0.82
KNN-5	10	Train	0.78	0.75	0.79
		Test	0.76	0.72	0.78

Teniendo en cuenta las características del problema y las consecuencias de los diferentes tipos de errores:

1. Seleccionar una de las tres métricas expuestas para medir la performance del modelo. Justificar la elección.
2. En base a tu respuesta anterior y a los resultados en train y test de los 5 modelos, seleccionar uno y justificar tu elección.

Pregunta 4 (25 puntos)

Estás diseñando un modelo para detectar correos electrónicos spam. Cuentas con un conjunto de datos de **entrenamiento** de 6 observaciones con dos características categóricas:

- `tipo_remitente`: indica si el remitente es desconocido o conocido.
- `frecuencia_palabras`: indica la frecuencia de palabras sospechosas que tiene el correo (baja, media o alta).

El objetivo es predecir si un correo es spam (`es_spam`: sí o no).

ID	tipo_remitente	frecuencia_palabras	es_spam
1	desconocido	alta	sí
2	conocido	baja	no
3	desconocido	media	sí
4	desconocido	baja	no
5	desconocido	alta	sí
6	conocido	baja	no


1. Entrenar un modelo de árboles de clasificación usando el conjunto de datos de entrenamiento, con el siguiente hiperparámetro:
 - altura máxima del árbol (`max_depth`) = 2
2. Usar el siguiente conjunto de datos de test para medir la performance del modelo en términos de accuracy, reportar ese valor.

ID	tipo_remitente	frecuencia_palabras	es_spam
7	desconocido	baja	sí
8	conocido	baja	no

Pregunta 5 (15 puntos)

1. Considerando un árbol de clasificación con la siguiente forma, decidir por alguna de las siguientes alternativas. Tomar $\alpha = 0$ y el error de clasificación como criterio de impureza.

- Podar el árbol por la opción 1: sumatoria de error de clasificación = 0.28
- Podar el árbol por la opción 2: sumatoria de error de clasificación = 0.23
- No podar el árbol: sumatoria de error de clasificación = 0.2



2. Si el valor de alpha fuera 0.2, ¿qué alternativa elegirías?

Pregunta 6 (10 puntos):

Se desea usar GridSearchCV para seleccionar por cross-validation el conjunto de mejores hiperparámetros para entrenar un modelo CART. Con la siguiente grilla propuesta y usando 5 folds, ¿Cuántos modelos se entrenarían durante la búsqueda?

```
param_grid_clf = {  
    "max_depth": [None, 3, 5, 7, 9, 12, 15],  
    "min_samples_split": [2, 5, 10, 20, 50],  
    "min_samples_leaf": [1, 2, 5, 10, 20],  
    "ccp_alpha": [0.0, 1e-5, 1e-4, 1e-3, 1e-2],  
}
```

Pregunta extra (10 puntos):

La figura muestra un conjunto de datos binario en dos dimensiones (X_1, X_2)

- Cada círculo corresponde a una observación etiquetada: naranja (clase 0) o azul (clase 1).
- La línea punteada magenta es la **frontera de decisión óptima** (es decir, es la frontera de decisión del mejor clasificador posible para este conjunto de datos).
- Este conjunto de datos cuenta con 200 observaciones con clases balanceadas (100 observaciones clase 0 y 100 observaciones clase 1)

Calcular el **error de bayes** (mínimo error posible o error irreducible) de este conjunto de datos.

