Guía 2 de Ejercicios

CART · Árboles de decisión

Universidad de SanAndrés

Ejercicios

Ejercicio 1

A continuación se ven, por separado, algunas hojas extraídas de un modelo CART para clasificación ya entrenado.

```
samples = 35
value = [35, 0, 0]
class = Setosa
```

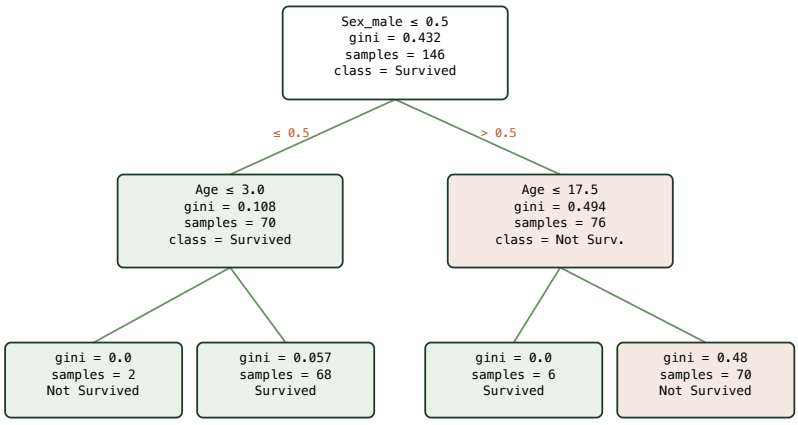
```
samples = 105
value = [35, 35, 35]
class = Setosa
```

```
samples = 40
value = [0, 5, 35]
class = Virginica
```

1. Calculá el índice de Gini para cada una.
2. ¿Con qué probabilidad clasifica cada una de estas hojas?

Ejercicio 2

Dado el siguiente árbol de clasificación ya entrenado (Sex_male = 1 si es hombre, 0 si es mujer):



Para cada uno de estos pasajeros, recorré el árbol desde la raíz y predecí la clase junto con la probabilidad de la hoja en la que cae:

a. Mujer (Sex_male = 0), Age = 25.

b. Hombre (Sex_male = 1), Age = 10.

c. Hombre (Sex_male = 1), Age = 40.

Ejercicio 3

¿Es necesario escalar los datos antes de entrenar un modelo CART? ¿Por qué?

Ejercicio 4

Usar el siguiente dataset de entrenamiento para entrenar manualmente un árbol de clasificación teniendo en cuenta los siguientes hiperparámetros. Tomar los siguientes cortes para la variable continua: 2.5 y 3.5.

- Altura máxima del árbol: 3 (3 niveles).
- Cantidad mínima de observaciones por nodo para dividir: 4.

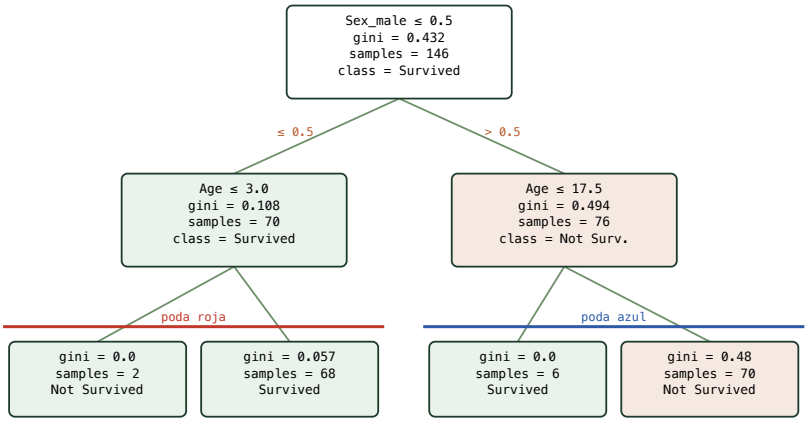
horas_estudio	participa_clase	usa_material_extra	aprueba
1	No	Sí	Sí
1.5	No	Sí	Sí
2	Sí	Sí	Sí
2.5	Sí	Sí	No
3	No	No	No
3.5	Sí	Sí	Sí
4	Sí	No	Sí
4.5	No	Sí	Sí
5	No	No	No
6	Sí	No	No

Ejercicio 5

¿Qué efecto tiene el parámetro alpha en la poda de un árbol de decisión?

Ejercicio 6

Se consideran dos podas alternativas para el siguiente modelo: la **roja** corta las dos hojas de la rama izquierda y la **azul** corta las dos de la rama derecha.



a. Con alpha = 0, ¿conviene aplicar alguna de las dos podas? Justificá mirando cómo cambia el error de clasificación en entrenamiento.

b. Si tuvieras que quedarte con una sola de las dos podas, ¿cuál elegirías y por qué?

Ejercicio 7

Para el siguiente conjunto de datos sobre contrataciones, construí un árbol de decisión de **profundidad máxima 2**. Mostrá los cálculos del índice de Gini para cada posible división en el nodo raíz y seleccioná la mejor. Luego repetí el proceso para el nodo hijo que corresponda.

Salario (miles USD)	Ciudad	Experiencia (años)	Contratado
50	A	5	Sí
60	B	3	Sí
70	A	10	Sí
80	C	2	No
90	B	7	No
100	C	15	No

Ejercicio 8

¿Qué significa que un árbol sea "greedy" (voraz)? ¿Qué implicancias tiene esto en la práctica?

Ejercicio 9

¿Por qué los árboles de decisión suelen sobreajustar? ¿Qué técnicas se pueden usar para evitarlo?

Ejercicio 10

(Regresión) Un árbol de regresión busca minimizar la varianza en sus hojas. Dado el siguiente dataset, determiná el punto de corte óptimo para la variable m^2 para predecir el precio. Calculá la reducción de varianza para el mejor corte.

m^2	Precio (miles USD)
100	250
120	300
150	400
160	420
200	500

Ejercicio 11

Volviendo al árbol del ejercicio 6, ¿cuál de las dos variables (Sex_male o Age) parece ser más importante para predecir la supervivencia? Justificá tu respuesta considerando la ganancia de información o la reducción de impureza de Gini en el primer nivel del árbol.

Ejercicio 12

Se entrenan dos árboles con el mismo dataset para un problema de clasificación. El **Árbol A** se entrena con min_samples_leaf = 1, mientras que el **Árbol B** se entrena con min_samples_leaf = 10. ¿Cuál de los dos es más propenso a sobreajustar y por qué?

Ejercicio 13

Explicá brevemente la diferencia entre el índice de Gini y la entropía como criterios de partición.

Ejercicio 14

Un árbol de decisión para regresión utiliza el criterio de varianza en vez de Gini. ¿Por qué? ¿Cómo se calcula la varianza en un nodo?

Soluciones

Ejercicio 1

> **a)** Gini $= 1 - \Sigma\, p^2$.
>
> - Hoja 1: $1 - (35/35)^2 = \mathbf{0}$. Nodo puro.
> - Hoja 2: $1 - 3\cdot(1/3)^2 = 1 - \frac{3}{9} = \frac{2}{3} \approx \mathbf{0.667}$. Máxima impureza para 3 clases.
> - Hoja 3: $1 - [(5/40)^2 + (35/40)^2] = 1 - (1/64 + 49/64) = 1 - 50/64 \approx \mathbf{0.219}$.

> **b)** La probabilidad es la proporción de cada clase en la hoja. Hoja 1: 100% Setosa. Hoja 2: 33.3% para cada una de las 3 clases. Hoja 3: 87.5% Virginica y 12.5% de la segunda clase.

Ejercicio 2

> **a)** Mujer (Sex_male = 0): en la raíz, $0 \leq 0.5 \rightarrow$ rama izquierda (Age ≤ 3.0). Age $= 25 > 3.0 \rightarrow$ hoja derecha: **Survived** (gini 0.057, 68 samples). Probabilidad $\approx$ 97% Survived.

> **b)** Hombre (Sex_male = 1): $1 > 0.5 \rightarrow$ rama derecha (Age ≤ 17.5). Age $= 10 \leq 17.5 \rightarrow$ hoja izquierda: **Survived** (gini 0.0, 6 samples). Probabilidad 100% Survived.

> **c)** Hombre (Sex_male = 1): $1 > 0.5 \rightarrow$ rama derecha (Age ≤ 17.5). Age $= 40 > 17.5 \rightarrow$ hoja derecha: **Not Survived** (gini 0.48, 70 samples, 42 Not / 28 Sí). Probabilidad $\approx$ 60% Not Survived.

Ejercicio 3

> No, no es necesario. Los árboles son inmunes al escalado: las divisiones se basan en umbrales sobre una variable a la vez, por lo que importa el orden de los valores, no su magnitud.

Ejercicio 4

El nodo raíz tiene 6 Sí y 4 No $\rightarrow$ Gini $= 1 - (6/10)^2 - (4/10)^2 = \mathbf{0.48}$. Evaluamos cada división posible:

> **1.** horas_estudio ≤ 2.5: izq (3 Sí, 1 No) $\rightarrow$ Gini 0.375; der (3 Sí, 3 No) $\rightarrow$ Gini 0.5. Ponderado $= (4/10)\cdot 0.375 + (6/10)\cdot 0.5 = \mathbf{0.45}$.

> **2.** horas_estudio ≤ 3.5: izq (4 Sí, 2 No) $\rightarrow$ Gini 0.444; der (2 Sí, 2 No) $\rightarrow$ Gini 0.5. Ponderado $=$ **0.467**.

> **3.** participa_clase: Sí (4 Sí, 2 No) $\rightarrow$ Gini 0.444; No (2 Sí, 2 No) $\rightarrow$ Gini 0.5. Ponderado $=$ **0.467**.

> **4.** usa_material_extra: Sí (5 Sí, 1 No) $\rightarrow$ Gini 0.278; No (1 Sí, 3 No) $\rightarrow$ Gini 0.375. Ponderado $= (6/10)\cdot 0.278 + (4/10)\cdot 0.375 = \mathbf{0.317}$.

El mejor primer corte es **usa_material_extra** (0.317, el menor). La rama **material = No** (1 Sí, 3 No, n=4) puede seguir dividiéndose, pero ningún corte la mejora limpiamente, así que predice la mayoría (No). La rama **material = Sí** (5 Sí, 1 No, n=6) se vuelve a dividir: el mejor corte es **participa_clase** (Sí $\rightarrow$ 2 Sí/1 No, No $\rightarrow$ 3 Sí/0 No puro; ponderado 0.222), aislando el único caso que no aprobó.

Ejercicio 5

> alpha (cost complexity pruning) controla la severidad de la poda. Con alpha = 0 no se poda nada. A medida que alpha crece, se penaliza más la complejidad (número de hojas), forzando a podar ramas que no aportan una reducción de impureza significativa.

Ejercicio 6

> **a)** No conviene ninguna. Con alpha = 0 el criterio de poda es solo el error de clasificación en entrenamiento (no se penaliza la complejidad), y **toda poda aumenta o mantiene ese error**. **Poda roja** (izquierda): las hojas separadas clasifican mal 0 + 2 = 2 casos; al fusionarlas el nodo predice Survived y erra 4. El error **sube de 2 a 4**. **Poda azul** (derecha): las hojas erran 0 + 28 = 28; al fusionarlas el nodo predice Not Survived y erra 34. El error **sube de 28 a 34**. Como ambas empeoran el error de entrenamiento y alpha = 0 no da ningún crédito por simplificar, no se poda.

> **b)** La **roja**. Aumenta el error solo en 2 casos (de 2 a 4), mucho menos que la azul (de 28 a 34). Además fusiona dos hojas que ya predicen casi lo mismo, mientras que la azul destruye una hoja pura (6 Survived bien clasificados).

Ejercicio 7

> Gini del nodo raíz (3 Sí, 3 No) = 0.5. El mejor primer corte es **Salario ≤ 75**, que da Gini ponderado 0: separa perfectamente los 3 Sí (salarios 50, 60, 70) de los 3 No (80, 90, 100). Como ambos nodos quedan puros, el árbol tiene profundidad 1 y no hace falta dividir más.

Ejercicio 8

> "Greedy" significa que en cada paso se toma la decisión que parece mejor en ese momento (la que más reduce la impureza), sin mirar si lleva a un árbol globalmente óptimo. Puede resultar en árboles subóptimos.

Ejercicio 9

> Porque pueden crecer hasta que cada hoja tenga una única observación, memorizando el ruido del set de entrenamiento. Se evita con post-poda (pruning), pre-poda (limitar profundidad, mínimo de muestras por nodo/hoja) o usando ensambles como Random Forest.

Ejercicio 10

> La varianza de un nodo es el promedio de los desvíos al cuadrado respecto de la media del nodo.

Nodo raíz. Media = (250 + 300 + 400 + 420 + 500) / 5 = 374. Var = $[(250-374)^2 + (300-374)^2 + (400-374)^2 + (420-374)^2 + (500-374)^2] / 5 = 39520 / 5 =$ **7904**.

Cortes candidatos (promedios entre m² consecutivos): 110, 135, 155, 180. Para cada uno, la varianza ponderada de los dos grupos:

> **110:** izq {250} → var 0; der {300, 400, 420, 500} → media 405, var 5075. Ponderada = (1/5)·0 + (4/5)·5075 = **4060**. Reducción = 7904 − 4060 = 3844.

> **135:** izq {250, 300} → media 275, var $[(250-275)^2 + (300-275)^2]/2$ = 625; der {400, 420, 500} → media 440, var 1866.7. Ponderada = (2/5)·625 + (3/5)·1866.7 = **1370**. Reducción = 7904 − 1370 = 6534.

> **155:** izq {250, 300, 400} → media 316.7, var 3888.9; der {420, 500} → media 460, var 1600. Ponderada = (3/5)·3888.9 + (2/5)·1600 = **2973.3**. Reducción = 4930.7.

> **180:** izq {250, 300, 400, 420} → media 342.5, var 4918.8; der {500} → var 0. Ponderada = (4/5)·4918.8 + (1/5)·0 = **3935**. Reducción = 3969.

El punto de corte óptimo es **$m^2 \leq 135$**: es el que da la menor varianza ponderada (1370) y por lo tanto la mayor reducción de varianza (**6534**).

Ejercicio 11

> La variable **Sex_male** es más importante en el primer nivel. La división por sexo reduce la impureza de 0.432 a un Gini ponderado de (70/146)·0.108 + (76/146)·0.494 ≈ **0.308**, la mayor ganancia de información posible en el nodo raíz.

Ejercicio 12

> El **Árbol A** es más propenso al sobreajuste. Con min_samples_leaf = 1 puede crear hojas con una sola muestra, adaptándose al ruido y a los casos particulares del entrenamiento. El Árbol B (min_samples_leaf = 10) está más regularizado.

Ejercicio 13

> Ambas son métricas de impureza. Gini es más rápido de calcular. La entropía, al usar un logaritmo, penaliza un poco más las mezclas de clases. En la práctica suelen dar resultados muy similares.

Ejercicio 14

> En regresión el objetivo es que las predicciones de una hoja estén lo más cerca posible del valor real, es decir, minimizar la dispersión. La varianza mide esa dispersión: se calcula como el promedio de las diferencias al cuadrado entre cada valor del nodo y la media del nodo.