

Guía de Ejercicios Validación de Modelos

Analítica de Datos, Universidad de San Andrés

Si encuentran algún error en el documento o hay alguna duda, mandenme un mail a rodriguezr@udesa.edu.ar y lo revisamos.

1. Ejercicios Conceptuales

1.1. Verdadero o Falso

1. La accuracy es siempre la mejor métrica para evaluar un modelo de clasificación.
2. Un modelo con $AUC = 0.3$ es peor que uno aleatorio.
3. La precisión mide la proporción de verdaderos positivos entre todas las predicciones positivas.
4. El recall y la especificidad suman siempre 1.
5. En un problema médico es más importante maximizar el recall que la precisión.
6. La curva ROC grafica precisión versus recall.
7. Un F1-Score alto garantiza que tanto precisión como recall son altos.
8. La matriz de confusión solo se puede usar para problemas binarios.
9. $AUC = 0.5$ indica un clasificador perfecto.
10. La curva PR es más informativa que ROC cuando las clases están desbalanceadas.
11. Una tasa de falsos positivos alta es siempre peor que una baja.
12. La especificidad es más importante que el recall en sistemas de justicia.
13. El False Discovery Rate y la precisión suman 1.

14. En problemas multiclase no existen falsos positivos.
15. Un modelo puede tener alta accuracy pero baja utilidad práctica.
16. El MSE penaliza más los errores grandes que el MAE.
17. Un R^2 negativo indica que el modelo es peor que predecir la media.
18. El RMSE tiene las mismas unidades que la variable objetivo.
19. El MAPE puede causar problemas cuando hay valores cero en los datos reales.
20. Un modelo con $R^2 = 0.8$ explica el 80 % de la varianza de la variable objetivo.

1.2. Opción Múltiple

1. ¿Cuál es la diferencia principal entre precisión y recall?
 - a) No hay diferencia, son sinónimos
 - b) Precisión se enfoca en predicciones positivas, recall en casos positivos reales
 - c) Recall es para problemas binarios, precisión para multiclase
 - d) Precisión es más importante que recall
2. En un modelo de detección de cáncer, ¿qué métrica priorizarías?
 - a) Accuracy
 - b) Precisión
 - c) Recall
 - d) F1-Score
3. ¿Qué representa un punto en la curva ROC?
 - a) Un modelo diferente
 - b) Un umbral de clasificación diferente
 - c) Una métrica diferente

- d) Un dataset diferente
4. Si tengo un dataset con 95 % de clase negativa y 5 % de clase positiva, ¿qué métrica puede ser engañosa?
- a) Accuracy
 - b) Recall
 - c) Precisión
 - d) AUC
5. ¿Cuándo usarías la curva PR en lugar de ROC?
- a) Siempre
 - b) Nunca
 - c) Cuando las clases están balanceadas
 - d) Cuando las clases están desbalanceadas
6. ¿Qué significa $AUC = 0.8$?
- a) 80 % de accuracy
 - b) 80 % de probabilidad de ranquear correctamente un par positivo-negativo
 - c) 80 % de precisión
 - d) 80 % de recall
7. ¿Cuál métrica es más sensible a valores atípicos?
- a) MSE
 - b) MAE
 - c) RMSE
 - d) R^2
8. ¿Qué significa un $R^2 = 0.3$?
- a) El modelo explica el 30 % de la varianza
 - b) El modelo tiene 30 % de accuracy

- c) El modelo es 30 % mejor que la media
- d) El modelo es 30 % peor que aleatorio

9. ¿Cuál es la principal ventaja del MAPE?

- a) Es más preciso que otras métricas
- b) Es fácil de interpretar como porcentaje
- c) No tiene problemas con valores cero
- d) Siempre es mejor que el MAE

2. Ejercicios Prácticos

2.1. Matriz de Confusión y Métricas Básicas

Un modelo de clasificación binaria para detectar fraude en transacciones tiene los siguientes resultados en un conjunto de prueba de 1000 transacciones:

		Real	
		0	1
Predicho	0	45	15
	1	5	935

- a. Calcular todas las métricas básicas: accuracy, precisión, recall, especificidad, F1-Score.
- b. ¿Qué puede concluir sobre el rendimiento del modelo?
- c. ¿Es la accuracy una buena métrica para este problema? Justificar.
- d. ¿Qué métrica sería más importante para este caso de uso y por qué?

2.2. Predicción de Precios

Un modelo para predecir el precio de casas (en miles de dólares) tiene los siguientes resultados en un conjunto de prueba:

Casa	Precio Real	Precio Predicho
1	300	280
2	450	470
3	200	190
4	600	620
5	350	330
6	500	480
7	250	260
8	400	420

- Calcular MSE, RMSE, MAE y R^2 para este modelo.
- ¿Qué métrica usarías para reportar el rendimiento a un cliente no técnico?
- Si una casa cuesta 0 dólares (regalo), ¿qué problema tendrías con el MAPE?
- ¿Qué estrategia usarías para manejar este problema?

2.3. Comparación de Modelos de Predicción

Tenés dos modelos para predecir ventas mensuales (en miles de unidades):

Modelo A: $MSE = 25$, $MAE = 3.5$, $R^2 = 0.85$

Modelo B: $MSE = 30$, $MAE = 3.2$, $R^2 = 0.82$

- ¿Cuál modelo elegirías si los errores grandes son muy costosos?
- ¿Cuál modelo elegirías si todos los errores tienen el mismo costo?
- ¿Qué información adicional necesitarías para tomar una decisión más informada?
- Si el R^2 del Modelo A fuera 0.95, ¿cambiaría tu respuesta en (a)?

2.4. Comparación de Modelos

Tenés dos modelos para clasificar emails como spam o no spam. Los resultados son:

- **Modelo A:** VP = 180, VN = 820, FP = 30, FN = 20
 - **Modelo B:** VP = 160, VN = 830, FP = 20, FN = 40
- a. Calcular precisión, recall y F1-Score para ambos modelos.
 - b. ¿Cuál modelo elegirías y por qué?
 - c. ¿Cambiaría tu elección si el costo de un falso negativo fuera 10 veces mayor que el de un falso positivo?

2.5. Matriz de Confusión Multiclase

Un modelo clasifica el clima en tres categorías: Soleado (S), Nublado (N), Lluvioso (L). La matriz de confusión es:

		Real		
		S	N	L
Predicho	S	85	10	5
	N	8	82	10
	L	7	12	81

- a. Calcular la accuracy total del modelo.
- b. Calcular la precisión, recall y F1-Score para cada clase.

- c. ¿Qué clase es la más difícil de predecir para el modelo?
- d. Calcular las métricas macro y micro average.

2.6. Curva ROC

Un modelo de clasificación binaria produce las siguientes probabilidades para 8 casos de prueba:

Caso	Clase Real	Probabilidad Positiva
1	Positivo	0.9
2	Negativo	0.8
3	Positivo	0.7
4	Positivo	0.6
5	Negativo	0.4
6	Negativo	0.3
7	Positivo	0.2
8	Negativo	0.1

- a. Para umbrales 0.5, 0.7 y 0.9, calcular TPR y FPR.
- b. ¿Qué umbral recomendarías si quieres minimizar falsos positivos?
- c. ¿Qué umbral recomendarías si quieres minimizar falsos negativos?
- d. Estimar el valor aproximado del AUC.

2.7. Problema Médico

Un hospital desarrolla un modelo para detectar neumonía en radiografías. El dataset tiene las siguientes características:

- 10,000 radiografías en total
- 500 casos positivos (neumonía)
- 9,500 casos negativos (sin neumonía)

El modelo A tiene una accuracy del 96 % pero detecta solo el 40 % de los casos de neumonía. El modelo B tiene una accuracy del 92 % pero detecta el 85 % de los casos de neumonía.

- a. Calcular las matrices de confusión aproximadas para ambos modelos.
- b. ¿Cuál modelo elegirías para uso clínico? Justificar.
- c. ¿Qué estrategias podrías usar para mejorar el modelo seleccionado?

2.8. Implementación en Python

Implementar en Python un análisis completo de validación de modelos que incluya:

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from sklearn.datasets import make_classification
4 from sklearn.model_selection import train_test_split
5 from sklearn.ensemble import RandomForestClassifier
6 from sklearn.linear_model import LogisticRegression
7 from sklearn.metrics import (classification_report,
8                               confusion_matrix,
9                               roc_curve, auc,
10                              precision_recall_curve)
11
12 # Generar dataset desbalanceado
13 X, y = make_classification(n_samples=1000, n_features=20,
14                           n_classes=2, weights=[0.9, 0.1],
15                           random_state=42)
16
17 # Completar el código para:
18 # 1. Dividir en train/test
19 # 2. Entrenar dos modelos diferentes
20 # 3. Calcular y comparar métricas
21 # 4. Graficar curvas ROC y PR
22 # 5. Crear matrices de confusión
23 # 6. Analizar cual modelo es mejor para este caso
```

2.9. Caso de Negocio

Una empresa de e-commerce quiere implementar un sistema de detección de reseñas falsas. Tenés los siguientes datos de rendimiento de tres modelos:

Modelo	Accuracy	Precisión	Recall	AUC
Naive Bayes	0.78	0.65	0.72	0.76
Random Forest	0.82	0.71	0.68	0.81
SVM	0.80	0.73	0.64	0.79

- a. ¿Qué modelo recomendarías si el objetivo principal es no bloquear reseñas legítimas?
- b. ¿Qué modelo recomendarías si el objetivo principal es mantener la calidad alta de reseñas?
- c. ¿Qué información adicional necesitarías para tomar una mejor decisión?
- d. Proponer una estrategia que combine múltiples modelos.

3. Soluciones

3.1. Verdadero o Falso

1. **Falso.** Accuracy puede ser engañosa con clases desbalanceadas.
2. **Verdadero.** $AUC < 0.5$ es peor que aleatorio (0.5).
3. **Verdadero.** $Precisión = VP / (VP + FP)$.
4. **Falso.** Recall + Especificidad no suman 1. Especificidad + FPR suman 1.
5. **Verdadero.** Es más importante no perder casos positivos (enfermos).
6. **Falso.** ROC grafica TPR vs FPR. PR grafica Precisión vs Recall.
7. **Verdadero.** F1 es la media armónica de precisión y recall.
8. **Falso.** También se usa para problemas multiclase.
9. **Falso.** $AUC = 0.5$ indica clasificador aleatorio, no perfecto.
10. **Verdadero.** PR es más sensible a clases minoritarias.
11. **Falso.** Depende del contexto y costos del problema.
12. **Verdadero.** Se prefiere no condenar inocentes.
13. **Verdadero.** $FDR = 1 - Precisión$.
14. **Falso.** Hay múltiples tipos de errores, pero el concepto se extiende.
15. **Verdadero.** Especialmente con clases desbalanceadas.
16. **Verdadero.** MSE eleva al cuadrado los errores, penalizando más los grandes.
17. **Verdadero.** R^2 negativo indica que el modelo es peor que predecir la media.
18. **Verdadero.** $RMSE = \sqrt{MSE}$, mantiene las unidades originales.
19. **Verdadero.** MAPE tiene división por cero cuando $y_i = 0$.
20. **Verdadero.** R^2 mide la proporción de varianza explicada.

3.2. Opción Múltiple

1. **b)** Precisión se enfoca en predicciones positivas correctas, recall en casos positivos reales detectados.
2. **c)** Recall - es crucial no perder casos de cáncer.
3. **b)** Un umbral de clasificación diferente.
4. **a)** Accuracy - un modelo que predice todo negativo tendría 95 % accuracy.
5. **d)** Cuando las clases están desbalanceadas.
6. **b)** 80 % de probabilidad de ranquear correctamente un par positivo-negativo.
7. **a)** MSE - eleva al cuadrado los errores, amplificando el impacto de valores atípicos.
8. **a)** El modelo explica el 30 % de la varianza de la variable objetivo.
9. **b)** Es fácil de interpretar como porcentaje, aunque tiene problemas con ceros.

3.3. Matriz de Confusión y Métricas Básicas

a) Métricas calculadas:

$$\begin{aligned}\text{Accuracy} &= \frac{45 + 935}{1000} = 0,98 \\ \text{Precisión} &= \frac{45}{45 + 15} = 0,75 \\ \text{Recall} &= \frac{45}{45 + 5} = 0,90 \\ \text{Especificidad} &= \frac{935}{935 + 15} = 0,984 \\ \text{F1} &= 2 \times \frac{0,75 \times 0,90}{0,75 + 0,90} = 0,818\end{aligned}$$

b) El modelo tiene alta accuracy y recall, pero precisión moderada.

- c) No, accuracy puede ser engañosa porque hay pocas transacciones fraudulentas.
- d) Recall es más importante para no perder casos de fraude.

3.4. Predicción de Precios

a) Cálculos:

$$\begin{aligned} \text{MSE} &= \frac{1}{8}[(300 - 280)^2 + (450 - 470)^2 + (200 - 190)^2 + (600 - 620)^2 + (350 - 330)^2 \\ &\quad + (500 - 480)^2 + (250 - 260)^2 + (400 - 420)^2] \\ &= \frac{1}{8}[400 + 400 + 100 + 400 + 400 + 400 + 100 + 400] = 325 \end{aligned}$$

$$\text{RMSE} = \sqrt{325} = 18,03$$

$$\text{MAE} = \frac{1}{8}[20 + 20 + 10 + 20 + 20 + 20 + 10 + 20] = 17,5$$

$$R^2 = 1 - \frac{325}{\text{varianza_real}} = 1 - \frac{325}{6500} = 0,95$$

$$\text{Donde: } \bar{y} = \frac{300 + 450 + 200 + 600 + 350 + 500 + 250 + 400}{8} = 381,25$$

$$\text{varianza_real} = (300 - 381,25)^2 + (450 - 381,25)^2 + \dots + (400 - 381,25)^2 = 6500$$

- b) RMSE o MAE - son fáciles de interpretar en las mismas unidades.
- c) División por cero en el denominador del MAPE.
- d) Reemplazar ceros por valor muy pequeño, filtrar ceros, o usar sMAPE.

3.5. Comparación de Modelos de Predicción

- a) Modelo A - tiene menor MSE (25 vs 30), penaliza menos los errores grandes.
- b) Modelo B - tiene menor MAE (3.2 vs 3.5), trata todos los errores por igual.
- c) Costos específicos de errores, distribución de los datos, interpretabilidad.
- d) Sí, $R^2 = 0.95$ indicaría que el Modelo A explica mucha más varianza, compensando el mayor MAE.

3.6. Comparación de Modelos

Modelo A:

$$\begin{aligned}\text{Precisión} &= \frac{180}{210} = 0,857 \\ \text{Recall} &= \frac{180}{200} = 0,90 \\ \text{F1} &= 0,878\end{aligned}$$

Modelo B:

$$\begin{aligned}\text{Precisión} &= \frac{160}{180} = 0,889 \\ \text{Recall} &= \frac{160}{200} = 0,80 \\ \text{F1} &= 0,842\end{aligned}$$

Modelo A tiene mejor recall y F1. Si los falsos negativos cuestan 10 veces más, definitivamente elegir Modelo A.

3.7. Matriz de Confusión Multiclase

a. $\text{Accuracy} = (85 + 82 + 81) / 300 = 0.827$

b. Calculando por clase:

- Soleado: $\text{Precisión} = 0.85$, $\text{Recall} = 0.85$, $\text{F1} = 0.85$
- Nublado: $\text{Precisión} = 0.82$, $\text{Recall} = 0.782$, $\text{F1} = 0.80$
- Lluvioso: $\text{Precisión} = 0.844$, $\text{Recall} = 0.81$, $\text{F1} = 0.827$

c. Nublado es la más difícil (menor F1).

3.8. Curva ROC

a. Para cada umbral:

- Umbral 0.5: $\text{TPR} = 0.75$, $\text{FPR} = 0.25$
- Umbral 0.7: $\text{TPR} = 0.75$, $\text{FPR} = 0.25$
- Umbral 0.9: $\text{TPR} = 0.25$, $\text{FPR} = 0.25$

- b. Para minimizar FP: umbral 0.9
- c. Para minimizar FN: umbral bajo (0.1)
- d. AUC aproximado: 0.75

3.9. Problema Médico

- a. Modelo A: VP=200, FN=300, FP=100, VN=9400. Modelo B: VP=425, FN=75, FP=725, VN=8775
- b. Modelo B porque detecta más casos de neumonía, crucial en medicina.
- c. Estrategias: datos más balanceados, ensemble, ajuste de umbral.

3.10. Implementación en Python

```
1 import numpy as np
2 import pandas as pd
3 from sklearn.datasets import make_classification
4 from sklearn.model_selection import train_test_split
5 from sklearn.linear_model import LogisticRegression
6 from sklearn.ensemble import RandomForestClassifier
7 from sklearn.metrics import classification_report,
8   confusion_matrix, roc_curve, auc, precision_recall_curve
9 import matplotlib.pyplot as plt
10
11 # Generar un dataset desbalanceado
12 X, y = make_classification(n_samples=5000, n_features=20,
13   n_informative=2, n_redundant=10,
14   n_clusters_per_class=1, weights
15   =[0.9, 0.1], flip_y=0, random_state=42)
16
17 # Division train/test
18 X_train, X_test, y_train, y_test = train_test_split(X, y,
19   test_size=0.3, stratify=y, random_state=42)
20
21 # Entrenamiento de modelos
22 lr = LogisticRegression()
23 rf = RandomForestClassifier()
24
25 lr.fit(X_train, y_train)
26 rf.fit(X_train, y_train)
27
28 # Predicciones
29 y_pred_lr = lr.predict(X_test)
30 y_pred_rf = rf.predict(X_test)
```

```

27 y_proba_lr = lr.predict_proba(X_test)[: ,1]
28 y_proba_rf = rf.predict_proba(X_test)[: ,1]
29
30 # Calculo de metricas
31 print("Logistic Regression")
32 print(confusion_matrix(y_test, y_pred_lr))
33 print(classification_report(y_test, y_pred_lr, digits=3))
34
35 print("Random Forest")
36 print(confusion_matrix(y_test, y_pred_rf))
37 print(classification_report(y_test, y_pred_rf, digits=3))
38
39 # Curva ROC
40 fpr_lr, tpr_lr, _ = roc_curve(y_test, y_proba_lr)
41 fpr_rf, tpr_rf, _ = roc_curve(y_test, y_proba_rf)
42 auc_lr = auc(fpr_lr, tpr_lr)
43 auc_rf = auc(fpr_rf, tpr_rf)
44
45 plt.figure()
46 plt.plot(fpr_lr, tpr_lr, label="Logistic Reg (AUC = %.2f)" %
         auc_lr)
47 plt.plot(fpr_rf, tpr_rf, label="Random Forest (AUC = %.2f)" %
         auc_rf)
48 plt.plot([0,1],[0,1], 'k--')
49 plt.xlabel("FPR")
50 plt.ylabel("TPR")
51 plt.title("Curva ROC")
52 plt.legend()
53 plt.show()
54
55 # Curva Precision-Recall
56 prec_lr, rec_lr, _ = precision_recall_curve(y_test,
         y_proba_lr)
57 prec_rf, rec_rf, _ = precision_recall_curve(y_test,
         y_proba_rf)
58
59 plt.figure()
60 plt.plot(rec_lr, prec_lr, label="Logistic Reg")
61 plt.plot(rec_rf, prec_rf, label="Random Forest")
62 plt.xlabel("Recall")
63 plt.ylabel("Precision")
64 plt.title("Curva Precision-Recall")
65 plt.legend()
66 plt.show()
67

```

```
68 # Analisis comparativo
69 # En este caso, mirar F1, recall y precision para la clase
    minoritaria (1)
70 # Tambien comparar AUC y la curva PR, que es mas informativa
    en datasets desbalanceados
```

3.11. Caso de Negocio

- a. Naive Bayes (mayor recall para no bloquear reseñas legítimas).
- b. SVM (mayor precisión para mantener calidad).
- c. Costos de errores, volumen de reseñas, recursos disponibles.
- d. Ensemble que combine todo con pesos según objetivos del negocio.