Guía 3 de Repaso

Preparación para el parcial

Universidad de SanAndrés

Ejercicios

Ejercicio 1

Una fintech quiere (i) estimar el monto que gastará cada cliente el próximo mes y (ii) decidir a qué clientes enviarles una promoción, sabiendo que el presupuesto solo alcanza para los 500 clientes con mayor probabilidad de recompra. ¿Cómo conviene plantear ambos problemas?

A. Los dos son de regresión, porque ambos parten de datos numéricos de gasto.
B. El monto es un problema de regresión; la recompra es un problema de clasificación del que se usa la probabilidad estimada para rankear y quedarse con los 500 primeros.
C. El monto es clasificación (gasta / no gasta) y la recompra es regresión, porque se predice un ranking numérico.
D. La recompra no es un problema de modelado: basta ordenar a los clientes por su gasto histórico.

Ejercicio 2

Un modelo estima el tiempo de entrega (en minutos) como
tiempo = 8 + 0,9·distancia + 4·hora_pico + 6·lluvia + 2·paradas_previas,
con la distancia en km y las binarias en 1/0. Se pide la predicción para un envío a 15 km, en hora pico, sin lluvia y con 3 paradas previas.

A. 25,5 minutos.
B. 27,5 minutos.
C. 37,5 minutos.
D. 31,5 minutos.

Ejercicio 3

Un modelo antifraude se evalúa sobre 1.000 transacciones, de las cuales 50 son fraudes. Con umbral 0,50 obtiene: TP = 40, FP = 60, FN = 10, TN = 890. Un compañero festeja que el modelo “tiene 93% de accuracy”. ¿Cuál es la lectura correcta?

A. El accuracy es engañoso con clases desbalanceadas: un modelo que dijera “nunca hay fraude” alcanzaría 95% de accuracy. Conviene mirar precisión (0,40) y recall (0,80) según el costo de cada error.
B. El 93% de accuracy es el resumen correcto: como integra aciertos en fraude y en legítimas en un solo número, ya pondera ambos errores y confirma que el modelo puede pasar a producción tal cual.
C. Como el recall es 0,80, el modelo deja pasar el 80% de los fraudes: solo caza 1 de cada 5, así que por más alto que sea el accuracy la herramienta es inservible para el negocio antifraude.
D. La precisión de 0,40 es un ruido irrelevante con clases tan desbalanceadas; en fraude la única métrica que resume bien el desempeño global es el accuracy, que acá ya da un excelente 93%.

Ejercicio 4

Se comparan cuatro modelos para predecir un precio. El equipo quiere buena generalización y, a igualdad de desempeño, un modelo interpretable con pocas variables. ¿Cuál es la primera elección más razonable?

Modelo	Variables	R^2 train	MAE val
Lineal	10	0,71	6,8
Polinómica (grado 4)	120	0,99	13,2
Ridge	120	0,88	6,1
Lasso	120 (conserva 22)	0,86	6,0

A. La polinómica de grado 4: su R^2 de entrenamiento (0,99) es el más alto de la tabla, señal de que capturó casi toda la señal, y las 120 variables le dan la flexibilidad que un modelo interpretable no tiene.

B. Ridge: al conservar las 120 variables retiene toda la información disponible, y por eso siempre generaliza mejor que Lasso, que al descartar variables tira relaciones útiles y arriesga subajustar.

C. Lasso: tiene el mejor MAE de validación (6,0), apenas por debajo de Ridge (6,1), y además reduce de 120 a 22 variables, cumpliendo el requisito de parsimonia.

D. La lineal con 10 variables: usar pocas variables desde el inicio evita cualquier sobreajuste y por eso su MAE de validación (6,8) es más confiable que el de los modelos con 120 variables, que memorizan ruido.

Ejercicio 5

Un modelo estima la probabilidad de demora con $z = -1 + 0{,}05 \cdot \text{distancia} + 0{,}9 \cdot \text{hora_pico} + 0{,}7 \cdot \text{lluvia} + 0{,}04 \cdot \text{pendientes}$ y $p = 1 / (1 + e^{-z})$. Para un pedido a 20 km, fuera de hora pico, con lluvia y 25 pedidos pendientes, usando umbral 0,50, ¿qué produce el modelo? ($e^{-1,7} \approx 0{,}183$)

A. $z = 0{,}30$; $p \approx 0{,}57$; predice demora.

B. $z = 1{,}70$; $p \approx 0{,}15$; predice a tiempo.

C. $z = 1{,}70$; $p \approx 0{,}50$; el modelo no puede decidir.

D. $z = 1{,}70$; $p \approx 0{,}85$; predice demora.

Ejercicio 6

Sobre 4 envíos, un modelo produce estos errores. El cuarto (120 min) fue una demora real por un corte de calle, no un error de carga. Se comparan MAE y MSE como pérdida de entrenamiento. ¿Qué afirmación es correcta?

Real	20	25	30	120
Predicho	22	24	28	40

A. MAE y MSE dan prácticamente lo mismo: como parten de las mismas diferencias real menos predicho, elevar al cuadrado solo reescala la métrica y el ranking de modelos no cambia, así que da igual cuál se use como pérdida.

B. El caso de 120 min domina el MSE (aporta $80^2 = 6.400$ de un MSE de 1.602,25, frente a un MAE de 21,25); si esos casos extremos son reales y no queremos que distorsionen al resto, MAE es más robusto, pero conviene decidirlo por validación.

C. Hay que eliminar el envío de 120 minutos antes de entrenar: como está muy lejos del resto de los valores, es un dato atípico que distorsiona la pérdida, y todo valor tan alejado conviene tratarlo como error de carga.

D. MSE es siempre preferible: al penalizar más fuerte los errores grandes obliga al modelo a no equivocarse en los casos extremos, que son justo los más costosos, y eso lo vuelve la mejor pérdida en cualquier escenario.

Ejercicio 7

Se clasifica un nuevo envío con distancia_km = 6 y pendientes = 12 usando KNN con distancia euclídea sobre esas dos variables. Las distancias euclídeas al nuevo punto son: envío 1 ≈ 2,24; envío 2 ≈ 2,24; envío 3 = 4,00; envío 4 ≈ 8,25; envío 5 ≈ 3,16. ¿Qué predice el modelo con k = 1 y con k = 3?

Envío	distancia_km	Pendientes	Clase
1	5	10	Demora
2	7	14	Demora
3	6	8	A tiempo
4	4	20	A tiempo
5	9	13	A tiempo

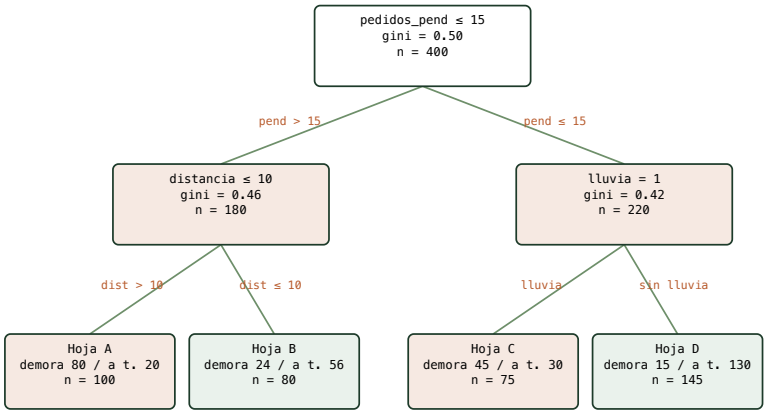
A. k = 1 → a tiempo; k = 3 → a tiempo: el envío 3 (a tiempo) está a distancia 4,00, muy cerca del punto nuevo, y su clase arrastra la predicción tanto con un vecino como con tres.

B. k = 1 → demora; k = 3 → a tiempo, porque en total la tabla tiene 3 envíos “a tiempo” y solo 2 “demora”, así que al ampliar la vecindad la clase mayoritaria del conjunto termina imponiéndose.

C. k = 1 → demora (vecino más cercano, envío 1 o 2); k = 3 → demora (2 demora vs 1 a tiempo entre los envíos 1, 2 y 5).

D. No se puede predecir con k = 1: hay un empate exacto en 2,24 entre los envíos 1 y 2, y KNN no sabe cuál vecino elegir, por lo que hay que subir a k = 2 para desempatar antes de clasificar.

Ejercicio 8



El siguiente árbol ya entrenado predice riesgo de demora; cada hoja predice la clase mayoritaria. Recorré el árbol para los tres pedidos y elegí la clasificación correcta.

Pedido	Pendientes	Distancia	Lluvia
P1	22	7 km	Sí
P2	10	15 km	Sí
P3	30	12 km	No

A. P1: a tiempo (70%); P2: demora (60%); P3: demora (80%).

B. P1: demora (80%); P2: a tiempo (87%); P3: a tiempo (70%).

C. P1: a tiempo (70%); P2: a tiempo (60%); P3: demora (80%).

D. Los tres dan demora, porque todos tocan al menos una condición de riesgo.

Ejercicio 9

Sobre 3.000 pedidos (300 con demora real), el equipo solo puede intervenir 150 pedidos por día. Se comparan dos modelos con umbral 0,50. ¿Cuál es la decisión metodológicamente correcta?

Modelo	Selecc. @0,50	TP	FP	AUC
Reg. logística	150	120	30	0,86
Árbol	250	150	100	0,91

A. Elegir la logística: con umbral 0,50 ya selecciona exactamente 150 pedidos, que coincide con la capacidad diaria, así que es el único modelo que calza con la restricción sin necesidad de tocar nada.

B. Elegir el árbol: su AUC (0,91) supera al de la logística (0,86) y, como el AUC resume el desempeño en todos los umbrales posibles, garantiza que también será el mejor bajo la restricción de intervenir solo 150.

C. Mantener el umbral 0,50 en ambos y descartar el árbol: al seleccionar 250 pedidos viola la capacidad de 150, y un modelo que propone más intervenciones de las que se pueden hacer no es utilizable en operaciones.

D. Fijar la restricción operativa (top-150) y comparar ambos ajustando el umbral para seleccionar 150: recién ahí se ve cuál captura más demoras reales dentro de la capacidad. El AUC ordena en general, pero no decide a un presupuesto fijo.

Ejercicio 10

Para el nodo raíz (6 “Sí” y 6 “No”, Gini = 0,50) se evalúan dos cortes: edad ≤ 30 (izq: 5 Sí/1 No; der: 1 Sí/5 No) y ingreso = Alto (Alto: 2 Sí/3 No; Bajo: 4 Sí/3 No). ¿Cuál conviene y por qué?

Cliente	Edad	Ingreso	Compra
1	22	Bajo	Sí
2	25	Bajo	Sí
3	28	Alto	Sí
4	29	Bajo	Sí
5	30	Alto	Sí
6	35	Bajo	No
7	40	Alto	No
8	45	Bajo	No
9	50	Alto	No
10	55	Bajo	Sí
11	60	Alto	No
12	65	Bajo	No

A. Ingreso = Alto: al ser una variable categórica define grupos naturales y limpios, y las categóricas siempre separan mejor que las continuas como la edad, que hay que cortar en un umbral arbitrario.

B. Edad ≤ 30: su Gini ponderado es 0,278, muy por debajo del de ingreso (≈ 0,486) y del nodo raíz (0,50); es el corte que más reduce la impureza.

C. Edad ≤ 30: es el mejor corte, pero solo porque deja el mismo Gini que la raíz (0,50) y así conserva el balance de clases, que es lo que un buen nodo debe mantener antes de seguir dividiendo.

D. Ninguno de los dos sirve: como el cliente 10 tiene 55 años y sin embargo compra, la edad no ordena bien a los clientes, y con un contraejemplo así ningún corte por edad puede reducir la impureza.

Ejercicio 11

En una regresión logística de churn, el coeficiente de la variable “reclamo sin resolver” (binaria) es 1,1. ¿Cuál es la interpretación correcta? ($e^{1,1} \approx 3,0$)

A. Tener un reclamo sin resolver multiplica los *odds* de churn por ≈ 3, manteniendo todo lo demás constante; el efecto sobre la probabilidad depende del punto de partida.

B. Tener un reclamo sin resolver aumenta la probabilidad de churn en 1,1, es decir 110 puntos porcentuales, porque en la logística cada coeficiente se suma directamente a la probabilidad de la clase positiva.

C. El coeficiente 1,1 indica que el 110% de los clientes con un reclamo sin resolver terminan haciendo churn, ya que el valor del coeficiente se lee como la tasa de eventos dentro de ese grupo.

D. Como el coeficiente 1,1 es mayor que 1, la variable satura el sigmoide y deja de aportar información útil, por lo que conviene eliminarla del modelo para que los coeficientes queden acotados entre 0 y 1.

Ejercicio 12

Dos árboles sobre los mismos datos. ¿Qué diagnóstico y qué acción son correctos?

Modelo	MAE train	MAE val
A (árbol prof. 2)	7,9	8,1
B (árbol sin límite)	0,8	9,5

A. B es mejor: su MAE de entrenamiento (0,8) es muchísimo menor que el de A (7,9), lo que muestra que aprendió la relación con gran precisión, y ese ajuste fino termina trasladándose también a datos nuevos.

B. Ambos rinden parecido: como los dos son árboles de decisión, la diferencia entre 0,8 y 9,5 en validación se explica por el azar de la partición train–val, no por sobreajuste, así que se puede elegir cualquiera.

C. B sobreajusta (brecha train–val enorme: 0,8 vs 9,5) y A subajusta un poco pero generaliza mejor (8,1). Conviene regularizar B (limitar profundidad / min. muestras por hoja o podar) y comparar por validación.

D. A sobreajusta: su error de entrenamiento (7,9) es más alto que el de B (0,8), y un error de entrenamiento alto es la señal clásica de que un modelo memorizó demasiado el conjunto de train y no generaliza.

Ejercicio 13

Un árbol de regresión busca el corte de m² que más reduce la varianza del precio (varianza del nodo raíz $\approx$ 106,8). Se comparan dos cortes: corte 1 separa {10, 12, 14} de {30, 32, 35}; corte 2 separa {10, 12, 14, 30} de {32, 35}. Calculá la varianza ponderada de cada uno y elegí. ¿Qué se concluye?

m²	40	45	50	90	95	100
Precio (miles)	10	12	14	30	32	35

A. Gana el corte 2: deja 4 observaciones en la primera hoja frente a 3 del corte 1, y una hoja con más datos estima su media con menor varianza, por lo que la partición más poblada reduce mejor la impureza total.

B. Son equivalentes: como ambos cortes parten los mismos seis precios en dos grupos, la varianza ponderada da igual en los dos casos y cualquiera reduce la impureza del nodo raíz en la misma cantidad.

C. Ninguno de los dos sirve: con tan pocas observaciones cualquier partición sobreajusta, así que conviene no dividir y usar la media global (22,17) como única predicción para todos los departamentos.

D. Gana el corte 1: varianza ponderada $\approx$ 3,44 (reducción $\approx$ 103), muy por debajo del corte 2 ($\approx$ 42,6), porque agrupa los departamentos por tamaño y deja cada hoja homogénea; el corte 2 mezcla un grande con los chicos.

Ejercicio 14

Un banco usa KNN sobre edad (años, ~20–70) e ingreso (pesos, ~20.000–200.000) sin estandarizar. Para un cliente de 30 años e ingreso 50.000, el "vecino más cercano" resulta ser alguien de 55 años con ingreso 50.100 (distancia ≈ 103), por encima de otro de 31 años con ingreso 90.000 (distancia ≈ 40.000). ¿Qué está ocurriendo y cómo se corrige?

A. El ingreso, por tener una escala mucho mayor, domina la distancia y vuelve irrelevante a la edad. En KNN hay que estandarizar (o normalizar) las variables antes de medir distancias para que todas pesen de forma comparable.

B. Es correcto: el vecino de 55 años tiene un ingreso casi idéntico (50.100 vs 50.000), y como el ingreso es la variable económicamente más relevante, es razonable que KNN lo considere efectivamente el cliente más parecido.

C. El problema se corrige aumentando k: al promediar más vecinos, las diferencias de escala entre edad e ingreso se compensan solas, porque la escala de las variables no influye en cómo KNN mide la distancia.

D. Hay que eliminar la variable edad: como su rango (20–70) es tan chico frente al del ingreso, casi no aporta a la distancia y solo agrega ruido, así que sacándola el vecino más cercano pasa a ser el correcto.

Ejercicio 15

Un hospital usa un modelo para decidir a qué pacientes hacerles un estudio adicional barato. No detectar un caso grave (falso negativo) es muchísimo más costoso que un estudio de más (falso positivo). ¿Qué métrica debería priorizar al elegir el umbral?

A. La precisión: al maximizarla se asegura que casi todos los pacientes marcados sean realmente graves, evitando estudios de más, que es el error que más conviene contener cuando los recursos del hospital son limitados.

B. El recall (sensibilidad), para minimizar los falsos negativos, aun a costa de más falsos positivos; el umbral se baja para capturar más casos positivos.

C. El accuracy: al resumir en un solo número todos los aciertos sobre casos graves y no graves, pondera ambos tipos de error a la vez y da la visión más completa para fijar el umbral en un problema clínico.

D. Ninguna métrica hace falta: como el estudio adicional es barato, lo eficiente es aplicarlo a todos los pacientes por igual y así ningún caso grave queda sin detectar, sin depender de umbrales ni de un modelo.

Ejercicio 16

Un modelo estima la duración de una ruta como
tiempo = 45 − 5·ruta_expres − 0,3·(velocidad_promedio − 40),
con ruta_expres binaria y la velocidad en km/h. Para una ruta expres con velocidad promedio de 60 km/h, ¿cuál es la predicción?

A. 45 minutos.

B. 40 minutos.

C. 28 minutos.

D. 34 minutos.

Ejercicio 17

Un equipo estandariza todas las variables (media 0, desvío 1) "para que el modelo funcione mejor" y luego entrena un árbol de decisión. ¿Qué es correcto afirmar?

A. Escalar es imprescindible; sin eso, la variable de mayor magnitud domina las divisiones del árbol.
B. Escalar mejora el árbol porque reduce la varianza de cada hoja terminal.
C. El escalado no cambia el árbol: las divisiones dependen del orden de los valores, no de su magnitud.
D. Escalar convierte el árbol en un modelo lineal y cambia por completo el resultado.

Ejercicio 18

Se evalúa un modelo con validación cruzada de 5 folds y se obtienen estos MAE por fold: 6,1 · 6,4 · 5,9 · 11,8 · 6,0. ¿Cuál es la lectura más adecuada?

A. El promedio (≈ 7,2) es la estimación del error, pero un fold se dispara (11,8 frente a ~6 en los otros cuatro): antes de confiar en el número conviene investigar ese fold (partición atípica, fuga o subgrupo difícil), porque la alta dispersión indica que el desempeño no es estable.
B. El error estimado es ≈ 6,1: el fold de 11,8 se aleja demasiado del resto, así que es un valor atípico que conviene descartar antes de promediar para que la estimación no quede contaminada por una partición defectuosa.
C. Hay que quedarse con el mejor fold (5,9) como estimación del error: representa el escenario en que el modelo rinde mejor y, al usar la partición más favorable, da la cota más limpia de lo que el modelo puede lograr.
D. El MAE válido es el del último fold (6,0): al recorrer los folds en orden, el último incorpora el modelo ya más ajustado, por lo que su error es el más representativo del desempeño final del entrenamiento.

Ejercicio 19

Para predecir antes de salir si un pedido llegará tarde, un analista arma el modelo y obtiene 99% de accuracy en validación. Entre las variables figura "cantidad de llamados del cliente reclamando por el pedido". En validación funciona genial, pero en producción el desempeño se desploma. ¿Cuál es la causa más probable?

A. El modelo simplemente sobreajustó al conjunto de validación: la variable de reclamos está bien, y con más árboles o mayor regularización se controla la varianza y el 99% se sostendrá también en producción.
B. Fuga de datos (leakage): los reclamos ocurren *durante o después* del envío, sobre todo cuando ya viene demorado, así que esa variable no está disponible en el momento de predecir (antes de salir) y arrastra información del resultado. Hay que excluir toda variable posterior al instante de la predicción.
C. El 99% en validación es una medición confiable que garantiza que el modelo es correcto; la caída en producción se debe al azar del período de despliegue y debería revertirse sola al acumular más pedidos.
D. Faltan variables predictoras: un modelo con tan pocas features es inestable, así que habría que sumar más atributos del pedido y del cliente para que el desempeño de validación se mantenga al pasar a producción.

Ejercicio 20

Un modelo de riesgo devuelve, para un cliente, $p = 0{,}40$. El área de cobranzas decide intervenir a todos los clientes con $p \geq 0{,}30$ porque el costo de perder al cliente es muy alto. ¿Qué clasificación corresponde y qué implica mover el umbral?

A. "No interviene": como $p = 0{,}40 < 0{,}50$, no supera el umbral estándar de clasificación, que es el corte válido por defecto y el único que corresponde aplicar salvo que el modelo se haya calibrado para otro valor.

B. El caso es ambiguo: $p = 0{,}40$ cae entre el umbral que fija cobranzas (0,30) y el estándar (0,50), zona en la que el modelo no puede decidir con confianza, por lo que conviene marcarlo como indeterminado y revisarlo a mano.

C. "Interviene": con umbral 0,30, como $0{,}40 \geq 0{,}30$ el caso es positivo. Bajar el umbral aumenta el recall a costa de más falsos positivos; no cambia el modelo entrenado, solo la regla de decisión.

D. Cambiar el umbral a 0,30 obliga a reentrenar el modelo desde cero: como el umbral forma parte de lo que se aprende durante el ajuste, moverlo cambia los pesos y exige volver a estimar el modelo con el nuevo corte.

Ejercicio 21

En KNN, un equipo prueba $k = 1$ y obtiene 100% de accuracy en entrenamiento pero mucho peor en validación; con $k = N$ (todos los puntos) el modelo predice siempre la clase mayoritaria. ¿Qué afirmación describe correctamente el rol de k?

A. Conviene siempre $k = 1$: al lograr accuracy perfecto en entrenamiento demuestra que aprendió todos los patrones sin error, y ese ajuste máximo sobre los datos es la mejor garantía de acierto también en validación.

B. El valor de k no afecta el resultado del modelo, solo la velocidad de cómputo: como KNN siempre mira a los mismos vecinos ordenados por distancia, cambiar k apenas modifica cuántos se recorren, no la clase predicha.

C. Un k grande siempre generaliza mejor que uno chico: al promediar más vecinos usa más información del conjunto y reduce el error, por eso conviene tomar k lo más grande posible hasta el total de puntos.

D. k chico → alta varianza (sobreajuste); k grande → alto sesgo (subajuste): se elige un k intermedio por validación (y k impar en binaria, para evitar empates).

Ejercicio 22

Dos hojas terminales de un clasificador: Hoja X con 63 positivos y 27 negativos; Hoja Y con 15 positivos y 45 negativos. ¿Qué afirmación es correcta?

A. Hoja X: predice positivo con 70% (Gini 0,42). Hoja Y: predice negativo con 75% (Gini 0,375). La hoja Y es un poco más pura.

B. Ambas hojas son igual de puras: la X tiene 90 casos y la Y tiene 60, y como la pureza de una hoja depende de cuántas observaciones agrupa, tener más casos no la hace ni más ni menos pura que la otra.

C. Hoja X predice positivo con 63% y Hoja Y predice positivo con 25%: la probabilidad de la hoja es directamente el conteo de la clase positiva (63 y 15) leído como porcentaje sobre 100, sin dividir por el total de la hoja.

D. El Gini de Y (60 casos) es mayor que el de X (90 casos) porque tiene menos observaciones: con menos datos la hoja queda más impura, ya que el Gini crece a medida que baja la cantidad de casos que sostienen la predicción.

Ejercicio 23

Una regresión lineal para predecir el precio tiene R^2 de 0,35 en entrenamiento y 0,34 en validación, y los residuos muestran una clara forma de U (curva). ¿Qué conviene hacer primero?

A. Regularizar con Lasso para reducir variables: el R^2 tan bajo indica que el modelo está sobreajustando ruido, y penalizar los coeficientes lo simplifica y sube el desempeño en validación acercándolo al de entrenamiento.

B. El modelo subajusta (error alto y parejo en train y val, con patrón no capturado en los residuos): conviene aumentar la capacidad —agregar términos no lineales/polinómicos o interacciones, o pasar a un modelo más flexible— antes que regularizar.

C. Bajar el umbral de decisión para mejorar el recall: al capturar más casos positivos se corrige el error, ya que un R^2 bajo suele deberse a un umbral mal fijado que descarta observaciones que el modelo sí explica.

D. Recolectar más filas: con un R^2 de apenas 0,35 el modelo se quedó corto de datos, y al aumentar el tamaño de la muestra la relación se estima con más precisión y el R^2 sube solo hacia valores aceptables.

Ejercicio 24

Se debe elegir un modelo para producción. El negocio exige poder explicar cada decisión a un cliente, operar con una capacidad fija de intervenciones y que el desempeño sea estable. Considerando la tabla, ¿cuál es la elección más defendible?

Modelo	AUC val	Recall @cap.	Interpretable	Estable en CV
Reg. logística	0,86	0,73	Sí (coef.)	Sí
Árbol podado	0,84	0,65	Sí (reglas)	Parcial (varía por fold)
Árbol sin podar	0,88	0,68	No	No (varía por fold)

A. El árbol sin podar: con el mayor AUC (0,88) es el que mejor ordena los casos por riesgo, y como el AUC es la métrica que resume el desempeño global, domina a los demás sin importar los otros criterios del negocio.

B. Cualquiera de los tres sirve: sus AUC (0,88 · 0,84 · 0,86) son parecidos, así que rinden casi igual y la elección se puede resolver por preferencia del equipo sin costo real de desempeño para el negocio.

C. La regresión logística: el mejor recall a capacidad (0,73), interpretable y estable en CV; domina al árbol podado en toda métrica, y su leve desventaja de AUC frente al árbol sin podar no compensa perder explicabilidad y estabilidad, que el negocio exige.

D. El árbol sin podar por su AUC (0,88), y para cumplir el requisito de explicar cada decisión al cliente alcanza con mostrarle ese AUC alto como evidencia de que el modelo acierta, sin necesidad de reglas legibles.

Soluciones

Ejercicio 1 – B El monto es una cantidad continua → **regresión**. La recompra es un evento binario → **clasificación**; como el presupuesto es fijo (500 clientes), no se usa el corte 0,50 sino que se **rankea por probabilidad** y se toman los 500 primeros (precisión a capacidad). Decir que ambos son regresión confunde el insumo (datos numéricos) con el tipo de target; invertir los problemas ignora que el monto es continuo y la recompra binaria; y ordenar por gasto histórico no modela la probabilidad de recompra.

Ejercicio 2 – D $8 + 0{,}9 \cdot 15 + 4 \cdot 1 + 6 \cdot 0 + 2 \cdot 3 = 8 + 13{,}5 + 4 + 0 + 6 = \mathbf{31{,}5}$. El distractor de 37,5 suma la lluvia (que acá vale 0); 25,5 olvida el término de paradas; 27,5 cuenta una sola parada en vez de multiplicar por 3.

Ejercicio 3 – A Con 950 negativos, predecir siempre "no fraude" ya da 95% de accuracy — más que el modelo. Por eso el accuracy engaña con desbalance. Precisión $= 40/(40+60) = \mathbf{0{,}40}$; recall $= 40/(40+10) = \mathbf{0{,}80}$. La decisión depende del costo relativo de FP y FN. Cuidado con el distractor que dice que "deja pasar el 80%": recall 0,80 significa que *captura* el 80% de los fraudes, no lo contrario.

Ejercicio 4 – C Lasso: mejor MAE de validación (6,0), apenas por debajo de Ridge (6,1), pero además hace **selección de variables** (120 → 22), que es justo lo que pide el negocio. La polinómica tiene R^2 train 0,99 pero MAE val 13,2 → sobreajuste clásico. "Ridge siempre generaliza mejor" y "menos variables evita todo sobreajuste" son falsos como reglas absolutas.

Ejercicio 5 – D $z = -1 + 0{,}05 \cdot 20 + 0{,}9 \cdot 0 + 0{,}7 \cdot 1 + 0{,}04 \cdot 25 = -1 + 1 + 0 + 0{,}7 + 1 = \mathbf{1{,}7}$. $p = 1/(1 + e^{-1{,}7}) = 1/(1 + 0{,}183) \approx \mathbf{0{,}85} \geq 0{,}50$ → **demora**. El distractor con $p \approx 0{,}15$ invierte el sigmoide (0,15 corresponde a $z = -1{,}7$, no a $z = +1{,}7$); el de $z = 0{,}30$ calcula mal el puntaje.

Ejercicio 6 – B MAE $= (2+1+2+80)/4 = \mathbf{21{,}25}$; MSE $= (4+1+4+6.400)/4 = \mathbf{1.602{,}25}$. El caso de 120 aporta $80^2 = 6.400$ al MSE: lo domina. Si esas demoras extremas son **reales**, no se eliminan (eso es A, incorrecta eliminar datos reales); MAE es más robusto a su influencia, pero la decisión final se toma comparando por validación. "MSE siempre es preferible" convierte una preferencia en regla universal.

Ejercicio 7 – C Ordenando por distancia euclídea: envío 1 (2,24), envío 2 (2,24), envío 5 (3,16), envío 3 (4,00), envío 4 (8,25). Con **k = 1** gana el vecino más cercano (envío 1 o 2, ambos a 2,24) → **demora**. Con **k = 3** los tres vecinos más cercanos son los envíos 1 (demora), 2 (demora) y 5 (a tiempo) → voto 2 a 1 → **demora**. La trampa es el distractor que cuenta "3 a tiempo en total": KNN mira solo los k vecinos más próximos, no toda la tabla; el empate en 2,24 no impide clasificar, ambos vecinos son de la misma clase.

Ejercicio 8 – A Recorrido: **P1** (pend 22 > 15 → izq; dist 7 ≤ 10 → Hoja B): 24 demora / 56 a tiempo → **a tiempo, 70%**. **P2** (pend 10 ≤ 15 → der; lluvia Sí → Hoja C): 45/30 → **demora, 60%**. **P3** (pend 30 > 15 → izq; dist 12 > 10 → Hoja A): 80/20 → **demora, 80%**. La clave es leer bien la condición de cada nodo; el distractor de "los tres dan demora" razona por "tocar una condición de riesgo", que no es cómo se recorre un árbol.

Ejercicio 9 – D Con capacidad fija de 150, la comparación honesta es **a igual cantidad de seleccionados**: se ajusta el umbral de cada modelo para que seleccione 150 y se ve cuál mete más TP ahí adentro. El AUC resume el ranking global pero no garantiza el mejor desempeño a un presupuesto puntual; elegir por el umbral por defecto (0,50) es arbitrario; y descartar un modelo por "seleccionar más de 150" ignora que eso se corrige moviendo el umbral.

Ejercicio 10 – B Gini(edad ≤ 30): izq (5 Sí/1 No) = $1 - (5/6)^2 - (1/6)^2 = 0{,}278$; der (1 Sí/5 No) = 0,278; ponderado = $(6/12)\cdot 0{,}278 + (6/12)\cdot 0{,}278 =$ **0,278**. Gini(ingreso): Alto (2/3) = 0,48, Bajo (4/3) = 0,490; ponderado ≈ **0,486**. Edad reduce mucho más la impureza (0,278 < 0,486 < 0,50). Que "las categóricas siempre separan mejor" es un mito; edad no "deja el mismo Gini que la raíz" (baja de 0,50 a 0,278); y sí separa, pese al cliente de 55 años que compra.

Ejercicio 11 – A En logística los coeficientes son aditivos **en el log-odds**: un coeficiente de 1,1 multiplica los *odds* por $e^{1,1} \approx 3{,}0$. El efecto sobre la **probabilidad** no es constante: depende del punto de partida por la forma del sigmoide. Leerlo como "+110 puntos de probabilidad" confunde log-odds con probabilidad; "el 110% de los clientes" y "eliminar la variable porque 1,1 > 1" no tienen sentido.

Ejercicio 12 – C Diagnóstico por la brecha train–val: B tiene 0,8 vs 9,5 → **sobreajuste** severo (memoriza el entrenamiento). A tiene 7,9 vs 8,1 → generaliza, con leve subajuste. Acción: regularizar B (profundidad, min. muestras por hoja, poda) y comparar por validación. Un menor error de entrenamiento no es, por sí solo, señal de mejor modelo.

Ejercicio 13 – D **Corte 1**: izq {10,12,14} media 12, var (4+0+4)/3 = 2,67; der {30,32,35} media 32,33, var 4,22; ponderada = $(3/6)\cdot 2{,}67 + (3/6)\cdot 4{,}22 =$ **3,44** (reducción ≈ 103,4). **Corte 2**: izq {10,12,14,30} media 16,5, var 62,75; der {32,35} media 33,5, var 2,25; ponderada = $(4/6)\cdot 62{,}75 + (2/6)\cdot 2{,}25 =$ **42,6**. El corte 1 reduce muchísimo más la varianza porque separa limpio por tamaño; el corte 2 arrastra el departamento de 30 (grande) hacia el grupo de los chicos y ensucia esa hoja. Usar la media global sería no dividir.

Ejercicio 14 – A El ingreso va en decenas de miles y la edad en decenas: sin estandarizar, la distancia euclídea queda **gobernada por el ingreso** (una diferencia de 40.000 pesos pesa infinitamente más que 25 años). Por eso un vecino con edad muy distinta pero ingreso casi igual aparece "más cerca". La solución es **estandarizar / normalizar** antes de calcular distancias. Subir k no corrige el problema de escala; eliminar la edad descarta información útil.

Ejercicio 15 – B Cuando el falso negativo es mucho más costoso que el falso positivo, se prioriza el **recall** y se **baja el umbral** para capturar más positivos, aceptando más FP (estudios de más, que son baratos). Priorizar la precisión minimizaría FP, justo lo contrario de lo que conviene acá. El accuracy esconde el desbalance de costos.

Ejercicio 16 – D $45 - 5\cdot 1 - 0{,}3\cdot(60 - 40) = 45 - 5 - 0{,}3\cdot 20 = 45 - 5 - 6 =$ **34**. El error típico es olvidar el "−40" y hacer $0{,}3\cdot 60 = 18$ (da 22) o ignorar el término de velocidad (da 40).

Ejercicio 17 – C Los árboles parten por umbrales sobre una variable a la vez; solo importa el **orden** de los valores, invariante ante estandarización → el árbol resultante es idéntico. No hace daño pero no aporta. Sí importaría en modelos con distancias (KNN) o con penalización sobre la escala de los coeficientes (Ridge/Lasso). Los otros distractores atribuyen al escalado efectos que no tiene en árboles.

Ejercicio 18 – A El promedio es $(6{,}1+6{,}4+5{,}9+11{,}8+6{,}0)/5 = \mathbf{7{,}24}$, y ese es el estimador de generalización por CV. Pero el valor está inflado por un **único fold anómalo** (11,8) mientras los otros cuatro rondan 6: la gran dispersión es la señal importante. No se descarta el fold "porque sí" (eso sería hacer trampa: podría revelar una partición con un subgrupo difícil o una fuga); primero se investiga. Quedarse con el mejor fold es optimista y sesgado; "el último" no tiene sentido, los folds no tienen orden temporal.

Ejercicio 19 – B Los reclamos del cliente aparecen **mientras el pedido ya está demorado**, es decir, son posteriores (o simultáneos) al resultado que se quiere predecir *antes* de salir. Incluirlos es **fuga de datos**: el modelo "ve" una consecuencia de la demora, por eso da 99% en validación (donde el dato está completo) y se derrumba en producción (donde, al momento de predecir, todavía no hubo reclamos). Regla: excluir toda variable que no esté disponible en el instante exacto de la predicción. Más datos o más regularización no arreglan un problema de *qué* variable se usa, no de *cuántas*.

Ejercicio 20 – C Con umbral 0,30, la regla es "positivo si $p \geq 0{,}30$"; como $0{,}40 \geq 0{,}30 \rightarrow$ **interviene**. Mover el umbral **no reentrena** nada: solo cambia la regla de decisión sobre las mismas probabilidades. Bajarlo sube el recall y, en general, aumenta los falsos positivos (baja la precisión). Aplicar 0,50 a ciegas ignora la decisión de negocio, y no hay "zona ambigua": la regla es un simple $\geq$.

Ejercicio 21 – D k controla el equilibrio sesgo–varianza en KNN. **k = 1** siempre acierta en entrenamiento (el vecino más cercano es el propio punto) pero sobreajusta: frontera irregular, alta varianza. **k = N** colapsa a "predecir siempre la mayoría": máximo sesgo, subajuste. El k óptimo es intermedio y se elige por validación; en binaria se prefiere k impar para evitar empates. Los otros distractores (k = 1 siempre, k indiferente, k grande siempre mejor) son afirmaciones falsas sobre el rol de k.

Ejercicio 22 – A Hoja X: mayoría positivo, prob = 63/90 = **0,70**; Gini $= 1 - 0{,}7^2 - 0{,}3^2 =$ **0,42**. Hoja Y: mayoría negativo, prob = 45/60 = **0,75**; Gini $= 1 - 0{,}25^2 - 0{,}75^2 =$ **0,375**. Menor Gini = más pura → Y es algo más pura. El distractor que da "63% y 25%" reporta la proporción de la clase minoritaria como si fuera la predicción de la hoja.

Ejercicio 23 – B Error alto y **parejo** en train y val (0,35 vs 0,34) + residuos con patrón (forma de U) = **subajuste**: el modelo lineal no captura la relación. La acción es **aumentar capacidad** (términos polinómicos, interacciones, modelo más flexible). Regularizar empeora un modelo que ya es demasiado simple; el umbral no aplica a regresión; y más datos no arreglan un sesgo de especificación.

Ejercicio 24 – C El negocio fija tres criterios duros: explicabilidad, operar a capacidad y estabilidad. La logística los cumple los tres y además tiene el **mejor recall a capacidad** (0,73). Frente al **árbol podado** —su competidor más cercano— lo domina en todo (AUC 0,86 vs 0,84; recall 0,73 vs 0,65; y el podado solo es "parcialmente" estable). El **árbol sin podar** tiene el AUC más alto (0,88) pero es el peor a capacidad (0,68), no es interpretable y no es estable: elegir por AUC solo ignora las tres restricciones duras.