

Guía de Ejercicios Boosting

Analítica de Datos, Universidad de San Andrés

Si encuentran algún error en el documento o hay alguna duda, mandenme un mail a rodriguezf@udesa.edu.ar y lo revisamos.

1. Ejercicios

1.1. Ejercicio 1


¿De qué manera son entrenados los clasificadores débiles en este tipo de modelos? ¿Por qué?

1.2. Ejercicio 2


Considerando el siguiente conjunto de datos de entrenamiento y los clasificadores débiles entrenados en las dos primeras iteraciones de un algoritmo de AdaBoost.M1, indicar el error de clasificación del clasificador, el peso del clasificador y los pesos de cada una de las observaciones para cada una de las dos iteraciones.

X_1	X_2	X_3	Y	w_0	pred 1	w_1	pred 2	w_2
0.1	1.2	3.1	1					
1	0.5	2.3	1					
0.3	1	1.8	-1					
2	1.5	0.7	-1					
1.5	2	1	1					
2.3	0.3	1.1	1					
1.8	1.8	2.2	-1					
0.5	1.1	0.9	-1					
2.2	1.4	1.5	1					
0.6	0.9	2	-1					

Stump - Iteración 1




Stump - Iteración 2




1.3. Ejercicio 3

Clasificar a las observaciones 1, 2 y 3 teniendo en cuenta el modelo de AdaBoost.M1 expuesto a continuación. ¿Por qué es importante para un modelo AdaBoost.M1 de clasificación binario que las etiquetas sean -1 y 1?


Stump - Iteración 1



Stump - Iteración 2



Stump - Iteración 3



Parámetro	Valor
α_1	1.0986
α_2	1.0397
α_3	1.1343

Obs	X_1	X_2	X_3
1	1	1.8	3
2	0.9	0.7	1.9
3	1.5	1.2	1.1

1.4. Ejercicio 4


¿Qué efecto tiene el learning rate sobre cada uno de los clasificadores en un modelo AdaBoost.M1?

1.5. Ejercicio 5


Clasificar a las observaciones A, B y C con el siguiente modelo de XGBoost.

Obs	f0	f1	f2	f3	f4
A	0.3	-0.1	0.9	-0.7	0.2
B	-1	-0.5	1	0	0.3
C	2	1.5	-1	0.3	-0.7


Árbol 1



Árbol 2



Árbol 3



1.6. Ejercicio 6

¿Cómo se elige la cantidad de árboles en modelos de boosting? ¿De qué parámetro depende?

1.7. Ejercicio 7

Una academia de cursos online quiere predecir si una persona se inscribirá ($y=1$) o no ($y=0$) a un curso corto a partir de las siguientes 3 variables:

- Tiene Beca: Si / No.

- Turno: Mañana / Tarde.
- Canal: Referido / Web / Redes.

Usar el siguiente dataset para entrenar y testear un modelo XGBoost con los siguientes hiperparámetros:

- $\text{max_depth} = 2$
- $\lambda = \alpha = \gamma = 0$
- $\text{n_estimators} = 3$
- $\text{subsample} = 0.8$
- $\text{learning_rate } \eta = 0.3$
- $\text{colsample_bytree} = 0.66$

Train

id	Beca	Turno	Canal	y
1	Si	M	Ref	1
2	No	T	Web	0
3	Si	M	Ref	1
4	No	T	Red	0
7	Si	T	Ref	1
8	No	M	Red	0
9	Si	M	Ref	1

Test

id	Beca	Turno	Canal	y
5	Si	M	Ref	1
6	No	M	Web	0
10	No	T	Web	0

Para cada iteración mostrar los cálculos de gradientes, hessianos, ganancia de los splits y peso de cada hoja, actualización de predicciones y probabilidades. Usar el dataset de test para reportar accuracy y la pérdida del modelo (log-loss).

2. Soluciones

2.1. Ejercicio 1

Los clasificadores debiles en modelos de boosting son entrenados de manera secuencial, donde cada nuevo clasificador se enfoca en corregir los errores cometidos por los clasificadores anteriores. Esto se logra mediante el ajuste de los pesos de las observaciones: aquellas que fueron mal clasificadas reciben mayor peso en la siguiente iteracion, forzando al nuevo clasificador a prestarles mas atencion. De esta manera, el modelo aprende iterativamente enfocandose en los casos mas dificiles.

2.2. Ejercicio 2

Primero calculamos los pesos iniciales (todos iguales): $w_0 = \frac{1}{10} = 0,1$ para cada observacion.

Iteracion 1

El stump divide segun $X_3 \leq 2,1$:

- Nodo izquierdo (True): predice clase -1
- Nodo derecho (False): predice clase +1

Predicciones para cada observacion:

- Obs 1: $X_3 = 3,1 > 2,1 \rightarrow \text{pred} = +1$ (real = +1) ✓
- Obs 2: $X_3 = 2,3 > 2,1 \rightarrow \text{pred} = +1$ (real = +1) ✓
- Obs 3: $X_3 = 1,8 \leq 2,1 \rightarrow \text{pred} = -1$ (real = -1) ✓
- Obs 4: $X_3 = 0,7 \leq 2,1 \rightarrow \text{pred} = -1$ (real = -1) ✓
- Obs 5: $X_3 = 1 \leq 2,1 \rightarrow \text{pred} = -1$ (real = +1) ×
- Obs 6: $X_3 = 1,1 \leq 2,1 \rightarrow \text{pred} = -1$ (real = +1) ×
- Obs 7: $X_3 = 2,2 > 2,1 \rightarrow \text{pred} = +1$ (real = -1) ×
- Obs 8: $X_3 = 0,9 \leq 2,1 \rightarrow \text{pred} = -1$ (real = -1) ✓

- Obs 9: $X_3 = 1,5 \leq 2,1 \rightarrow \text{pred} = -1$ (real = +1) $\times$
- Obs 10: $X_3 = 2 \leq 2,1 \rightarrow \text{pred} = -1$ (real = -1) $\checkmark$

Error del clasificador: $\varepsilon_1 = \sum_{i:\text{error}} w_i = 0,1 \times 4 = 0,4$

Peso del clasificador: $\alpha_1 = \frac{1}{2} \ln \left(\frac{1-\varepsilon_1}{\varepsilon_1} \right) = \frac{1}{2} \ln \left(\frac{0,6}{0,4} \right) = \frac{1}{2} \ln(1,5) \approx 0,2027$

Actualizacion de pesos:

- Para observaciones correctas: $w_{\text{new}} = w_{\text{old}} \cdot e^{-\alpha_1} = 0,1 \cdot e^{-0,2027} \approx 0,0817$
- Para observaciones incorrectas: $w_{\text{new}} = w_{\text{old}} \cdot e^{\alpha_1} = 0,1 \cdot e^{0,2027} \approx 0,1225$

Normalizando: $Z_1 = 6 \cdot 0,0817 + 4 \cdot 0,1225 = 0,9802$

Iteracion 2

El stump divide segun $X_2 \leq 1,15$ usando los nuevos pesos.

- Obs 1: $X_2 = 1,2 > 1,15 \rightarrow \text{pred} = +1$ (real = +1) $\checkmark$
- Obs 2: $X_2 = 0,5 \leq 1,15 \rightarrow \text{pred} = -1$ (real = +1) $\times$
- Obs 3: $X_2 = 1 \leq 1,15 \rightarrow \text{pred} = -1$ (real = -1) $\checkmark$
- Obs 4: $X_2 = 1,5 > 1,15 \rightarrow \text{pred} = +1$ (real = -1) $\times$
- Obs 5: $X_2 = 2 > 1,15 \rightarrow \text{pred} = +1$ (real = +1) $\checkmark$
- Obs 6: $X_2 = 0,3 \leq 1,15 \rightarrow \text{pred} = -1$ (real = +1) $\times$
- Obs 7: $X_2 = 1,8 > 1,15 \rightarrow \text{pred} = +1$ (real = -1) $\times$
- Obs 8: $X_2 = 1,1 \leq 1,15 \rightarrow \text{pred} = -1$ (real = -1) $\checkmark$
- Obs 9: $X_2 = 1,4 > 1,15 \rightarrow \text{pred} = +1$ (real = +1) $\checkmark$
- Obs 10: $X_2 = 0,9 \leq 1,15 \rightarrow \text{pred} = -1$ (real = -1) $\checkmark$

Error: $\varepsilon_2 = 0,0833 + 0,0833 + 0,1250 + 0,1250 = 0,4167$

$\alpha_2 = \frac{1}{2} \ln \left(\frac{0,5833}{0,4167} \right) \approx 0,1682$

La tabla completa seria:

X_1	X_2	X_3	Y	w_0	pred 1	w_1	pred 2	w_2
0.1	1.2	3.1	1	0.1	+1	0.0833	+1	0.0714
1	0.5	2.3	1	0.1	+1	0.0833	-1	0.1001
0.3	1	1.8	-1	0.1	-1	0.0833	-1	0.0714
2	1.5	0.7	-1	0.1	-1	0.0833	+1	0.1001
1.5	2	1	1	0.1	-1	0.1250	+1	0.1071
2.3	0.3	1.1	1	0.1	-1	0.1250	-1	0.1501
1.8	1.8	2.2	-1	0.1	+1	0.1250	+1	0.1501
0.5	1.1	0.9	-1	0.1	-1	0.0833	-1	0.0714
2.2	1.4	1.5	1	0.1	-1	0.1250	+1	0.1071
0.6	0.9	2	-1	0.1	-1	0.0833	-1	0.0714

2.3. Ejercicio 3

Para clasificar usamos la formula: $H(x) = \text{sign} \left(\sum_{t=1}^3 \alpha_t h_t(x) \right)$

Observacion 1: $X_1 = 1, X_2 = 1,8, X_3 = 3$

- $h_1: X_2 = 1,8 > 1,15 \rightarrow \text{pred} = +1$
- $h_2: X_3 = 3 > 2,1 \rightarrow \text{pred} = +1$
- $h_3: X_1 = 1 \leq 2,25 \rightarrow \text{pred} = +1$

$$f(x_1) = 1,0986(1) + 1,0397(1) + 1,1343(1) = 3,2726 > 0 \rightarrow \text{Clase } +1$$

Observacion 2: $X_1 = 0,9, X_2 = 0,7, X_3 = 1,9$

- $h_1: X_2 = 0,7 \leq 1,15 \rightarrow \text{pred} = -1$
- $h_2: X_3 = 1,9 \leq 2,1 \rightarrow \text{pred} = -1$
- $h_3: X_1 = 0,9 \leq 2,25 \rightarrow \text{pred} = +1$

$$f(x_2) = 1,0986(-1) + 1,0397(-1) + 1,1343(1) = -1,0040 < 0 \rightarrow \text{Clase } -1$$

Observacion 3: $X_1 = 1,5, X_2 = 1,2, X_3 = 1,1$

- $h_1: X_2 = 1,2 > 1,15 \rightarrow \text{pred} = +1$
- $h_2: X_3 = 1,1 \leq 2,1 \rightarrow \text{pred} = -1$

- $h_3: X_1 = 1,5 \leq 2,25 \rightarrow \text{pred} = +1$

$$f(x_3) = 1,0986(1) + 1,0397(-1) + 1,1343(1) = 1,1932 > 0 \rightarrow \text{Clase } +1$$

Es importante que las etiquetas sean -1 y 1 (y no 0 y 1) porque AdaBoost utiliza el producto entre la prediccion y el valor real para determinar si hubo error y para actualizar los pesos. Con etiquetas -1 y +1, cuando $y_i \cdot h(x_i) < 0$ hay error, y cuando $y_i \cdot h(x_i) > 0$ la clasificacion es correcta. Esto simplifica las formulas matematicas del algoritmo.

2.4. Ejercicio 4

El learning rate (o factor de reduccion) ν en AdaBoost multiplica a cada α_t , reduciendo la influencia de cada clasificador individual en el modelo final. Esto hace que el modelo aprenda mas lentamente, requiriendo mas iteraciones para alcanzar el mismo nivel de performance. Un learning rate menor ayuda a reducir el overfitting ya que cada clasificador tiene menos peso, pero requiere entrenar mas clasificadores para lograr buena performance. La formula queda:

$$H(x) = \text{sign} \left(\sum_{t=1}^T \nu \cdot \alpha_t h_t(x) \right)$$

2.5. Ejercicio 5

En XGBoost, las predicciones se obtienen sumando los valores de las hojas de todos los arboles. Partimos de una prediccion inicial de 0 y vamos acumulando.

Observacion A: $f0 = 0,3, f1 = -0,1, f2 = 0,9, f3 = -0,7, f4 = 0,2$

Arbol 1:

- $f0 = 0,3 \geq -0,0626790971$ (False) $\rightarrow$ rama derecha
- $f2 = 0,9 < 1,35387242$ (True) $\rightarrow$ leaf = 1.47733867

Arbol 2:

- $f0 = 0,3 \geq 0,250492841$ (False) $\rightarrow$ rama derecha
- $f1 = -0,1 \geq -0,857157528$ (False) $\rightarrow$ leaf = 1.12084329

Arbol 3:

- $f2 = 0,9 \geq 0,00524369953$ (False) $\rightarrow$ rama derecha
- $f2 = 0,9 \geq 0,473832935$ (False) $\rightarrow$ leaf = 0.120746091

Prediccion: $y_A = 0 + 1,47733867 + 1,12084329 + 0,120746091 = 2,7189$

Probabilidad: $p_A = \frac{1}{1+e^{-2,7189}} = 0,938$

Clasificacion A: Positiva (ya que $y_A > 0$ o $p_A > 0,5$)

Observacion B: $f0 = -1, f1 = -0,5, f2 = 1, f3 = 0, f4 = 0,3$

Arbol 1:

- $f0 = -1 < -0,0626790971$ (True) $\rightarrow$ rama izquierda
- $f1 = -0,5 < 0,955142319$ (True) $\rightarrow$ leaf = -1.6915288

Arbol 2:

- $f0 = -1 < 0,250492841$ (True) $\rightarrow$ rama izquierda
- $f1 = -0,5 < 0,955142319$ (True) $\rightarrow$ leaf = -1.08458626

Arbol 3:

- $f2 = 1 \geq 0,00524369953$ (False) $\rightarrow$ rama derecha
- $f2 = 1 \geq 0,473832935$ (False) $\rightarrow$ leaf = 0.120746091

Prediccion: $y_B = 0 + (-1,6915288) + (-1,08458626) + 0,120746091 = -2,6553$

Probabilidad: $p_B = \frac{1}{1+e^{2,6553}} = 0,065$

Clasificacion B: Negativa

Observacion C: $f0 = 2, f1 = 1,5, f2 = -1, f3 = 0,3, f4 = -0,7$

Arbol 1:

- $f_0 = 2 \geq -0,0626790971$ (False) $\rightarrow$ rama derecha
- $f_2 = -1 < 1,35387242$ (True) $\rightarrow$ leaf = 1.47733867

Arbol 2:

- $f_0 = 2 \geq 0,250492841$ (False) $\rightarrow$ rama derecha
- $f_1 = 1,5 \geq -0,857157528$ (False) $\rightarrow$ leaf = 1.12084329

Arbol 3:

- $f_2 = -1 < 0,00524369953$ (True) $\rightarrow$ rama izquierda
- $f_1 = 1,5 \geq -0,0720101222$ (False) $\rightarrow$ leaf = 0.814428747

Prediccion: $y_C = 0 + 1,47733867 + 1,12084329 + 0,814428747 = 3,4126$

Probabilidad: $p_C = \frac{1}{1+e^{-3,4126}} = 0,968$

Clasificacion C: Positiva

2.6. Ejercicio 6

La cantidad de arboles en modelos de boosting se elige mediante validacion cruzada o usando un conjunto de validacion, monitoreando la metrica de interes (accuracy, AUC, etc.) en datos no vistos. El proceso se detiene cuando el modelo deja de mejorar o comienza a deteriorarse por overfitting (early stopping). Esta cantidad depende principalmente del learning rate: un learning rate bajo requiere mas arboles para alcanzar el mismo nivel de performance, mientras que un learning rate alto necesita menos arboles pero puede hacer que el modelo sea mas propenso al overfitting.

2.7. Ejercicio 7

...