

Trabajo Práctico Integrador

Analítica de Datos, Universidad de San Andrés

1. Generalidades

El trabajo es grupal e integra los contenidos de la materia: desde EDA y preparación de datos hasta entrenamiento y evaluación de modelos de Machine Learning supervisado.

- Grupos de **3 o 4 personas**.
- Un mismo dataset no puede ser elegido por más de dos grupos.
- Inscripción del grupo y del dataset elegido en la planilla compartida.
- **Fecha límite de inscripción: jueves 21/05 (clase 9).**

El trabajo se entrega y se defiende en **dos tandas**. Después de la primera defensa los grupos reciben una devolución que deben incorporar antes de la segunda entrega.

2. Datasets

Pueden elegir uno de la lista o proponer uno propio (sujeto a aprobación antes de la fecha límite). Para cada uno se indica el tema y el tipo de problema sugerido.

Datasets pesados (Yellow Cab, HVFHS, Yelp completo) requieren acotar el alcance y justificarlo. Datasets sensibles (policiales, judiciales, salud) requieren una sección de sesgos y consideraciones éticas.

2.1. AirBnB Buenos Aires

- **Tema:** alojamiento.
- **Tipo sugerido:** regresión / clasificación.
- **Link:** <https://insideairbnb.com/buenos-aires/>

2.2. Encuesta Mundial de Salud Escolar (EMSE 2018)

- **Tema:** educación / salud.
- **Tipo sugerido:** clasificación.
- **Link:** <http://datos.salud.gob.ar/dataset/base-de-datos-de-la-3-encuesta-mundial-de-salud-escolar-emse-con-resultados-nacionales-argentina/archivo/9888b372-8094-45e2-8b62-40630838c5dc>

2.3. Estadísticas sobre Ejecución de la Pena (SNEEP)

- **Tema:** judicial.
- **Tipo sugerido:** clasificación. Elegir un año.
- **Link:** <https://datos.jus.gob.ar/dataset/sneep/archivo/5fd7ce53-c741-4837-9850-d2879fec8a6b>

2.4. Recorridos en Ecobicis

- **Tema:** tránsito.
- **Tipo sugerido:** regresión / clasificación. Elegir un año.
- **Link:** <https://data.buenosaires.gob.ar/dataset/bicicletas-publicas>

2.5. Crímenes reportados en Chicago

- **Tema:** policial.
- **Tipo sugerido:** clasificación. Elegir un año.
- **Link:** https://data.cityofchicago.org/Public-Safety/Crimes-2001-to-Present/ijzp-q8t2/related_content

2.6. Denuncias a la policía de NY

- **Tema:** policial.
- **Tipo sugerido:** clasificación. Datos 2024–2025.
- **Link:** https://data.cityofnewyork.us/Public-Safety/NYPD-Complaint-Data-Current-Year-To-Date-/5uac-w243/about_data

2.7. Yellow Cab NYC

- **Tema:** tránsito.
- **Tipo sugerido:** regresión. Acotar mes/año por el tamaño.
- **Link:** <https://www1.nyc.gov/site/tlc/about/tlc-trip-record-data.page>

2.8. Eventos de violencia organizada (UCDP GED)

- **Tema:** conflictos bélicos.
- **Tipo sugerido:** clasificación.
- **Link:** https://ucdp.uu.se/downloads/index.html#ged_global

2.9. TMDb Movies Dataset 2024

- **Tema:** ocio.
- **Tipo sugerido:** regresión.
- **Link:** <https://www.kaggle.com/datasets/asaniczka/tmdb-movies-dataset-2023-930k-movies>

2.10. Pacientes con diabetes en 130 hospitales (US)

- **Tema:** salud.
- **Tipo sugerido:** clasificación (readmisión).
- **Link:** <https://archive.ics.uci.edu/dataset/296/diabetes+130-us+hospitals+for+years+1999-2008>

2.11. Precios Claros — Base SEPA

- **Tema:** comercio.
- **Tipo sugerido:** regresión / clasificación. Elegir una cadena.
- **Link:** <https://datos.gob.ar/dataset/produccion-precios-claros---base-sepa>

2.12. High-Volume For-Hire Services (HVFHS)

- **Tema:** tránsito.
- **Tipo sugerido:** regresión / clasificación. Elegir un año.
- **Link:** <https://www1.nyc.gov/site/tlc/about/tlc-trip-record-data.page>

2.13. Reviews de Yelp

- **Tema:** comercio.
- **Tipo sugerido:** clasificación.
- **Link:** <https://business.yelp.com/data/resources/open-datasets/>

2.14. Dataset propio

- **Tema:** a definir por el grupo.
- **Tipo sugerido:** a justificar.
- **Link:** sujeto a aprobación previa.

3. Consignas

3.1. Entrega 1 — EDA y preparación de datos

3.1.1. EDA

- Cargar el dataset y describir origen, contexto y forma de recolección.

- Número de observaciones, número de variables, tipos de datos.
- Distribuciones marginales y relaciones bivariadas.
- Errores, outliers y valores faltantes. Clasificar los faltantes (MCAR, MAR, MNAR).

3.1.2. Visualización

- Elegir el gráfico adecuado según el tipo de variable y el análisis.
- Justificar la elección de cada gráfico.
- Interpretar lo que se ve.

3.1.3. Definición del problema de ML supervisado

- Plantear un problema de clasificación o regresión.
- Definir la variable target.
- Definir las métricas de evaluación y justificar su elección.

3.1.4. Preprocesamiento

- Limpieza general del dataset.
- Split (train/test o train/validation/test). Justificar la estrategia.
- Tratamiento de valores faltantes.
- Detección y manejo de outliers.
- Escalado/normalización cuando corresponda.

El preprocesamiento que use estadísticas del dataset debe ajustarse solo con train.

3.1.5. Feature engineering

- Creación de nuevos features justificada.
- Codificación de variables categóricas.
- Discretización cuando corresponda.
- En clasificación: análisis de balance de clases y, si corresponde, técnica de balanceo justificada.

3.1.6. Reducción de dimensionalidad

- Selección de features con al menos un método (filtros, correlación, importancia desde un modelo base, etc.).
- PCA: implementación, varianza explicada y discusión.

3.2. Entrega 2 — Modelado y conclusiones

3.2.1. Modelado

- Un baseline simple (regresión lineal/logística, árbol o dummy).
- Al menos dos modelos más vistos en clase (KNN, Random Forest, Boosting, Naive Bayes, etc.).
- Validación cruzada sobre train.
- Tuning de hiperparámetros del mejor modelo.
- Tabla comparativa de resultados.
- Performance final sobre test, reportada una sola vez.

3.2.2. Interpretación y conclusiones

- Interpretabilidad: feature importance, coeficientes o herramientas similares (SHAP, permutation importance).
- Conclusiones sobre el uso del modelo y sus limitaciones.

- Sesgos del dataset y consideraciones éticas (obligatorio en datasets sensibles).
- Incorporación de la devolución recibida en la Entrega 1.

4. Entregas

Cada entrega incluye:

1. **Repositorio de GitHub** actualizado con el código de la etapa correspondiente. `README.md` y `requirements.txt` incluidos. No subir el dataset crudo si es pesado.
2. **Informe parcial**: notebook ejecutado de punta a punta, con celdas de markdown explicando cada paso.
3. **Presentación**: hasta 6 diapositivas + carátula por entrega, con link al repositorio.

Entrega	Contenido	Fecha límite
Entrega 1	EDA y preparación de datos	jueves 04/06
Entrega 2	Modelado y conclusiones	jueves 18/06

5. Defensas orales

Cada entrega se defiende oralmente en clase. La devolución de la primera defensa debe incorporarse en la segunda entrega.

Defensa	Clase	Fecha
Defensa 1 — EDA y preparación	Clase 11	04/06
Defensa 2 — Modelado y conclusiones	Clase 13	18/06

- 15 minutos por grupo: 10' de exposición + 5' de preguntas.
- Todos los integrantes exponen una parte aproximadamente igual.
- Cualquier integrante puede recibir preguntas sobre cualquier parte del trabajo.

6. Evaluación

La nota final se compone de las dos entregas, con peso aproximadamente igual.

Dimensión	Peso	Entrega
Entendimiento del dataset y del problema	5 %	1
EDA y visualizaciones	8 %	1
Preprocesamiento y feature engineering	8 %	1
Reducción de dimensionalidad	5 %	1
Modelado: elección, validación, comparación, tuning	10 %	2
Interpretación y conclusiones	5 %	2
Incorporación de la devolución de la Entrega 1	3 %	2
Repositorio y reproducibilidad	6 %	1 y 2
Presentación y defensa oral	50 %	1 y 2

No se aceptan trabajos sin componente de modelado.

7. Uso de inteligencia artificial

Se incentiva el uso de herramientas de inteligencia artificial (ChatGPT, Claude, Copilot, etc.) durante todo el trabajo práctico: para explorar el dataset, generar código, debuggear, redactar el informe o lo que necesiten. La única condición es que entiendan perfecto qué carajo están haciendo. Si en la defensa oral no saben contestar algo porque lo hizo la IA y no ustedes, se penalizará fuerte.